

Exo 1 | Q1, Q2, Q3 cf. corrigé partiel 2019.

3) p-valeur observée = $1 - F(7)$ où $F = \text{CDF du Bin}(14, 1/2)$ (cf partiel 2019 pr justification)

4) p-valeur observée $> \alpha$ donc on accepte H_0 au niveau α .

5) Le test a été fait sur un petit échantillon ($n=14$). Donc ce n'est pas forcément le meilleur résultat. si le test nous dit d'accepter H_0 : il se peut qu'il y ait bien une différence entre les deux produits mais n'étant pas assez grande, le test n'arrive pas à la détecter (cf. calculs de puissance dans le chap 1).

6) cf Wilcoxon des rangs signés.

5) Il vaut mieux utiliser Wilcoxon des rangs signés car utilisation + d'informations donc + puissant.

Exo 2 | 1. a) fléau de la dimension : modèle trop général, trop peu d'observations dans un voisinage en grande dimension (d'où ordre de $n^{d/2}$, d est en exposant) cf. cours remarque 5.16.

1. b) Modèle additif par exo cf. cours rem. 5.16

2 a) cf cours début de 3.2.1.

2 b) Nana - Whittay.

3 (a) et (b) cf. théo 3.16.

3 (c) cf. prop 3.18.

$$\underline{\text{Exo 3}} \quad 1) \quad E(\hat{r}(0) - r(0))^2 = E[(\hat{r}(0) - r(0))^2 \mathbb{1}_E] + E[(\hat{r}(0) - r(0))^2 \mathbb{1}_{E^c}]$$

$$= E(E_Y(\hat{r}(0) - r(0))^2 \mathbb{1}_E) + E(E_Y(\hat{r}(0) - r(0))^2 \mathbb{1}_{E^c})$$

car E ne dépend que des X_i .

De plus :

• sur E : $\hat{r}(0) = \bar{r}(0)$ p.s. car $P(\exists i = 1, \dots, n \text{ t.q. } X_i = 0) \leq \sum_{i=1}^n P(X_i = 0) = 0$
car la loi des X_i est absolument continue par rapport à Lebesgue.

• sur E^c : $\hat{r}(0) = 0$

2)

$$E_Y(\bar{r}(0) - r(0))^2 = \underbrace{E_Y(\bar{r}(0) - E_Y(\bar{r}(0)))^2}_{\text{var}} + \underbrace{(E_Y(\bar{r}(0)) - r(0))^2}_{\text{biais}^2} \quad (\text{décomposition biais/variance})$$

(détails voir encours chap 1)

Dans toute la suite, on note K_h la fonction définie par $\boxed{K_h(x) = \frac{1}{h} k(\frac{x}{h}) \text{ pour } x \in \mathbb{R}.}$

$$3) \quad P(E^c) = P(\forall i: K_h(X_i) = 0) \quad \text{car } K \geq 0$$

$$= P(\forall i: X_i \notin [-h, h]) \quad \text{car support de } K = [-1, 1].$$

$$= (P(X_1 \notin [-h, h]))^n \quad (X_1, \dots, X_n \text{ iid})$$

$$= \left(1 - \int_{-h}^h f_X(x) dx\right)^n$$

$$\hookrightarrow \int_X(x) \geq p_1 \quad \forall x \in [-1, 1]$$

$$\text{et } 2p_1 h \leq 1$$

$$\leq (1 - 2p_1 h)^n$$

$$\hookrightarrow 1 - x \leq e^{-x} \quad \forall x \geq 0.$$

$$\leq \exp(-2p_1 n h)$$

3) b) Plaçons-nous sur E :

$$E_Y(\bar{r}(0)) = E_Y\left(\frac{\sum_{i=1}^n Y_i K_h(X_i)}{\sum_{i=1}^n K_h(X_i)}\right) = \frac{\sum_{i=1}^n E_Y(Y_i) K_h(X_i)}{K_h(X_i)}$$

$$= \frac{\sum_{i=1}^n r(X_i) K_h(X_i)}{\sum_{i=1}^n K_h(X_i)} + \frac{\sum_{i=1}^n K_h(X_i) E_Y(\xi_i)}{\sum_{i=1}^n K_h(X_i)} \quad \downarrow \quad E_Y(\xi_i) = 0 \quad \forall i$$

$$= \frac{\sum_{i=1}^n r(X_i) K_h(X_i)}{\sum_{i=1}^n K_h(X_i)}$$

a) Montrons que $E_Y(\xi_i) = 0 \quad \forall i$: il suffit par symétrie de le voir par $i=1$,
on va montrer que $E_Y(\xi_1) = E(\xi_1 | X_1)$.

Soit g une fonction mesurable bornée.

$$\begin{aligned} \bullet E(g(X_1^1) \xi_1) &= E(E(g(X_1^1) \xi_1 | X_2, \dots, X_n)) \\ &= E(h(X_2^1)) \quad \text{où} \quad h(x_2^1) = E(g(X_1^1) \xi_1 | X_2^1 = x_2^1) \\ &= E(g(X_1, x_2^1) \xi_1) \end{aligned}$$

$$\curvearrowright \text{ car } (X_1, \xi_1) \stackrel{d}{=} X_2^1$$

$$\text{car } (X_1, \xi_1) = (X_1, Y_1 - r(X_1))$$

$$\text{et } (X_1, Y_1) \stackrel{d}{=} X_2^1$$

$$\text{donc } h(x_2^1) = E(g(X_1, x_2^1) E(\xi_1 | X_1))$$

$$\begin{aligned} \bullet E(g(X_1^1) E(\xi_1 | X_1)) &= E(E[g(X_1^1) E(\xi_1 | X_1) | X_2^1]) \\ &= E(E(X_2^1)) \end{aligned}$$

$$\text{où } h(x_2^1) = E(g(X_1, x_2^1) E(\xi_1 | X_1)) \quad \text{car } X_1 \stackrel{d}{=} X_2^1$$

D' où $l(x_2) = h(x_2^2)$.

$$\text{D'où } E(g(x_2^2) | S_1) = E(h(x_2^2)) = E(l(x_2^2)) = E(g(x_2^2) | S_1)$$

Ainsi: $E(S_1 | X_1^2) = E(S_1 | X_1) = 0$.
↑ n est la fonction de régression.

NB: de manière générale, on a en fait montré (comme l'exo fait en vous dans le chap 5) que si $(X, Y) \perp Z$ alors $(Y | X, Z) = E(Y | X)$.

(En fait on l'a fait avec $X = X_1$, $Y = S_1$ et $Z = X_1^2$).
on peut en fait montrer que $Y \perp Z$ i.e. X et Z sont indépendants conditionnellement à X sachant $(X, Y) \perp Z$ (cf. TDO exo 4 statistical learning pour l'indép conditionnelle).

Plus généralement on a: $\forall$ tribus $\mathcal{H}, \mathcal{F}_1, \mathcal{F}_2$
 $\mathcal{H} \perp (\mathcal{F}_1, \mathcal{F}_2) \Leftrightarrow \mathcal{H} \perp \mathcal{F}_1$ et $\mathcal{H} \perp \mathcal{F}_2$.
(cf. Kallenberg p 111 "foundations of modern probability")

5) On se place sur $\mathcal{E}$.

$$\begin{aligned} \text{Donc } E_Y(\bar{r}(0)) - r(0) &= \frac{\sum_{i=1}^n r(X_i) K_h(X_i)}{\sum_{i=1}^n K_h(X_i)} - r(0) \frac{\sum_{i=1}^n K_h(X_i)}{\sum_{i=1}^n K_h(X_i)} \\ &= \frac{\sum_{i=1}^n (r(X_i) - r(0)) K_h(X_i)}{\sum_{i=1}^n K_h(X_i)} \end{aligned}$$

Et comme $r \in \mathcal{L}(\rho, L)$ on a: $|r(X_i) - r(0)| \leq L |X_i|^\rho \xrightarrow{X \gg 0}$
 Puis $K_h(X_i) = 0$ si $|X_i| > h$. Donc $|r(X_i) - r(0)| K_h(X_i) \leq L |X_i|^\rho K_h(X_i) \leq L h^\rho K_h(X_i)$
 Ainsi $|E_Y(\bar{r}(0)) - r(0)| \leq L h^\rho \frac{\sum_{i=1}^n K_h(X_i)}{\sum_{i=1}^n K_h(X_i)} = L h^\rho$.

6) Variance conditionnelle: sur $\mathcal{E}$ on a $E_Y(\bar{r}(0) - E_Y(\bar{r}(0)))^2 = \text{Var}_Y(\bar{r}(0)) = \text{Var}_Y\left(\frac{\sum_{i=1}^n K_h(X_i) Y_i}{\sum_{i=1}^n K_h(X_i)}\right)$
 or $Y_1, \dots, Y_n$ sont indépendants conditionnellement à $X_1, \dots, X_n$. (g. énoncé)
 Ainsi on a:

$$\text{Var}_Y\left(\frac{\sum_{i=1}^n K_h(X_i) Y_i}{\sum_{i=1}^n K_h(X_i)}\right) = \frac{\sum_{i=1}^n K_h^2(X_i) \text{Var}_Y(Y_i)}{\left(\sum_{i=1}^n K_h(X_i)\right)^2}$$

$$\text{or } \text{Var}_Y(Y_i) = \text{Var}_Y(r(X_i) + \xi_i) = \text{Var}_Y(\xi_i) = \text{Var}(\xi_i | X_i) \leq \sigma^2$$

per
idem 23a)
hyp
énoncé.

$$\text{Donc } \text{Var}_Y(\bar{r}(0)) \leq \frac{\sigma^2 \sum_{i=1}^n K_h^2(X_i)}{\left(\sum_{i=1}^n K_h(X_i)\right)^2}$$

$$\text{Donc } E(\text{Var}_Y(\bar{r}(0)) | \mathcal{E}) \leq \sigma^2 E\left(\frac{\sum_{i=1}^n K_h^2(X_i) \mathbb{1}_{\mathcal{E}}}{\left(\sum_{i=1}^n K_h(X_i)\right)^2}\right).$$

Remarque: voir que

• "chain rule" (prop 6.8)

(i) $\Rightarrow$ (ii) où

et (ii) $\mathcal{H} \perp \mathcal{F}_2$ et

• on montre que

• si (A) est vrai alors

$$\begin{aligned} E\left(\prod_{i=1}^n f_i(Y_i) \mid X_2^1\right) &= E\left(\prod_{i=1}^n f_i(Y_i) \mid X_2^1\right) \in \left(\prod_{i=1}^n f_i(Y_i) \mid X_2^1\right) \\ &= E\left(\prod_{i=1}^n f_i(Y_i) \mid X_2^1\right) E\left(\prod_{i=2}^n f_i(Y_i) \mid X_2^1\right) \\ &= \dots = \prod_{i=2}^n E\left(f_i(Y_i) \mid X_2^1\right) \end{aligned}$$

$Y_1, \dots, Y_n$ sont indép conditionnellement à $X_1, \dots, X_n$:

plll Kallenberg) $\forall$ tribus $\mathcal{G}, \mathcal{H}, \mathcal{F}_1, \mathcal{F}_2$

(i) $\mathcal{H} \perp (\mathcal{F}_1, \mathcal{F}_2)$

$\mathcal{H} \perp \mathcal{F}_2$

$\mathcal{G}, \mathcal{F}_2$
 $\mathcal{H} \perp \mathcal{F}_2$

$Y_i \perp (Y_1, \dots, Y_n) \mid X_2^1$ (1)

• Montrons 'N'. on a $(X_2, Y_2), \dots, (X_n, Y_n)$ indép. Donc $\forall i = 1, \dots, n-1$
 $(X_i, Y_i) \perp (X_1, Y_1, \dots, X_{i-1}, Y_{i-1}, X_{i+1}, Y_{i+1}, \dots, X_n, Y_n) := (X_1^{n-i}, Y_1^{n-i})$
 $\Rightarrow Y_i \perp_{X_i} (X_1^{n-i}, Y_1^{n-i})$

(chain rule $(G = \{\phi, \sigma\})$
 $\mathcal{F}_2 = \sigma(X_i)$
 $\mathcal{F}_2 = \sigma(Y_i)$
 $\mathcal{H} = \sigma(X_1^{n-i}, Y_1^{n-i})$

$$\Rightarrow Y_i \perp_{X_i, X_1^{n-i}} Y_1^{n-i}$$

$$\Rightarrow Y_i \perp_{X_1^n} (Y_{i+1}, \dots, Y_n)$$

(chain rule: $G = \sigma(X_2^n)$ $\mathcal{H} = \sigma(Y_1)$
 $\mathcal{F}_2 = \sigma(X_1^{n-i})$
 $\mathcal{F}_2 = \sigma(Y_1^{n-i})$)

7. Par la symétrie de E par rapport aux X_i et du fait que les X_i sont iid. on a:
 $\forall i = 1 \dots n$ donc
 $\frac{K_h(X_i) \Delta E}{(\sum_{j=1}^n K_h(X_j))^2} \sim \frac{K_h(X_1) \Delta E}{(\sum_{j=1}^n K_h(X_j))^2}$

$$\sigma^2 E \left(\frac{\sum_{i=1}^n K_h^2(X_i) \Delta E}{(\sum_{i=1}^n K_h(X_i))^2} \right) = \sigma^2 E \left(\frac{K_h^2(X_1) \Delta E}{(\sum_{i=1}^n K_h(X_i))^2} \right)$$

8) $K_h(X_i) = K\left(\frac{X_i}{h}\right) \geq \frac{1}{h} |X_i| \leq 1$ car $K(u) \geq 1 \forall u \in [-1, 1]$ car $\frac{1}{|u|^{1/4}} \geq 1 \forall u \in [-1, 1]$.
 Donc $\left(\sum_{i=1}^n K_h(X_i)\right)^2 \geq \left(\sum_{i=1}^n \eta_i\right)^2$ donc $\frac{1 \leq \eta_i \leq \frac{1}{h} \wedge \varepsilon}{\left(\sum_{i=1}^n K_h(X_i)\right)^2} \leq \frac{1 \leq \eta_i \leq \frac{1}{h} \wedge \varepsilon}{\left(\sum_{i=1}^n \eta_i\right)^2} \leq \frac{1}{\left(\frac{1}{h}\right)^2} = \frac{4}{(n\bar{p})^2}$.

9) $E(K_h^2(X_1)) = \int_{-1}^1 K_h^2(x) f_X(x) dx \leq p_2 \int_{\mathbb{R}} K_h^2(x) dx = p_2 \int_{\mathbb{R}} K^2\left(\frac{x}{h}\right) dx$
 $= p_2 h \int_{\mathbb{R}} K^2(u) du$
 donc

10) Comme $K \geq 0$, $\frac{K_h(X_1)}{\left(\sum_{i=1}^n K_h(X_i)\right)^2} \leq 1$

$E\left[\frac{K_h^2(X_1)}{\left(\sum_{i=1}^n K_h(X_i)\right)^2} \wedge \frac{\sum_{i=1}^n \eta_i \leq \frac{n\bar{p}}{2} \wedge \varepsilon}{\left(\sum_{i=1}^n K_h(X_i)\right)^2}\right] \leq P\left(\sum_{i=1}^n \eta_i \leq \frac{n\bar{p}}{2}\right) = P\left(\sum_{i=1}^n \eta_i - n\bar{p} \leq -\frac{n\bar{p}}{2}\right)$

Or $\sum_{i=1}^n \eta_i \sim \text{Bin}(n, \bar{p})$ donc, d'après l'inégalité donnée dans l'énoncé, comme $-\frac{n\bar{p}}{2} < 0$ on a:
 $P\left(\sum_{i=1}^n \eta_i - n\bar{p} \leq -\frac{n\bar{p}}{2}\right) \leq \exp\left(-\frac{\left(\frac{n\bar{p}}{2}\right)^2}{2n\bar{p}}\right) \leq \exp\left(-\frac{n\bar{p}}{8}\right)$

11) En utilisant la question 7

$\check{\sigma}(0) := E\left[\left(\bar{r}(0) - E\bar{r}(0)\right)^2 \wedge \varepsilon\right] \leq \frac{1}{n} E\left[\frac{K_h^2(X_1)}{\left(\sum_{i=1}^n K_h(X_i)\right)^2} \wedge \varepsilon\right]$

Puis en utilisant

Q9:

$\check{\sigma}(0) \leq \frac{r^2 n^4 h p_2}{(n\bar{p})^2} \int_{\mathbb{R}} K^2(u) du + \frac{1}{n} \exp\left(-\frac{n\bar{p}}{8}\right)$

Or $\bar{p} = P(|X| \leq h) = \int_{-h}^h f_X(x) dx$ Donc $2p_2 h \leq \bar{p}$

Ainsi

$\check{\sigma}(0) \leq c \frac{n h}{(n h)^2} + \frac{1}{n} \exp(-c_2 n h)$

$\leq c_2 \left(\frac{1}{n h} + \frac{1}{n} \exp(-c_2 n h) \right)$

où c, c_1 et c_2

ne dépendent

ni de n ni de h

$\left(\int_{\mathbb{R}} K^2(u) du = \int_{-1}^1 \frac{1}{\sqrt{u}} du < +\infty \right)$

12) En combinant les questions 2, 3, 5 et 11, on obtient

$$E[(\hat{r}(o) - r(o))^2] \leq [h^{2\beta} + c_1 \left(\frac{1}{nh} + n \exp(-c_2 nh) \right) + r(o)^2 \exp(-2p_1 nh)]$$

$$\leq c_3 \left(h^{2\beta} + \frac{1}{nh} + n \exp(-c_4 nh) \right) \quad \text{si } c_3 \text{ et } c_4 \text{ ne dépendent ni de } n \text{ ni de } h.$$

On cherche h t.g

$$h^{2\beta} = \frac{1}{nh}$$

i.e $h = n^{-\frac{1}{2\beta+1}}$

De plus on a alors $\frac{1}{nh} = h^{2\beta} = n^{-\frac{2\beta}{2\beta+1}}$ et

$$n \exp(-c_2 nh) = n \exp(-c_2 n^{\frac{1}{2\beta+1}}) = o\left(n^{-\frac{2\beta}{2\beta+1}}\right)$$

Donc $E[(\hat{r}(o) - r(o))^2] \leq C n^{-\frac{2\beta}{2\beta+1}}$

Exo 1 | Q1, Q2, Q3 cf. corrigé partiel 2019.

3) p-valeur observée = $1 - F(7)$ où $F = \text{CDF du Bin}(14, 1/2)$ (cf partiel 2019 pr justification)

4) p-valeur observée $> \alpha$ donc on accepte H_0 au niveau α .

5) Le test a été fait sur un petit échantillon ($n=14$). Donc ce n'est pas forcément le meilleur résultat. si le test nous dit d'accepter H_0 : il se peut qu'il y ait bien une différence entre les deux produits mais n'étant pas assez grande, le test n'arrive pas à la détecter (cf. calculs de puissance dans le chap 1).

6) cf Wilcoxon des rangs signés.

5) Il vaut mieux utiliser Wilcoxon des rangs signés car utilisation + d'informations donc + puissant.

Exo 2 | 1. a) fléau de la dimension : modèle trop général, trop peu d'observations dans un voisinage en grande dimension (de l'ordre de $n^{d/2}$, d est en exposant) cf. cours remarque 5.16.

1. b) Modèle additif par exo cf. cours rem. 5.16

2 a) cf cours début de 3.2.1.

2 b) Nona-Whitney.

3 (a) et (b) cf. théo 3.16.

3 (c) cf. prop 3.18.

