

Introduction à la statistique non-paramétrique

Partiel – 2025

Exercice 1 (Questions de cours) (5pts) :

1. (a) (1.5pts) Citer deux tests d'adéquation à une loi donnée (un test d'adéquation à une loi donnée est censé indiquer si un échantillon suit une loi donnée), parmi les tests vus en cours (**juste les noms des tests**).

- Test d'adéquation de Kolmogorov-Smirnov.
- Test d'adéquation du Khi-deux.

Remarques :

- Le test de Student sur un échantillon n'est absolument pas un test d'adéquation (c'est un test sur la moyenne!!). Idem pour le test du signe (test sur la médiane).
- Ne pas confondre « test d'adéquation » (sur un échantillon donc) et « test d'homogénéité ». Lire l'énoncé!!!

Ne pas confondre non plus « test d'adéquation à une famille de lois » et « test d'adéquation à une loi donnée ». Lire l'énoncé!!!

- (b) (1.5pts) Donner **rapidement** deux différences importantes entre ces deux tests.

- K-S est non asymptotique : donc utilisable même pour n petit. Le test du Khi-deux est un test asymptotique (n doit être suffisamment grand, d'autant plus que les fréquences théoriques p_j sont proches de 0 ou de 1).
- K-S est conçu pour des lois continues tandis que le Khi-deux est conçu pour les lois discrètes à support fini.

2. (2pts) On effectue un test non asymptotique, avec pour résultat : « on accepte H_0 ». Faut-il se méfier du résultat si la taille d'échantillon est petite? Et si au contraire le résultat du test est « on rejette H_0 »? Expliquer **rapidement**.

On va donner une explication longue et précise ici, du fait que la majorité d'entre vous ne semblez pas avoir compris.

Dans cette question¹, on suppose que les conditions du test sont réalisées : on suppose donc qu'il n'y a pas de problèmes de représentativité de la population totale dans l'échantillon et qu'il n'y a pas d'outliers². On ne mentionne pas non plus de problèmes liés aux tests multiples³. Évidemment, comme évoqué plusieurs fois en cours, ces problèmes peuvent se poser dans la pratique et vous devez les prendre en compte. De plus, évidemment, il faut toujours prendre en compte le fait que, dans tous les cas, quelle que soit la taille d'échantillon, on peut faire une erreur (erreur de première espèce et erreur de seconde espèce). Mais la question portait ici sur ce qui se passe spécifiquement quand la taille d'échantillon est faible et portait donc essentiellement sur le fait que **l'erreur de première espèce est contrôlée alors que l'erreur de seconde espèce ne l'est pas**.

1. comme expliqué plusieurs fois en cours...

2. Si vous craignez d'avoir des outliers dans votre échantillon, il est alors peut-être plus judicieux d'utiliser un test insensible ou moins sensibles aux outliers. De plus le lien n'est pas clair avec la taille d'échantillon, car vous pouvez vous retrouver avec la même proportion d'outliers dans votre plus grand échantillon...

3. qui n'ont d'ailleurs pas de lien clair avec la taille d'échantillon

- **Si le test rejette H_0** : l'erreur possible est alors l'erreur de première espèce : le test «répond H_1 » alors que l'on est sous H_0 . **L'erreur de première espèce est toujours contrôlée** (c'est le principe d'un test fréquentiste). Pour un α donné, l'erreur de première espèce est toujours inférieure ou égale à α (et on prend α petit en général). Donc la taille d'échantillon n'intervient pas. Cela signifie que la probabilité que le test se trompe dans ce cas est inférieure ou égale à α ⁴. Évidemment ceci n'est vrai que pour un test non asymptotique ! Donc pas d'inquiétude vis-à-vis de la taille de l'échantillon dans ce cas.
- **Si le test accepte H_0** : l'erreur possible est alors l'erreur de seconde espèce : le test «répond H_0 » alors que l'on est sous H_1 . **L'erreur de seconde espèce n'est jamais contrôlée** (asymétrie entre H_0 et H_1 dans un test fréquentiste). Nous avons vu en cours (cf. poly chap 1) que la puissance (fonction qui n'est définie que sous H_1 donc cela ne concerne que H_1) dépend de n . Elle est d'autant plus grande que n est grand. Donc, pour une même force de "signal" (par ex, pour une même différence entre F et F_0 dans le test K-S), il y a une plus grande probabilité que le test rejette H_0 (ce qu'il est censé faire puisqu'on est sous H_1) quand n est grand. Autrement dit, quand n est petit, et si on est vraiment sous H_1 , «le test n'arrive à le voir » que si le « signal » est assez fort. Il faut donc prendre en compte ce fait quand vous utilisez un test non asymptotique avec une taille d'échantillon faible et que le test accepte H_0 .

On peut aussi passer par la p-valeur pour expliquer cela :

- **Si le test rejette H_0** : l'erreur possible est alors l'erreur de première espèce : le test «répond H_1 » alors que l'on est sous H_0 . Or, sous H_0 , la p-valeur suit souvent une loi uniforme (ou pas loin d'être uniforme) sur $[0, 1]$ (et ce, quelque soit la valeur de n !). Si votre p-valeur est de 0,01 par ex, et si sous êtes vraiment sous H_0 , alors il y a une probabilité égale 1% (ou environ égale à 1%) de tomber sur une telle p-valeur.
- **Si le test accepte H_0** : l'erreur possible est alors l'erreur de seconde espèce : le test «répond H_0 » alors que l'on est sous H_1 . La p-valeur, sous H_1 , dépend de n (cf. poly). Sa loi n'est évidemment plus uniforme sur $[0, 1]$! Plus généralement, sa loi sous H_1 n'est pas contrôlée. En particulier, sous H_1 et pour un même « signal », plus n est grand, plus la p-valeur a des chances d'être petite (ce qui est souhaitable puisqu'on est sous H_1)

L'estimation d'une quantité inconnue est plus précise quand on a plus de données. Cela se traduit, **pour les tests**, par une puissance plus grande quand n est grand. L'intervalle de confiance, sur lequel est basé le test (et lié à la loi de la stat sous H_0), est plus petit quand n est grand.

Exercice 2 (7pts) : cf. TD.

Remarques :

1. Ne parlez pas de LGN quand on ne vous le demande pas. Il s'agissait juste du TCL (+ continuité de F).
2. pour « $\hat{F}_n(x) \geq t \Leftrightarrow x \geq \hat{F}_n^{(-1)}(t)$ », plutôt que "par le cours", je préfère que vous disiez : "c'est une propriété vérifiée par toutes les CDF".

Exercice 3 (8.5pts) : cf. Corrigé annales. Ne pas confondre le test proposé dans l'énoncé avec le test d'adéquation à une loi donnée de Kolmogorov-Smirnov. Le test proposé dans l'énoncé correspond à l'adéquation à une FAMILLE de lois, ici les lois de Pareto avec $\alpha = 1$. C'est l'équivalent du test d'adéquation à la famille des lois exponentielles vu en cours. L'idée de remplacer le paramètre inconnu par l'EMV ne fonctionne pas avec toutes les familles de lois (i.e. ne donne pas tjs une stat de loi indép du paramètre inconnu sous H_0).,

4. encore une fois : si tout le reste est correct bien sûr, c'est-à-dire pas de problème grave lié aux hypothèses du modèle...