

Introduction à la statistique non-paramétrique

EXAMEN D'APPEL 2017 – Durée : 2h00

Documents, calculatrices, téléphones et smartphones interdits

Les deux exercices sont indépendants

Exercice 1

On observe un n -échantillon $(X_1, Y_1), \dots, (X_n, Y_n)$ de même loi qu'un couple de variables aléatoires réelles (X, Y) . On suppose que le vecteur (X, Y) admet pour densité la fonction $f_{X,Y}$. Pour toutes fonctions f_1 et f_2 de deux variables, on note dans la suite $\star$ le produit de convolution entre f_1 et f_2 quand celui-ci est défini : pour tout $(x, y) \in \mathbb{R}^2$,

$$(f_1 \star f_2)(x, y) = \iint f_1(x - u, y - v) f_2(u, v) du dv.$$

On suppose dans la suite que f_X , la densité de X , est connue.

Partie A Proposer un estimateur à noyau de $f(x, \cdot)$, la densité conditionnelle de Y conditionnellement à $X = x$ où on rappelle que pour tout x et tout y ,

$$f(x, y) := f_{Y|X=x}(x, y) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

On ne précisera pas la valeur du paramètre de lissage mais on montrera que l'estimateur proposé est parfaitement défini.

Partie B Dans cette partie, on construit un estimateur alternatif de f , noté $\tilde{f}_h$, dont on mesure les performances à x fixé en utilisant le risque R_x défini par :

$$R_x(\tilde{f}_h) = \mathbb{E} \left[\|\tilde{f}_h - f\|_{2,x}^2 \right],$$

où pour toute fonction g ,

$$\|g\|_{2,x} = \left(\int_{\mathbb{R}} g^2(x, y) dy \right)^{1/2}.$$

1. Montrer que pour tout $i \in \{1, \dots, n\}$,

$$f_X(X_i) \neq 0 \quad \text{presque sûrement.}$$

On définit alors pour tout $(x, y) \in \mathbb{R}^2$

$$\tilde{f}_h(x, y) = \frac{1}{nh_1 h_2} \sum_{i=1}^n \frac{1}{f_X(X_i)} K \left(\frac{x - X_i}{h_1}, \frac{y - Y_i}{h_2} \right),$$

où $h = (h_1, h_2)$ avec $h_1 > 0, h_2 > 0$ et $K : \mathbb{R}^2 \mapsto \mathbb{R}$ un noyau à support compact tel que $\|K\|_2^2 = \iint K^2(u, v) du dv < \infty$.

On rappelle la notation K_h :

$$K_h(x, y) = \frac{1}{h_1 h_2} K\left(\frac{x}{h_1}, \frac{y}{h_2}\right)$$

2. Calculer $\mathbb{E}[\tilde{f}_h(x, y)]$ en fonction de f et K_h où pour tout $(x, y) \in \mathbb{R}^2$:

$$K_h(x, y) = \frac{1}{h_1 h_2} K\left(\frac{x}{h_1}, \frac{y}{h_2}\right).$$

3. On considère $\delta(x)$ un minorant de f_X au voisinage de x . Montrer que si h_1 est assez petit, la variance de $\tilde{f}_h(x, y)$ vérifie :

$$\text{var}(\tilde{f}_h(x, y)) \leq \frac{1}{\delta(x)n} (K_h^2 \star f)(x, y).$$

4. En déduire alors que si h_1 est assez petit,

$$R_x(\tilde{f}_h) \leq \|K_h \star f - f\|_{2,x}^2 + \frac{\|K\|_2^2}{\delta(x)nh_1 h_2}.$$

Au préalable, on établira soigneusement une décomposition biais-variance adaptée au problème.

5. On suppose que f_X ne s'annule pas et qu'il existe une constante M telle que

$$\sup_x \|f\|_{2,x} \leq M.$$

Montrer que si on peut écrire $K(x, y) = K^{(1)}(x)K^{(2)}(y)$, où $K^{(1)}$ et $K^{(2)}$ sont deux noyaux, alors pour tout h ,

$$R_x(\tilde{f}_h) \geq \|K_h \star f - f\|_{2,x}^2 + \frac{\|K^{(2)}\|_2^2}{nh_1 h_2} \times \int \frac{[K^{(1)}(s)]^2}{f_X(x - sh_1)} ds - \frac{M\|K\|_1}{n}.$$

6. On suppose que f_X est continue en x . On suppose également que h_1 tend vers 0 lorsque n tend vers $+\infty$. Sous les hypothèses de la question précédente, en déduire la valeur asymptotique de $R_x(\tilde{f}_h)$ lorsque n tend vers $+\infty$.

Exercice 2

On considère un n -échantillon $X = (X_1, \dots, X_n)$ de variables aléatoires. On note F la fonction de répartition et F_n la fonction de répartition empirique associées à cet échantillon. Si les variables X_i sont de lois normales de paramètres μ et σ^2 , on note également N_{μ, σ^2} leur fonction de répartition commune.

1. On suppose que $F = N_{\mu, \sigma^2}$. Déterminer l'estimateur du maximum de vraisemblance $(\hat{\mu}, \hat{\sigma}^2)$ de (μ, σ^2) .

2. On pose

$$\Delta_n = \sup_{t \in \mathbb{R}} |F_n(t) - N_{\hat{\mu}, \hat{\sigma}^2}(t)|.$$

Montrer que si $F = N_{\mu, \sigma^2}$, alors la loi de Δ_n ne dépend pas de μ et σ^2 .

3. En déduire un test d'appartenance à la famille des lois normales, c'est-à-dire un test de

$$H_0 : F \in \mathcal{FN} \quad \text{contre} \quad H_1 : F \notin \mathcal{FN},$$

où

$$\mathcal{FN} = \{G : \exists (\mu, \sigma^2) \in (\mathbb{R} \times \mathbb{R}_+^*) \text{ tel que } G = N_{\mu, \sigma^2}\}.$$

4. Construire un test d'appartenance à la famille des lois exponentielles, c'est-à-dire un test de

$$H_0 : F \in \mathcal{E} \quad \text{contre} \quad H_1 : F \notin \mathcal{E},$$

où

$$\mathcal{E} = \{G : \exists \lambda \in \mathbb{R}_+^* \text{ tel que } \forall x, G(x) = (1 - \exp(-\lambda x))1_{x \geq 0}\}.$$

5. *Application (quasi indépendante du reste de l'exercice)* : Les lois des statistiques de test des questions 3 et 4 ont été tabulées. On fournit ci-dessous quelques quantiles intéressants pour $n = 4$:

	$q_{5\%}$	$q_{10\%}$	$q_{90\%}$	$q_{95\%}$
Stat du test d'appartenance à la loi normale	0.18	0.20	0.36	0.39
Stat du test d'appartenance à la loi expo	0.21	0.23	0.44	0.48

Considérons la réalisation d'un échantillon de taille $n = 4$:

0.66 3.51 1.92 1.05

Nous cherchons à tester si cet échantillon est distribué selon une loi normale et s'il est distribué selon une loi exponentielle. Pour cela nous proposons d'appliquer les tests précédemment construits.

Sur la figure ?? (à droite et à gauche) nous avons tracé la fonction de répartition empirique correspondant à l'échantillon donné. D'autre part, à gauche nous avons tracé la fonction $N_{\hat{\mu}, \hat{\sigma}^2}$ où $\hat{\mu}$ et $\hat{\sigma}^2$ sont les estimateurs du maximum de vraisemblance ($\hat{\mu} = 1.78$ $\hat{\sigma}^2 = 1.20$). A droite nous avons tracé la fonction de répartition de la loi exponentielle de paramètre $\hat{\lambda}$ ($\hat{\lambda} = 0.56$).

- Par une lecture graphique sur la figure ??, donner la valeur de la statistique des 2 tests.
- En utilisant les quantiles donnés ci-dessus, effectuer les 2 tests pour un niveau 5%.
- Les deux conclusions vous semblent-elles cohérentes ?




FIGURE 1 – Exercice 2 : fonction de répartition empirique de l'échantillon (en escalier) et fonction de répartition à tester.