

Introduction à la statistique non-paramétrique

Examen – 2019 – Durée : 2h00

Calculatrices, téléphones et smartphones interdits

Une page A4 manuscrite autorisée

Le barème est indicatif

En vert : les questions/exercices faciles ou très proches du cours ou du TD.

Exercice 1 : (5pts) On considère un n -échantillon i.i.d. $X = (X_1, \dots, X_n)$ de variables aléatoires. On note F la fonction de répartition et $\hat{F}_n$ la fonction de répartition empirique associées à cet échantillon. Si les variables X_i sont de lois normales de paramètres μ et σ^2 , on note également N_{μ, σ^2} leur fonction de répartition commune. On pose $\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ et $\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$.

1. (2pts) On pose

$$\Delta_n = \sup_{t \in \mathbb{R}} |\hat{F}_n(t) - N_{\hat{\mu}, \hat{\sigma}^2}(t)|.$$

Montrer que si $F = N_{\mu, \sigma^2}$, alors la loi de Δ_n ne dépend pas de μ et σ^2 .

2. (0.5pt) En déduire un test d'appartenance à la famille des lois normales, c'est-à-dire un test de

$$H_0 : F \in \mathcal{FN} \quad \text{contre} \quad H_1 : F \notin \mathcal{FN},$$

où

$$\mathcal{FN} = \left\{ G : \exists (\mu, \sigma^2) \in (\mathbb{R} \times \mathbb{R}_+^*) \text{ tel que } G = N_{\mu, \sigma^2} \right\}.$$

3. *Application (quasi indépendante du reste de l'exercice) :* La loi de la statistique de test de la question 3 a été tabulée. On s'intéresse aussi au test, vu en cours (section 2.3.2 du poly), d'appartenance à la famille exponentielle. On fournit ci-dessous quelques quantiles intéressants pour $n = 4$:

	$q_{5\%}$	$q_{10\%}$	$q_{90\%}$	$q_{95\%}$
Stat du test d'appartenance à la loi normale	0.18	0.20	0.36	0.39
Stat du test d'appartenance à la loi expo	0.21	0.23	0.44	0.48

Considérons la réalisation d'un échantillon de taille $n = 4$:

0.66 3.51 1.92 1.05

Nous cherchons à tester si cet échantillon est distribué selon une loi normale et s'il est distribué selon une loi exponentielle. Pour cela nous proposons d'appliquer le test précédemment construit et le test du cours. Sur la figure ?? (à droite et à gauche) nous avons tracé la fonction de répartition empirique correspondant à l'échantillon donné. D'autre part, à gauche nous avons tracé la fonction $N_{\hat{\mu}, \hat{\sigma}^2}$ où $\hat{\mu}$ et $\hat{\sigma}^2$ sont les estimateurs du maximum de vraisemblance ($\hat{\mu} = 1.78$ $\hat{\sigma}^2 = 1.20$). A droite nous avons tracé la fonction de répartition de la loi exponentielle de paramètre $\hat{\lambda}$ ($\hat{\lambda} = 0.56$).

- (a) (1pt) Par une lecture graphique sur la figure ??, donner la valeur de la statistique des 2 tests.




FIGURE 1 – Exercice 3 : fonction de répartition empirique de l'échantillon (en escalier) et fonction de répartition à tester.

(b) (1pt) En utilisant les quantiles donnés ci-dessus, effectuer les 2 tests pour un niveau 5%.

(c) (0.5pt) Les deux conclusions vous semblent-elles cohérentes ?

Exercice 2 : (15pts)

Pour deux fonctions u et v définies sur $\mathbb{R}$, à valeurs dans $\mathbb{R}$ et intégrables, on notera $u * v$ leur produit de convolution : pour tout $x \in \mathbb{R}$,

$$u \star v(x) = \int_{-\infty}^{+\infty} u(x-t)v(t)dt.$$

Pour une fonction g définie sur $\mathbb{R}$ et à valeurs dans $\mathbb{R}$, et $h > 0$, on pose

$$g_h(x) = \frac{1}{h}g\left(\frac{x}{h}\right).$$

On se donne $X_1, \dots, X_n$ un n -échantillon de variables aléatoires réelles. On considère une densité f bornée et continue sur $\mathbb{R}$. On considère un noyau K de carré intégrable. On estime f à l'aide de l'estimateur à noyau suivant : pour $h > 0$,

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right), \quad x \in \mathbb{R}.$$

Soit x_0 fixé dans $\mathbb{R}$. On note pour toute fonction g ,

$$\|g\|_2^2 = \int_{-\infty}^{+\infty} g^2(u)du.$$

1. (1.5pts) Montrer que

$$\lim_{h \rightarrow 0} \frac{1}{h} \int_{-\infty}^{+\infty} K\left(\frac{u - x_0}{h}\right) f(u)du = f(x_0).$$

2. (1.5pts) Montrer que, si on pose $\tilde{K} = \frac{K}{\|K\|_2}$,

$$\text{var}(\hat{f}_n(x_0)) = \frac{1}{nh} \|K\|_2^2 \tilde{K}_h^2 * f(x_0) - \frac{1}{n} (K_h * f(x_0))^2.$$

3. (1pt) En déduire que

$$\lim_{h \rightarrow 0} nh \text{var}(\hat{f}_n(x_0)) = f(x_0) \|K\|_2^2.$$

4. On suppose que la fonction f est deux fois continument dérivable et f'' est bornée. On suppose que K vérifie de plus que

$$\int_{-\infty}^{+\infty} tK(t)dt = 0, \quad \int_{-\infty}^{+\infty} t^2|K(t)|dt < \infty.$$

On pose

$$k_2 := \int_{-\infty}^{+\infty} t^2 K(t) dt.$$

- a) (1.5pts) Montrer qu'il existe $u_t \in (0, 1)$ tel que

$$\mathbb{E}[\hat{f}_n(x_0)] - f(x_0) = \frac{1}{h} \int_{\mathbb{R}} K\left(\frac{t-x_0}{h}\right) \frac{(t-x_0)^2}{2} [f''(x_0 + u_t(t-x_0)) - f''(x_0)] dt + \frac{1}{2} h^2 f''(x_0) k_2.$$

- b) (1pt) Soit $\varepsilon > 0$ et, pour tout réel v , soit α_v un réel dépendant de v et tel que $\alpha_v \in (0, 1)$. Montrer qu'il existe $M > 0$ tel que

$$\left| \int_{|v| > M} K(v) v^2 [f''(x_0 + h\alpha_v v) - f''(x_0)] dv \right| \leq \varepsilon.$$

- c) (2pts) Montrer que si on pose $\varepsilon_1(h) = \frac{1}{h} \int_{\mathbb{R}} K\left(\frac{t-x_0}{h}\right) \frac{(t-x_0)^2}{2} [f''(x_0 + u_t(t-x_0)) - f''(x_0)] dt$, alors

$$\lim_{h \rightarrow 0} h^{-2} \varepsilon_1(h) = 0.$$

On suppose jusqu'à la fin de l'exercice que

$$\|\mathbb{E}[\hat{f}_n] - f\|_2^2 = \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \varepsilon_2(h),$$

où ε_2 est une fonction ne dépendant pas de n et qui vérifie :

$$\lim_{h \rightarrow 0} h^{-4} \varepsilon_2(h) = 0.$$

- d) (2pts) En déduire que

$$\mathbb{E}[\|\hat{f}_n - f\|_2^2] \leq \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \frac{\|K\|_2^2}{nh} + \varepsilon_2(h).$$

- e) (1pt) Déterminer précisément la valeur h^* qui minimise

$$h \mapsto \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \frac{\|K\|_2^2}{nh}.$$

- f) (2pts) Si on suppose que f est la densité d'une loi gaussienne de moyenne μ et de variance σ^2 , calculer $\|f''\|_2^2$ en fonction de σ .

- g) (0.5pt) Dans le cadre de la question f), proposer un estimateur de σ , noté $\hat{\sigma}$.

- h) (1pt) Toujours dans le cadre de la question f), déterminer un estimateur de h^* en fonction de n , $\|K\|_2$, k_2 et $\hat{\sigma}$. Que devient cette expression si K est le noyau gaussien ?