

Introduction à la statistique non-paramétrique

Examen – 2023 – Durée : 2h00

Une demi-page A4 manuscrite autorisée

Le total est sur 25 points donc vous n'avez pas besoin de traiter toutes les questions.

Exercice 1 : (5pts)

Une entreprise crée un nouveau produit et, avant de le lancer sur le marché, souhaite savoir si ce nouveau produit est vraiment meilleur que l'ancien. Pour cela, elle dispose d'un échantillon de 14 individus indépendants qui testent les deux produits. Le résultat est le suivant : sur les 14 individus, 8 ont préféré le nouveau produit à l'ancien.

1. (0.5pt) Formuler l'hypothèse nulle et l'alternative.
2. (1pt) Quel test utiliser ici et pourquoi ?
3. (1.5pts) Exprimer la p-valeur observée en fonction de la fonction de répartition d'une loi à préciser.
4. (0.25pt) Après calcul, on trouve une p-valeur observée égale à environ 0.39. Tester au niveau $\alpha = 0.05$.
5. (0.75pt) Quelle mise en garde peut-on faire à la suite de ce résultat ?
6. Dans cette question, on suppose que le sondage effectué par l'entreprise est différent : au lieu de seulement dire quel produit ils ont préféré, les individus doivent mettre une note de 0 à 20 aux deux produits.
 - (a) (0.5pt) Quel test, vu en cours, peut-on envisager si le sondage est effectué ainsi ? (Juste le nom du test)
 - (b) (0.5pt) Toujours dans les conditions de ce nouveau sondage, est-il préférable d'utiliser le test de la question 2 ou bien le test de la question 6(a) ? Pourquoi ? (Réponse très rapide)

Exercice 2 (questions de cours) : (6.5pts)

1. On dispose d'un échantillon i.i.d. $(X_1, Y_1), \dots, (X_n, Y_n)$ de variables aléatoires à valeurs dans $\mathbb{R}^d \times \mathbb{R}$, de même loi qu'un couple (X, Y) . On suppose que la fonction de régression r définie par $r(x) = E(Y | X = x)$, pour $x \in \mathbb{R}^d$, existe.

On rappelle que l'estimateur de Nadaraya-Watson de la fonction de régression peut s'utiliser en toute dimension en définissant

$$\hat{r}(x) = \frac{\sum_{i=1}^n Y_i K\left(\frac{X_i - x}{h}\right)}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}$$

où $K : \mathbb{R}^d \rightarrow \mathbb{R}$ est intégrable et d'intégrale 1.

On suppose que $n = 70$ et $d = 5$.

- (a) (0.5pt) Pourquoi est-il déconseillé d'utiliser l'estimateur de Nadaraya-Watson dans ce contexte ? (Réponse courte)

- (b) (0.5pt) Proposer un autre modèle non paramétrique (vu en cours) à essayer qui soit plus judicieux dans ce contexte. (Réponse courte)
2. On dispose de deux échantillons i.i.d. et indépendants entre eux correspondant à des hauteurs d'arbres. Le premier échantillon correspond à des érables champêtres et le second à des érables de Montpellier. On veut savoir si l'une de ces deux variétés d'érable a tendance à être plus grande que l'autre ou pas.
- (a) (1pt) On décide de modéliser le problème à l'aide de la moyenne. On appelle μ_1 la hauteur moyenne d'un érable de Montpellier et μ_2 la hauteur moyenne d'un érable champêtre. Le problème de test est alors

$$H_0 : \mu_1 = \mu_2, \quad \text{contre} \quad H_1 : \mu_1 \neq \mu_2$$

On décide ensuite d'effectuer le test de Student. Citer rapidement deux problèmes potentiels liés à l'utilisation de ce test.

- (b) (0.5pt) Citer un test non-paramétrique permettant également de répondre à la question initiale (par une autre modélisation du problème). (Juste le nom)
3. Soient $X_1, \dots, X_n$ n variables aléatoires réelles i.i.d. de loi continue, de statistique d'ordre X^* et de vecteur des rangs $R_X = (R_1, \dots, R_n)$.
- (a) (1.5pts) Donner la loi de R_X en la justifiant.
- (b) (2pts) Montrer que R_X et X^* sont indépendants.
- (c) (0.5pt) Soit $s \in \{1, \dots, n\}$, donner la loi de $(R_1, \dots, R_s)$ (sans justification).

Exercice 3 : (13.5pts)

Soit (X, Y) un couple de variables aléatoires à valeurs réelles tel que $E(|Y|) < +\infty$. On note r la fonction de régression de Y sur X

$$r(x) = E(Y \mid X = x).$$

On dispose d'un échantillon i.i.d. $(X_1, Y_1), \dots, (X_n, Y_n)$ de même loi que (X, Y) .

On note ξ le résidu conditionnel : $\xi = Y - E(Y \mid X) = Y - r(X)$. On a donc

$$Y_i = r(X_i) + \xi_i, \quad i = 1, \dots, n$$

On suppose que la loi de X est absolument continue par rapport à la mesure de Lebesgue et on note f_X la densité correspondante. On suppose que f_X est nulle en dehors de $[-1, 1]$.

Pour $\beta \in]0, 1]$ et $L > 0$, on note $\Sigma(\beta, L)$ la (β, L) -classe de Holder définie par l'ensemble des fonctions $f : \mathbb{R} \rightarrow \mathbb{R}$ satisfaisant

$$\forall x, y \in \mathbb{R} \quad |f(x) - f(y)| \leq L|x - y|^\beta$$

On suppose que :

- A. Il existe $\beta \in]0, 1]$ et $L > 0$ tels que $r \in \Sigma(\beta, L)$.
- B. Pour tout $x \in [-1, 1]$, $\mathbb{E}(\xi^2 \mid X = x) \leq \sigma^2 < \infty$.
- C. Il existe des constantes p_1 et p_2 telles que $0 < p_1 \leq f_X(x) \leq p_2$ pour tout $x \in [-1, 1]$.

On désire estimer la fonction de régression r à l'aide de l'échantillon. On utilise pour cela l'estimateur de Nadaraya-Watson. Ici nous décidons d'utiliser une fonction K qui n'est pas définie en zéro :

$$K(u) = \frac{1}{|u|^{1/4}} \mathbf{1}_{|u| \leq 1} \quad \text{pour } u \in \mathbb{R} \setminus \{0\}$$

L'estimateur de Nadaraya-Watson de fenêtre $h > 0$ est alors donné par

$$\hat{r}(x) = \begin{cases} Y_i & \text{si } x = X_i \text{ pour un certain } i=1, \dots, n, \\ 0 & \text{si } \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) = 0, \\ \frac{\sum_{i=1}^n Y_i K\left(\frac{X_i - x}{h}\right)}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)} & \text{sinon} \end{cases}$$

On veut prouver que, sous les hypothèses ci-dessus, l'estimateur $\hat{r}$ est tel que le risque quadratique ponctuel $\mathbb{E}[(\hat{r}(x_0) - r(x_0))^2]$, pour $x_0 \in]-1, 1[$, est optimal si la fenêtre h est choisie convenablement. Autrement dit on veut prouver que l'estimateur, bien qu'interpolant les données, ne fait pas de surajustement. Dans la suite, sans perte de généralité, on suppose que $x_0 = 0$.

Notations :

Pour une variable Z fonction de $(X_1, Y_1), \dots, (X_n, Y_n)$, on note $\mathbb{E}_Y(Z)$ l'espérance de Z conditionnelle à $(X_1, \dots, X_n)$: $\mathbb{E}_Y(Z) = \mathbb{E}(Z \mid X_1, \dots, X_n)$.

Résultat admis : soit B une variable binomiale de paramètres (n, p) alors, pour tout $t > 0$, on a

$$\mathbb{P}(B - np \leq -t) \leq \exp\left(-\frac{t^2}{2np}\right).$$

1. On note $\mathcal{E}$ l'événement $\mathcal{E} = \{\sum_{i=1}^n K(\frac{X_i}{h}) \neq 0\}$. Montrer que

$$\mathbb{E}[(\hat{r}(0) - r(0))^2] = \mathbb{E}\left[\mathbb{E}_Y\left(\bar{r}(0) - r(0)\right)^2 \mathbf{1}_{\mathcal{E}}\right] + r(0)^2 \mathbb{P}(\mathcal{E}^c)$$

$$\text{où } \bar{r}(0) = \frac{\sum_{i=1}^n Y_i K(\frac{X_i}{h})}{\sum_{i=1}^n K(\frac{X_i}{h})}.$$

2. (court) En déduire que

$$\mathbb{E}[(\hat{r}(0) - r(0))^2] = \mathbb{E}\left[\mathbb{E}_Y\left[(\bar{r}(0) - \mathbb{E}_Y \bar{r}(0))^2\right] \mathbf{1}_{\mathcal{E}}\right] + \mathbb{E}\left[(\mathbb{E}_Y(\bar{r}(0)) - r(0))^2 \mathbf{1}_{\mathcal{E}}\right] + r(0)^2 \mathbb{P}(\mathcal{E}^c)$$

3. On suppose que $2p_1 h \leq 1$. Montrer que

$$\mathbb{P}(\mathcal{E}^c) \leq (1 - 2p_1 h)^n \leq \exp(-2p_1 n h).$$

4. On se place sur l'événement $\mathcal{E}$.

(a) (bonus) Montrer que $E_Y(\xi_i) = 0$ pour tout i .

(b) En déduire que

$$E_Y[\bar{r}(0)] = \frac{\sum_{i=1}^n r(X_i) K(\frac{X_i}{h})}{\sum_{i=1}^n K(\frac{X_i}{h})}.$$

5. Montrer que

$$|\mathbb{E}_Y[\bar{r}(0)] - r(0)| \mathbf{1}_{\mathcal{E}} \leq Lh^\beta.$$

6. Montrer que

$$\mathbb{E}_Y\left[(\bar{r}(0) - \mathbb{E}_Y \bar{r}(0))^2\right] \mathbf{1}_{\mathcal{E}} \leq \sigma^2 \frac{\sum_{i=1}^n K^2(\frac{X_i}{h})}{\left(\sum_{i=1}^n K(\frac{X_i}{h})\right)^2} \mathbf{1}_{\mathcal{E}}.$$

Pour cette question, on admettra que $Y_1, \dots, Y_n$ sont indépendants conditionnellement à $X_1^n = (X_1, \dots, X_n)$.

7. (court) En déduire que

$$\mathbb{E}\left[(\bar{r}(0) - \mathbb{E}_Y \bar{r}(0))^2 \mathbf{1}_{\mathcal{E}}\right] \leq \sigma^2 n \mathbb{E}\left[\frac{K^2(\frac{X_1}{h})}{\left(\sum_{i=1}^n K(\frac{X_i}{h})\right)^2} \mathbf{1}_{\mathcal{E}}\right].$$

8. (court) On pose $\eta_i = \mathbf{1}_{|X_i| \leq h}$. Montrer que

$$\mathbb{E}\left[\frac{K^2(\frac{X_1}{h})}{\left(\sum_{i=1}^n K(\frac{X_i}{h})\right)^2} \mathbf{1}_{\sum_{i=1}^n \eta_i > \frac{n\bar{p}}{2}} \mathbf{1}_{\mathcal{E}}\right] \leq \frac{4}{(n\bar{p})^2} \mathbb{E}\left[K^2(\frac{X_1}{h})\right]$$

où $\bar{p} = \mathbb{P}(|X_1| \leq h)$.

9. (court) En déduire que

$$\mathbb{E}\left[\frac{K^2(\frac{X_1}{h})}{\left(\sum_{i=1}^n K(\frac{X_i}{h})\right)^2} \mathbf{1}_{\sum_{i=1}^n \eta_i > \frac{n\bar{p}}{2}} \mathbf{1}_{\mathcal{E}}\right] \leq \frac{4hp_2}{(n\bar{p})^2} \int_{\mathbb{R}} K^2(u) du$$

10. Montrer que

$$\mathbb{E}\left[\frac{K^2(\frac{X_1}{h})}{\left(\sum_{i=1}^n K(\frac{X_i}{h})\right)^2} \mathbf{1}_{\sum_{i=1}^n \eta_i \leq \frac{n\bar{p}}{2}} \mathbf{1}_{\mathcal{E}}\right] \leq \exp\left(-\frac{n\bar{p}}{8}\right).$$

11. En déduire qu'il existe des constantes $c_1 > 0$ et $c_2 > 0$ ne dépendant ni de n ni de h telles que

$$\mathbb{E}\left[(\mathbb{E}_Y(\bar{r}(0)) - \bar{r}(0))^2 \mathbf{1}_{\mathcal{E}}\right] \leq c_1 \left(\frac{1}{nh} + n \exp(-c_2 nh)\right).$$

12. En déduire qu'il existe une constante $C > 0$ ne dépendant pas de n telle que, si h est convenablement choisi,

$$\mathbb{E}\left[(\hat{r}(0) - r(0))^2\right] \leq C n^{-\frac{2\beta}{2\beta+1}}.$$