

Introduction à la statistique non-paramétrique

Examen – 2024 – Durée : 2h00

Une page A4 manuscrite autorisée

Le barème est indicatif.

Le total des points est égal à 22 mais le résultat final reste sur 20.

Exercice 1 (10pts) :

On considère le problème de régression non-paramétrique à design fixe sur l'intervalle $[0; 1]$:

$$Y_i = r(x_i) + \varepsilon_i, \quad i \in \{1, \dots, n\},$$

où les ε_i sont i.i.d. centrées de variance σ^2 .

Partie 1 : On s'intéresse à l'estimation de $r(x)$ pour $x \in]0; 1[$ fixé. On considère un estimateur linéaire $\hat{r}(x)$:

$$\hat{r}(x) = \sum_{i=1}^n w_{i,n}(x) Y_i$$

où les poids déterministes $w_{i,n}(x)$ satisfont les propriétés suivantes :

Propriété 1 : il existe $\ell \in \mathbb{N}^*$ tel que

$$\sum_{i=1}^n (x_i - x)^k w_{i,n}(x) = 0, \quad k \in \{1, \dots, \ell\}, \quad (1)$$

Propriété 2 : il existe une constante $C > 0$ telle que

$$\sum_{i=1}^n |w_{i,n}(x)| \leq C \quad (2)$$

Propriété 3 :

$$\sum_{i=1}^n w_{i,n}(x) = 1. \quad (3)$$

On suppose que la fonction r appartient à la classe de Holder $\Sigma(\beta, L)$ pour certaines valeurs de $\beta > 1$ et $L > 0$. On rappelle ici la définition de cette classe :

$$\Sigma(\beta, L) = \{g : \mathbb{R} \rightarrow \mathbb{R} \text{ t.q. } g \text{ est } \ell \text{ fois dérivable et} \\ \forall (x, y) \in \mathbb{R}^2 \quad |g^{(\lfloor \ell \rfloor)}(y) - g^{(\ell)}(x)| \leq L|x - y|^{\beta - \ell}\}$$

On a noté ℓ l'entier défini par

$$\ell = \begin{cases} \beta - 1 & \text{si } \beta \text{ est un entier} \\ \text{partie entière de } \beta & \text{sinon} \end{cases}$$

On note également

$$b(x) = \mathbb{E}[\hat{r}(x)] - r(x) \quad \text{et} \quad V(x) = \text{var}(\hat{r}(x)).$$

1. (2pts) Montrer que pour tout $i \in \{1, \dots, n\}$, il existe $\eta_i \in]0; 1[$ tel que

$$b(x) = \sum_{i=1}^n w_{i,n}(x) \left(r^{(\ell)}(x + \eta_i(x_i - x)) - r^{(\ell)}(x) \right) \frac{(x_i - x)^\ell}{\ell!}$$

2. (0.5pt) En déduire que

$$|b(x)| \leq \frac{L}{\ell!} \sum_{i=1}^n |w_{i,n}(x)| |x_i - x|^\beta.$$

3. (1pt) Montrer que

$$V(x) \leq C\sigma^2 \times \sup_{x \in \mathbb{R}} \sup_{1 \leq i \leq n} |w_{i,n}(x)|.$$

4. (1pt) Soit $h > 0$ fixé. On suppose que l'on peut choisir les poids $w_{i,n}(x)$ tels que

Propriété 4 : pour tout i

$$w_{i,n}(x) = 0 \quad \text{si } |x_i - x| > h; \quad (4)$$

Propriété 5 :

$$\sup_{x \in \mathbb{R}} \sup_{1 \leq i \leq n} |w_{i,n}(x)| \leq \frac{M}{nh} \quad (5)$$

où M est une constante.

En déduire une majoration de $|b(x)|$ et de $V(x)$ en fonction de $C, M, \sigma^2, n, h, \beta, L$ et ℓ .

5. (1.5pts) Par un choix adéquat de h que vous préciserez, donner un contrôle optimal du risque quadratique ponctuel de l'estimateur $\hat{r}(x)$. (On se place dans le cas où n est très grand et où on ne se soucie pas des constantes exactes.)

Partie 2 : On s'intéresse maintenant plus particulièrement à l'estimateur par polynômes locaux. On choisit un polynôme de degré ℓ (donc le degré du polynôme est choisi en fonction de la régularité de la fonction r). Rappelons que c'est un estimateur linéaire avec, pour tout $i = 1, \dots, n$,

$$\omega_i(x) = K(z_i) e_1^T B_{n,x}^{-1} V_\ell(z_i)$$

où on a noté

$$z_i = \frac{x_i - x}{h}, \quad V_\ell(z_i) = \begin{pmatrix} 1 \\ z_i \\ \vdots \\ z_i^\ell \\ \frac{z_i^\ell}{\ell!} \end{pmatrix}, \quad B_{n,x} = \sum_{i=1}^n K(z_i) V_\ell(z_i) V_\ell(z_i)^T.$$

Nous faisons les hypothèses suivantes sur le noyau et sur le design.

Hyp1 : Il existe un nombre réel $\lambda_0 > 0$ et un entier positif n_0 tels que la plus petite valeur propre de la matrice $\frac{B_{n,x}}{nh}$, notée $\lambda_{\min}(\frac{B_{n,x}}{nh})$, satisfait

$$\lambda_{\min}(\frac{B_{n,x}}{nh}) \geq \lambda_0$$

pour tout $n \geq n_0$ et pour tout $x \in [0, 1]$.

Hyp2 : Il existe un nombre réel $a_0 > 0$ tel que pour tout intervalle $A \subset [0, 1]$ et pour tout $n \geq 1$

$$\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{x_i \in A\}} \leq a_0 \max(\text{Leb}(A), 1/n)$$

où $\text{Leb}(A)$ désigne la mesure de Lebesgue sur A .

Hyp3 : Le noyau K est à support compact dans $[-1, 1]$ et il existe un nombre $K_{max} < \infty$ tel que $|K(u)| \leq K_{max}, \forall u \in \mathbb{R}$.

1. (0.5pt) Vérifier que la propriété (4)¹ est satisfaite par l'estimateur par polynômes locaux sous les hypothèses Hyp1, Hyp2 et Hyp3.
2. (2pts) Vérifier que la propriété (5) est également satisfaite pour une constante M ne dépendant que de λ_0 et K_{max} .
3. (1.5pts) Vérifier que, si h est choisi tel que $nh \geq \frac{1}{2}$, la propriété (2) est satisfaite pour une constante C ne dépendant que de λ_0 , K_{max} et a_0 .

Exercice 2 (questions de cours) (6pts + 2pts bonus) :

1. (a) (0.75pt) Citer deux tests d'adéquation à une loi donnée (un test d'adéquation à une loi donnée est censé indiquer si un échantillon suit une loi donnée), parmi les tests vus en cours (juste les noms des tests).
(b) (0.75pt) Donner rapidement deux différences importantes entre ces deux tests.
2. (1pt) On effectue un test non asymptotique, avec pour résultat : « on accepte H_0 ». Faut-il se méfier du résultat si la taille d'échantillon est petite ? Et si au contraire le résultat du test est « on rejette H_0 » ? Expliquer rapidement.
3. (a) (1pt) Expliciter l'hypothèse nulle H_0 et l'hypothèse alternative H_1 associées au test de Mann-Whitney.
(b) (+0.5pt, bonus) Expliquer rapidement pourquoi ce test n'est pas vraiment d'un test d'égalité en loi de deux échantillons.
4. (0.5pt) Expliquer rapidement ce qu'on entend par « échantillons appariés ».
5. (1pt) Donner un exemple prouvant que le test du signe ne devrait pas être considéré comme un test d'homogénéité (i.e. comme un test permettant de savoir si deux échantillons suivent la même loi).
6. On dispose d'un échantillon i.i.d. $(X_1, Y_1), \dots, (X_n, Y_n)$ de variables aléatoires à valeurs dans $\mathbb{R}^d \times \mathbb{R}$, de même loi qu'un couple (X, Y) . On suppose que la fonction de régression r définie par $r(x) = E(Y | X = x)$, pour $x \in \mathbb{R}^d$, existe.
On suppose que $n = 60$ et $d = 5$.
(a) (0.75pt) Pourquoi est-il déconseillé d'utiliser un estimateur par polynôme local dans ce contexte ? (Réponse courte)
(b) (+0.5pt, bonus) Proposer un autre modèle non paramétrique (mentionné en cours) qui soit plus judicieux à essayer dans ce contexte. (Réponse courte)

1. les propriétés (1) et (3) sont également vérifiées par l'estimateur, justification non exigée ici.

7. (0.75pt) On suppose qu'un estimateur par polynômes locaux avec une fenêtre h a été calculé sur des données $(X_1, Y_1), \dots, (X_n, Y_n)$. On note cet estimateur $\hat{r}_h$. On cherche une fenêtre optimale h parmi une grille de valeurs H . Posons

$$\hat{h} = \arg \min_{h \in H} \frac{1}{n} \sum_{i=1}^n \left(Y_i - \hat{r}_h(X_i) \right)^2.$$

Pourquoi le choix de $\hat{h}$ est-il déconseillé ? (réponse courte).

8. (+1pt bonus) Un risque empirique nul entraîne-t-il toujours un surajustement (surajustement=overfitting) ? Expliquer rapidement.

Exercice 3 (3.5pts) :

Soit $X_1, \dots, X_n$ un échantillon i.i.d. de loi de fonction de répartition F continue. Soit $p \in]0, 1[$. On note x_p le quantile d'ordre p de F .

On va montrer dans cet exercice comment obtenir un intervalle de confiance sur x_p sans connaître F (en supposant seulement que F est continue).

Soit $\alpha \in]0, 1]$ un niveau de confiance. On note $\hat{F}_n$ la fonction de répartition empirique et on note $\hat{F}_n^{(-1)}$ la fonction quantile (ou inverse généralisée) associée à $\hat{F}_n$.

1. (0.75pt) Donner la limite en loi de $\sqrt{n}(\hat{F}_n(x) - F(x))$ quand n tend vers l'infini.
2. (0.75pt) Donner la limite en loi de $\sqrt{n}(\hat{F}_n(x_p) - p)$ quand n tend vers l'infini.
3. (0.75pt) En déduire que

$$P\left(p - \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{p(1-p)}{n}} \leq \hat{F}_n(x_p) < p + \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{p(1-p)}{n}}\right) \xrightarrow{n \rightarrow +\infty} 1 - \alpha$$

où Φ est la fonction de répartition de la loi normale standard.

4. (1.25pt) En utilisant la fonction inverse généralisée $\hat{F}_n^{(-1)}$, en déduire un intervalle de confiance asymptotique de niveau $1 - \alpha$ pour x_p .