

Introduction à la statistique non-paramétrique

Examen – 2025 – Durée : 2h00

Une page A4 manuscrite autorisée

Le barème est indicatif.

Le total des points est égal à 22 mais le résultat final reste sur 20.

Exercice 1 (6.5pts) : Soient f une densité (par rapport à la mesure de Lebesgue) appartenant à la classe de Holder $\Sigma(\beta, L)$ et $(X_1, \dots, X_n)$ un n -échantillon de variables aléatoires de densité f .

Rappelons la définition de $\Sigma(\beta, L)$: pour tout $\beta > 0$ et tout $L > 0$, on définit la classe de Holder de régularité β et de rayon L par

$$\Sigma(\beta, L) = \{g : \mathbb{R} \rightarrow \mathbb{R} \text{ t.q. } g \text{ est } \lfloor \beta \rfloor \text{ fois dérivable et} \\ \forall (x, y) \in \mathbb{R}^2 \quad |g^{(\lfloor \beta \rfloor)}(y) - g^{(\lfloor \beta \rfloor)}(x)| \leq L|x - y|^{\beta - \lfloor \beta \rfloor}\}$$

On rappelle que, si $\beta > 0$ et $L > 0$, il existe une constante $M(\beta, L)$ telle que

$$\sup_{x \in \mathbb{R}} \sup_{f \in \Sigma_d(\beta, L)} f(x) \leq M(\beta, L)$$

où on a noté $\Sigma_d(\beta, L)$ l'intersection de $\Sigma(\beta, L)$ et de l'ensemble des densités.

On suppose que K est un noyau d'ordre $\ell = \lfloor \beta \rfloor$ tel que $\int |u|^\beta |K(u)| du < \infty$ et $\int K^2(u) du < \infty$.

1. (3pts) Montrer que, pour tout $x_0 \in \mathbb{R}$, et pour tout $h > 0$ le biais peut être borné comme suit :

$$|\mathbb{E}[\hat{f}_n(x_0)] - f(x_0)| \leq C_1 h^\beta$$

où C_1 dépend de L, ℓ, β et K .

2. (1.5pts) Montrer que

$$\text{var}(\hat{f}_n(x_0)) \leq \frac{C_2}{nh}$$

où C_2 dépend de $M(\beta, L)$ et de K .

3. (2pts) Montrer qu'il existe une constante $C > 0$ telle que, si h est convenablement choisie,

$$\mathbb{E} \left[\left(\hat{f}_n(x_0) - f(x_0) \right)^2 \right] \leq C n^{-\frac{2(\beta)}{2\beta+1}}.$$

Exercice 2 (5pts) :

Une entreprise crée un nouveau produit et souhaite savoir si ce nouveau produit est vraiment meilleur que l'ancien. Pour cela, elle dispose d'un échantillon de 14 individus indépendants qui testent les deux produits. Le résultat est le suivant : sur les 14 individus, 8 ont préféré le nouveau produit à l'ancien.

1. (0.5pt) Formuler l'hypothèse nulle et l'alternative.
2. (1pt) Quel test utiliser ici et pourquoi ?
3. (1.5pts) Exprimer la p-valeur observée en fonction de la fonction de répartition d'une loi à préciser.
4. (0.25pt) Après calcul, on trouve une p-valeur observée égale à environ 0.39. Tester au niveau $\alpha = 0.05$.
5. (0.75pt) Quelle mise en garde peut-on faire à la suite de ce résultat ?
6. Dans cette question, on suppose que le sondage effectué par l'entreprise est différent : au lieu de seulement dire quel produit ils ont préféré, les individus doivent mettre une note de 0 à 20 aux deux produits.
 - (a) (0.5pt) Quel test, vu en cours, peut-on envisager si le sondage est effectué ainsi ? (Juste le nom du test)

- (b) (0.5pt) Toujours dans les conditions de ce nouveau sondage, est-il préférable d'utiliser le test de la question 2 ou bien le test de la question 6(a) ? Pourquoi ? (Réponse très rapide)

Exercice 3 (3pts) : On considère l'estimateur par polynômes locaux de degré ℓ , basé sur un noyau K et une fenêtre h , et calculé en $x \in \mathbb{R}$. On note pour tout $u \in \mathbb{R}$,

$$V_\ell(u) = \left(1, u, \dots, \frac{u^\ell}{\ell!}\right)^T.$$

On suppose que la matrice

$$B = \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) V_\ell\left(\frac{X_i - x}{h}\right) V_\ell\left(\frac{X_i - x}{h}\right)^T$$

est inversible. On considère un polynôme Q de degré inférieur ou égal à ℓ . On suppose que les observations associées au design $X_1, \dots, X_n$ vérifient $Y_i = Q(X_i)$

1. (0.5pt) Montrer que

$$Q(X_i) = q(x)^T V_\ell\left(\frac{X_i - x}{h}\right),$$

où

$$q(x) = (Q(x), Q'(x)h, \dots, Q^{(\ell)}(x)h^\ell)^T.$$

2. (1pt) Donner l'expression de l'estimateur $\hat{r}_n^\ell(x)$, l'estimateur par polynômes locaux, en fonction de

$$\hat{\theta}_n(x) = \arg \min_{\theta \in \mathbb{R}^{\ell+1}} ((q(x) - \theta)^T B (q(x) - \theta))$$

3. (1pt) Montrer que $\hat{\theta}_n(x) = q(x)$ et en déduire que

$$\sum_{i=1}^n Q(X_i) w_{i,n}^\ell(x) = Q(x)$$

où les $w_{i,n}^\ell(x)$ sont les poids de l'estimateur par polynômes locaux associés au design.

4. (0.5pt) En déduire que pour tout $1 \leq k \leq \ell$,

$$\sum_{i=1}^n (X_i - x)^k w_{i,n}^\ell(x) = 0, \quad \sum_{i=1}^n w_{i,n}^\ell(x) = 1.$$

Exercice 4 (5.5pts + 2pts) :

- (0.75pts) Quelle différence principale y-a-t-il entre le test d'homogénéité de Kolmogorov Smirnov et le test de Mann-Whitney ? (réponse courte)
- (0.75pts) Quand utilise-t-on le test de Mann-Whitney plutôt que le test de Student ? (réponse courte)
- (a) (1pt) Qu'appelle-t-on le fléau de la dimension (curse of dimensionality) ? (réponse assez courte)
(b) (1pt) Que peut-on envisager pour remédier à ce problème ? (réponse assez courte)
- (1pt) Soit r une fonction définie sur $\mathbb{R}$ et à valeurs réelles et soit $x \in \mathbb{R}$. Soit $\hat{r}(x)$ un estimateur de $r(x)$ calculé à partir d'un échantillon i.i.d. $(X_1, Y_1), \dots, (X_n, Y_n)$ de couples de v.a. réelles. On note E_Y l'espérance conditionnelle sachant $(X_1, \dots, X_n)$. Montrer qu'on a

$$E_Y(\hat{r}(x) - r(x))^2 = [E_Y(\hat{r}(x)) - r(x)]^2 + E_Y[\hat{r}(x) - E_Y(\hat{r}(x))]^2.$$

5. (1pt) Considérons le problème suivant : on se donne n points $x_1, \dots, x_n$ dans un intervalle $[a, b]$. Parmi toutes les fonctions f définies sur $[a, b]$ et possédant deux dérivées continues, trouver celle qui minimise la somme des résidus quadratiques pénalisée

$$\sum_{i=1}^n \{y_i - f(x_i)\}^2 + \lambda \int_a^b \{f''(t)\}^2 dt,$$

où λ est un paramètre de lissage fixé.

Décrire rapidement la solution. (On ne demande pas de preuve).

6. (+2pts) La loi de la p-valeur d'un test dépend-elle de la taille de l'échantillon ?