

Introduction à la statistique non-paramétrique**EXAMEN – 6 juin 2014 – Durée : 2h00****Documents, calculatrices, téléphones et smartphones interdits***Un point sera attribué en plus ou en moins suivant la qualité de la calligraphie et de la présentation***Question de cours**

On se place dans le modèle de régression non-paramétrique classique

$$Y_i = r(X_i) + \varepsilon_i, \quad i = 1, \dots, n,$$

avec (X_i, Y_i) un couple i.i.d. de variables aléatoires réelles, r la fonction de régression à estimer définie pour tout $x \in \mathbb{R}$ par $r(x) = \mathbb{E}[Y_1 | X_1 = x]$ et pour tout $i = 1, \dots, n$, ε_i satisfait :

$$\mathbb{E}[\varepsilon_i | X_i] = 0, \quad \text{var}(\varepsilon_i) = \sigma^2,$$

pour σ^2 constante positive. On suppose que f_X la densité des X_i est connue mais pas la densité des couples (X_i, Y_i) . Dans ce cadre, proposer un estimateur non-paramétrique de r dépendant de f_X , des $(X_i, Y_i)_{i=1, \dots, n}$ et d'un noyau K .

Exercice 1 : Tests multiples

L'objectif de cet exercice est de proposer une procédure de tests multiples lorsque le nombre d'hypothèses à tester est élevé. On considère dans tout l'exercice $(\Omega, \mathcal{A}, \mathbb{P}_\theta, \theta \in \Theta)$ un modèle statistique.

Partie A. On se place tout d'abord dans le cadre simple où on veut tester

$$H_0 : \theta \in \Theta_0 \quad \text{contre} \quad H_1 : \theta \in \Theta_1$$

où Θ_0 et Θ_1 sont deux sous-ensembles disjoints de Θ . Pour cela, on dispose d'une observation réelle X de loi $\mathbb{P}_\theta$. Pour $\alpha \in]0, 1[$ donné, on considère un test de H_0 contre H_1 de la forme $\phi_\alpha(X) = 1_{X \geq k_\alpha}$ où $k_\alpha \in \mathbb{R}$. On se place dans le cadre où la p -valeur de ce test s'écrit pour tout $x \in \mathbb{R}$:

$$\hat{p}(x) = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(X \geq x).$$

L'objectif de cette partie est de montrer l'inégalité (2) ci-dessous, c'est-à-dire que sous H_0 , $\hat{p}(X)$ est stochastiquement plus grande qu'une variable de loi uniforme sur $]0, 1[$. On note pour $\theta \in \Theta_0$ et pour $x \in \mathbb{R}$, $T_\theta(x)$ la queue de distribution de X sous $\mathbb{P}_\theta$:

$$T_\theta(x) = \mathbb{P}_\theta(X \geq x)$$

et on suppose que la fonction $x \rightarrow T_\theta(x)$ est continue.

1. Uniquement dans cette question, on suppose que $\Theta = \mathbb{R}_+^*$, qu'il existe $0 < r_0 < s_0 < +\infty$ tels que $\Theta_0 = [r_0, s_0]$ et que sous $\mathbb{P}_\theta$, X suit une loi exponentielle d'espérance $1/\theta$.
 - (a) Déterminer $\hat{p}(x)$ pour tout $x > 0$.
 - (b) Calculer pour tout $u \in]0, 1[$,

$$\sup_{\theta \in \Theta_0} \mathbb{P}_\theta(\hat{p}(X) \leq u).$$

2. Soit $\theta \in \Theta_0$. On définit pour tout $u \in]0, 1[$,

$$G_{T_\theta}(u) = \inf\{x \in \mathbb{R} : T_\theta(x) \leq u\}.$$

- (a) Montrer que pour tout $u \in]0, 1[$,

$$T_\theta(G_{T_\theta}(u)) \leq u. \tag{1}$$

- (b) En déduire que pour tout $x \in \mathbb{R}$ et pour tout $u \in]0, 1[$,

$$T_\theta(x) \leq u \iff x \geq G_{T_\theta}(u).$$

3. Montrer alors que pour tout $\theta \in \Theta_0$ et pour tout $u \in]0, 1[$,

$$\mathbb{P}_\theta(T_\theta(X) \leq u) \leq u.$$

4. En déduire alors que pour tout $\theta \in \Theta_0$ et pour tout $u \in]0, 1[$,

$$\mathbb{P}_\theta \left(\sup_{\theta' \in \Theta_0} T_{\theta'}(X) \leq u \right) \leq u.$$

5. En déduire enfin que pour tout $u \in]0, 1[$,

$$\sup_{\theta \in \Theta_0} \mathbb{P}_\theta(\hat{p}(X) \leq u) \leq u. \tag{2}$$

6. On suppose uniquement dans cette question que X suit une loi de Bernoulli de paramètre $\theta \in]0, 1[$.
 - (a) Calculer $T_\theta(x)$ pour tout $x \in \mathbb{R}$.
 - (b) Déterminer alors $T_\theta(G_{T_\theta}(\theta))$.
 - (c) Montrer que (1) n'est pas satisfaite pour certaines valeurs de u .

Partie B. Dans cette partie, indépendante de la partie A, pour $m \in \mathbb{N}^*$, on considère $2m$ sous-ensembles de Θ notés $\Theta_{01}, \Theta_{11}, \Theta_{02}, \Theta_{12}, \dots, \Theta_{0m}, \Theta_{1m}$ avec pour tout $i \in \{1, \dots, m\}$

$$\Theta_{0i} \cap \Theta_{1i} = \emptyset$$

et on veut réaliser simultanément m tests

$$H_{0i} : \theta \in \Theta_{0i} \quad \text{contre} \quad H_{1i} : \theta \in \Theta_{1i}, \quad i = 1, \dots, m.$$

On note I_0 l'ensemble des indices i pour lesquels H_{0i} est vraie :

$$I_0 = \{i \in \{1, \dots, m\} : H_{0i} \text{ est vraie}\}.$$

On cherche à construire une procédure de tests multiples qui retourne un ensemble $\hat{R} \subset \{1, \dots, m\}$ correspondant aux indices i pour lesquels H_{0i} est rejetée. On note FP le cardinal de l'ensemble des indices correspondant aux hypothèses nulles rejetées à tort et TP le cardinal de l'ensemble des indices correspondant aux hypothèses nulles rejetées à raison :

$$\text{FP} = \text{card}(\hat{R} \cap I_0), \quad \text{TP} = \text{card}(\hat{R} \setminus I_0).$$

FP est le cardinal des *faux positifs* et TP celui des *vrais positifs*. Idéalement, on cherche une procédure de tests de sorte que FP soit petit et TP soit grand. Pour cela, pour tout i , on suppose que pour tester H_{0i} contre H_{1i} , on dispose d'une statistique $\hat{p}_i$ satisfaisant (2) : pour tout $u \in]0, 1[$,

$$\sup_{\theta \in \Theta_{0i}} \mathbb{P}_\theta(\hat{p}_i \leq u) \leq u. \quad (3)$$

1. On propose tout d'abord la procédure de Bonferroni qui permet le contrôle de FP en posant pour $\alpha \in]0, 1[$:

$$\hat{R} = \left\{ i \in \{1, \dots, m\} : \hat{p}_i \leq \frac{\alpha}{m} \right\}.$$

- (a) Montrer que

$$\mathbb{P}(\text{FP} > 0) \leq \sum_{i \in I_0} \sup_{\theta \in \Theta_{0i}} \mathbb{P}_\theta(\hat{p}_i \leq \alpha/m).$$

- (b) En utilisant (3), en déduire que

$$\mathbb{P}(\text{FP} > 0) \leq \alpha.$$

2. La procédure de Bonferroni contrôle le nombre de faux positifs mais produit en général un petit nombre de vrais positifs. Aussi, on propose l'alternative suivante. On se donne une fonction $f : \{0, 1, \dots, m\} \rightarrow [0, m]$ supposée croissante et on ordonne les statistique $\hat{p}_i$ par ordre croissant :

$$\hat{p}_{(1)} \leq \hat{p}_{(2)} \leq \dots \leq \hat{p}_{(m)}.$$

On cherche à contrôler le rapport FDR défini par

$$\text{FDR} = \mathbb{E} \left[\frac{\text{FP}}{\text{FP} + \text{TP}} 1_{\{\text{FP} + \text{TP} \geq 1\}} \right]$$

avec la convention $0/0 = 0$. On pose pour $\alpha \in]0, 1[$,

$$\hat{R} = \left\{ i \in \{1, \dots, m\} : \hat{p}_i \leq \frac{\alpha f(\hat{k})}{m} \right\}$$

avec

$$\hat{k} = \max \left\{ k \in \{1, \dots, m\} : \hat{p}_{(k)} \leq \frac{\alpha f(k)}{m} \right\}.$$

En particulier, on pose $\hat{k} = 0$ et $\hat{R} = \emptyset$ si pour tout entier k , $\hat{p}_{(k)} > \frac{\alpha f(k)}{m}$.

(a) Montrer que

$$\hat{k} = \text{card}(\hat{R})$$

et que pour $j \geq \hat{k}$,

$$f(\hat{k}) \leq f(\min(j, m)).$$

(b) Etablir alors que

$$\text{FDR} = \sum_{i \in I_0} \mathbb{E} \left[1_{\{\hat{p}_i \leq \alpha f(\hat{k})/m\}} \times \frac{1_{\{\hat{k} \geq 1\}}}{\hat{k}} \right].$$

(c) Montrer que si $\hat{k} \geq 1$,

$$\frac{1}{\hat{k}} = \sum_{j=1}^{+\infty} \frac{1_{\{j \geq \hat{k}\}}}{j(j+1)}.$$

(d) En d duire finalement que

$$\text{FDR} \leq \frac{\alpha \text{card}(I_0)}{m} \sum_{j=1}^{+\infty} \frac{f(\min(j, m))}{j(j+1)}.$$

(e) Conclure que si f satisfait

$$\sum_{j=1}^{+\infty} \frac{f(\min(j, m))}{j(j+1)} \leq 1 \tag{4}$$

alors

$$\text{FDR} \leq \alpha.$$

(f) Donner un exemple de fonction f satisfaisant (4).

Exercice 2

On considère les deux échantillons observés suivants :

$$x = (0.11, 0.20, 0.69, 1.02) \quad y = (0.86, 0.99, 1.24, 1.57, 1.62)$$

On cherche à tester l'hypothèse nulle H_0 : "les deux échantillons proviennent d'une même loi" contre H_1 : "les deux échantillons proviennent de deux lois différentes".

1. Rappeler la forme de la statistique du test de Kolmogorov-Smirnov à deux échantillons.
2. A l'aide de la Table (1), et éventuellement de la Figure (1) des fonctions de répartition empiriques, calculer la p-valeur du test de Kolmogorov-Smirnov.
3. Rappeler la forme de la statistique de Mann-Whitney, et donner son espérance sous H_0 ainsi que ses valeurs minimale et maximale.
4. A l'aide de la Table (2), calculer la p-valeur du test de Mann-Whitney.

x	0.20	0.25	0.30	0.35	0.40	0.50	0.55	0.60	0.75	0.80	1
$P(h_{4,5} \geq x)$	1	0.99	0.97	0.87	0.75	0.56	0.43	0.29	0.14	0.079	0.016

TABLE 1 – Table de la loi de la statistique de Kolmogorov-Smirnov $h_{4,5}$.

x	0	1	2	3	4	5	6	7	8	9	10
$P(W_X \leq x)$	0.0079	0.016	0.032	0.056	0.095	0.14	0.21	0.28	0.37	0.45	0.55
x	11	12	13	14	15	16	17	18	19	20	
$P(W_X \leq x)$	0.63	0.72	0.79	0.86	0.90	0.94	0.97	0.98	0.99	1.00	

TABLE 2 – Table de la loi de la statistique de Mann-Whitney W_X , à laquelle on a soustrait la valeur minimale.




FIGURE 1 – Fonctions de répartition empiriques des échantillons x (en trait plein) et y (en pointillé).