

Introduction à la statistique non-paramétrique

EXAMEN – 26 mai 2016 – Durée : 2h00

Documents, calculatrices, téléphones et smartphones interdits

Problème : Estimation adaptative de densité

Pour toutes fonctions u et v , définies sur $\mathbb{R}$, à valeurs dans $\mathbb{R}$ et intégrables, on notera $u \star v$ leur produit de convolution : Pour tout $x \in \mathbb{R}$,

$$(u \star v)(x) = \int_{-\infty}^{+\infty} u(x-t)v(t)dt.$$

On rappelle que si u et v appartiennent respectivement à $\mathbb{L}_1(\mathbb{R})$ et $\mathbb{L}_2(\mathbb{R})$ alors

$$\|u \star v\|_2 \leq \|u\|_1 \times \|v\|_2,$$

où pour $p \in \{1, 2\}$, $\|\cdot\|_p$ désigne la norme $\mathbb{L}_p$ sur $\mathbb{R}$. On considère dans la suite $X_1, \dots, X_n$ des variables aléatoires i.i.d. de densité de probabilité f par rapport à la mesure de Lebesgue sur $\mathbb{R}$. On souhaite estimer f à l'aide de ces variables. Etant donné $\mathcal{H}$, un ensemble de fenêtres strictement positives, pour $h \in \mathcal{H}$, on considère l'estimateur à noyau de f défini pour tout $x \in \mathbb{R}$ par

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{j=1}^n K\left(\frac{x - X_j}{h}\right).$$

Dans toute la suite, on suppose que le noyau K est pair et satisfait $\|K\|_2 < \infty$. On considère $R_n(\hat{f}_h, f)$ le risque quadratique intégré de $\hat{f}_h$:

$$R_n(\hat{f}_h, f) = \mathbb{E} \left[\|\hat{f}_h - f\|_2^2 \right].$$

Partie A - Analyse du risque de $\hat{f}_h$

On fixe $h \in \mathcal{H}$.

1. Montrer que

$$\mathbb{E}[\hat{f}_h] = K_h \star f$$

où on a posé pour tout $x \in \mathbb{R}$, $K_h(x) = \frac{1}{h} K\left(\frac{x}{h}\right)$.

2. Etablir que

$$\mathbb{E} \left[\|\hat{f}_h - \mathbb{E}[\hat{f}_h]\|_2^2 \right] \leq \frac{\|K\|_2^2}{nh}.$$

3. En déduire que

$$R_n(\hat{f}_h, f) \leq \|K_h \star f - f\|_2^2 + \frac{\|K\|_2^2}{nh}.$$

Indication : On utilisera la décomposition biais-variance de $R_n(\hat{f}_h, f)$.

Partie B - Méthode de Goldenshluger-Lepski

On fixe $\varepsilon > 0$ et on pose pour tout $h \in \mathcal{H}$,

$$A(h) = \sup_{h' \in \mathcal{H}} \left\{ \|\hat{f}_{h,h'} - \hat{f}_{h'}\|_2 - \frac{\xi}{\sqrt{nh'}} \|K\|_2 \right\},$$

où pour h et h' appartenant à $\mathcal{H}$,

$$\hat{f}_{h,h'} = K_h \star \hat{f}_{h'}, \quad \xi = (1 + \varepsilon)(1 + \|K\|_1).$$

Enfin, on définit $\hat{f}$ l'estimateur de f par $\hat{f}_{\hat{h}}$ où

$$\hat{h} = \arg \min_{h \in \mathcal{H}} \left\{ A(h) + \frac{\xi}{\sqrt{nh}} \|K\|_2 \right\}.$$

On fixe $h \in \mathcal{H}$.

1. Montrer que pour tout $h' \in \mathcal{H}$, $\hat{f}_{h,h'} = \hat{f}_{h',h}$.

2. (a) Etablir que

$$\|\hat{f} - f\|_2 \leq A_1 + A_2 + \|\hat{f}_h - f\|_2,$$

avec

$$A_1 = \|\hat{f}_{\hat{h}} - \hat{f}_{h,\hat{h}}\|_2, \quad A_2 = \|\hat{f}_h - \hat{f}_{h,\hat{h}}\|_2.$$

(b) Montrer que

$$A_1 \leq A(h) + \frac{\xi}{\sqrt{n\hat{h}}} \|K\|_2, \quad A_2 \leq A(\hat{h}) + \frac{\xi}{\sqrt{n\hat{h}}} \|K\|_2.$$

(c) En déduire que

$$\|\hat{f} - f\|_2 \leq 2A(h) + \frac{2\xi}{\sqrt{n\hat{h}}} \|K\|_2 + \|\hat{f}_h - f\|_2.$$

3. Si on pose pour $h' \in \mathcal{H}$,

$$w(h, h') = \|\hat{f}_{h, h'} - \mathbb{E}[\hat{f}_{h, h'}] - \hat{f}_{h'} + \mathbb{E}[\hat{f}_{h'}]\|_2 - \frac{\xi}{\sqrt{nh'}} \|K\|_2,$$

montrer que

$$A(h) \leq \sup_{h' \in \mathcal{H}} \|\mathbb{E}[\hat{f}_{h, h'}] - \mathbb{E}[\hat{f}_{h'}]\|_2 + \sup_{h' \in \mathcal{H}} w(h, h').$$

4. Montrer que pour tout $x \in \mathbb{R}$,

$$\mathbb{E}[\hat{f}_{h, h'}(x)] - \mathbb{E}[\hat{f}_{h'}(x)] = \int K_{h'}(x - v) \left[\int K_h(v - u) f(u) du - f(v) \right] dv.$$

5. En d  duire que

$$\|\mathbb{E}[\hat{f}_{h, h'}] - \mathbb{E}[\hat{f}_{h'}]\|_2 \leq \|K\|_1 \times \|K_h \star f - f\|_2.$$

6. On admet que

$$\mathbb{E} \left[\sup_{h, h' \in \mathcal{H}} w^2(h, h') \right] \leq \frac{C_1}{n},$$

o   C_1 ne d  pend que de ε et K . Montrer alors que

$$R_n(\hat{f}, f) \leq C_2 \inf_{h \in \mathcal{H}} \left\{ \|K_h \star f - f\|_2^2 + \frac{\|K\|_2^2}{nh} \right\} + \frac{C_2}{n},$$

o   C_2 ne d  pend que de ε et K .

7. On suppose que f appartient    l'espace de Sobolev $\mathcal{W}(\alpha, L)$ ou $\alpha > 0$ et $L > 0$. On admet que K nous permet d'avoir la propri  t   suivante : Pour tout $h > 0$,

$$\|K_h \star f - f\|_2^2 \leq L^2 h^{2\alpha}.$$

On suppose que l'on peut prendre $\mathcal{H} = \mathbb{R}_+^*$. Montrer qu'il existe une constante C ne d  pendant que de ε , L , α et K telle que pour n assez grand,

$$R_n(\hat{f}, f) \leq C n^{-\frac{2\alpha}{2\alpha+1}}.$$

Justifier pourquoi cette m  thode est qualifi  e d'adaptative.

Exercice : Tests non-paramétriques

Une entreprise teste un nouveau modèle de pneus. Pour cela, des tests d'usure sont effectués, dans les mêmes conditions, sur un échantillon de pneus de l'ancien modèle (modèle A) et du nouveau modèle (modèle B). Le tableau suivant donne le nombre de milliers de kilomètres parcouru par chaque pneu testé avant usure :

Modèle A	26	49	52	80	102	106	115	121	135
Modèle B	47	58	64	91	94	109	116	132	179

L'entreprise souhaite déterminer si les pneus du modèle B peuvent parcourir plus de kilomètres avant d'être usés que ceux du modèle A .

1. Rappeler les définitions des statistiques W_X et W_Y (notations du cours) du test de Mann-Whitney.
2. Énoncer l'hypothèse nulle et l'hypothèse alternative.
3. À l'aide de la table de Mann-Whitney ci-dessous, déterminer la zone de rejet au niveau 2.5%.
4. Quelle est la conclusion du test ?

	1	2	3	4	5	6	7	8	9
1	-	-	-	-	-	-	-	-	-
2	-	-	-	-	-	-	-	0	0
3	-	-	-	-	0	1	1	2	2
4	-	-	-	0	1	2	3	4	4
5	-	-	0	1	2	3	5	6	7
6	-	-	1	2	3	5	6	8	10
7	-	-	1	3	5	6	8	10	12
8	-	0	2	4	6	8	10	13	15
9	-	0	2	4	7	10	12	15	17

Table de Mann-Whitney pour la statistiques W_X pour différentes valeurs de n et p (notations du cours). Le tableau donne la plus grande valeur v telle que $\mathbb{P}(W_X \leq v) \leq 0,025$. Chaque ligne correspond à une valeur de n , chaque colonne à une valeur de p .