

Examen *Introduction à la statistique non-paramétrique*

Université Paris-Dauphine PSL – M1

Mai 2018

Durée : 2h00

Exercice 1 : Estimation non-paramétrique d'intensité Poissonienne (9.5 pts)

On s'intéresse aux arrivées des malades et des blessés dans un service d'urgences hospitalier sur une période donnée notée $[0, D]$ où D est une constante strictement positive. On note N le nombre d'arrivées pendant $[0, D]$ et $T_1, \dots, T_N$ les instants de ces arrivées. On modélise ces arrivées selon un processus de Poisson d'intensité f où f est une fonction positive intégrable et de support $[0, D]$. Cela signifie que si pour tout intervalle I , on note $N_I = \text{card}\{j : T_j \in I\}$, alors N_I suit une loi de Poisson de paramètre $\int_I f(x)dx$ et si $I_1, \dots, I_p$ sont p intervalles disjoints de $[0, D]$, alors $N_{I_1}, \dots, N_{I_p}$ sont des variables indépendantes.

On admettra les deux propriétés suivantes :

- Propriété 1 : N est une variable aléatoire de loi de Poisson de paramètre $m = \int_0^D f(x)dx$:

$$\mathbb{P}(N = n) = \frac{e^{-m} m^n}{n!}, \forall n \in \mathbb{N}.$$

- Propriété 2 : Pour $n \in \mathbb{N}^*$, conditionnellement à l'événement $N = n$, $T_1, \dots, T_N$ a même loi que la statistique d'ordre $(X_{(1)}, \dots, X_{(n)})$ d'un n -échantillon i.i.d. $X_1, \dots, X_n$ de densité $m^{-1} \times f$ par rapport à la mesure de Lebesgue.

On cherche à estimer la fonction f . Pour K un noyau et $h > 0$, on considère $\hat{f}$ l'estimateur de f défini pour tout $x \in [0, D]$ par, lorsque N est non nul,

$$\hat{f}(x) = \sum_{i=1}^N K_h(x - T_i), \quad \text{avec } K_h(u) = h^{-1} K(h^{-1}u) \text{ pour tout } u \in \mathbb{R}.$$

Si $N = 0$, on pose $\hat{f}(x) = 0$. Dans la suite, on notera $*$ le produit de convolution standard sur $\mathbb{R}$ entre deux fonctions.

1. Montrer que

$$\mathbb{E}[\hat{f}(x) | N = n] = \frac{n}{m} (K_h * f)(x), \forall x \in [0, D].$$

2. En utilisant la Propriété 1, en déduire que

$$\mathbb{E}[\hat{f}(x)] = (K_h * f)(x), \forall x \in [0, D].$$

3. Soit V et W deux variables aléatoires quelconques. Redémontrer la formule classique :

$$\text{var}(V) = \mathbb{E}[\text{var}(V|W)] + \text{var}(\mathbb{E}[V|W]).$$

4. Montrer que

$$\text{var}(\hat{f}(x)) = (K_h^2 * f)(x), \forall x \in [0, D].$$

5. On étudie à présent $R(\hat{f})$ le risque quadratique intégré de l'estimateur $\hat{f}$ en fonction du paramètre m . On pose ainsi

$$R(\hat{f}) = \mathbb{E}[\|\hat{f} - f\|_2^2]$$

où, pour toute fonction g ,

$$\|g\|_2^2 = \int_0^D g^2(x) dx$$

- a) Montrer que

$$R(\hat{f}) = \|K_h * f - f\|_2^2 + \int_0^D \text{var}(\hat{f}(x)) dx.$$

- b) Montrer que

$$\int_0^D \text{var}(\hat{f}(x)) dx \leq \frac{m}{h} \int_{-\infty}^{+\infty} K^2(u) du.$$

- c) On suppose que la densité $\tilde{f} = \frac{f}{m}$ est lipschitzienne : il existe une constante $L > 0$ telle que pour tous réels u et v

$$|\tilde{f}(u) - \tilde{f}(v)| \leq L|u - v| \quad (1)$$

Montrer que

$$\|K_h * f - f\|_2^2 \leq DL^2 \left(\int_{-\infty}^{+\infty} |K(v)| |v| dv \right)^2 (hm)^2.$$

- d) En déduire qu'il existe une valeur de h telle que

$$R(\hat{f}) \leq Cm^{4/3},$$

où C est une constante ne dépendant que de K , L et D .

- e) On suppose m connu et on cherche à estimer l'intensité renormalisée $\tilde{f}$ définie en 5.c). Quel estimateur proposeriez-vous ? Toujours sous l'hypothèse (1), déterminer la vitesse de convergence du risque quadratique intégré de cet estimateur de $\tilde{f}$ en fonction du paramètre m .

Exercice 2 : Tests (4.5 pts)

Partie A

On souhaite comparer la réussite scolaire des garçons et des filles. On dispose des observations d'un échantillon i.i.d. de notes de filles et d'un échantillon i.i.d. de notes de garçons. Ces deux échantillons sont supposés indépendants. On note $(X_i)_{1 \leq i \leq n_1}$ les variables aléatoires associées aux notes des filles et $(Y_i)_{1 \leq i \leq n_2}$ les variables aléatoires associées aux notes des garçons.

1. On décide de modéliser le problème en utilisant les moyennes μ_1 et μ_2 des deux lois. Énoncer le problème de test correspondant.

2. On suppose que les données sont gaussiennes $X_1, \dots, X_{n_1} \stackrel{iid}{\sim} \mathcal{N}(\mu_1, \sigma^2)$ et $Y_1, \dots, Y_{n_2} \stackrel{iid}{\sim} \mathcal{N}(\mu_2, \sigma^2)$. Quel test peut-on utiliser ? Rappeler sa définition (on ne demande pas la démonstration). On fera un test de niveau α .
3. On suppose dans cette question que les lois ne sont pas gaussiennes et qu'elles pourraient même avoir une variance infinie. Proposer une autre modélisation du problème et proposer un test correspondant.

Partie B

L'objectif de cet exercice est d'étudier la performance du test de Student à un seul échantillon quand il est effectué sur un échantillon non gaussien.

On suppose que l'on dispose d'un échantillon i.i.d. $(X_1, \dots, X_n)$ tel que $\mathbb{E}X_1^2 < \infty$. On note σ^2 la variance de X_1 et $\mu = \mathbb{E}X_1$. On veut tester $H_0 : \mu = 0$ contre $H_1 : \mu > 0$ au niveau α pour $\alpha \in (0, 1)$.

On appelle Φ le test de Student. On a donc $\Phi = \mathbf{1}_{T_n > q_{1-\alpha}^{T(n-1)}}$ où $q_{1-\alpha}^{T(n-1)}$ est le quantile d'ordre $1-\alpha$ de la loi de Student à $n-1$ degrés de liberté et $T_n = \frac{\sqrt{n}\bar{X}}{\hat{\sigma}}$ avec $\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$.

1. Montrer que, sous H_0 , T_n tend en loi vers la loi normale standard quand n tend vers l'infini.
2. Montrer que l'erreur de première espèce du test de Student appliqué à l'échantillon $(X_1, \dots, X_n)$ tend vers α quand n tend vers l'infini.
3. Montrer que la puissance du test tend simplement vers 1 quand n tend vers l'infini.

Exercice 3 : Quantiles (6 pts)

Soit $(F_n)_{n \geq 0}$ une suite de fonctions de répartition sur $\mathbb{R}$ et F une fonction de répartition sur $\mathbb{R}$. On note $F^{(-1)}$ et $F_n^{(-1)}$ les fonctions quantiles correspondantes. On veut prouver le résultat suivant : F_n converge vers F en tout point de continuité de F si et seulement si $F_n^{(-1)}$ converge vers $F^{(-1)}$ en tout point de continuité de $F^{(-1)}$.

On suppose d'abord que $F_n^{(-1)}$ converge vers $F^{(-1)}$ en tout point de continuité de $F^{(-1)}$.

1. Montrer que l'ensemble des points de discontinuité d'une fonction croissante est au plus dénombrable.

Aide : on remarquera pour cela qu'une fonction croissante est discontinue en $a \in \mathbb{R}$ si et seulement si $\lim_{x \rightarrow a^-} f(x) < \lim_{x \rightarrow a^+} f(x)$.

2. Soit $U \sim \mathcal{U}[0, 1]$. Montrer que $F_n^{-1}(U) \rightarrow F^{-1}(U)$ p.s.
3. Conclure que $F_n^{-1} \rightarrow F^{-1}$ en tout point de continuité de F^{-1} .

On suppose désormais que F_n converge vers F en tout point de continuité de F . Soit V une variable gaussienne standard et Φ sa fonction de répartition.

4. Montrer que $F_n(V) \rightarrow F(V)$ p.s..
5. Montrer que $\Phi(F_n^{-1}(t)) \rightarrow \Phi(F^{-1}(t))$ en tout point de continuité de F^{-1} .
6. Conclure.