

Introduction à la statistique non-paramétrique

EXAMEN – 30 Mai 2013 – Durée : 2h00

Documents, calculatrices, téléphones et smartphones interdits

Exercice 1 : Estimation non-paramétrique d'intensité Poissonienne

On s'intéresse aux arrivées des malades et des blessés dans un service d'urgences hospitalier sur une période donnée notée $[0, D]$ où D est une constante strictement positive. On note N le nombre d'arrivées pendant $[0, D]$ et $T_1, \dots, T_N$ les instants de ces arrivées. On modélise ces arrivées selon un *processus de Poisson d'intensité* f où f est une fonction positive intégrable et de support $[0, D]$. Cela signifie que si pour tout intervalle I , on note $N_I = \text{card}\{j : T_j \in I\}$, alors N_I suit une loi de Poisson de paramètre $\int_I f(x)dx$ et si $I_1, \dots, I_p$ sont p intervalles disjoints de $[0, D]$ alors $N_{I_1}, \dots, N_{I_p}$ sont des variables indépendantes.

On admettra les deux propriétés suivantes (la première étant évidente) :

Propriété 1 : N est une variable aléatoire de loi de Poisson de paramètre $m = \int_0^D f(x)dx$:

$$\mathbb{P}(N = n) = \exp(-m) \frac{m^n}{n!}, \quad \forall n \in \mathbb{N}.$$

Propriété 2 : Pour $n \in \mathbb{N}^*$, conditionnellement à l'événement $N = n$, $T_1, \dots, T_N$ a même loi qu'un n -échantillon $X_1, \dots, X_n$ de densité $m^{-1} \times f$.

On cherche à estimer la fonction f . Pour K un noyau et $h > 0$, on considère $\hat{f}$ l'estimateur de f défini pour tout $x \in [0, D]$ par

$$\hat{f}(x) = \sum_{i=1}^N K_h(x - T_i),$$

lorsque N est non nul avec $K_h(u) = h^{-1}K(h^{-1}u)$ pour tout $u \in \mathbb{R}$. Si $N = 0$, on pose $\hat{f}(x) = 0$. Dans la suite, on notera $\star$ le produit de convolution standard sur $\mathbb{R}$ entre 2 fonctions.

1. En utilisant la Propriété 2, montrer que

$$\mathbb{E}[\hat{f}(x)|N = n] = \frac{n}{m} \times (K_h \star f)(x), \quad \forall x \in [0, D].$$

2. En utilisant la Propriété 1, en déduire que

$$\mathbb{E}[\hat{f}(x)] = (K_h \star f)(x), \quad \forall x \in [0, D].$$

3. Soit V et W deux variables aléatoires quelconques. Redémontrer la formule classique :

$$\text{var}(V) = \mathbb{E}[\text{var}(V|W)] + \text{var}(\mathbb{E}[V|W]).$$

4. En appliquant cette formule avec $V = \hat{f}(x)$ et $W = N$, montrer alors que

$$\text{var}(\hat{f}(x)) = (K_h^2 \star f)(x), \quad \forall x \in [0, D].$$

5. On étudie à présent $R(\hat{f})$ le risque quadratique intégré de l'estimateur $\hat{f}$ en fonction du paramètre m .

- a) On pose ainsi

$$R(\hat{f}) = \mathbb{E}[\|\hat{f} - f\|_2^2]$$

où pour toute fonction g ,

$$\|g\|_2^2 = \int_0^D g^2(x) dx.$$

Montrer que

$$R(\hat{f}) = \|K_h \star f - f\|_2^2 + \int_0^D \text{var}(\hat{f}(x)) dx.$$

- b) Montrer que

$$\int_0^D \text{var}(\hat{f}(x)) dx \leq \int_{-\infty}^{+\infty} K^2(u) du \times \frac{m}{h}.$$

- c) On suppose que la densité $\tilde{f} = m^{-1}f$ est lipschitzienne : il existe une constante $L > 0$ telle que pour tous réels u et v

$$|\tilde{f}(u) - \tilde{f}(v)| \leq L|u - v|. \quad (1)$$

Montrer alors que

$$\|K_h \star f - f\|_2^2 \leq DL^2 \left(\int_{-\infty}^{+\infty} |K(v)| |v| dv \right)^2 \times (hm)^2.$$

- d) En déduire alors qu'il existe une valeur de h telle que

$$R(\hat{f}) \leq Cm^{\frac{4}{3}},$$

où C est une constante ne dépendant que de K , L et D .

6. On suppose m connu et on cherche à estimer l'intensité renormalisée $\tilde{f}$ définie en 5.c). Quel estimateur proposeriez-vous ? Toujours sous l'hypothèse (1), déterminer la vitesse de convergence du risque quadratique intégré de cet estimateur de $\tilde{f}$ en fonction du paramètre m .

Exercice 2 : test des suites de Wald-Wolfowitz

La question 6 peut être traitée indépendamment du reste de l'exercice.

On observe n variables aléatoires binaires identiquement distribuées $(X_1, \dots, X_n)$ à valeurs dans $\{0, 1\}$; on souhaite tester l'indépendance de ces variables. On note N_0 le nombre d'occurrences de la valeur 0 et N_1 le nombre d'occurrences de la valeur 1 :

$$N_0 = \sum_{i=1}^n \mathbb{I}_{X_i=0}; \quad N_1 = \sum_{i=1}^n \mathbb{I}_{X_i=1}; \quad N_0 + N_1 = n.$$

Au vu des observations $x_1, \dots, x_n$, on appelle *suite* un ensemble d'indices successifs $\{j, j+1, j+2, \dots, k\}$ tel que

- $x_j = x_{j+1} = \dots = x_k$
- si $j > 1$ alors $x_j \neq x_{j-1}$
- si $k < n$ alors $x_k \neq x_{k+1}$

et on note S le nombre de suites. Une suite correspond donc à un bloc d'observations successives qui prennent toutes la même valeur. Par exemple, pour les observations

1111001111100001

le nombre de suites est 5.

1. Montrer que si les (X_i) sont indépendantes alors la loi conditionnelle de S sachant N_0 et N_1 est libre de loi de X .
2. En déduire un test de H_0 : "les variables $(X_1, \dots, X_n)$ sont indépendantes". Ce test s'appelle test des suites de Wald-Wolfowitz.
3. *Application 1* : Sur les 30 jours du mois d'avril 2013, on a noté 1 si on a observé de la pluie à la station Saint-Germain-des-Prés à Paris, et 0 si on n'a pas observé de pluie. Les données collectées sont :

000110001111100001110000010001

soit 12 jours de pluie au total. A quel niveau rejetez-vous l'hypothèse d'indépendance ?

(Source des données : Météo Paris)

4. On se donne deux échantillons de variables aléatoires continues $Y_1, \dots, Y_m$ et $Z_1, \dots, Z_p$. On souhaite adapter le test de Wald-Wolfowitz pour tester l'hypothèse H_0 : " Y et Z proviennent de la même distribution". Pour cela, on note $W_1, \dots, W_{m+p}$ l'agrégation des deux échantillons (Y_i) et (Z_j) , et on ordonne les W_k . On note alors

$$X_k = \begin{cases} 0 & \text{si } \exists i : W_{(k)} = Y_i \\ 1 & \text{si } \exists j : W_{(k)} = Z_j \end{cases}$$

On construit la v.a. S comme précédemment. Justifier l'utilisation de S pour tester l'hypothèse H_0 .

5. *Application 2* : On souhaite comparer l'effet de deux somnifères, notés A et B. Pour ce faire, on fait appel à 17 cobayes. Chaque cobaye se voit administrer l'un des deux somnifères, et on mesure l'augmentation (ou la diminution) du temps de sommeil en heures par rapport à une nuit sans somnifère. Les observations sont :

Traitement A	-1.6	-1.2	-0.2	-0.1	0.0	0.7	2.0	3.4	3.7
Traitement B	0.1	0.8	1.1	1.6	1.9	4.4	4.6	5.5	

(Source des données : Cushny & Peebles 1905).

On souhaite tester l'hypothèse H_0 : "les deux traitements ont le même effet" à l'aide du test de Wald-Wolfowitz. Au niveau $\alpha = 0.05$, rejetez-vous H_0 ?

6. Répéter le test de la question précédente à l'aide d'un test vu en cours.

Tables statistiques

On donne ci-dessous la fonction de répartition pour :

- $S_{18,12}$, la statistique de Wald-Wolfowitz pour $N_0 = 18$ et $N_1 = 12$
- $S_{9,8}$, la statistique de Wald-Wolfowitz pour $N_0 = 9$ et $N_1 = 8$
- $W_{8,9}$, la statistique vue en cours pour tester que deux échantillons de tailles 8 et 9 sont identiquement distribués.

Rappelons que $P(W_{8,9} \leq x) = 1 - P(W_{8,9} \leq 71 - x)$.

x	$P(S_{18,12} \leq x)$	$P(S_{9,8} \leq x)$	$P(W_{8,9} \leq x)$
4	0.000	0.005	0.000
5	0.000	0.021	0.000
6	0.000	0.069	0.001
7	0.001	0.158	0.002
8	0.004	0.318	0.003
9	0.011	0.499	0.004
10	0.030	0.701	0.006
11	0.066	0.842	0.008
12	0.132	0.939	0.010
13	0.233	0.980	0.014
14	0.364	0.996	0.018
15	0.514	0.999	0.023
16	0.661	1	0.030
17	0.791	1	0.037
18	0.994	-	0.046
19	0.947	-	0.057
20	0.978	-	0.069
21	0.993	-	0.084
22	0.998	-	0.100
23	0.999	-	0.118
24	1	-	0.138
25	1	-	0.161
26	-	-	0.185
27	-	-	0.212
28	-	-	0.240
29	-	-	0.271
30	-	-	0.303
31	-	-	0.336
32	-	-	0.371
33	-	-	0.407
34	-	-	0.444
35	-	-	0.481
36	-	-	0.519