

Introduction à la statistique non-paramétrique
PARTIEL – 11 mars 2014 – Durée : 2h00

Documents, calculatrices, téléphones et smartphones interdits.

Le problème et les exercices sont indépendants.

Problème

On observe $X_1, \dots, X_n$ n variables réelles i.i.d. On note F la fonction de répartition associée à chacune des variables X_i . L'objectif du problème est d'estimer q_β le quantile d'ordre β de la loi de probabilité des X_i pour $\beta \in]0, 1[$. On rappelle la définition de q_β :

$$q_\beta = \inf\{x \in \mathbb{R} : F(x) \geq \beta\}.$$

On ordonne les variables X_i en posant

$$X^\star = (X^{(1)}, \dots, X^{(n)}),$$

avec

$$\{X^{(1)}, \dots, X^{(n)}\} = \{X_1, \dots, X_n\}, \quad X^{(1)} \leq X^{(2)} \leq \dots \leq X^{(n)}.$$

Pour estimer q_β , on propose

$$\hat{q}_{\beta,n} = X^{([n\beta])},$$

avec pour tout $u \in \mathbb{R}_+$,

$$[u] = \min\{m \in \mathbb{N} : m \geq u\}.$$

Partie A)

Soit $\varepsilon > 0$. On suppose que F est strictement croissante sur $[q_\beta - \varepsilon, q_\beta + \varepsilon]$.

1. On pose

$$d_\epsilon = \min\left(F(q_\beta + \epsilon) - \beta, \beta - F(q_\beta - \epsilon)\right).$$

Montrer que $d_\epsilon > 0$.

2. Montrer que

$$\sum_{i=1}^n \mathbf{1}_{X_i \leq q_\beta + \epsilon} < n\beta \quad \Longleftrightarrow \quad q_\beta + \epsilon < \hat{q}_{\beta,n}$$

3. Montrer que si $\hat{q}_{\beta,n} < q_\beta - \epsilon$ alors

$$\sum_{i=1}^n \mathbf{1}_{X_i \leq q_\beta - \epsilon} \geq n\beta.$$

4. En utilisant l'inégalité de Hoeffding, montrer alors que

$$\mathbb{P}(\hat{q}_{\beta,n} > q_\beta + \varepsilon) \leq \exp(-2n(F(q_\beta + \varepsilon) - \beta)^2).$$

On énoncera au préalable l'inégalité de Hoeffding sans omettre les hypothèses nécessaires à son application.

5. Montrer de la même manière que

$$\mathbb{P}(\hat{q}_{\beta,n} < q_{\beta} - \varepsilon) \leq \exp(-2n(\beta - F(q_{\beta} - \varepsilon))^2).$$

6. Montrer que

$$\mathbb{P}(|\hat{q}_{\beta,n} - q_{\beta}| > \varepsilon) \leq 2 \exp(-2nd_{\varepsilon}^2).$$

7. Montrer qu'il existe un ensemble Ω_{ε} tel que $\mathbb{P}(\Omega_{\varepsilon}) = 1$ et que sur Ω_{ε} il existe un entier n_0 tel que pour tout $n \geq n_0$,

$$|\hat{q}_{\beta,n} - q_{\beta}| \leq \varepsilon.$$

8. Finalement, démontrer soigneusement que si F est strictement croissante au voisinage de q_{β} , alors $\hat{q}_{\beta,n}$ converge presque sûrement vers q_{β} lorsque n tend vers l'infini.

Partie B)

Dans cette partie, on considère toujours $\beta \in]0, 1[$ connu et on cherche à construire un intervalle de confiance asymptotique pour q_{β} . Dans la suite, on suppose que la distribution des X_i dépend d'un paramètre θ inconnu. On suppose que cette distribution admet également une densité sur $\mathbb{R}$ que l'on note f_{θ} . On suppose que f_{θ} est strictement positive au voisinage de q_{β} . Dans la suite, on utilisera sans démonstration le résultat suivant :

$$\sqrt{n}(\hat{q}_{\beta,n} - q_{\beta}) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}\left(0, \frac{\beta(1-\beta)}{f_{\theta}^2(q_{\beta})}\right).$$

1. On suppose qu'il existe $\hat{\theta}_n$ un estimateur de θ tel que

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{} \theta \quad \text{en probabilité}$$

et on suppose que

$$(u, x) \mapsto f_u(x)$$

est continue au voisinage de (θ, q_{β}) .

(a) Montrer que

$$f_{\hat{\theta}_n}(\hat{q}_{\beta,n}) \xrightarrow[n \rightarrow +\infty]{} f_{\theta}(q_{\beta}) \quad \text{en probabilité.}$$

(b) Pour $\alpha \in]0, 1[$, en déduire un intervalle de confiance $I_{n,\alpha}$ pour q_{β} de niveau asymptotiquement égal à $1 - \alpha$.

2. On suppose que les variables X_i suivent une loi exponentielle de paramètre $\theta > 0$ inconnu.

(a) Pour $\alpha \in]0, 1[$, à l'aide de ce qui précède, proposer un intervalle de confiance pour q_{β} , dépendant de $\hat{q}_{\beta,n}$, de niveau asymptotiquement égal à $1 - \alpha$.

(b) Dans ce cas particulier, pouvez-vous proposer un autre intervalle de confiance pour q_{β} ne dépendant pas de $\hat{q}_{\beta,n}$?

Exercice 1

Une critique régulièrement émise envers l'industrie cinématographique est une préférence pour les actrices jeunes, alors que les acteurs masculins de tous âges peuvent avoir accès à des grands rôles. Afin de tester cette hypothèse, on note l'âge des premiers rôles masculin et féminin des 9 films en lice pour l'Oscar 2014 du meilleur film.

Age de l'acteur principal	40	57	44	52	39.2	77	48	36	39
Age de l'actrice principale	39.5	55	41.5	49	39.5	84	79	30	23

TABLE 1 – Dans l'ordre : *American Bluff*, *Capitaine Phillips*, *Dallas Buyers Club*, *Gravity*, *Her*, *Le Loup de Wall Street*, *Nebraska*, *Philomena*, *Twelve Years a Slave*

On cherche à savoir si les actrices sont plus jeunes que les acteurs dans les films américains à succès. On propose d'utiliser le test de Wilcoxon. On traite l'âge comme une variable continue.

1. Rappeler la définition des tests du signe et de Wilcoxon.
2. Expliquer pourquoi on utilise ici le test de Wilcoxon.
3. Enoncer l'hypothèse nulle et l'hypothèse alternative. Rappeler l'expression de la statistique de test W_9 et son espérance sous H_0 .
4. Calculer la p -valeur du test à l'aide de la table ci-dessous.

k	0	1	2	3	4	5	6	7	8	9
$\mathbb{P}[W_9 \leq k]$	0.0019	0.0039	0.0058	0.0097	0.0136	0.0195	0.0273	0.0371	0.0488	0.0644
k	10	11	12	13	14	15	16	17	18	19
$\mathbb{P}[W_9 \leq k]$	0.0820	0.1015	0.125	0.1503	0.1796	0.2128	0.2480	0.2851	0.3261	0.3671
k	20	21	22	23	24	25	26	27	28	29
$\mathbb{P}[W_9 \leq k]$	0.4101	0.4550	0.5	0.5449	0.5898	0.6328	0.6738	0.7148	0.7519	0.7871
k	30	31	32	33	34	35	36	37	38	39
$\mathbb{P}[W_9 \leq k]$	0.8203	0.8496	0.875	0.8984	0.9179	0.9355	0.9511	0.9628	0.9726	0.9804
k	40	41	42	43	44	45				
$\mathbb{P}[W_9 \leq k]$	0.9863	0.9902	0.9941	0.9960	0.9980	1				

Exercice 2

On considère un échantillon $X_1, \dots, X_n$ de variables iid réelles de loi diffuse, et $m \in \mathbb{R}$. On souhaite tester l'hypothèse H_0 : “la médiane de la loi des X_i est égale à m ”, contre l'hypothèse alternative H_1 : “la médiane de la loi des X_i est strictement inférieure à m ”. On considère la statistique de test

$$S = \sum_{i=1}^n \mathbf{1}_{\{X_i > m\}}.$$

1. Montrer que sous H_0 , la statistique S est libre en loi de X , et qu'on a alors $S \sim \text{Bin}(n, \frac{1}{2})$.
2. Le 11 janvier 2014, la vitesse maximale sur le périphérique parisien est passée de 80 km/h à 70 km/h. Un enseignant dauphinois s'interroge de l'impact de cette mesure sur son temps de trajet total en voiture depuis une ville de la banlieue Sud. Une longue série de données a permis de montrer qu'avec un périphérique limité à 80 km/h, le temps de trajet médian est de 38 min.

Suite au passage à une vitesse limitée à 70 km/h, il recueille un échantillon de $n = 23$ temps de trajet en minutes :

26 29 31 26 32 29 37 37 29 37 30 47 41 37 45 35 35 36 32 30 43 30 35.

Ayant le sentiment que son temps de trajet a diminué, il souhaite tester l'hypothèse nulle que ces observations sont des réalisations d'une loi dont la médiane est toujours de 38 minutes, contre l'hypothèse alternative que la médiane est moindre. Calculer la p -valeur du test à l'aide de la table ci-dessous.

k	3	4	5	6	7	8	9	10	11	12
$\mathbb{P}[S \leq k]$	0.0002	0.0013	0.0053	0.0173	0.0466	0.105	0.2024	0.3388	0.5	0.6612
k	13	14	15	16	17	18	19	20	21	22
$\mathbb{P}[S \leq k]$	0.7976	0.895	0.9534	0.9827	0.9947	0.9987	0.9998	1	1	1

Source des données : Waze.