

Introduction à la statistique non-paramétrique

PARTIEL – 26 mars 2015 – Durée : 2h00

Documents, calculatrices, téléphones et smartphones interdits

Exercice 1 : On considère un n -échantillon $(X_1, \dots, X_n)$. On note F la fonction de répartition et F_n la fonction de répartition empirique associées à cet échantillon. Soient x et y deux réels tels que $x \leq y$. Calculer $\text{Cov}(F_n(x), F_n(y))$, la covariance de $F_n(x)$ et de $F_n(y)$ en fonction de n , $F(x)$ et $F(y)$.

Exercice 2 : L'objectif est de démontrer le théorème de Glivenko Cantelli. On n'utilisera donc pas ce résultat dans la suite. On considère un n -échantillon $(X_1, \dots, X_n)$. On note F la fonction de répartition et F_n la fonction de répartition empirique associées à cet échantillon. On définit pour tout $y \in]0, 1[$,

$$F^{(-1)}(y) = \inf \{u \in \mathbb{R} : F(u) \geq y\}.$$

On pose pour tout $x \in \mathbb{R}$,

$$F(x^-) = \lim_{u \rightarrow x, u < x} F(u) = \mathbb{P}(X_1 < x)$$

et

$$F_n(x^-) = \frac{1}{n} \sum_{i=1}^n 1_{X_i < x}.$$

Pour $m \geq 2$, on note

$$M_{m,n} = \max_{k \in \{1, \dots, m-1\}} \left\{ \max \left\{ |F_n(x_{k,m}) - F(x_{k,m})|, |F_n(x_{k,m}^-) - F(x_{k,m}^-)| \right\} \right\},$$

où pour tout $k \in \{1, \dots, m-1\}$, $x_{k,m} = F^{(-1)}(k/m)$.

1. Soit $m \geq 2$ fixé. Soit $k \in \{1, \dots, m-1\}$ fixé également.
 - a) En utilisant la loi forte des grands nombres, montrer que

$$\lim_{n \rightarrow +\infty} F_n(x_{k,m}) = F(x_{k,m}) \quad \text{presque sûrement.}$$

- b) En utilisant les mêmes arguments, montrer soigneusement que

$$\lim_{n \rightarrow +\infty} F_n(x_{k,m}^-) = F(x_{k,m}^-) \quad \text{presque sûrement.}$$

2. Pour tout $m \geq 2$, déduire de la question précédente qu'il existe un ensemble A_m tel que $\mathbb{P}(A_m) = 1$ et sur A_m ,

$$\lim_{n \rightarrow +\infty} M_{m,n} = 0.$$

3. Soit $k \in \{2, \dots, m-1\}$ et $x \in [x_{k-1,m}; x_{k,m}[$ fixés.

a) Montrer que

$$F(x_{k-1,m}) - M_{m,n} \leq F_n(x) \leq F(x_{k,m}^-) + M_{m,n}$$

b) Redémontrer la propriété vue en cours : pour tout $y \in]0; 1[$

$$F\left(F^{(-1)}(y)\right) \geq y.$$

c) En déduire que

$$F(x_{k-1,m}) - F(x) \geq -\frac{1}{m} \quad \text{et} \quad F(x_{k,m}^-) - F(x) \leq \frac{1}{m}.$$

4. Déduire finalement que pour tout $x \in [x_{1,m}; x_{m-1,m}[$,

$$|F_n(x) - F(x)| \leq \frac{1}{m} + M_{m,n}.$$

On admettra que cette inégalité reste valable lorsque $x < x_{1,m}$ et $x \geq x_{m-1,m}$.

5. Enoncer et démontrer alors le théorème de Glivenko-Cantelli.

Exercice 3 : On a mesuré le rythme des battements cardiaques de 9 sujets pris au hasard parmi les étudiants se présentant spontanément au camion de centre de transfusion sanguine pour faire un don du sang. Après le don du sang, les étudiants prennent une collation sur place. L'infirmière en profite pour leur mesurer leur rythme cardiaque. Les résultats sont les suivants exprimés en nombre de battements cardiaques par minute.

Sujet	1	2	3	4	5	6	7	8	9
Mesure avant le don du sang	78	101	77	75	92	77	64	87	65
Mesure après le don du sang	84	80	67	72	79	76	66	80	61

Déterminer à l'aide du test de Wilcoxon et de la table ci-dessous l'influence du don du sang sur le battement cardiaque des étudiants. Au préalable, on formulera clairement les hypothèses nulle et alternative testées.

k	0	1	2	3	4	5	6	7	8	9
$P[W_9 \leq k]$	0.0019	0.0039	0.0058	0.0097	0.0136	0.0195	0.0273	0.0371	0.0488	0.0644
k	10	11	12	13	14	15	16	17	18	19
$P[W_9 \leq k]$	0.0820	0.1015	0.125	0.1503	0.1796	0.2128	0.2480	0.2851	0.3261	0.3671
k	20	21	22	23	24	25	26	27	28	29
$P[W_9 \leq k]$	0.4101	0.4550	0.5	0.5449	0.5898	0.6328	0.6738	0.7148	0.7519	0.7871
k	30	31	32	33	34	35	36	37	38	39
$P[W_9 \leq k]$	0.8203	0.8496	0.875	0.8984	0.9179	0.9355	0.9511	0.9628	0.9726	0.9804
k	40	41	42	43	44	45				
$P[W_9 \leq k]$	0.9863	0.9902	0.9941	0.9960	0.9980	1				