

Introduction à la statistique non-paramétrique

Partiel – 2019 – Durée : 2h00

Une demi page A4 manuscrite autorisée

Le barème est indicatif

Avec trois étoiles : les exercices ou questions plus difficiles.

Exercice 1 : (4pts)

Une marque crée un nouveau parfum et, avant de le lancer sur le marché, souhaite savoir si ce nouveau parfum est vraiment meilleur que l'ancien. Pour cela, elle dispose d'un échantillon aléatoire de 100 individus indépendants qui testent les deux produits. Le résultat est le suivant : sur les 100 individus, 58 ont préféré le nouveau parfum.

1. Formuler l'hypothèse nulle et l'alternative.
2. Quel test utiliser ici ?
3. Donner la p-valeur observée et tester au niveau 5%

Ci-dessous les valeurs de $F(x)$ pour quelques valeurs de x , où F est la fonction de répartition de la loi binomiale de paramètres 100 et $1/2$.

x	41	42	43	57	58	59
F(x)	0.04	0.07	0.10	0.93	0.96	0.97

Exercice 2 (6.5pts)

1. On observe deux échantillons iid $X_1^n = (X_1, \dots, X_n)$ et $Y_1^m = (Y_1, \dots, Y_m)$, qui sont aussi indépendants entre eux, de tailles respectives n et m et de fonctions de répartition respectives F et G . On veut tester l'hypothèse $H_0 : F = G$ contre l'alternative $H_1 : \exists t \in \mathbb{R}$ tel que $F(t) < G(t)$.
 - (a) En vous appuyant sur $\hat{F}_n$ et $\hat{G}_m$, les fonctions de répartition empiriques calculées respectivement à partir des échantillons X_1^n et Y_1^m , proposer une statistique de test (0.5pts) qui soit
 - i. adaptée au problème posé (i.e. comportement différent sous H_0 et sous H_1) (1pts)
 - ii. libre de la loi des observations sous H_0 lorsque les fonctions de répartition sont continues. (2pts)
 - (b) En déduire un test de niveau α de l'hypothèse H_0 contre l'alternative H_1 en le justifiant. (1pt)
2. On observe un échantillon iid X_1^n de loi de fonction de répartition F continue.
 - (a) On veut savoir si cet échantillon suit une loi donnée de fonction de répartition F_0 continue. On veut donc tester $H_0 : F = F_0$ contre $H_1 : F \neq F_0$. Rappeler le test que l'on fait. (0.5pt)
 - (b) ***On effectue ce test sur un échantillon de loi F_0 . Quelle est la probabilité que la p-valeur observée soit plus petite ou égale à 5% ? (1,5pts)

Exercice 3 : (5pts) On observe $X_1, \dots, X_n$ n variables réelles i.i.d. On note F la fonction de répartition associée à chacune des variables X_i . L'objectif de fournir un intervalle de confiance asymptotique pour q_β , le quantile d'ordre β de la loi des X_i , où $\beta \in]0, 1[$. Dans la suite, on suppose que la loi des X_i dépend d'un paramètre θ inconnu. On suppose que cette distribution admet également une densité sur $\mathbb{R}$, que l'on note f_θ . On suppose que f_θ est strictement positive et continue au voisinage de q_β . On rappelle que, sous ces conditions,

$$\sqrt{n}(\hat{q}_{n,\beta} - q_\beta) \xrightarrow{\text{Loi}} \mathcal{N}\left(0, \frac{\beta(1-\beta)}{f_\theta^2(q_\beta)}\right).$$

1. On suppose qu'il existe $\hat{\theta}_n$ un estimateur de θ tel que

$$\hat{\theta}_n \xrightarrow{n \rightarrow \infty} \theta \quad \text{en probabilité}$$

et on suppose que

$$(u, x) \mapsto f_u(x)$$

est continue au voisinage de (θ, q_β) .

- (a) Montrer que (1pt)

$$f_{\hat{\theta}_n}(\hat{q}_{\beta,n}) \xrightarrow{n \rightarrow \infty} f_\theta(q_\beta) \quad \text{en probabilité}$$

- (b) Pour $\alpha \in]0, 1[$, à l'aide de ce qui précède, proposer un intervalle de confiance pour q_β , dépendant de $\hat{q}_{\beta,n}$, de niveau asymptotiquement égal à $1 - \alpha$. (1.5pts)
2. On suppose que les variables X_i suivent une loi exponentielle de paramètre $\theta > 0$ inconnu.
 - (a) Pour $\alpha \in]0, 1[$, à l'aide de ce qui précède, proposer un intervalle de confiance asymptotique pour q_β , dépendant de $\hat{q}_{\beta,n}$, de niveau égal à $1 - \alpha$. (1pt)
 - (b) Dans ce cas particulier, pouvez-vous proposer un autre intervalle de confiance pour q_β ne dépendant pas de $\hat{q}_{\beta,n}$? (1.5pts)

Exercice 4 * :** (5pts) On souhaite établir que l'hypothèse de continuité est essentielle pour l'établissement de la formule

$$\|\hat{F}_n - F_0\|_\infty = \max_{1 \leq j \leq n} \left\{ \max \left\{ \frac{j}{n} - F_0(X_{(j)}); F_0(X_{(j)}) - \frac{j-1}{n} \right\} \right\} \quad (1)$$

vue en cours. Pour cela, on considère $(X_1, \dots, X_n)$ un n -échantillon iid de loi de Bernoulli de paramètre $1/2$. On note F_0 la fonction de répartition de chaque X_i .

1. Calculer $F_0(x)$ pour tout $x \in \mathbb{R}$. (0.5pt)
2. Montrer qu'il existe Ω tel que $\mathbb{P}(\Omega) = 1$ et sur Ω ,

$$\|\hat{F}_n - F_0\|_\infty \rightarrow 0$$

quand n tend vers $+\infty$. (0.5pt)

3. Montrer qu'il existe $\Omega' \subset \Omega$ tel que $\mathbb{P}(\Omega') = 1$ et sur Ω' , il existe n_0 (aléatoire, « $n_0 = n_0(\omega)$ ») tel que pour tout $n \geq n_0$,

$$\sum_{i=1}^n X_i < \frac{3n}{4}.$$

En déduire alors que si p_n est la partie entière de $n/4$, on a : $X_{(p_n)} = 0$ si $n \geq n_0$ (2pts)

4. En calculant $F_0(X_{(p_n)}) - \frac{p_n-1}{n}$, montrer que sur Ω' , (1) n'est pas vraie pour n assez grand. (2pts)