

Introduction à la statistique non-paramétrique

PARTIEL – 17 mars 2016 – Durée : 2h00

Documents, calculatrices, téléphones et smartphones interdits

Exercice 1 : Soit $X = (X_1, \dots, X_n)$ un n -échantillon. Pour tout $x \in \mathbb{R}$, on note

$$F(x) = \mathbb{P}(X_1 \leq x)$$

la fonction de répartition des variables et

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}},$$

leur fonction de répartition empirique. On suppose que F est continue et que $F(x) \in]0, 1[$ pour tout $x \in \mathbb{R}$. Soit $x_0 \in \mathbb{R}$ fixé.

1. Étudier la convergence en loi de $\sqrt{n}(F_n(x_0) - F(x_0))$. Soit

$$U_n = \frac{\sqrt{n}(F_n(x_0) - F(x_0))}{\sqrt{F_n(x_0)(1 - F_n(x_0))}} \mathbf{1}_{\{0 < F_n(x_0) < 1\}} \quad (\text{avec la convention } 0/0 = 0).$$

Montrer que U_n converge en loi vers la distribution gaussienne centrée réduite. En déduire un intervalle de confiance de niveau asymptotiquement égal à $1 - \alpha$ pour $F(x_0)$.

2. Soit $U_1, \dots, U_n$ une suite de variables uniformes sur $[0, 1]$ et, pour tout $\alpha \in [0, 1]$, $\xi_{n,\alpha}$ le quantile d'ordre α de la loi de $h_n = \sup_{t \in [0,1]} \left| \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{U_i \leq t\}} - t \right|$. Montrer que

$$B(n, \alpha) = \{H \text{ fonction de répartition telle que } \forall x \in \mathbb{R}, \\ F_n(x) - \xi_{n,1-\alpha} \leq H(x) \leq F_n(x) + \xi_{n,1-\alpha}\},$$

est une bande de confiance de niveau $1 - \alpha$ pour F .

3. Nous nous intéressons à une étude des paramètres morphologiques d'une espèce de crabes existant sous deux couleurs différentes (orange et bleue). Nous disposons de la mesure de la dimension du lobe frontal (en mm) de crabes dans le tableau 1.

Crabes bleus	11.9	11.8	11.6	9.7	8.2	11.2
Crabes oranges	13.7	17.6	19.1	17.5	21.3	

TABLE 1 – Dimension du lobe frontal (en mm).

Nous notons F (resp. G) la fonction de répartition de la dimension du lobe frontal des crabes bleus (resp. oranges).

- (a) Tracer sur le même graphique les fonctions de répartition empiriques F_n et G_p (n : nombre de crabes bleus et p : nombre de crabes oranges) des dimensions des lobes frontaux des crabes bleus et oranges.
- (b) Calculer un intervalle de confiance asymptotique à 95% pour $F(x_0)$ et $G(x_0)$ avec $x_0 = 11$ mm (on rappelle que la quantile d'ordre 0.975 de la loi $\mathcal{N}(0, 1)$ est à peu près égal à 1.96). Commenter.
- (c) Ajouter sur le graphique de la question (a) les frontières des bandes de confiance à 95% pour F et G sachant que $\xi_{5,0.05} = 0.56$ et $\xi_{6,0.05} = 0.52$.
- (d) On souhaite savoir si les dimensions des lobes frontaux des crabes bleus et oranges sont différentes. Écrire les hypothèses nulle et alternative du test de Kolmogorov-Smirnov. Quelle est la valeur de la statistique de ce test pour les données du tableau 1 ? Quelle autre procédure de test peut-on mettre en œuvre ?

Exercice 2 : On dit qu'une variable aléatoire V suit la loi de Pareto de paramètres $(m, \alpha) \in \mathbb{R}_+^* \times \mathbb{R}_+^*$ si la densité de la loi de V par rapport à la mesure de Lebesgue, notée $f_{m,\alpha}$, satisfait pour tout $x \in \mathbb{R}$,

$$f_{m,\alpha}(x) = \alpha m^\alpha x^{-\alpha-1} 1_{x \geq m}.$$

On observe $Z = (Z_1, \dots, Z_n)$ un n -échantillon de loi de Pareto de paramètres $(m, 1)$.

1. Déterminer $\hat{m}$ l'estimateur du maximum de vraisemblance de $m \in \mathbb{R}_+^*$.
2. Quelle est la loi de l'échantillon $m^{-1}Z = (m^{-1}Z_1, \dots, m^{-1}Z_n)$?
3. On considère la statistique de test suivante :

$$\tilde{h}_n(Z) = \sup_{t \geq \hat{m}} \left| \frac{1}{n} \sum_{i=1}^n 1_{Z_i > t} - \left(\frac{t}{\hat{m}} \right)^{-1} \right|.$$

Montrer que si la loi des Z_i appartient à $\mathcal{F}_1$, la famille des distributions de Pareto de paramètres m et 1 pour $m \in \mathbb{R}_+^*$, alors la statistique $\tilde{h}_n(Z)$ ne dépend pas du paramètre de la loi sous-jacente.

4. Proposer un test pour tester si la distribution d'une suite i.i.d. d'observations appartient à $\mathcal{F}_1$ (donner la définition précise de ce test et justifier votre réponse).

Exercice 3 : Soit n un entier naturel supérieur ou égal à 2. On considère n variables aléatoires indépendantes et identiquement distribuées $X_1, \dots, X_n$. On suppose que pour tout $(i, j) \in \{1, \dots, n\}^2$ avec $i \neq j$, $\mathbb{P}(X_i = X_j) = 0$. On considère $R_X = (R_X(1), \dots, R_X(n))$ le vecteur des rangs associé à ces variables. Dans cet exercice, on pourra utiliser sans démonstration que

$$\sum_{k=1}^n k = \frac{n(n+1)}{2} \quad \text{et} \quad \sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}.$$

1. Questions de cours :
 - (a) Rappeler la définition de R_X et rappeler (sans forcément donner la démonstration) pour tout $i \in \{1, \dots, n\}$ les valeurs de $\mathbb{E}(R_X(i))$ et de $\text{var}(R_X(i))$.

- (b) Calculer la valeur de $\mathbb{P}(R_X(i) = k, R_X(j) = l)$ pour tout $(i, j) \in \{1, \dots, n\}^2$ avec $i \neq j$ et pour tout $(k, l) \in \{1, \dots, n\}^2$.
- (c) Montrer par le calcul que $\text{cov}(R_X(i), R_X(j)) = -\frac{n+1}{12}$ pour tout $(i, j) \in \{1, \dots, n\}^2$ avec $i \neq j$.

2. On étudie à présent la variable

$$S(R_X) = \sum_{i=1}^n (R_X(i) - i)^2.$$

Montrer que

$$S(R_X) = \frac{n(n+1)(2n+1)}{3} - 2 \sum_{i=1}^n i R_X(i)$$

et en déduire que

$$\mathbb{E}[S(R_X)] = \frac{n^3 - n}{6} \quad \text{et} \quad \text{var}(S(R_X)) = \frac{n^2(n+1)^2(n-1)}{36}.$$

3. On introduit deux n -échantillons de variables aléatoires $U_1, \dots, U_n$ et $V_1, \dots, V_n$. On suppose que pour tout $(i, j) \in \{1, \dots, n\}^2$ avec $i \neq j$, $\mathbb{P}(U_i = U_j) = \mathbb{P}(V_i = V_j) = 0$. On considère R_U et R_V les vecteurs des rangs associés à ces échantillons. Enfin, on introduit le coefficient de Spearman associé aux échantillons $U_1, \dots, U_n$ et $V_1, \dots, V_n$:

$$\Delta_n(U, V) = \frac{\text{covemp}(R_U, R_V)}{\sqrt{\text{varemp}(R_U) \text{varemp}(R_V)}},$$

avec

$$\text{covemp}(R_U, R_V) = \frac{1}{n} \sum_{i=1}^n R_U(i) R_V(i) - \overline{R_U} \overline{R_V}, \quad \overline{R_U} = \frac{1}{n} \sum_{i=1}^n R_U(i), \quad \overline{R_V} = \frac{1}{n} \sum_{i=1}^n R_V(i)$$

et

$$\text{varemp}(R_U) = \text{covemp}(R_U, R_U), \quad \text{varemp}(R_V) = \text{covemp}(R_V, R_V).$$

Montrer que

$$\Delta_n(U, V) = 1 - \frac{6 \sum_{i=1}^n (R_U(i) - R_V(i))^2}{n(n^2 - 1)} \in [-1, 1].$$

4. On suppose que $R_V \circ R_U^{-1}$ a même loi que R_X . Montrer que $\Delta_n(U, V)$ est alors d'espérance nulle et déterminer sa variance.
5. On souhaite étudier un lien éventuel entre les variables U_i et V_i . En utilisant $\Delta_n(U, V)$, comment procéderiez-vous ?