

Choisir le bon test

- 1 éch. ou appariées, seulement $+/-$: signe.
- Appariées, différences numériques : Wilcoxon signé.
- 2 éch. indépendants, ordre/position : Mann–Whitney.
- Gaussien/moyennes : Student ou Welch.

Règles réflexes. Apparié $\Rightarrow$ travailler sur $D_i = V_i - U_i$. Retirer les zéros si un test de signe/rangs signés le demande. Alternatives : si $D_i > 0$ signifie “V plus grand”, rejeter pour grande statistique positive.

Test du signe

Hypothèses. X_i indépendantes, médiane commune m , $\mathbb{P}(X_i = m) = 0$. Pas besoin d’iid ni de moments.

Statistique.

$$S = \sum_{i=1}^n \mathbf{1}_{\{X_i > 0\}}, \quad H_0 : m = 0 \Rightarrow S \sim \mathcal{B}(n, 1/2).$$

Décisions.

$H_1 : m > 0$	: S grand,
$H_1 : m < 0$	: S petit,
$H_1 : m \neq 0$	: $ S - n/2 $ grand.

P-valeurs exactes. Si F_B est la cdf de $\mathcal{B}(n, 1/2)$ et s l’observation :

$$p_{>} = 1 - F_B(s - 1), \quad p_{<} = F_B(s), \quad p_{\neq} \simeq 2 \min(p_{>}, p_{<}).$$

Piège. Le test du signe teste une médiane/préférence appariée ; ce n’est pas un test d’homogénéité de lois.

Wilcoxon des rangs signés

Quand. Données appariées quantitatives, $X_i = D_i$. Plus puissant que le signe si la symétrie est plausible.

Hypothèses. X_i indépendantes, diffuses, médiane commune m , lois symétriques autour de m . Sous continuité : pas d’ex-aequo dans $|X_i|$ p.s.

Rangs.

$$W_n^+ = \sum_i R_{|X|}(i) \mathbf{1}_{\{X_i > 0\}},$$
$$W_n^- = \sum_i R_{|X|}(i) \mathbf{1}_{\{X_i < 0\}},$$
$$W_n^+ + W_n^- = \frac{n(n+1)}{2}.$$

Sous $H_0 : m = 0$.

$$W_n^+ \sim \sum_{k=1}^n k Y_k, \quad Y_k \stackrel{\text{iid}}{\sim} \mathcal{B}(1/2),$$
$$\mathbb{E} W_n^+ = \frac{n(n+1)}{4}, \quad \text{Var}(W_n^+) = \frac{n(n+1)(2n+1)}{24}.$$
$$Z = \frac{W_n^+ - \mathbb{E} W_n^+}{\sqrt{\text{Var}(W_n^+)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Décisions.

$H_1 : m > 0$: W_n^+ grand; $H_1 : m < 0$: W_n^+ petit;

$H_1 : m \neq 0$: $\left| W_n^+ - \frac{n(n+1)}{4} \right|$ grand.

Exact si $n \leq 20$; sinon approximation normale. Avec ties/zéros : attention, p-valeur exacte souvent invalide.

Mann–Whitney / rang-somme

Cadre. $U_1, \dots, U_n \stackrel{\text{iid}}{\sim} F$, $V_1, \dots, V_p \stackrel{\text{iid}}{\sim} G$, échantillons indépendants, lois diffuses. $H_0 : F = G$. Alternative surtout : décalage/ordre stochastique, pas tout $F \neq G$.

Rangs globaux. Regrouper U, V , rangs R_i pour U_i , S_j pour V_j .

$$\Sigma_U = \sum_i R_i, \quad \Sigma_V = \sum_j S_j,$$
$$M_U = \Sigma_U - \frac{n(n+1)}{2}, \quad M_V = \Sigma_V - \frac{p(p+1)}{2}.$$

$M_U + M_V = np, \quad M_U \sim M_V \quad (H_0).$

Interprétation. $M_V = \#\{(i, j) : U_i < V_j\}$. Si les V tendent plus petits, M_V petit et M_U grand.

Sous H_0 .

$$\mathbb{E}(M_U) = \frac{np}{2}, \quad \text{Var}(M_U) = \frac{np(n+p+1)}{12}.$$
$$Z = \frac{M_U - np/2}{\sqrt{np(n+p+1)/12}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Correction de continuité. Pour $P(T \geq a)$, utiliser $a - 0.5$. Pour $P(T \leq a)$, utiliser $a + 0.5$.

P-valeurs discrètes et tables

Queue droite. Pour statistique entière T , observation t , cdf F :

$$\mathbb{P}(T \geq t) = 1 - F(t - 1).$$

Queue gauche.

$$\mathbb{P}(T \leq t) = F(t).$$

Symétrie MW.

$$M_U + M_V = np, \quad \mathbb{P}(M_U \geq a) = \mathbb{P}(M_V \leq np - a)$$

en adaptant strict/large selon la table. Toujours noter le sens de l’alternative avant de choisir la queue.

Calcul des rangs

Calcul pratique. Pour des valeurs sans ex-aequo $x_1, \dots, x_n$:

$$R_X(i) = 1 + \sum_{j \neq i} \mathbf{1}_{\{x_j < x_i\}}.$$

Le plus petit a rang 1. Ex-aequo : remplacer les rangs occupés par leur moyenne ; ex. $(2, 4, 4, 7) \mapsto (1, 2.5, 2.5, 4)$.

Ex. Wilcoxon signé. Calculer sur $|x_i|$, pas sur x_i :

$\begin{matrix} x_i \\ x_i \\ R_{ X }(i) \end{matrix}$	$\left \begin{array}{cccccc} -0.15 & -0.42 & 0.22 & 0.60 & -0.10 \\ 0.15 & 0.42 & 0.22 & 0.60 & 0.10 \\ 2 & 4 & 3 & 5 & 1 \end{array} \right.$
--	---

$w_n^+ = 3 + 5 = 8, \quad w_n^- = 2 + 4 + 1 = 7.$

Méthode : trier $|x_i|$, donner les rangs, puis sommer selon le signe de x_i .

Formule Wilcoxon. Retirer $d_i = 0$, puis

$$R_{|D|}(i) = 1 + \sum_{j \neq i} \mathbf{1}_{\{|d_j| < |d_i|\}}.$$
$$W^+ = \sum_i R_{|D|}(i) \mathbf{1}_{\{d_i > 0\}}.$$

Ex. Mann–Whitney.

$$u = (3.5, 4.7, 1.2), \quad v = (0.7, 3.9).$$

Ordre global :

$$v_1 < u_3 < u_1 < v_2 < u_2.$$

Donc

$$r_1 = 3, \quad r_2 = 5, \quad r_3 = 2, \quad s_1 = 1, \quad s_2 = 4.$$

Ici r_i = rang de u_i , s_j = rang de v_j , dans le mélange u, v .

Formule MW. Sur l’échantillon global $Z = (U_1, \dots, U_n, V_1, \dots, V_p)$.

$$R_i = 1 + \sum_k \mathbf{1}_{\{Z_k < U_i\}}, \quad S_j = 1 + \sum_k \mathbf{1}_{\{Z_k < V_j\}}.$$

Puis $\Sigma_U = \sum_i R_i$, $\Sigma_V = \sum_j S_j$.

KS / adéquation : vocabulaire

Adéquation à une loi donnée F_0 .

$$D_n = \sup_x |\widehat{F}_n(x) - F_0(x)|.$$

Homogénéité deux échantillons.

$$D_{n,p} = \sup_x |\widehat{F}_n(x) - \widehat{G}_p(x)|.$$

KS détecte tout changement de loi ; MW vise surtout position/ordre. χ^2 : classes/discret, asymptotique. Ne pas confondre “loi donnée” et “famille avec paramètre estimé”.

Exemples corrigés tests

1. Annale 2016 : Mann–Whitney.

Pneus $A = (26, 49, 52, 80, 102, 106, 115, 121, 135)$.

$$B = (47, 58, 64, 91, 94, 109, 116, 132, 179).$$

Question : le modèle B parcourt-il plus de km avant usure que A ?

$$H_0 : F_A = F_B, \quad H_1 : B \text{ tend plus grand que } A.$$

Ordre global :

z	26	47	49	52	58	64	80	91	94
g	A	B	A	A	B	B	A	B	B
r	1	2	3	4	5	6	7	8	9

z	102	106	109	115	116
g	A	A	B	A	B
r	10	11	12	13	14

z	121	132	135	179
g	A	B	A	B
r	15	16	17	18

Donc

$$\Sigma_A = 1 + 3 + 4 + 7 + 10 + 11 + 13 + 15 + 17 = 81,$$
$$\Sigma_B = 2 + 5 + 6 + 8 + 9 + 12 + 14 + 16 + 18 = 90.$$
$$M_A = 81 - \frac{9 \cdot 10}{2} = 36, \quad M_B = 90 - \frac{9 \cdot 10}{2} = 45.$$

Vérif : $M_A + M_B = 81 = np$. Si $B > A$, rejeter pour M_A petit (ou M_B grand). Table $n = p = 9$, niveau 2.5% : région gauche $M_A \leq 17$. Or $36 > 17$, donc pas de rejet : pas assez de preuve que B dure plus.

2. Annale Partiel 2015 : Wilcoxon. Rythme cardiaque avant/après don. Prendre D = après – avant :

i	1	2	3	4	5
D_i	6	−21	−10	−3	−13
$ D_i $	6	21	10	3	13
R	5	9	7	3	8

i	6	7	8	9
D_i	−1	2	−7	−4
$ D_i $	1	2	7	4
R	1	2	6	4

$$W^+ = 5 + 2 = 7, \quad W^- = 9 + 7 + 3 + 8 + 1 + 6 + 4 = 38.$$

Vérif :

$$W^+ + W^- = \frac{9 \cdot 10}{2} = 45.$$

Si H_1 : le rythme après est plus faible, rejeter pour W^+ petit. Table : $P(W_9 \leq 7) \simeq 0.037$, donc rejet à 5% mais pas à 2.5%. Si H_1 bi-latérale : $p \simeq 2P(W_9 \leq 7) \simeq 0.074$, donc pas de rejet à 5%.

Preuves rapides. Signe : $m = 0 \Rightarrow \mathbb{P}(X_i > 0) = 1/2$. Wilcoxon : symétrie $\Rightarrow$ signes iid conditionnellement aux $|X_i|$. MW : sous H_0 , les rangs globaux forment une permutation uniforme.

Estimation de densité : KDE
Noyau.

$$K \in L^1(\mathbb{R}), \quad \int_{\mathbb{R}} K(u) \, du = 1.$$

Si $K \geq 0$, l'estimateur est une densité. Exemples : uniforme, triangulaire, Epanechnikov, biweight, gaussien. Parzen-Rosenblatt.

$$\widehat{f}_{n,h}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right) = \frac{1}{n} \sum_i K_h(x - X_i),$$

$$K_h(u) = h^{-1} K(u/h).$$

Fenêtre. h petit : biais faible, variance forte, estimateur ondulant. h grand : lissage fort, variance faible, biais fort. Le choix de h compte plus que le choix de K .
Risque KDE ponctuel
Espérance.

$$\mathbb{E} \widehat{f}_{n,h}(x_0) = \int K(v) f(x_0 - hv) \, dv = (K_h * f)(x_0).$$

Décomposition.

$$\mathbb{E}(f(x_0) - f(x_0))^2 = (\mathbb{E} \widehat{f}(x_0) - f(x_0))^2 + \text{Var}(\widehat{f}(x_0)).$$

Ordre du noyau.

$$K \text{ d'ordre } \ell \iff \int u^j K(u) \, du = 0, \quad j = 1, \dots, \ell.$$

Biais Holder. Si $f \in \Sigma(\beta, L)$, $\ell = \lfloor \beta \rfloor$, $\int |u|^\beta |K(u)| \, du < \infty$:

$$\left| \mathbb{E} \widehat{f}_{n,h}(x_0) - f(x_0) \right| \leq C_B h^\beta.$$

Variance.

$$\text{Var}(\widehat{f}_{n,h}(x_0)) \leq \frac{\|f\|_\infty \|K\|_2^2}{nh}.$$

Balance.

$$\text{MSE} \leq C_1 h^{2\beta} + \frac{C_2}{nh}.$$

$$h^* \asymp n^{-1/(2\beta+1)}, \quad \text{MSE}(h^*) \lesssim n^{-2\beta/(2\beta+1)}.$$

En dimension d : variance $\sim 1/(nh^d)$, taux $n^{-2\beta/(2\beta+d)}$.
Annales guidées ch4
Examen 2025 : biais KDE. On part de

$$\mathbb{E} \widehat{f}_h(x_0) = \int K(u) f(x_0 - hu) \, du.$$

Donc, comme $\int K = 1$,

$$\mathbb{E} \widehat{f}_h(x_0) - f(x_0) = \int K(u) \{f(x_0 - hu) - f(x_0)\} \, du.$$

Rédaction : faire Taylor à l'ordre $\ell = \lfloor \beta \rfloor$. Les termes en u^j disparaissent car $\int u^j K = 0$. Le reste Holder donne

$$|f^{(\ell)}(x_0 - \xi hu) - f^{(\ell)}(x_0)| \leq L|h u|^{\beta-\ell},$$

donc $|\text{biais}| \leq C h^\beta$.
Examen 2025 : variance + taux. Indépendance :

$$\text{Var}(\widehat{f}_h(x_0)) = \frac{1}{n} \text{Var}\left(h^{-1} K\left(\frac{x_0 - X}{h}\right)\right).$$

Puis $\text{Var } Z \leq \mathbb{E} Z^2$, changement $u = (x_0 - t)/h$, $f \leq M$:

$$\text{Var}(\widehat{f}_h(x_0)) \leq \frac{M \|K\|_2^2}{nh}.$$

Enfin

$$\text{MSE} \leq C_1 h^{2\beta} + C_2/(nh).$$

Équilibrer $h^{2\beta}$ et $1/(nh)$: $h \asymp n^{-1/(2\beta+1)}$, taux $n^{-2\beta/(2\beta+1)}$.
Examen 2019 : AMISE. Si $f \in C^2$, $\int u K = 0$, $k_2 = \int u^2 K(u) \, du$, écrire

$$\mathbb{E} \|\widehat{f} - f\|_2^2 \lesssim \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \frac{\|K\|_2^2}{nh}.$$

Pour minimiser $ah^4 + b/(nh)$: dériver

$$4ah^3 - \frac{b}{nh^2} = 0 \Rightarrow h^5 = \frac{b}{4an}.$$

Ici

$$h^* = \left(\frac{\|K\|_2^2}{nk_2^2 \|f''\|_2^2} \right)^{1/5}.$$

Examen 2016. GL : comparer plusieurs lissages $\widehat{f}_{h,h'}$, $K_h * \widehat{f}_{h'}$: adaptatif = ne pas connaître α avant de choisir h .
Régression non paramétrique
Design aléatoire.

$$r(x) = \mathbb{E}(Y \mid X = x), \quad Y = r(X) + \varepsilon, \quad \mathbb{E}(\varepsilon \mid X) = 0.$$

Si $\mathbb{E} Y^2 < \infty$, $r(X)$ minimise $\mathbb{E}(Y - g(X))^2$.
Design déterministe.

$$Y_i = r(x_i) + \varepsilon_i, \quad \mathbb{E} \varepsilon_i = 0, \quad \text{Var}(\varepsilon_i) = \sigma^2.$$

OLS / projection.

$$\widehat{\beta} = (X^T X)^{-1} X^T Y, \quad \widehat{Y} = P_m Y.$$

$$\mathbb{E} \|\widehat{Y}^m - r^*\|_2^2 = \|(I - P_m) r^*\|_2^2 + \sigma^2 |m|.$$

$$\mathbb{E} \|\widehat{Y}^m - Y\|_2^2 = \|(I - P_m) r^*\|_2^2 + \sigma^2 (n - |m|).$$

Preuve : développer, terme croisé nul, $\mathbb{E}(\xi^T A \xi) = \text{tr}(A \text{Cov } \xi)$, $\text{tr } P_m = |m|$.
Nadaraya-Watson
Formule.

$$\widehat{r}_n(x) = \frac{\sum_i Y_i K((X_i - x)/h)}{\sum_i K((X_i - x)/h)}$$

si le dénominateur est non nul ; sinon 0.

$$\widehat{r}_n(x) = \sum_i \omega_i(x) Y_i, \quad \sum_i \omega_i(x) = 1.$$

Avec noyau uniforme : moyenne locale des Y_i tels que $X_i \in [x - h, x + h]$.
Extrêmes. $h \rightarrow \infty$: moyenne constante $\widehat{Y}$, biais fort. $h \rightarrow 0$: interpolation/oscillations, variance forte. $\ell = 0$ dans les polynômes locaux.
Polynômes locaux

$$z_i = \frac{X_i - x}{h}, \quad V_\ell(u) = \left(1, u, \dots, \frac{u^\ell}{\ell!}\right)^T.$$

$$\widehat{\theta}(x) = \arg \min_{\theta \in \mathbb{R}^{\ell+1}} \sum_i K(z_i) \left(Y_i - \sum_{k=0}^\ell \theta_k \frac{z_i^k}{k!} \right)^2.$$

$$\widehat{r}_n^\ell(x) = \widehat{\theta}_0 = e_1^T \widehat{\theta}.$$

$$B_{n,x} = \sum_i K(z_i) V_\ell(z_i) V_\ell(z_i)^T.$$

Si $B_{n,x}$ inversible :

$$\widehat{\theta} = B_{n,x}^{-1} \sum_i K(z_i) Y_i V_\ell(z_i),$$

$$\widehat{r}_n^\ell(x) = \sum_i w_i(x) Y_i, \quad w_i = K(z_i) e_1^T B_{n,x}^{-1} V_\ell(z_i).$$

Reproduction polynomiale. Pour tout polynôme Q de degré $\leq \ell$:

$$\sum_i w_i(x) Q(X_i) = Q(x).$$

Donc

$$\sum_i w_i(x) = 1, \quad \sum_i (X_i - x)^k w_i(x) = 0, \quad 1 \leq k \leq \ell.$$

Risque régression locale
Estimateur linéaire $\widehat{r}(x) = \sum_i w_i(x) Y_i$. Si $r \in \Sigma(\beta, L)$, moments nuls jusqu'à $\ell = \lfloor \beta \rfloor$:

$$|\text{biais}(x)| \leq \frac{L}{\ell!} \sum_i |w_i(x)| |x_i - x|^\beta.$$

Si $\sum_i |w_i| \leq C$, $w_i = 0$ hors $|x_i - x| \leq h$, $\sup_i |w_i| \leq M/(nh)$:

$$|\text{biais}| \lesssim h^\beta, \quad \text{Var}(\widehat{r}(x)) = \sigma^2 \sum_i w_i^2 \lesssim \frac{\sigma^2}{nh}.$$

$$\text{MSE} \lesssim h^{2\beta} + \frac{1}{nh},$$

$$h^* \asymp n^{-1/(2\beta+1)},$$

$$\text{MSE}(h^*) \lesssim n^{-2\beta/(2\beta+1)}.$$

Validation croisée / choix
Erreur d'entraînement.

$$\widehat{R}_{train}(h) = \frac{1}{n} \sum_i (Y_i - \widehat{r}_h(X_i))^2$$

est optimiste ; choisir h par training error favorise h trop petit / surapprentissage.
Hold-out.

$$\widehat{R}(h) = \frac{1}{|I_2|} \sum_{i \in I_2} (Y_i - \widehat{r}_h^{(-I_2)}(X_i))^2.$$

K -fold.

$$\widehat{R}(h) = \frac{1}{K} \sum_{k=1}^K \frac{1}{|I_k|} \sum_{i \in I_k} (Y_i - \widehat{r}_h^{(-I_k)}(X_i))^2.$$

LOOCV rapide. Si $\widehat{r}_h(x) = \sum_j \omega_j(x) Y_j$:

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \widehat{r}_h(X_i)}{1 - \omega_{i,h}(X_i)} \right)^2.$$

Choisir $\widehat{h} \in \arg \min_{h \in H} CV(h)$, puis réentraîner sur tout l'échantillon.
Grande dimension et modèles
Local en dimension d : masse utile $\sim nh^d$. Si d grand, il faut beaucoup de données : malédiction de la dimension.

$$\text{Taux densité/régression locale} \approx n^{-2\beta/(2\beta+d)}.$$

Solutions structurelles à citer :

$$r(x) = c + \sum_{j=1}^d g_j(x_j) \quad \text{modèle additif,}$$

$$r(x) = x_1^T \beta + g(x_2) \quad \text{partiellement linéaire.}$$

Le degré local $\ell = 1$ ou 2 est courant ; degré trop grand $\Rightarrow$ constantes mauvaises, instabilité.
Annales guidées ch5
Examen 2025 : reproduction. On suppose $Y_i = Q(X_i)$, $\deg Q \leq \ell$. Écrire Taylor exact :

$$Q(X_i) = q(x)^T V_\ell(z_i),$$

$$q = (Q(x), Q'(x)h, \dots, Q^{(\ell)}(x)h^\ell)^T.$$

Dans le critère local,

$$\sum_i K(z_i) \{Y_i - \theta^T V_\ell(z_i)\}^2 = (q - \theta)^T B (q - \theta).$$

Comme B est inversible, le minimum est $\widehat{\theta} = q$. Donc

$$\widehat{r}^\ell(x) = \widehat{\theta}_0 = Q(x) \quad \text{et} \quad \sum_i w_i(x) Q(X_i) = Q(x).$$

Pour obtenir les identités, choisir $Q(u) = 1$ puis $Q(u) = (u - x)^k$:

$$\sum_i w_i = 1, \quad \sum_i (X_i - x)^k w_i = 0.$$

Examen 2024 : risque poids. Plan de rédaction. 1) Biais :

$$\mathbb{E} \widehat{r}(x) - r(x) = \sum_i w_i \{r(x_i) - r(x)\}.$$

Taylor ; les moments $\sum_i (x_i - x)^k w_i = 0$ annulent les termes. Reste :

$$|\text{biais}| \leq \frac{L}{\ell!} \sum_i |w_i| |x_i - x|^\beta.$$

Si $w_i = 0$ hors $|x_i - x| \leq h$ et $\sum |w_i| \leq C$, alors biais $\lesssim h^\beta$. 2) Variance :

$$\text{Var}(\widehat{r}(x)) = \sigma^2 \sum_i w_i^2 \leq \sigma^2 (\max_i |w_i|) \sum_i |w_i| \lesssim \frac{1}{nh}.$$

Puis $h^{2\beta} \sim 1/(nh)$.
Questions rapides 2023-2025. Si $n \simeq 60$, $d = 5$: localement on garde environ nh^d points ; trop petit en grande dimension. Réponse : éviter NW/polynôme local brut, proposer modèle additif $r = c + \sum g_j(x_j)$. Si h choisi par erreur d'entraînement, dire : même données pour ajuster et évaluer $\Rightarrow$ surapprentissage, h trop petit ; utiliser CV/LOOCV.