

# Design déterministe, erreur de prédiction OLS sur une nouvelle donnée

Données :  $(Y_1, x_1), \dots, (x_n, Y_n)$ .

Hypothèses :

$$Y_i = x_i^T w + b + \epsilon_i, i = 1, \dots, n$$

$\epsilon_1, \dots, \epsilon_n$  indép  $E(\epsilon_i) = 0$  et  $E(\epsilon_i^2) = \sigma^2$ .

$(1, x_{i,1}, x_{i,2}, \dots, x_{i,p}) \in \mathbb{R}^{p+1}$  :  $p$  covariables (dans le vecteur  $x_i$ ) plus l'intercept.

$w = (w_1, \dots, w_p) \in \mathbb{R}^p$ ,  $b \in \mathbb{R}$ .

Nouvelle donnée :  $(x_{n+1}, Y_{n+1})$ , telle que  $Y_{n+1} = x_{n+1}^T w + b + \epsilon_{n+1}$  avec  $\epsilon_{n+1}$  indépendante de  $(Y_1, x_1), \dots, (x_n, Y_n)$  et t.q.  $E(\epsilon_{n+1}) = 0$  et  $E(\epsilon_{n+1}^2) = \sigma^2$ .

But : prédire  $Y_{n+1}$  (inconnu) à partir de  $x_{n+1}$  et des données  $(Y_1, x_1), \dots, (x_n, Y_n)$ .

On utilise l'OLS  $(\hat{w}, \hat{b})$  calculé sur les données  $(Y_1, x_1), \dots, (x_n, Y_n)$ .

Matrice de design notée  $\mathbf{X}$  (première colonne = intercept). Dim :  $n \times (p+1)$ .

On note  $a_i = (1, x_{i,1}, x_{i,2}, \dots, x_{i,p}) \in \mathbb{R}^{p+1}$  la  $i$ ème ligne de  $\mathbf{X}$  et  $\theta = (b, w_1, \dots, w_p)$ . On a donc, pour tout  $i = 1, \dots, n+1$ ,

$$Y_i = a_i^T \theta + \epsilon_i$$

L'erreur de prédiction est donnée par <sup>a</sup>

$$E(Y_{n+1} - x_{n+1}^T \hat{w} - \hat{b})^2 = E(Y_{n+1} - a_{n+1}^T \hat{\theta})^2 = \sigma^2(1 + a_{n+1}^T (\mathbf{X}^T \mathbf{X})^{-1} a_{n+1})$$

a. cf. polycopié de Donnet-Ryder ou de Guyader

## 0.1 Cas particulier : $p = 1$

En dimension 1 (une seule colonne autre que l'intercept) l'erreur est donnée par

$$\sigma^2 \left( 1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Donc l'erreur de prédiction est grande quand "la nouvelle donnée  $x_{n+1}$  est loin des points  $x_1, \dots, x_n$  utilisés pour calculer  $\hat{\theta}$ ".

(pour plus de détails, cf le polycopié d'Arnaud Guyader (page 15))

<https://perso.lpsm.paris/~aguyader/files/teaching/Regression.pdf>

Ceci reste vrai dans le cas général et ce point est surtout intéressant quand le design est réellement déterministe (nous avons fait l'expérience nous-même et donc nous avons choisi les  $x_i$ ) (ils sont alors souvent uniformément répartis sur un certain intervalle). **Cela signifie en particulier que nous ne devrions pas extrapoler les résultats en dehors de l'intervalle auquel appartiennent les  $x_i$  utilisés pour entraîner le modèle (trop d'incertitude en dehors de cet intervalle).**

Remarque : Si le design est au contraire aléatoire<sup>1</sup> nous pouvons en quelque sorte "négliger" (la plupart du temps) le cas où la nouvelle donnée est loin du nuage de points de l'échantillon d'entraînement car une nouvelle donnée aura justement tendance à se retrouver dans le même intervalle que les données initiales ( $X_{n+1}$  est alors de même loi que les données initiales  $X_1, \dots, X_n$ , et si  $n$  est grand, on a alors, avec les données d'entraînement, un aperçu assez bon du support de la loi de  $X$ . On peut voir aussi que  $\frac{(X_{n+1} - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$  a tendance à être proche de  $\frac{1}{n} \frac{(X_{n+1} - E(X))^2}{\text{var}(X)} = \frac{(\text{la variable } X_{n+1} \text{ centrée réduite})^2}{n}$ ).

1. nous disposons donc d'un échantillon i.i.d.  $X_1, \dots, X_n$

## 0.2 Cas général (plus compliqué techniquement)

On va seulement donner une idée approximative de ce qui se produit pour éviter les détails techniques.

On peut en fait réécrire la quantité  $a_{n+1}^T (\mathbf{X}^T \mathbf{X})^{-1} a_{n+1}$  apparaissant dans l'erreur de prédiction, pour faire (plus ou moins) apparaître la distance entre la nouvelle donnée  $x_{n+1}$  et le centre de gravité du nuage de points  $\bar{x}$  (comme pour le cas facile  $p = 1$ ). La distance n'est alors pas la distance euclidienne mais une distance (plus ou moins) liée à l'inverse de la matrice de corrélation empirique des covariables.

Ainsi, comme en dimension 1, on retrouve le fait que la prédiction est incertaine quand "la nouvelle donnée est loin des données utilisées pour entraîner le modèle".

Et en plus, s'il y a beaucoup de corrélation dans les colonnes de la matrice  $\mathbf{X}$  alors il se peut que certaines valeurs propres de la matrice de corrélation empirique soient petites donc certaines valeurs propres de la matrice inverse seront grandes, ce qui peut entraîner une mauvaise prédiction dans des directions particulières (par ex quand la valeur propre minimale de la matrice de corrélation est très petite et que  $(x_{n+1} - \bar{x})$  a une direction proche de celle du vecteur propre associé à cette petite valeur propre).