

2. Log-vraisemblance: $\ln(\beta, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{\|Y - X\beta\|_2^2}{2\sigma^2} + C$

On cherche $(\hat{\beta}, \hat{\sigma}^2) \in \underset{\beta \in \mathbb{R}^3, \sigma^2 > 0}{\operatorname{argmax}} \ln(\beta, \sigma^2)$

Ce pb d'opti ressemble bcp au pb d'opti de l'exo 2 Partie 2. On procède de manière similaire. Fixons σ^2 et cherchons $\underset{\beta \in \mathbb{R}^3}{\operatorname{argmax}} \ln(\beta, \sigma^2) = \underset{\beta \in \mathbb{R}^3}{\operatorname{argmax}} \frac{\|Y - X\beta\|_2^2}{2\sigma^2}$

$= \underset{\beta \in \mathbb{R}^3}{\operatorname{argmin}} \frac{\|Y - X\beta\|_2^2}{2}$ (*)
pb indépendant de σ^2 !

Posons $f(\beta) = \frac{\|Y - X\beta\|_2^2}{2} = \frac{\|Y\|_2^2}{2} + \frac{\|X\beta\|_2^2}{2} - \frac{2Y^T(X\beta)}{2}$

(Détails: $\|u-v\|^2 = \|u\|^2 + \|v\|^2 - 2\langle u, v \rangle \quad \forall u, v \in \mathbb{R}^n$
et $\langle u, v \rangle = U^T V$ si U et V sont des vecteurs colonnes représentant u et v)

Donc $f(\beta) = \frac{\|Y\|_2^2}{2} + \underbrace{(X\beta)^T X\beta}_{\beta^T X^T X \beta} - (X\beta)^T Y$

(détails: $\langle u, v \rangle = \langle v, u \rangle$ donc $U^T V = V^T U$)

Donc $f(\beta) = \|Y\|_2^2 + \frac{\beta^T X^T X \beta}{2} - \beta^T X^T Y$

$= c + \frac{\beta^T A \beta}{2} - \beta^T b$

où $A = X^T X$, $c \in \mathbb{R}$ (constante i.i.), $b = X^T Y \in \mathbb{R}^3$ vecteur constant.

Donc d'après l'exemple fondamental du cours d'opti et méthodes num (cf. page 58)
on a $\nabla f(\beta) = \frac{A + A^T}{2} \beta - b = A\beta - b$ car $A = X^T X$ est symétrique.

$= X^T X \beta - X^T Y$

et $H_f(\beta) = A = X^T X$ (cf. page 68 du poly: voir par: $\nabla f(\beta+h) - \nabla f(\beta) = A(\beta+h) - A\beta = Ah$)
Hessienne de f en β

Or $\forall$ matrice A on a: $\underline{A^T A \geq 0}$: en effet si $A \in \mathbb{M}_{n \times p}(\mathbb{R})$ et si $x \in \mathbb{R}^p$ alors $x^T A^T A x = (Ax)^T Ax = \|Ax\|_2^2 \geq 0$.

Donc $H_f(\beta) \geq 0 \quad \forall \beta \in \mathbb{R}^3$ donc f est convexe sur $\mathbb{R}^3$. Donc il suffit de trouver le (ou les) point(s) critique(s) pour résoudre (*):

$\nabla f(\beta) = 0 \Leftrightarrow X^T X \beta - X^T Y = 0$

Or $X^T X > 0$ ("définit positif") donc $X^T X$ est inversible,

En effet, on a déjà vu que $X^T X > 0$. Il reste à voir que si $x \in \mathbb{R}^3$ est t.g. $x^T X^T X x = 0$ alors $x = 0$. Or on a:

$$x^T X^T X x = \|Xx\|^2 \text{ et si } \|Xx\| = 0 \text{ alors } Xx = 0 \text{ i.e.}$$

$x_1 1 + x_2 u + x_3 v = 0$ (on pose $x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$, on rappelle que $1, u$ et v sont des colonnes de X).

Pour l'énoncé nous dit que les colonnes de X sont linéairement indépendantes. Donc on obtient bien $x_1 = x_2 = x_3 = 0$.

Ainsi $(X^T X)^{-1}$ existe et

$$X^T X \beta = X^T Y \Leftrightarrow \beta = (X^T X)^{-1} X^T Y.$$

$$\text{Donc } \boxed{\hat{\beta}^{MLE} = (X^T X)^{-1} X^T Y}$$

$$\text{Et finalement } \hat{\sigma}^2 \in \operatorname{argmax}_{\sigma^2 > 0} \ln(\hat{\sigma}, \sigma^2) = \operatorname{argmax}_{\sigma^2 > 0} -\frac{n}{2} \log \sigma^2 - \frac{\|Y - X\hat{\beta}\|_2^2}{2\sigma^2}$$

Exactement le m^e pb que dans l'exo 1 (et l'exo 2 partie 2)

$$\text{donc } \boxed{\hat{\sigma}^2 = \frac{\|Y - X\hat{\beta}\|_2^2}{n}}$$

Remarque importante pour la suite: pour trouver $\hat{\beta}$ on pourrait aussi passer par des résultats d'algèbre linéaire.

Rappel: Soit F un sous-espace de $\mathbb{R}^n$ et $x \in \mathbb{R}^n$. La projection orthogonale de x sur F est l'unique solution du pb d'opti $\inf_{u \in F} \|x - u\|_2$

Donc $\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^3} \|Y - X\beta\|_2^2$ se traduit par le fait que $\hat{\beta}$ est t.g.

$$\boxed{X\hat{\beta} = P_F Y \quad \text{où } F = \{y = X\beta \in \mathbb{R}^n : \beta \in \mathbb{R}^3\}} \quad \text{et } P_F = \text{proj. ortho sur } F$$

F est donc l'image de l'appli linéaire associée à la matrice X . C'est aussi l'espace vectoriel engendré par les colonnes de la matrice X .

Or, quand X a des colonnes linéairement indépendantes, la matrice de projection orthogonale sur l'image de X est donnée par: $P_F = X(X^T X)^{-1} X^T$.

$$\text{Donc } X\hat{\beta} = X(X^T X)^{-1} X^T Y \quad (\text{on a})$$

Or X a des col. lin. indép $\Rightarrow$ l'appl. associée à X est injective

Donc $(**)$ $\Leftrightarrow \hat{\beta} = (X^T X)^{-1} X^T y$

On retrouve bien le résultat donné par la 1^{ère} méthode.

Pour voir pourquoi $P_F = X(X^T X)^{-1} X^T$, cf. détails page suivante.

$$P = X (X^T X)^{-1} X^T$$

v.g. $P = \text{proj ortho sur } F$.

$$P^2 = X \underbrace{(X^T X)^{-1} X^T X}_{= I_n} (X^T X)^{-1} X = X (X^T X)^{-1} X = P$$

Donc $P = \text{proj orthogonale sur un sous-espace } F$.

Reste à voir que $F = \text{Im } X = \{x \in \mathbb{R}^n : \exists \beta \in \mathbb{R}^3 \text{ t.q. } x = X\beta\}$
 $= \text{le sous-espace engendré par } \{1, u, v\} \text{ i.e. les colonnes de } X$.

Soit $x \in F$ alors $\exists \beta \in \mathbb{R}^3 \text{ t.q. } x = X\beta$

$$\text{Donc } P x = X \underbrace{(X^T X)^{-1} X^T X}_{= I_n} \beta = X\beta = x$$

Soit $x \in F^\perp$ alors $P x = X (X^T X)^{-1} X^T x$

Rappel: si $A \in \mathcal{M}_{n,p}(\mathbb{R})$ et $x \in \mathbb{R}^p$ alors $Ax = \begin{pmatrix} \langle a_1, x \rangle \\ \langle a_2, x \rangle \\ \vdots \\ \langle a_n, x \rangle \end{pmatrix}$
 où $a_1, \dots, a_n$ sont les lignes de la matrice A .

Donc ici, avec $A = X^T \in \mathcal{M}_{3,n}(\mathbb{R})$ et $x \in \mathbb{R}^n$

$$\text{on a } X^T x = \begin{pmatrix} \langle a_1, x \rangle \\ \langle a_2, x \rangle \\ \langle a_3, x \rangle \end{pmatrix} \text{ où } a_1, a_2, a_3 \text{ sont les lignes de } X^T, \text{ i.e. les colonnes de } X.$$

$$\text{Donc } X^T x = \begin{pmatrix} \langle 1, x \rangle \\ \langle u, x \rangle \\ \langle v, x \rangle \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \text{ car } x \in F^\perp = (\text{Vect}(1, u, v))^\perp$$

Résumé: $\left. \begin{array}{l} \bullet P \text{ est un projecteur} \\ \bullet Px = x \quad \forall x \in F \\ \bullet Px = 0 \quad \forall x \in F^\perp \end{array} \right\} \Rightarrow P = \text{proj ortho sur } F$.

Remarque: on aurait pu aussi passer par:

- $P^2 = P$ (donc P est un projecteur)
- $P^T = P$ (facile à montrer) donc P est un proj ortho.
- $Px = x \quad \forall x \in F$ et $\text{Im } P \subset F$. (puisque $P = XA$ avec $A = (X^T X)^{-1} X^T$)