

Introduction à la statistique non paramétrique

poly: ©Laëtitia Comminges, Gabriel Turinici

aucune diffusion de ce document n'est permise sans accord ECRIT des auteurs

18 janvier 2026

Table des matières

1	Introduction et rappels	4
1.1	Qu'est-ce que la statistique non-paramétrique ?	4
1.2	Quelques problèmes de statistique non-paramétrique	4
1.2.1	Estimation de la fonction de répartition	4
1.2.2	Estimation de densité	4
1.2.3	Régression non-paramétrique	5
1.2.4	Tests non-paramétriques	5
1.3	Rappels d'inégalités classiques	5
1.4	Théorèmes de convergence classique	6
1.4.1	Lemme de Slutsky	6
1.4.2	Delta-méthode	7
1.5	Rappels sur l'espérance conditionnelle	7
1.5.1	Calcul d'espérance conditionnelle	7
1.5.2	Propriété du transfert conditionnel	8
1.6	Rappels sur les quantiles et les lois symétriques	9
1.6.1	Quantiles	9
1.6.2	Loi symétrique	9
1.7	Rappels sur les tests (fréquentistes) paramétriques	10
1.7.1	Comparaison de test, principe de Neyman	12
1.8	Intuition et calculs : exemples de niveau L3	13
1.8.1	Intuition	13
1.8.2	Exemple de calculs de puissance	15
1.8.3	La p -valeur	18
1.8.4	Interprétation des p -valeurs	22
2	Estimation de la fonction de répartition	24
2.1	Consistance des fonctions de répartition empiriques	24
2.2	Estimation de quantiles	28
2.3	Test d'ajustement à une loi ou à une famille de lois	32
2.3.1	Ajustement à une loi donnée	32
2.3.2	Ajustement à une famille paramétrique de lois : le cas des familles exponentielles	38
2.4	Test d'homogénéité de Kolmogorov Smirnov	39
2.5	Tests d'adéquation du khi-deux	40
2.5.1	Test d'adéquation à une loi donnée	40
2.5.2	Test du chi-deux d'indépendance	42
3	Tests robustes	44
3.1	Un exemple	44
3.2	Un test paramétrique : le test de Student	45
3.2.1	Un seul échantillon	45
3.2.2	Deux échantillons indépendants	46
3.2.3	Echantillons appariés (paired data)	47
3.2.4	Importance des conditions d'application	49

3.2.5	Illustration numérique - (lecture facultative)	49
3.3	Test du signe	54
3.3.1	Test du signe sur un seul échantillon	54
3.3.2	Test du signe sur deux échantillons	55
3.4	Statistiques d'ordre et de rang	57
3.5	Test des rangs signés de Wilcoxon	58
3.5.1	Sur un échantillon	58
3.5.2	Échantillons appariés	63
3.6	Test de Wilcoxon de la somme des rangs (Mann-Whitney)	64
3.6.1	Résultats préliminaires sur le vecteur des rangs	64
3.6.2	Définition et propriétés du test de Mann-Whitney)	66
4	Estimation de densités par estimateurs à noyau	72
4.1	Quelques rappels d'analyse utiles pour les chapitres 4 et 5	72
4.2	Introduction	72
4.3	Estimation non paramétrique de la densité	74
4.3.1	Un estimateur simple de la densité : l'histogramme	74
4.3.2	Estimateurs à noyaux	78
4.4	Risque quadratique ponctuel des estimateurs à noyau sur la classe des espaces de Holder	82
4.5	Choix de la fenêtre h par validation croisée	84
5	Régression non paramétrique	88
5.1	Introduction	88
5.1.1	Design aléatoire	88
5.1.2	Design déterministe	89
5.2	Estimateur des moindres carrés (OLS) non paramétrique	90
5.2.1	Modèle linéaire : rappels	90
5.2.2	Équilibre biais-variance dans le cas de l'OLS et dans un contexte simple	91
5.2.3	OLS non paramétrique	91
5.3	Estimateur de Nadaraya-Watson	93
5.4	Estimateur par polynômes locaux	95
5.4.1	Splines de lissage et splines de régression	98
5.4.2	Définition d'une spline cubique et splines de régression	98
5.4.3	Splines de lissage	98
5.4.4	Grande dimension	100
5.5	Choix des paramètres de régularisation	102
5.5.1	Risque empirique, surajustement	102
5.5.2	Validation croisée - 'Cross-Validation' - CV	104
5.5.3	Pour les étudiants qui ont du mal à comprendre la CV	105
5.5.4	Calcul du LOOCV pour l'estimateur par polynômes locaux	106
6	Corrigés des exercices	109
6.1	Corrigés des exercices du chapitre 3	109
6.1.1	Exercice 1	109
6.1.2	Exercice 2	110
6.1.3	Exercice 3	112
6.1.4	Exercice 4	113
6.2	Corrigés des exercices du chapitre 4	115
6.2.1	Exercice 1	115
6.2.2	Exercice 2	123

Introduction

Ces notes de cours font suite aux notes du cours d'introduction à la statistique non paramétrique de Vincent Rivoirard (qui s'est inspiré d'un cours de Catherine Mathias), Laëtitia Comminges et Gabriel Turinici.

Chapitre 1

Introduction et rappels

1.1 Qu'est-ce que la statistique non-paramétrique ?

La statistique paramétrique est le cadre classique de la statistique. Le modèle statistique est défini par un paramètre $\theta \in \mathbb{R}^k$ pour un certain entier k .

Exemple 1.1. — *Modèle linéaire gaussien. La loi $\mathbb{P}_\theta$ des observations vérifie $\mathbb{P}_\theta = \mathcal{N}(\mu, \sigma^2 I_n)$. le paramètre $\theta = (\mu, \sigma^2) \in \mathbb{R}^n \times \mathbb{R}_+^*$ suffit à déterminer la loi des observations.*

— *Observation du nombre d'arrivées à un guichet : $Y \sim P(\lambda)$ (Poisson).*

Par opposition, en statistique non-paramétrique, le modèle n'est pas décrit par un nombre fini de paramètres (ou de manière équivalente par un paramètre de dimension finie).

Exemple 1.2. *Un constructeur automobile étudie le comportement d'achat de ses clients. Il a la conviction que la somme qu'ils sont prêts à déboursier est une fonction de leur revenu et de la distance parcourue quotidiennement et à partir de n observations recueillies par sondage, il postule le modèle statistique suivant :*

$$Y_i = f(X_i) + \epsilon_i, \quad i = 1, \dots, n$$

où les ϵ_i sont iid de loi $\mathcal{N}(0, \sigma^2)$ et $X_i = (X_{i1}, X_{i2}) = (\text{revenu}, \text{distance})$ et $Y_i = \text{somme à déboursier}$.

On peut faire différentes hypothèses a priori sur la fonction f (selon l'expérience, les connaissances a priori sur les données, ou après une représentation graphique des données)

— on peut supposer que f est une fonction affine des variables explicatives, on obtient alors un modèle linéaire (ici gaussien puisqu'on a supposé les erreurs gaussiennes) : $f(X_i) = \theta_1 + \theta_2 X_{i1} + \theta_3 X_{i2}$

— On peut aussi ne faire aucune hypothèse sur la forme de la fonction f , et faire juste une hypothèse de régularité minimum. On obtient alors un modèle non-paramétrique.

1.2 Quelques problèmes de statistique non-paramétrique

1.2.1 Estimation de la fonction de répartition

On observe $X_1, \dots, X_n$ n variables réelles de loi $\mathbb{P}$. On cherche à estimer la loi $\mathbb{P}$. Or $\mathbb{P}$ est entièrement décrite par sa fonction de répartition

$$F : \begin{array}{ll} \mathbb{R} & \rightarrow [0, 1] \\ x & \rightarrow \mathbb{P}([-\infty, x]) \end{array}$$

On construit un estimateur $\hat{F}_n$ de F à l'aide des n observations $X_1, \dots, X_n$.

1.2.2 Estimation de densité

On observe toujours $X_1, \dots, X_n$ n variables réelles de loi $\mathbb{P}$. Mais on suppose en plus que $\mathbb{P}$ est absolument continue par rapport à la mesure de Lebesgue et on souhaite estimer sa densité f . En général, la dérivée de $\hat{F}_n$ n'est pas une bonne solution.




FIGURE 1.1 – Estimation de densité avec python, fonction "gaussian_kde" du package "scipy.stats.kde".

1.2.3 Régression non-paramétrique

On observe une suite de couples $((X_i, Y_i))_{1 \leq i \leq n}$ obéissant au modèle

$$Y_i = f(X_i) + \epsilon_i, \quad i = 1, \dots, n$$

On cherche à estimer la fonction de régression f .

On peut aussi considérer d'autres problèmes de statistique non-paramétrique qui ne sont pas directement de l'estimation.

1.2.4 Tests non-paramétriques

Deux exemples de problèmes possibles :

- Soit X une v.a. et $\mathbb{P}$ une distribution donnée. A l'aide de $X_1, \dots, X_n$ iid de même loi que X , tester :

$$H_0 : X \sim \mathbb{P}, \quad \text{contre} \quad X \not\sim \mathbb{P}$$

- Soient X et Y deux v.a. et $(X_1, \dots, X_n)$ et $(Y_1, \dots, Y_m)$ des échantillons de mêmes lois respectivement que X et Y . A l'aide des deux échantillons on peut :

- tester s'il s'agit de la même loi : $H_0 : X \sim Y$ contre $H_1 : X \not\sim Y$
- tester l'indépendance entre X et Y : $H_0 : X \perp\!\!\!\perp Y$ contre $H_1 : X$ et Y sont non indépendants.

1.3 Rappels d'inégalités classiques

Inégalité de Markov

Soit X une v.a.r. positive telle que $\mathbb{E}(X) < \infty$. Alors $\forall t > 0$

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}(X)}{t}$$

Inégalité de Bienaymé-Tchebycheff (B-T)

Soit X une v.a.r. telle que $\mathbb{E}(X^2) < \infty$. Alors pour tout $t > 0$,

$$\mathbb{P}(|X - \mathbb{E}(X)| > t) \leq \frac{\text{Var}(X)}{t^2}$$

Inégalité de Hoeffding

Soient $Y_1, \dots, Y_n$ des v.a.r. indépendantes centrées et telles que

$$a_i \leq Y_i \leq b_i \text{ p.s. pour tout } i$$

Alors

$$\forall t > 0, \quad \mathbb{P}\left(\sum_{i=1}^n Y_i \geq t\right) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

Remarque 1.1

Sous les mêmes hypothèses, on a aussi

$$\forall t > 0, \quad \mathbb{P}\left(\left|\sum_{i=1}^n Y_i\right| \geq t\right) \leq 2 \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

Exemple 1.2

Comparaison entre Hoeffding et B-T : soit $X_1, \dots, X_n \stackrel{iid}{\sim} Be(p)$ avec $p \in (0, 1)$. On cherche un intervalle de confiance bilatéral de niveau $1 - \alpha$ pour p avec l'une des inégalités ci-dessus :

- Si on utilise l'inégalité B-T, $\mathbb{P}(|\bar{X} - p| > c) \leq \frac{p(1-p)}{nc^2} \leq \frac{1}{4c^2n} := \alpha$. Donc $\mathbb{P}(p \in [\bar{X} - \frac{1}{2\sqrt{n\alpha}}, \bar{X} + \frac{1}{2\sqrt{n\alpha}}]) \geq 1 - \alpha$. Pour $\alpha = 5\%$ et $n = 100$, la précision, i.e. la demi-longueur, de cet intervalle est $\frac{1}{\sqrt{n\alpha}} = 0.22$.
- Si on utilise l'inégalité de Hoeffding, $\mathbb{P}(|\bar{X} - p| > c) \leq 2 \exp(-2nc^2)$, Donc $\mathbb{P}(p \in [\bar{X} - \sqrt{\frac{\log(\frac{2}{\alpha})}{2n}}, \bar{X} + \sqrt{\frac{\log(\frac{2}{\alpha})}{2n}}]) \geq 1 - \alpha$. Pour $\alpha = 5\%$ et $n = 100$, la précision, i.e. la demi-longueur, de cet intervalle est $\sqrt{2\frac{\log(\frac{2}{\alpha})}{n}} = 0.14$.

1.4 Théorèmes de convergence classique

1.4.1 Lemme de Slutsky

Théorème 1.3

Soient $(X_n)_{n \geq 0}$ et $(Y_n)_{n \geq 0}$ deux suites de vecteurs aléatoires tels que

- $X_n \xrightarrow{loi} X$ où X est un vecteur aléatoire quelconque.
- $Y_n \xrightarrow{proba} c$ où c est un vecteur constant.

alors $(X_n, Y_n) \xrightarrow{loi} (X, c)$.

Conséquence : $X_n + Y_n \xrightarrow{loi} X + c$, $X_n Y_n \xrightarrow{loi} cX$, et de manière générale, pour toute fonction continue f (ou continue là où les variables prennent leurs valeurs) $f(X_n, Y_n) \xrightarrow{loi} f(X, c)$.

1.4.2 Delta-méthode

Théorème 1.4

On se donne une suite $(U_n)_n$ de vecteurs aléatoires de $\mathbb{R}^m$, une suite déterministe $(a_n)_n$ et une application $\ell : \mathbb{R}^m \rightarrow \mathbb{R}^p$ telles que

- $a_n \rightarrow +\infty$
- $\exists U \in \mathbb{R}^m$ un vecteur déterministe (=constant) et V un vecteur aléatoire tels que $a_n(U_n - U) \xrightarrow{loi} V$.
- ℓ est une fonction différentiable en U de différentielle $D\ell(U) \in M_{pm}(\mathbb{R})$.

Alors

$$a_n(\ell(U_n) - \ell(U)) \xrightarrow{loi} D\ell(U)V.$$

Exemple 1.5

Soit $X_1, \dots, X_n \stackrel{iid}{\sim} P(\lambda)$ avec $\lambda > 0$. Alors d'après le théorème central limite (noté 'TCL' dorénavant) on a $\sqrt{n}(\bar{X} - \lambda) \xrightarrow{loi} N(0, \lambda)$. Donc on a aussi, d'après le théorème ci-dessus,

$$\sqrt{n}(\sqrt{\bar{X}} - \sqrt{\lambda}) \xrightarrow{loi} N(0, \frac{1}{4})$$

En effet ici $\mathbb{R}^m = \mathbb{R}^p = \mathbb{R}$, $U_n = \bar{X}$, $U = \lambda$, $a_n = \sqrt{n}$, $V \sim N(0, \lambda)$, $\ell(u) = \sqrt{u}$, donc $D\ell(U) = \ell'(u) = \frac{1}{2\sqrt{\lambda}}$ et $D\ell(U)V \sim N(0, \frac{\lambda}{4\lambda})$.

1.5 Rappels sur l'espérance conditionnelle

Soit X et Y deux variables aléatoires à valeurs dans $\mathbb{R}^k$ et $\mathbb{R}^p$. Pour $x \in \mathbb{R}^k$, on note $\mathbb{P}_Y^{X=x}$ la loi conditionnelle de Y sachant $X = x$.

1.5.1 Calcul d'espérance conditionnelle

On rappelle que l'espérance conditionnelle de Y sachant X , que l'on note ici $\mathbb{E}(Y|X)$, est une variable aléatoire qui peut s'écrire comme une fonction mesurable de X :

$$\mathbb{E}(Y | X) = g(X) \quad \text{où} \quad g(x) = \mathbb{E}(Y | X = x).$$

Exemple 1.6

1. Soit U et V deux v.a. réelles. On rappelle la définition de la variance conditionnelle :

$$\mathbf{Var}(U | V) = \mathbb{E}[(U - \mathbb{E}(U | V))^2 | V] = \mathbb{E}[U^2 | V] - (\mathbb{E}[U | V])^2.$$

On a

$$\mathbf{Var}(U | V) = g(V) \quad \text{où} \quad g(v) = \mathbf{Var}(U | V = v),$$

i.e. $g(v)$ est la variance de U pour la loi conditionnelle sachant $V = v$.

En effet $\mathbf{Var}(U | V) = \mathbb{E}[U^2 | V] - (\mathbb{E}[U | V])^2 = \ell(V) - (h(V))^2$ avec $\ell(v) = \mathbb{E}[U^2 | V = v]$ et $h(v) = \mathbb{E}[U | V = v]$. Donc $\ell(v) - h(v)^2 = \mathbf{Var}(U | V = v)$.

2. Soit r une fonction définie sur $\mathbb{R}$ et à valeurs réelles et soit $x \in \mathbb{R}$. Soit $\hat{r}(x)$ un estimateur de $r(x)$ calculé à partir d'un échantillon i.i.d. $(X_1, Y_1), \dots, (X_n, Y_n)$ de couples de v.a. réelles. On note E_Y l'espérance conditionnelle sachant $(X_1, \dots, X_n)$. On a

$$E_Y[(\hat{r}(x) - r(x))^2] = [E_Y(\hat{r}(x)) - r(x)]^2 + E_Y[(\hat{r}(x) - E_Y(\hat{r}(x)))^2].$$

En effet,

$$E_Y[(\hat{r}(x) - r(x))^2] = g(X_1, \dots, X_n)$$

avec

$$g(x_1, \dots, x_n) = E[(\hat{r}(x) - r(x))^2 \mid X_1 = x_1, \dots, X_n = x_n].$$

Pour simplifier, on va noter E_n l'espérance pour la loi conditionnelle sachant $X_1 = x_1, \dots, X_n = x_n$. On a donc

$$\begin{aligned} g(x_1, \dots, x_n) &= E_n[(\hat{r}(x) - r(x))^2] = \text{variance} + \text{biais au carré} \\ &= E_n[(\hat{r}(x) - E_n(\hat{r}(x)))^2] + [E_n(\hat{r}(x)) - r(x)]^2 \end{aligned}$$

Ainsi on a bien

$$\begin{aligned} E_Y[(\hat{r}(x) - r(x))^2] &= g(X_1, \dots, X_n) \\ &= [E_Y(\hat{r}(x)) - r(x)]^2 + E_Y[(\hat{r}(x) - E_Y(\hat{r}(x)))^2]. \end{aligned}$$

1.5.2 Propriété du transfert conditionnel

Soit $f : \mathbb{R}^{p+k} \rightarrow \mathbb{R}^q$ une fonction borélienne. Alors la loi conditionnelle de $f(X, Y)$ sachant $X = x$ vérifie

$$\mathbb{P}_{f(X,Y)}^{X=x} = \mathbb{P}_{f(x,Y)}^{X=x}$$

et donc

$$\mathbb{E}[f(X, Y) \mid X = x] = \mathbb{E}[f(x, Y) \mid X = x]$$

En particulier si X et Y sont indépendantes, on a

$$\mathbb{P}_{f(X,Y)}^{X=x} = \mathbb{P}_{f(x,Y)}$$

et donc

$$\mathbb{E}[f(X, Y) \mid X = x] = \mathbb{E}[f(x, Y)].$$

Exemple 1.7

Supposons que X et Y sont des v.a. réelles indépendantes. On a

$$\mathbb{P}(Y \leq X) = \mathbb{E}(\mathbb{1}_{Y \leq X}) = \mathbb{E}(\mathbb{E}[\mathbb{1}_{Y \leq X} \mid X]) = \mathbb{E}[g(X)]$$

où

$$g(x) = \mathbb{E}[\mathbb{1}_{Y \leq X} \mid X = x] = \mathbb{E}[\mathbb{1}_{Y \leq x}] = F_Y(x)$$

où on a noté F_Y la fonction de distribution cumulative (ou encore fonction de répartition, dorénavant notée 'CDF') de Y . Donc on a

$$\mathbb{P}(Y \leq X) = \mathbb{E}[F_Y(X)]$$

dès que X et Y sont indépendantes.

Autre formulation de ce résultat :

$$\begin{aligned}
 \mathbb{P}(Y \leq X) &= \mathbb{E}[\mathbb{1}_{Y \leq X}] = \int \mathbb{1}_{y \leq x} d\mathbb{P}_{X,Y}(x, y) \\
 &= \int \mathbb{1}_{y \leq x} d\mathbb{P}_Y \otimes d\mathbb{P}_X(y, x) \\
 &= \int \left[\int \mathbb{1}_{y \leq x} d\mathbb{P}_Y(y) \right] d\mathbb{P}_X(x) \\
 &= \int F_Y(x) d\mathbb{P}_X(x) \\
 &= \mathbb{E}[F_Y(X)].
 \end{aligned}$$

Vous trouverez, si besoin, des exercices corrigés de calcul d'espérance conditionnelle dans le livre de Yves Ouyard, "Probabilités 2, master, agrégation".

1.6 Rappels sur les quantiles et les lois symétriques

1.6.1 Quantiles

On ne donne ici que la définition dans le cas simple où la loi est de CDF F continue et strictement croissante.

Soit X une variable aléatoire réelle de CDF F continue et strictement croissante. Pour $\alpha \in (0, 1)$, on appelle quantile d'ordre α de la loi F l'unique réel q_α^F tel que

$$F(q_\alpha^F) = \mathbb{P}(X \leq q_\alpha^F) = \alpha$$

autrement dit

$$q_\alpha^F = F^{-1}(\alpha) \tag{1.1}$$

Attention, quand la CDF n'est pas continue, l'équation ci-dessus n'a pas toujours de solution. De plus si la CDF n'est pas strictement croissante, l'équation peut avoir une infinité de solutions. La définition générale d'un quantile apparaît dans le chapitre 2.

1.6.2 Loi symétrique

Définition 1.8

Une variable réelle X a une loi symétrique (par rapport à 0) si $X \sim -X$.

- Si la CDF F est continue, cela se traduit par $F(x) = 1 - F(-x)$.
- Si la CDF F est continue et strictement croissante, cela se traduit par $q_{1-\alpha}^F = -q_\alpha^F$ pour tout $\alpha \in (0, 1)$.
- Si la loi a une densité f , cela se traduit par $f(-x) = f(x)$ pour presque tout $x \in \mathbb{R}$.
- Une v.a. réelle X a une distribution symétrique par rapport à b ssi $X - b$ a une distribution symétrique par rapport à 0, autrement dit ssi $X - b \sim -X + b$, autrement dit

$$X \sim 2b - X.$$

- Si X a une loi symétrique alors $\mathbb{P}(|X| > c) = \mathbb{P}(X > c) + \mathbb{P}(-X > c) = 2\mathbb{P}(X > c)$.

- Si la loi de X est symétrique et si $\mathbb{P}(X = 0) = 0$ alors la variable aléatoire $|X|$ est indépendante de la variable aléatoire $\mathbb{1}_{X > 0}$. En effet, soit A mesurable, la symétrie de la loi de X implique

$$\mathbb{P}(|X| \in A, X > 0) = \mathbb{P}(|-X| \in A, -X > 0) \tag{1.2}$$

et

$$\mathbb{P}(X > 0) = \mathbb{P}(X < 0) \quad (1.3)$$

(1.2) se réécrit

$$\mathbb{P}(|X| \in A, X > 0) = \mathbb{P}(|X| \in A, -X > 0)$$

ce qui implique

$$\mathbb{P}(|X| \in A) = \mathbb{P}(|X| \in A, X > 0) + \mathbb{P}(|X| \in A, X < 0) = 2\mathbb{P}(|X| \in A, X > 0) \quad (1.4)$$

(1.3) combinée avec la propriété $\mathbb{P}(X = 0) = 0$ impliquent

$$\mathbb{P}(X > 0) = \frac{1}{2} \quad (1.5)$$

(1.4) combiné avec (1.5) impliquent

$$\mathbb{P}(|X| \in A, X > 0) = \frac{1}{2}\mathbb{P}(|X| \in A) = \mathbb{P}(X > 0)\mathbb{P}(|X| \in A).$$

Exemple 1.9

La loi normale standard et la loi de Student sont des distributions symétriques (par rapport à 0). La loi $Be(1/2)$ est symétrique par rapport à $1/2$. La loi $B(n, 1/2)$ est symétrique par rapport à $n/2$.

1.7 Rappels sur les tests (fréquentistes) paramétriques

Test et erreur de test

Situation

On considère une expérience statistique engendrée par une observation X à valeurs dans $(\mathcal{X}, \mathcal{A})$ et associée à la famille de lois de probabilités

$$\{\mathbb{P}_\theta, \theta \in \Theta\}.$$

L'ensemble des paramètres Θ est un sous-ensemble de $\mathbb{R}^d$, avec $d \geq 1$. Attention il n'y a pas de structure probabiliste sur Θ !

Principe du test statistique

On veut « décider » à partir de l'observation de X si une propriété de la loi de X est vérifiée ou non. Cette propriété se traduit mathématiquement par un sous-ensemble $\Theta_0 \subset \Theta$ de l'ensemble des paramètres, et la propriété signifie que $\theta \in \Theta_0$.

Définition 1.10

On teste « l'hypothèse nulle » notée H_0

$$H_0 : \theta \in \Theta_0$$

contre « l'alternative » notée H_1 ou H_a

$$H_1 : \theta \in \Theta_1,$$

avec $\Theta_0 \subset \Theta$, $\Theta_1 \subset \Theta$ et $\Theta_0 \cap \Theta_1 = \emptyset$. Construire un test signifie construire une procédure $\phi = \phi(X)$ de la forme

$$\phi(X) = 1_{\{X \in \mathcal{R}\}} = \begin{cases} 0 & \text{si } X \notin \mathcal{R}. \quad \text{« on ne rejette pas l'hypothèse nulle »} \\ 1 & \text{si } X \in \mathcal{R}. \quad \text{« on rejette l'hypothèse nulle »} \end{cases} \quad (1.6)$$

avec $\mathcal{R}$ mesurable.



Mise en garde 1.11

Sauf pour les test triviaux qui rejettent toujours ou ne rejettent jamais H_0 , $\phi(X)$ a deux valeurs 0 et 1. Donc il est prévu qu'on se trompe parfois, par exemple en rejetant H_0 à tort ; donc il faut être attentif au langage et préférer si possible dire "les données ne soutiennent pas l'hypothèse H_0 " plutôt que " H_0 est fausse" ou même "on rejette H_0 "; ceci car, à nouveau, il est certain que parfois on se trompera en rejetant H_0 (c'est écrit dans la définition d'un test non-trivial).

Définition 1.12

On désigne indifféremment l'ensemble $\mathcal{R} \subset \mathcal{A}$ ou bien l'événement $\{X \in \mathcal{R}\}$ comme **zone de rejet** ou encore **zone critique** du test ϕ .

Définition 1.13

L'hypothèse H_j ($j = 0$ ou $j = 1$) est dite **simple** si Θ_j est réduit à un singleton, sinon H_j est dite **composite**.

Par exemple, un test de la forme $H_0 : \theta = 1$ contre $H_1 : \theta > 1$ a une hypothèse nulle simple et une alternative composite.

Erreur de test

Lorsque l'on effectue un test, il y a quatre possibilités. Deux sont anecdotiques et correspondent à une bonne décision :

- Ne pas rejeter l'hypothèse H_0 alors que $\theta \in \Theta_0$ (c'est-à-dire l'hypothèse H_0 est vraie).
- Rejeter l'hypothèse H_0 alors que $\theta \in \Theta_1$ (c'est-à-dire l'hypothèse H_0 est fausse).

Les deux autres possibilités sont celles qui vont nous occuper, et correspondent à une erreur de décision :

- Rejeter l'hypothèse H_0 alors que $\theta \in \Theta_0$ (c'est-à-dire l'hypothèse H_0 est vraie).
- Ne pas rejeter l'hypothèse H_0 alors que $\theta \in \Theta_1$ (c'est-à-dire l'hypothèse H_0 est fausse).

Définition 1.14: Erreur de première et seconde espèce

L'erreur de première espèce, ou encore de "type I" correspond à la probabilité maximale de rejeter l'hypothèse alors qu'elle est vraie :

$$\sup_{\theta \in \Theta_0} \mathbb{E}_\theta[\phi(X)] = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta[X \in \mathcal{R}].$$

L'erreur de seconde espèce ("type II") correspond à la probabilité maximale de ne pas rejeter l'hypothèse H_0 alors qu'elle est fausse :

$$\sup_{\theta \in \Theta_1} \mathbb{E}_\theta[1 - \phi(X)] = \sup_{\theta \in \Theta_1} \mathbb{P}_\theta[X \notin \mathcal{R}]. \quad (1.7)$$

Remarque 1.15

Sur Θ_0 et Θ_1 il n'y a pas de préférence (entre paramètres) exprimée sous la forme de loi de probabilités. Tous les éléments sont aussi importants ce qui explique les "sup" (= "pire cas") dans la définition.

Remarque 1.16

D'après cette terminologie, l'erreur de première espèce mesure la probabilité (maximale) de rejeter à tort, et l'erreur de seconde espèce d'accepter à tort. Dans le langage courant, nous avons deux notions, celle de « faux positif » et « faux négatif ». Pour les associer aux erreurs de type I ou II il faut préciser qui est H_0 , attention ceci peut être contre-intuitif parfois. Par exemple dans le domaine médical, un test recherche la présence d'un virus/ bactérie/ anomalie physiologique ou génétique/ ... Dans ce cas H_0 correspond à l'absence de l'anomalie (test négatif) et H_1 à la présence (test positif) ; ainsi commettre une erreur de première espèce revient à faire un « faux positif », et commettre une erreur de seconde espèce revient à faire un « faux négatif ».



Mise en garde 1.17

Dans la plupart des situations, Θ_0 est « plus petit » que Θ_1 et le contrôle de l'erreur de seconde espèce (1.7) est difficile, surtout si Θ_1 contient des points « très proches » de Θ_0 . On peut imaginer que pour des points de Θ_1 qui convergent vers un point de Θ_0 l'erreur de seconde espèce est de 100% moins l'erreur de première espèce. Elle donne alors peu d'informations nouvelles sur le test en question car elle est trop agrégée (à cause du "sup").

Pour le cas typique d'un Θ_0 singleton et Θ_1 son complémentaire, l'erreur de type II n'apporte pas d'information utile pour discriminer des tests statistiques ayant la même erreur de type I. Pour des informations plus précises, on introduit alors la fonction de puissance d'un test, qui mesure sa performance locale (= en tout point) sur l'alternative.

Définition 1.18

La fonction de puissance du test ϕ est l'application

$$\beta : \Theta_1 \rightarrow [0, 1]$$

définie par

$$\theta \in \Theta_1 \rightsquigarrow \beta(\theta) = \mathbb{P}_\theta[X \in \mathcal{R}].$$

1.7.1 Comparaison de test, principe de Neyman

Idéalement, on souhaite que l'erreur de première espèce et l'erreur de seconde espèce soient toutes deux simultanément petites. Les deux tests triviaux

$$\phi_1 = 1_\emptyset, \quad \text{et} \quad \phi_2 = 1_{\mathcal{A}}$$

qui consistent respectivement à ne jamais rejeter l'hypothèse et à la rejeter systématiquement, sans utiliser l'observation X , ont respectivement une erreur de première espèce nulle et une erreur de seconde espèce nulle. Malheureusement la puissance de ϕ_1 est catastrophique : $\beta(\theta) = 0$ en tout point θ de toute alternative Θ_1 . De même l'erreur de première espèce de ϕ_2 est égale à 1, même si l'hypothèse est réduite à un point, quelle que soit l'hypothèse.

Une méthodologie, proposée historiquement par Neyman, consiste à imposer une dissymétrie dans la problématique de test : on décide que le contrôle de l'erreur de première espèce est crucial. La démarche de construction de test sera alors, parmi les tests qui ont une erreur de première espèce contrôlée, de choisir le (ou les) test(s) le(s) plus puissant(s), c'est-à-dire ayant une erreur de seconde espèce la plus petite possible.

Définition 1.19

Soit $\alpha \in [0, 1]$ un niveau de risque. Un test ϕ est de **niveau** α si son erreur de première espèce est **inférieure ou égale** à α .

Définition 1.20

On dit qu'un test est de **taille** α si l'erreur de première espèce est **égale** à α .

Remarque 1.21

Un test veut mesurer l'adéquation de l'hypothèse H_0 avec les observations. Pour cela il détermine les valeurs typiques de X sous H_0 . Si la réalisation x de X n'est pas l'une des valeurs typiques, il rejette H_0 . Sinon, faute de mieux, il conserve H_0 .

Le niveau α peut être vu comme le risque maximal que l'on accepte de prendre en rejetant à tort H_0 .

On prend pour H_0 :

- une hypothèse communément admise
- une hypothèse de prudence (critère de coût, de sécurité etc)
- la seule hypothèse sous laquelle on peut travailler mathématiquement.

Exemple 1.22

En pratique, 2 groupes avec des visées et intérêts différents auront des couples (H_0, H_1) inversés (ex : industriels et consommateurs).

Donnons un exemple concret de ce cas : la limite légale d'un polluant contenu dans les déchets d'une usine est de 6mg/kg. On effectue un dosage sur 20 prélèvements sur lesquels on observe une moyenne empirique de 7mg/kg avec un écart-type empirique de 2.4mg/kg. On admet que la loi de dosage est gaussienne.

On observe donc $X_1, \dots, X_{20} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ avec μ et σ^2 inconnus. Pour le directeur de l'usine, l'erreur la plus grave serait de conclure que le niveau de polluant est trop élevé alors qu'il ne l'est pas. Il choisit donc comme hypothèses

$$H_0 : \mu \leq 6 \quad \text{contre} \quad H_1 : \mu > 6.$$

Prenons maintenant le point de vue de l'écologiste. Si la limite est supérieure à 8mg/kg, il y a danger. Contrairement au directeur d'usine, l'écologiste considère que l'erreur la plus grave serait de conclure que le niveau de polluant n'est pas trop élevé alors qu'en réalité il l'est. Il effectue donc le test suivant

$$H_0 : \mu \geq 8 \quad \text{contre} \quad \mu < 8.$$

1.8 Intuition et calculs : exemples de niveau L3

1.8.1 Intuition

Prenons l'exemple simple de test suivant :

$$X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2), \quad \sigma \text{ connu.}$$

$$H_0 : \mu = 3 \quad \text{contre} \quad \mu \neq 3$$

Dans la pratique : nous observons $x_1, \dots, x_n$. Comme nous voulons savoir si la moyenne est égale à 3 ou plus grande que 3, naturellement nous regardons la moyenne empirique $\bar{x}$. Imaginons que $\bar{x} = 3.5$. Alors que conclure ? Cela dépend de plusieurs facteurs, plus exactement, ça dépend ici de n et de σ .

En effet, le problème est que, évidemment, on ne tombera jamais sur 3 exactement. Imaginons que la vraie moyenne est 3. Alors comme les X_i sont aléatoires et qu'on n'en a qu'une quantité finie n , on n'a jamais l'information exacte sur μ en utilisant l'échantillon, mais seulement une information approchée et aléatoire.

Donc si la moyenne empirique vaut 3.5, la question est : est-ce que la vraie moyenne est 3 et que je tombe sur 3.5 parce que c'est aléatoire ? Ou bien est-ce que c'est parce que ce n'est pas 3 la vraie moyenne ?

Pour répondre à ces questions, il faut utiliser les tests, et surtout utiliser toutes les informations que l'on a à notre disposition (ou que l'on peut déduire des données), en particulier la taille de l'échantillon et la variance σ^2 . En effet ce sont ces deux informations qui vont nous aider à savoir si c'est "normal" de tomber sur 3.5 en ayant une vraie moyenne de 3, ou bien si c'est "anormal" (ou "atypique").

Ici regardons ce qui se passe sous H_0 , c'est-à-dire quand $\mu = 3$ (c'est toujours ce qu'on fait en fréquentiste, on regarde ce qu'il est censé se passer sous H_0 , donc asymétrie des deux hypothèses). Si on est vraiment sous H_0 , alors la question est : qu'est-ce qu'une valeur "normale" (ou "usuelle" ou "typique") de $\bar{X}$ quand $\mu = 3$? Il suffit pour cela de standardiser pour se ramener à une variable normale standard et utiliser les quantiles de $N(0, 1)$. En effet, si $\mu = 3$ on a

$$\sqrt{n} \frac{\bar{X} - 3}{\sigma} \sim N(0, 1)$$

Donc, comme le quantile d'ordre 97.5% de la loi normale standard vaut 1.96 (environ) on a

$$\mathbb{P}_3\left(\sqrt{n} \frac{|\bar{X} - 3|}{\sigma} \leq 1.96\right) = 95\%$$

Autrement dit, on peut dire que, avec une très grande probabilité, ici plus précisément avec une probabilité de 95%, la variable aléatoire

$$T = \sqrt{n} \frac{\bar{X} - 3}{\sigma}$$

se trouve dans l'intervalle $[-1.96, 1.96]$. Autrement dit, une valeur "typique" de la statistique T , si on est vraiment sous H_0 , est une valeur entre -1.96 et 1.96.

Ainsi si on tombe sur une valeur qui sort de cette intervalle, on se dit que ça n'est pas une valeur "normale" pour T sous H_0 et donc on rejette H_0 .

Il est évidemment toujours possible que, tout en étant sous H_0 , c'est-à-dire ici, tout en ayant une vraie valeur de μ égale à 3, on tombe sur une valeur observée de T qui sorte de l'intervalle $[-1.96, 1.96]$, puisque la loi normale a son support sur $\mathbb{R}$. Mais ceci se produit "rarement" et donc la possibilité de se tromper en rejetant à tort H_0 est faible : ici 5% (on prend toujours α petit). C'est l'erreur de type I.

Maintenant illustrons cette dépendance par rapport à σ et n dans notre exemple (donc on suppose toujours $\bar{x} = 3.5$) sur notre décision finale .

1. Imaginons d'abord que $\sigma = 1$ et $n = 100$. Alors la valeur observée de T est $t = \sqrt{100} \frac{3.5-3}{1} = 5$. Comme 5 est en dehors de l'intervalle $[-1.96, 1.96]$, on conclut que c'est une valeur "anormale" pour H_0 et donc on rejette H_0 .
2. Imaginons que $\sigma = 5$ et $n = 100$. Alors la valeur observée de T est $t = \sqrt{100} \frac{3.5-3}{5} = 1$. Alors on ne rejette pas H_0 . L'idée est que c'est très possible que la vraie valeur de μ soit 3 et de tomber sur une valeur aussi grande que 3.5 ici, car les données ont une grande variance.
3. Imaginons que $\sigma = 1$ et $n = 9$. Alors la valeur observée de T est $t = \sqrt{9} \frac{3.5-3}{1} = 1.5$. Alors à nouveau on ne rejette pas H_0 . L'idée est qu'une valeur de $\bar{x} = 3.5$ n'est pas "anormale" pour H_0 si on n'a pas beaucoup de données (le résultat est peu précis si on n'a très peu de données donc il n'est pas "anormal" d'avoir vraiment $\mu = 3$ tout en ayant une valeur $\bar{x}$ un peu "éloignée" de 3).

Une autre alternative H_1

Dans l'exemple précédent, nous avons choisi $H_1 : \mu \neq 3$. Comment faire si $H_1 : \mu > 3$?

On va alors juste modifier la région de rejet.

Il faut en fait toujours regarder H_1 pour savoir quand rejeter. On part donc de la statistique T , qui suit une loi normale standard sous H_0 .

Quand on est sous H_1 , cette statistique a tendance à prendre de grandes valeurs, car $\bar{X}$ est un estimateur de μ et donc $\bar{X} - 3$ est proche de $\mu - 3$ qui est strictement positif sous H_1 . Ensuite cette quantité, $\bar{X} - 3$, qui sera donc probablement strictement positive si on est sous H_1 , est multipliée par $\sqrt{n}$ (et divisée par σ) pour obtenir T . Donc on se dit, au moins si n est suffisamment grand et si μ est suffisamment éloigné de 3, que la statistique T va être "grande" sous H_1 , donc on rejette H_0 quand T est "trop grand". Donc la forme de la région de rejet est $T > c$ où c est une constante à déterminer en fonction, à nouveau, du comportement typique sous H_0 de T . Ici on a donc un encadrement unilatéral de T sous H_0 . Le quantile d'ordre 95% de $N(0, 1)$ vaut environ 1.64. On peut alors dire que

$$\mathbb{P}_3(T \leq 1.64) = 95\%$$

C'est-à-dire que, avec une grande probabilité, plus précisément ici 95%, et si on est vraiment sous H_0 , la statistique T doit être plus petite que 1.64. Donc on rejette H_0 si ce n'est pas le cas.

Fonction puissance

Un test fréquentiste est toujours basé sur une statistique dont on connaît le comportement sous H_0 et on a toujours borné l'erreur de première espèce par α . On sait donc, par construction, que si on est vraiment sous H_0 et si on rejette H_0 (à tort donc), la probabilité de se tromper est faible. Dans la construction, on regarde quand même H_1 mais c'est uniquement au moment de savoir la forme de la région de rejet. (En réalité on est quand même censé dès le départ choisir une statistique qui aura un comportement différent sous H_0 et sous H_1 , de façon à pouvoir faire la différence entre les deux hypothèses.)

Maintenant, après avoir construit le test, on est intéressé par l'erreur de seconde espèce et par la fonction puissance, c'est-à-dire, on est intéressé par ce qui se passe sous H_1 . On veut que la probabilité de rejeter H_0 , quand on est sous H_1 , soit grande, c'est-à-dire qu'on veut que la puissance soit grande. La fonction puissance nous permet de comparer différents tests de même niveau. Une des propriétés souhaitées est alors que, si on a suffisamment de données, on puisse dire qu'on est sous H_1 quand on l'est bien, avec une très grande probabilité. C'est le cas quand le test est "convergent" (ou "consistant") : la fonction puissance tend vers 1 quand n tend vers l'infini.

Évidemment, comme son nom l'indique, la puissance est une fonction, car elle dépend de l'alternative exacte. En effet en général, Θ_1 est une hypothèse composite, et on a souvent une infinité de cas possibles (exemple : $\Theta_1 = \mathbb{R} \setminus \{3\}$ ou $\Theta_1 =]3, +\infty[$). Il est évidemment plus facile de voir qu'on est sous H_1 quand le vrai μ vaut 10 que quand il vaut 3.5 (toutes choses étant égales par ailleurs). De plus, la puissance dépend également de la taille de l'échantillon et de σ .

1.8.2 Exemple de calculs de puissance

Reprenons l'exemple des données gaussiennes ci-dessus

$$X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2).$$

Calculons la puissance dans différents cas. On appelle α le niveau dans les 3 exemples ci-dessous.

1. σ connu et problème de test

$$H_0 : \mu = 3 \quad \text{contre} \quad H_1 : \mu \neq 3.$$

$\phi = \mathbb{1}_{|T|>q}$ avec $q = q_{1-\frac{\alpha}{2}}^{N(0,1)}$ et $T = \sqrt{n} \frac{\bar{X}-3}{\sigma}$. La fonction puissance, pour $\mu \neq 3$, est donnée par

$$\begin{aligned}\underline{\beta}(\mu) &= \mathbb{P}_{\mu}(|T| > q) = \mathbb{P}_{\mu}(|\sqrt{n} \frac{\bar{X}-3}{\sigma}| > q) \\ &= \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-3}{\sigma} > q) + \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-3}{\sigma} < -q) \\ &= \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-\mu+\mu-3}{\sigma} > q) + \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-\mu+\mu-3}{\sigma} < -q) \\ &= \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-\mu}{\sigma} > q + \sqrt{n} \frac{3-\mu}{\sigma}) + \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-\mu}{\sigma} < -q + \sqrt{n} \frac{3-\mu}{\sigma}) \\ &= 1 - \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-\mu}{\sigma} \leq q + \sqrt{n} \frac{3-\mu}{\sigma}) + \mathbb{P}_{\mu}(\sqrt{n} \frac{\bar{X}-\mu}{\sigma} < -q + \sqrt{n} \frac{3-\mu}{\sigma}) \\ &= 1 - \Phi(q + \sqrt{n} \frac{3-\mu}{\sigma}) + \Phi(-q + \sqrt{n} \frac{3-\mu}{\sigma})\end{aligned}$$

Quelques exemples d'applications numériques avec $\alpha = 5\%$ (arrondis à deux chiffres après la virgule) :

Code python pour calculer α, β .

```
import numpy as np
import scipy.stats as stat
import matplotlib.pyplot as plt

def puissance(alpha, sigma, n, mu_reel, mu_H0):
    q = stat.norm.ppf(1 - alpha/2)
    z = np.sqrt(n) * (mu_H0 - mu_reel) / sigma
    beta = 1 - stat.norm.cdf(q + z) + stat.norm.cdf(-q + z)
    return beta

murange = np.linspace(0, 6, 200)
betan100 = np.array([puissance(0.05, 1, 100, mu, 3.0) for mu in murange])
betan10 = np.array([puissance(0.05, 1, 10, mu, 3.0) for mu in murange])
betan2 = np.array([puissance(0.05, 1, 2, mu, 3.0) for mu in murange])

plt.plot(murange, betan100, label="n=100")
plt.plot(murange, betan10, label="n=10")
plt.plot(murange, betan2, label="n=2")
plt.xlabel(r"$\mu$")
plt.ylabel("Puissance")
plt.title(r"Puissance pour $\sigma=1$, $\mu_{H0}=3.0$")
plt.legend()
plt.show()
```

=====Resultats:=====

```
mu= 3.5  muH0= 3.0  sigma= 1  n= 100  beta( 3.5 )= 1.0
mu= 3.5  muH0= 3.0  sigma= 1  n= 10  beta( 3.5 )= 0.35
mu= 3.5  muH0= 3.0  sigma= 2  n= 100  beta( 3.5 )= 0.71
mu= 3.1  muH0= 3.0  sigma= 1  n= 100  beta( 3.1 )= 0.17
```

2. σ connu et problème de test

$$H_0 : \mu = 3 \quad \text{contre} \quad H_1 : \mu > 3.$$




FIGURE 1.2 – Fonction puissance pour les exemples du test bilatéral $\mu = 3$ contre $\mu \neq 3$.

$\phi = \mathbb{1}_{T>q}$ avec $q = q_{1-\alpha}^{N(0,1)}$ et $T = \sqrt{n} \frac{\bar{X}-3}{\sigma}$. La fonction puissance, pour $\mu > 3$, est donnée par

$$\begin{aligned} \beta(\mu) &= \mathbb{P}_\mu(T > q) = \mathbb{P}_\mu\left(\sqrt{n} \frac{\bar{X}-3}{\sigma} > q\right) = \mathbb{P}_\mu\left(\sqrt{n} \frac{\bar{X}-\mu}{\sigma} > q + \sqrt{n} \frac{3-\mu}{\sigma}\right) \\ &= 1 - \mathbb{P}_\mu\left(\sqrt{n} \frac{\bar{X}-\mu}{\sigma} \leq q + \sqrt{n} \frac{3-\mu}{\sigma}\right) = 1 - \Phi\left(q + \sqrt{n} \frac{3-\mu}{\sigma}\right). \end{aligned}$$

Dans ces deux premiers exemples, on voit immédiatement que la fonction puissance tend vers 1 lorsque $n \rightarrow \infty$. Cela signifie que pour tout μ de l'alternative et pour tout $\epsilon > 0$, il existe une taille d'échantillon n_0 telle que la probabilité de rejeter à tort H_1 , quand on est sous $\mathbb{P}_\mu$ pour ce μ particulier, est plus petite que ϵ si $n \geq n_0$. En revanche, dans les deux cas, on peut montrer que la fonction puissance ne tend pas vers 1 uniformément, ce qui signifie que ce n_0 dépend de μ (considérer par exemple la suite $\mu_n = 3 + \frac{1}{n}$). L'erreur de seconde espèce, qui est définie par un sup, ne tend pas vers 0. Voir aussi l'encadré 1.7.

Remarque 1.23

Il faut toujours **prendre des précautions dans ses conclusions quand la taille d'échantillon est petite et que le résultat du test est l'acceptation de H_0** .

Prenons l'exemple précédent pour expliquer ce fait. On pressent bien que, quand on est sous H_1 , plus $\mu - 3$ est petit, plus la probabilité de rejeter à raison H_0 est faible. Essayons de quantifier un peu plus cette intuition. Fixons une probabilité, disons $1 - \epsilon$ avec $\epsilon > 0$, et considérons maintenant la question : pour quelles valeurs de μ a-t-on $\beta(\mu) \geq 1 - \epsilon$? En utilisant l'expression précédente, on trouve

$$\mu - 3 \geq \frac{\sigma}{\sqrt{n}} (\Phi^{-1}[1 - \alpha] - \Phi^{-1}(\epsilon))$$

On voit donc que, plus n est petit, plus μ doit être loin de 3 pour satisfaire à cette inégalité.

Autrement dit, quand n est petit, et si vous êtes sous H_1 , il sera plus difficile de s'en rendre compte (à moins que le signal, i.e. ici la différence $\mu - 3$, soit vraiment fort). Donc quand votre taille d'échantillon est petite, et que votre test ne rejette pas H_0 , mettez toujours un bémol au résultat en précisant qu'il y avait peut-être un signal mais que la taille de l'échantillon n'a peut-être pas permis de le percevoir.

En revanche, si votre test rejette H_0 , et que votre taille d'échantillon est petite, pas d'inquiétude : cela signifie au contraire que le signal était particulièrement fort. D'autre part, l'erreur de première espèce, contrairement à l'erreur de seconde espèce ou à la fonction puissance, ne dépend pas de n . Donc si votre test est de niveau α , l'erreur de première espèce est inférieure à α quelle que soit la valeur de n .

3. σ inconnu et problème de test

$$H_0 : \mu = 3 \quad \text{contre} \quad H_1 : \mu > 3.$$

Si σ est inconnu, on ne peut plus baser notre test sur $T = \sqrt{n} \frac{\bar{X}-3}{\sigma}$ car T n'est plus calculable. On remplace donc σ par un estimateur, ici prenons $\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$. Avec cet estimateur $\hat{\sigma}$, on définit donc $T = \sqrt{n} \frac{\bar{X}-3}{\hat{\sigma}}$. La loi de cette statistique sous H_0 est la loi de Student à $n-1$ degrés de liberté. En effet on a

$$T = \sqrt{n} \frac{\bar{X}-3}{\hat{\sigma}} = \frac{\sqrt{n} \frac{\bar{X}-3}{\sigma}}{\frac{\hat{\sigma}}{\sigma}} = \frac{\sqrt{n} \frac{\bar{X}-3}{\sigma}}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}} \quad (1.8)$$

avec

$$\sqrt{n} \frac{\bar{X}-3}{\sigma} \sim N(0,1) \quad \text{et} \quad \frac{\hat{\sigma}^2}{\sigma^2} = \frac{\sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2}}{n-1} \sim \frac{\chi^2(n-1)}{n-1}$$

et $\bar{X}$ est indépendant de $\hat{\sigma}^2$. On pose donc $\phi = \mathbb{1}_{T>q}$ avec $q = q_{1-\alpha}^{T(n-1)}$. Ce test est appelé test de Student.

La fonction puissance, pour $\mu > 3$, est donnée par

$$\begin{aligned} \underline{\beta}(\mu) &= \mathbb{P}_\mu(T > q) = \mathbb{P}_\mu\left(\sqrt{n} \frac{\bar{X}-3}{\hat{\sigma}} > q\right) = \mathbb{P}_\mu(\sqrt{n}(\bar{X} - \mu + \mu - 3) > q\hat{\sigma}) \\ &= \mathbb{P}_\mu(\sqrt{n}(\bar{X} - \mu) > q\hat{\sigma} + \sqrt{n}(3 - \mu)) = \mathbb{P}_\mu\left(\sqrt{n} \frac{\bar{X} - \mu}{\sigma} > \frac{q\hat{\sigma} + \sqrt{n}(3 - \mu)}{\sigma}\right) \\ &= 1 - \mathbb{P}_\mu\left(\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \leq \frac{q\hat{\sigma} + \sqrt{n}(3 - \mu)}{\sigma}\right). \end{aligned}$$

Si on pose $U = \sqrt{n} \frac{\bar{X} - \mu}{\sigma}$ et $V = \frac{q\hat{\sigma} + \sqrt{n}(3 - \mu)}{\sigma}$ on a $\underline{\beta}(\mu) = 1 - \mathbb{P}(U \leq V)$ avec U et V indépendantes, puisque $\bar{X}$ et $\hat{\sigma}$ sont indépendantes. Donc, d'après l'exemple 2 de la section 1.5, $\underline{\beta}(\mu) = 1 - \mathbb{E}[F_U(V)]$ où F_U est la CDF de $U = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \sim N(0,1)$. On obtient donc finalement

$$\underline{\beta}(\mu) = 1 - \mathbb{E}\left(\Phi\left(\frac{q\hat{\sigma} + \sqrt{n}(3 - \mu)}{\sigma}\right)\right).$$

On peut ensuite vérifier que la puissance tend bien simplement vers 1 quand n tend vers l'infini. Pour cela on peut utiliser l'expression ci-dessus. Mais on peut aussi déduire cette propriété directement, sans faire appel à cette expression.

On a, sous H_1 :

- $\hat{\sigma}^2 \xrightarrow[n \rightarrow \infty]{p.s.} \sigma^2$.
- $\bar{X}_n \xrightarrow[n \rightarrow \infty]{p.s.} \mu > 3$.
- $q_{1-\alpha}^{T(n-1)} \xrightarrow[n \rightarrow \infty]{} q_{1-\alpha}^{N(0,1)}$ car la loi de Student à $n-1$ degrés de liberté tend vers la loi normale standard (cf. théorème 2.22 et exemple 2.23).

Donc $T_n \xrightarrow[n \rightarrow \infty]{p.s.} +\infty$. Par conséquent, $P_\mu(T_n > q_{1-\alpha}^{T(n-1)}) \xrightarrow[n \rightarrow \infty]{} 1$.

1.8.3 La p -valeur

Définition 1.24: p-valeur

Supposons avoir construit une famille de tests $\phi_\alpha(X)$, chacun de niveau α , pour $\alpha \in [0, 1]$. La p -valeur associée à cette famille est la variable aléatoire réelle définie par

$$p(X) = \inf\{\alpha \in [0, 1] : \phi_\alpha(X) = 1\}.$$

Interprétation de la p -valeur : plus la p -valeur observée est petite, plus on a envie de rejeter H_0 car cela signifie que la valeur observée de la statistique utilisée pour le test est atypique pour H_0 .

Remarque 1.25

On constate que $p(X)$ est le niveau à partir duquel on se met à rejeter H_0 . C'est comme si on faisait le test sans connaître le α et on tire la conclusion à la fin une fois que le α est dévoilé. Donc

- Si $p(x) < \alpha$ alors on rejette H_0 au niveau α .
- Si $p(x) > \alpha$ alors on conserve H_0 au niveau α .

Remarque 1.26

Une p -valeur petite ne veut pas dire que l'on a plus de chances d'être sous H_1 que sous H_0 : ça dépend en fait du comportement de la p -valeur sous H_1 . On sait que, sous certaines conditions du moins (cf. chapitre 2), la p -valeur suit une loi uniforme sous H_0 , mais on ne connaît pas forcément le comportement de la p -valeur sous H_1 .

De plus, la question de la probabilité de H_0 sachant les données est une question bayésienne à laquelle on peut répondre si on a un a priori sur l'alternative (il faut aussi parfois un a priori sur H_0). Attention donc à l'interprétation des p -valeurs, **ne pas dire** "la p -valeur est petite donc la probabilité que H_0 soit fausse est grande".

De plus, une p -valeur importante n'implique pas forcément que H_0 soit vraie. Il se peut que le test ne soit pas puissant. Par exemple considérons le test $\phi(X) \equiv 0$: ce test ne rejette jamais H_0 et a donc une p -valeur égale à 1^a. Un exemple moins trivial : si la taille d'échantillon est faible, la p -valeur ne sera pas particulièrement petite si le signal n'est pas particulièrement fort (pas assez fort pour compenser la faible taille d'échantillon).

^a. L'ensemble dans la définition de la p -valeur est vide, par convention on prend son sup pour définir la p -valeur, c'est-à-dire que la p -valeur est égale à 1

Exemple 1.27

Il apparait compliqué de travailler avec la p -valeur puisque celle ci fait intervenir tous les tests de la famille. Ceci peut poser des problèmes de calcul. Cependant des solutions existent. Un exemple de cas où le calcul de la p -valeur est très simple^a : supposons que le test est de la forme $\phi_\alpha(X) = \mathbb{1}_{T(X) > k_\alpha}$, que $\Theta_0 = \{\theta_0\}$ et que la statistique $T(X)$ a, sous $\mathbb{P}_{\theta_0}$, une loi de CDF F_0 strictement croissante et continue. Alors on a $k_\alpha = F_0^{-1}(1 - \alpha)$ la p -valeur observée est donnée par

$$\begin{aligned} p(x) &= \inf\{\alpha \in]0, 1[: T(x) > F_0^{-1}(1 - \alpha)\} = \inf\{\alpha \in]0, 1[: F_0(T(x)) > 1 - \alpha\} \\ &= \inf\{\alpha \in]0, 1[: \alpha > 1 - F_0(T(x))\} = 1 - F_0(T(x)). \end{aligned}$$

$$\mathbb{P}_{\theta_0}(T(X) > k_\alpha) = \alpha \iff 1 - F_0(k_\alpha) = \alpha \iff k_\alpha = F_0^{-1}(1 - \alpha).$$

^a. dans cet exemple on peut aussi appliquer directement le théorème de Wasserman

Dans ce cours, on supposera toujours que

- le test est conçu de façon à maximiser la région de rejet.
- $\phi_\alpha(X)$ décroît quand α décroît.

La première hypothèse est naturelle, elle dit que toute région de rejet plus grande (parmi ceux compatibles avec la structure du test) donnera un niveau α supérieur. Dans la définition d'un test de niveau α , on exige que l'erreur de première espèce soit plus petite que α . On a alors une infinité de solutions possibles : en effet si $\mathbb{P}_{\theta_0}(T > c_1) \leq \alpha$ alors $\mathbb{P}_{\theta_0}(T > c_2) \leq \alpha$ pour tout $c_2 > c_1$. Si on veut minimiser l'erreur de seconde espèce, il faut alors maximiser la région de rejet (et donc prendre c le plus petit possible).

La seconde hypothèse est aussi très naturelle. Elle se réécrit

$$\alpha_1 \leq \alpha_2 \implies \mathcal{R}_{\alpha_1} \subset \mathcal{R}_{\alpha_2}$$

autrement dit, si on rejette à un niveau α_1 alors on rejette aussi à tout niveau $\alpha_2 \geq \alpha_1$.

Théorème 1.28: "théorème de Wasserman"

On suppose que les tests que l'on fait à un niveau α donné maximisent la région de rejet.

- Supposons qu'une famille de tests soit de la forme $\phi_\alpha(X) = \mathbb{1}_{T(X) \leq k_\alpha}$, pour $\alpha \in]0, 1[$. Alors, si le test est de taille α , la p-valeur s'écrit

$$p(x) = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(T(X) \leq T(x)),$$

où x est la valeur observée de X .

- Pour une famille de tests de taille α de la forme $\phi_\alpha(X) = \mathbb{1}_{T(X) \geq k_\alpha}$, on a $p(x) = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(T(X) \geq T(x))$.
- Si la variable $T(X)$ a une loi discrète de CDF F_0 fixe sous H_0 et si la famille de tests est de la forme $\phi_\alpha(X) = \mathbb{1}_{T(X) \leq k_\alpha}$ alors

$$p(x) = F_0(T(x)) = \mathbb{P}_{H_0}(T(X) \leq T(x))$$

- Si la variable $T(X)$ a une loi discrète de CDF F_0 fixe sous H_0 et si la famille de tests est de la forme $\phi_\alpha(X) = \mathbb{1}_{T(X) \geq k_\alpha}$, avec les mêmes hypothèses, on a $p(x) = \mathbb{P}_{H_0}(T(X) \geq T(x))$.

Admis. Vous pouvez trouver une preuve manuscrite sur teams.

Ces formules sont encore vraies s'il existe θ_0 tel que pour tout t ,

$$\sup_{\theta \in \Theta_0} \mathbb{P}_\theta(T(X) \leq t) = \mathbb{P}_{\theta_0}(T(X) \leq t)$$

si le test s'écrit $\phi_\alpha(X) = \mathbb{1}_{T(X) \leq k_\alpha}$ ou

$$\sup_{\theta \in \Theta_0} \mathbb{P}_\theta(T(X) \geq t) = \mathbb{P}_{\theta_0}(T(X) \geq t)$$

si le test s'écrit $\phi_\alpha(X) = \mathbb{1}_{T(X) \geq k_\alpha}$

Remarque 1.29

On rencontrera souvent des tests basés sur des lois discrètes écrits sous la forme $\phi = \mathbb{1}_{T > q}$ où q sera un quantile de la loi de la statistique T sous H_0 . Le test n'est alors pas écrit directement comme dans le théorème ci-dessus. Mais si la loi de T est à valeurs entières (par exemple, car ça marche aussi pour tout ensemble discret), alors q est un entier (cf. TD L3 teams). Donc $\{T > q\} = \{T \geq q + 1\}$.

Exemple 1.30

- Soit $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ avec μ et σ^2 inconnus. On veut tester

$$H_0 : \mu = 2 \quad \text{contre} \quad H_1 : \mu \leq 2.$$

Le test utilisé est alors le test de Student (cf "exemples de calcul de puissance", item 3). Le test est alors $\phi = \mathbb{1}_{T < q_\alpha^{T(n-1)}}$ avec $T = \sqrt{n} \frac{\bar{X} - 2}{\hat{\sigma}}$. On est alors dans les conditions d'application du théorème de Wassermann, item 1 : en effet, puisque la loi de Student est une loi continue et puisque l'hypothèse nulle est simple, on a bien un test de taille α (et pas seulement de niveau α). La p -valeur observée est donc donnée par

$$p(x_1^n) = F_{T(n-1)}(T(x_1^n))$$

où $T(x_1^n)$ est l'observation de la statistique $T(X_1^n)$.

Application numérique : $n = 20$, $\frac{1}{20} \sum_{i=1}^{20} x_i = 1.34$ et $\sqrt{\frac{1}{19} \sum_{i=1}^{20} (x_i - \bar{x})^2} = 1.06$, ce qui donne la valeur observée $T(x_1^n) = \sqrt{20}(1.34 - 2)/1.06 = -2.78$. La p -valeur observée est donnée par $p(x_1^n) \approx 0.006$. On peut trouver cette valeur sur R en utilisant la commande `pt(-2.78, 19)`. Pour obtenir directement ce résultat sans faire de calcul, on peut utiliser la commande R

`t.test(x, mu=2, alternative="less")` où $x = x_1^n$ est l'échantillon observé (donc un vecteur).

- Soit $X_1, \dots, X_n \stackrel{iid}{\sim} Be(p)$. On veut tester

$$H_0 : p = 1/2 \quad \text{contre} \quad H_1 : p > 1/2.$$

On utilise la statistique $T = \sum_{i=1}^n X_i$ qui suit, sous H_0 , une loi binomiale $B(n, 1/2)$. Au vu de H_1 , on rejette quand T est trop grand. Donc on pose $\phi = \mathbb{1}_{T > c}$ où c est déterminé par le fait que le test est de niveau α

$$\mathbb{P}_{1/2}(T > c) \leq \alpha. \quad (1.9)$$

Attention ici la statistique T est discrète donc sa CDF $F_{B(n, 1/2)}$ sous $\mathbb{P}_{1/2}$ n'est pas continue. Donc on ne peut pas toujours avoir l'égalité.

On verra dans le chapitre 2 que le plus petit entier c vérifiant (1.9) est donné par $c = q_{1-\alpha}^{B(n, 1/2)}$, i.e. le quantile d'ordre $1 - \alpha$ de la loi binomiale $B(n, 1/2)$. Cela donne le test suivant

$$\phi = \mathbb{1}_{T > q_{1-\alpha}^{B(n, 1/2)}}.$$

Comme T est presque sûrement à valeurs entières, on a

$$\phi = \mathbb{1}_{T > q_{1-\alpha}^{B(n, 1/2)}} = \mathbb{1}_{\{T \geq q_{1-\alpha}^{B(n, 1/2)} + 1\}}$$

Donc il a bien l'une des formes indiquées dans le théorème de Wassermann. Nous sommes bien dans les conditions d'application de ce théorème (cas discret), ainsi

$$p(x_1^n) = \mathbb{P}(Z \geq T(x_1^n)) = 1 - \mathbb{P}(Z < T(x_1^n)) = 1 - F_{B(n, 1/2)}(T(x_1^n) - 1).$$

où Z désigne une variable aléatoire de loi $B(n, 1/2)$.

Par exemple, si $n = 20$, et si la valeur observée de $\sum_{i=1}^n X_i$ est 11 alors la p -valeur du test est $p(x_1^n) = 0.41$. Donc on a tendance à ne pas rejeter H_0 au vu des données.

On peut obtenir cette valeur sur R avec la commande `pbinom(10, 20, 1/2)`. On retrouve cette p -valeur directement utilisant la commande

`binom.test(11, 20, 1/2, alternative="greater")`

ou en Python avec les commandes

```
from scipy.stats import binom_test
binom_test(11, 20, alternative='greater')
```

Remarque 1.31

On peut faire le même type de remarques pour la p-valeur que pour la fonction puissance :

- Sous H_1 la p-valeur dépend, entre autres, de la taille d'échantillon.
- Sous H_0 la p-valeur suit souvent une loi uniforme sur $[0, 1]$ (ou une loi proche d'une loi uniforme)(cf. chap 2). Donc son comportement est connu et "fixe".

Par exemple, si on considère le problème de test $H_0 : \mu = 0$ contre $H_1 : \mu > 0$ pour des données i.i.d. de loi $\mathcal{N}(\mu, 1)$, et si on note $\bar{x}$ la moyenne empirique observée, on obtient (exercice facile)

$$p(x_1^n) = 1 - \Phi(\sqrt{n}\bar{x}).$$

où Φ est la CDF de la loi $\mathcal{N}(0, 1)$.

On voit bien que, pour une même moyenne empirique observée, si celle-ci est positive, la p-valeur sera d'autant plus petite que la taille d'échantillon sera grande.

Méthode pour construire un test

1. Choix de H_0 et H_1 .
2. Détermination de $T(X)$, la statistique de test. On doit connaître sa loi sous H_0 . Evidemment on souhaite aussi que cette statistique ait un comportement différent sous H_0 et sous H_1 pour pouvoir discriminer les deux hypothèses.
3. Allure de la zone de rejet en fonction de H_1 (i.e. en fonction du comportement de $T(X)$ sous H_1).
4. Observation de la réalisation $T(x)$ de $T(X)$.
5. Calcul de la p-valeur associée $p(x)$ et comparaison à un seuil fixé par un non-statisticien.
6. Conservation ou non de H_0 .

1.8.4 Interprétation des p-valeurs

Comme la p-valeur est définie comme un infimum, ce n'est pas forcément un "min" donc on ne sait pas a priori si $p(x) \in \{\alpha \in]0, 1[: \phi_\alpha(x) = 1\}$, c'est-à-dire qu'on ne sait pas si on rejette H_0 pour le niveau $\alpha = p(x)$. Appelons α^* la p-valeur $p(x)$ de façon à la considérer comme un niveau. Pour fixer les idées (ça ne change rien au raisonnement), supposons que $\phi_{\alpha^*}(x) = 1$, autrement dit, pour le niveau α^* on rejette H_0 . On rappelle que le niveau α est choisi comme étant la probabilité de rejeter à tort H_0 (ou un majorant de cette probabilité si on ne peut pas avoir l'égalité pour tout α).

Donc si on regarde la p-valeur comme un niveau α^* , alors on rejette pour ce niveau α^* et, si α^* est très petit, alors la probabilité de rejeter à tort est très faible. En quelque sorte, plus la p-valeur observée est petite, plus on a envie de rejeter H_0 .

Supposons que l'on ait observé une p-valeur de $p = 0.001$, qui est donc très petite. Alors pour le niveau $\alpha = 5\%$ on rejette H_0 puisque $0.001 < 0.05$. Mais en plus, le fait de connaître la p-valeur nous apporte une information supplémentaire : le fait que p soit vraiment petit ici nous donne une certaine confiance dans notre rejet. Par exemple si on avait eu $p = 0.04$ alors on aurait aussi rejeté au niveau $\alpha = 5\%$ mais on l'aurait fait avec moins d'assurance.

Les logiciels de statistique donnent toujours la p-valeur quand on leur demande de faire un test. Prenons l'exemple du test de Student. On a dans un vecteur x un échantillon de gaussiennes de moyenne et variance inconnues et on veut tester $H_0 : \mu = 1.5$ contre $\mu \neq 1.5$ où μ est la moyenne. Alors on peut utiliser la commande R suivante

```
t.test(x,mu=1.5)
```

dont la sortie est

One Sample t-test

```
data: x
t = -1.9561, df = 19, p-value =
0.06532
alternative hypothesis: true mean is not equal to 1.5
95 percent confidence interval:
0.6181763 1.5298237
sample estimates:
mean of x
1.074
```

On tombe sur une p-valeur d'environ 0.06 donc on ne rejette pas H_0 au niveau 5%. Là encore, comme la p-valeur est proche du niveau, on n'a pas une confiance énorme en le résultat final.

Interprétation à l'aide du théorème de Wassermann

Reprenons un des exemples précédents : premier item de "exemples de calculs de p -valeurs". La p -valeur s'écrit dans cet exemple $p(x_1^n) = F_{T(n-1)}(T(x_1^n))$. Dans l'application numérique, la valeur observée de la statistique T est $t = -2.78$. Si on est vraiment sous H_0 , t est alors censée être la valeur observée d'une statistique qui suit une loi de Student à 19 degrés de liberté, et la p -valeur mesure alors la probabilité qu'une variable de Student à 19 degrés de liberté soit plus petite que -2.78, c'est-à-dire la probabilité d'observer une valeur de T plus petite que -2.78 **si on est vraiment sous H_0** . Donc la p -valeur mesure en quelque sorte le côté atypique de la valeur observée, par rapport à ce qu'il est censé se passer sous H_0 .

Ici, si on était vraiment sous H_0 , il y aurait une probabilité de 1% d'observer une valeur inférieure ou égale à -2.78 pour la statistique T . Donc -2.78 est plutôt une valeur atypique pour H_0 et on penche donc pour le rejet de H_0 .