

Chapitre 2

Estimation de la fonction de répartition

2.1 Consistance des fonctions de répartition empiriques

On considère $X_1^n = (X_1, \dots, X_n)$ un n -échantillon iid de CDF F :

$$\forall x \in \mathbb{R}, \quad F(x) = \mathbb{P}(X_1 \leq x).$$

On rappelle que :

- F est croissante
- F est continue à droite
- $\lim_{x \rightarrow +\infty} F(x) = 1$ et $\lim_{x \rightarrow -\infty} F(x) = 0$.

Étant croissante, F a une limite à gauche en tout point et elle admet au plus un nombre dénombrable de discontinuités (ce sont les points x tel que $\mathbb{P}(X_j = x) \neq 0$).

Il existe un estimateur naturel de F : la fonction de répartition empirique.

Définition 2.1

La fonction de répartition empirique associée à $X_1^n = (X_1, \dots, X_n)$ est la fonction aléatoire définie par :

$$\hat{F}_n : \begin{array}{ll} \mathbb{R} & \rightarrow [0, 1] \\ x & \rightarrow \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq x} \end{array}$$

Remarque 2.2

Pour insister sur le caractère aléatoire de $\hat{F}_n$, on peut écrire parfois $\hat{F}_n(\omega, x)$ au lieu de $\hat{F}_n(x)$. $\hat{F}_n(\omega, x)$ désigne donc la valeur de la CDF $\hat{F}_n$ en x quand l'observation est ω .

Définition 2.3

Soient $X_1, \dots, X_n$ n v.a. réelles. La statistique d'ordre $X^* = (X_{(1)}, \dots, X_{(n)})$ est définie par $\{X_{(1)}, \dots, X_{(n)}\} = \{X_1, \dots, X_n\}$ et $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$.

Remarque 2.4

On construit facilement $\hat{F}_n$ car c'est une fonction en escalier. Fixons ω et écrivons $(x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega))$. Alors $\hat{F}_n(\omega, x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{x_i \leq x}$ est la fonction de répartition de la variable aléatoire Z à valeurs dans $\{x_1, \dots, x_n\}$ et telle que $\mathbb{P}(Z = x_i) = \frac{k}{n}$ si la valeur x_i apparaît k fois dans $\{x_1, \dots, x_n\}$. Par exemple, si tous les x_i distincts, alors $\hat{F}_n(\omega, \cdot)$ est la CDF de la loi uniforme sur $\{x_1, \dots, x_n\}$.

Soit $(X_{(1)}, \dots, X_{(n)})$ la statistique d'ordre associée à X_1^n . La fonction $\hat{F}_n(\omega, \cdot)$ est discontinue aux points $X_{(j)}(\omega)$. Elle a un saut égal au nombre de fois où la valeur $X_i(\omega)$ apparaît dans $\{X_1(\omega), \dots, X_n(\omega)\}$. En particulier si tous les $X_i(\omega)$ sont distincts, i.e. $X_{(j)}(\omega) < X_{(j+1)}(\omega)$ pour tout j , alors $\hat{F}_n(\omega, x) = \frac{j}{n}$ pour tout $x \in [X_{(j)}(\omega), X_{(j+1)}(\omega)[$. Dans tous les cas, elle vaut 0 sur $] - \infty, X_{(1)}(\omega)[$ et 1 sur $[X_{(n)}(\omega), +\infty[$.

Proposition 2.5

Soit $x \in \mathbb{R}$, $\hat{F}_n(x)$ est un estimateur sans biais de $F(x)$
et $\lim_{n \rightarrow \infty} \hat{F}_n(x) = F(x)$ p.s. Par ailleurs

$$\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{Loi} \mathcal{N}(0, F(x)(1 - F(x)))$$

Démonstration. $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq x}$ avec $\mathbb{1}_{X_i \leq x} \stackrel{iid}{\sim} Be(F(x))$ donc $\lim_{n \rightarrow \infty} \hat{F}_n(x) = F(x)$ p.s. découle de la LGN. La deuxième propriété vient du TCL en remarquant que $\mathbf{Var}(\mathbb{1}_{X_i \leq x}) = F(x)(1 - F(x))$. $\square$

Ce résultat est de nature paramétrique car x est fixé. On peut aller plus loin.

Théorème 2.6: Glivenko-Cantelli

Soit $(X_1, \dots, X_n)$ un n -échantillon iid de fonction de répartition F . Alors la fonction de répartition empirique est un estimateur fortement consistant de F pour la norme de la convergence uniforme :

$$\lim_{n \rightarrow \infty} \|\hat{F}_n - F\|_{\infty} = \lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| = 0 \quad \text{p.s. } \omega \in \Omega \quad (2.1)$$

On admet ce théorème. Vous pouvez trouver une preuve dans le partiel 2015.

Définition 2.7: Fonction quantile

A toute fonction de répartition F on associe son inverse généralisé $F^{(-1)}$ définie comme suit :

$$\forall q \in [0, 1] \quad F^{(-1)}(q) = \inf\{x \in \mathbb{R} : F(x) \geq q\}$$

$F^{(-1)}$ est aussi appelée la fonction quantile.

Proposition 2.8

On a $F^{(-1)} = F^{-1}$ quand F est bijective. De plus,

1. $F(F^{(-1)}(q)) \geq q$ pour tout $q \in [0, 1]$.
2. $\forall x \in \mathbb{R}, \forall q \in [0, 1], \quad F(x) \geq q \Leftrightarrow x \geq F^{(-1)}(q)$.
3. Si $U \sim U[0, 1]$ alors $F^{(-1)}(U)$ est une v.a. de fonction de répartition F .
4. Si F est continue alors $F(F^{(-1)}(q)) = q$ pour tout $q \in]0, 1[$.
5. Si Z admet pour fonction de répartition F continue alors $F(Z) \sim U[0, 1]$.
6. $F^{(-1)}$ est croissante.

Démonstration. 1. Par définition de $F^{(-1)}(q)$, il existe une suite $(u_n)_{n \geq 0}$ telle que $F(u_n) \geq q$ et $u_n \xrightarrow{n \rightarrow \infty} F^{(-1)}(q)$ en décroissant (c'est donc une limite à droite). Comme F est continue à droite, $F(u_n) \rightarrow F(F^{(-1)}(q))$. Donc $F(F^{(-1)}(q)) \geq q$.

2. • Si $F(x) \geq q$ alors par définition $F^{(-1)}(q) \leq x$.




FIGURE 2.1 – Fonction de répartition (en rouge) avec palier et saut

- Si $x \geq F^{(-1)}(q)$ alors par croissance de F on a $F(x) \geq F(F^{(-1)}(q))$ donc $F(x) \geq q$ par l'item 1.
- 3. D'après l'item 2 on a, si $t \in [0, 1]$, $\mathbb{P}(F^{(-1)}(U) \leq t) = \mathbb{P}(U \leq F(t))$ et $\mathbb{P}(U \leq F(t)) = F(t)$ car $F(t) \in [0, 1]$.
- 4. D'après l'item 1, il suffit de montrer que $F(F^{(-1)}(q)) \leq q$. Si F est continue alors $]0, 1[\subset \text{Im}(F)$, d'après le théorème des valeurs intermédiaires. Donc il existe $x_q \in \mathbb{R}$ tel que $F(x_q) = q$. Donc par définition $F^{(-1)}(q) \leq x_q$. Donc par croissance de F , $F(F^{(-1)}(q)) \leq q$.
- 5. Soit $t \in]0, 1[$. On a

$$\begin{aligned} \mathbb{P}(F(Z) < t) &= 1 - \mathbb{P}(F(Z) \geq t) = 1 - \mathbb{P}(Z \geq F^{(-1)}(t)) = \mathbb{P}(Z < F^{(-1)}(t)) \\ &= F(F^{(-1)}(t)) = t \end{aligned}$$

où on a utilisé l'item 2 pour la 2ème ligne, le fait que F est continue pour la 4ème ligne, et l'item 4 pour la dernière ligne. Comme $] - \infty, x] = \cap_{t > x}] - \infty, t[$ on a $\mathbb{P}(F(Z) \leq x) = \lim_{t \rightarrow x, t > x} \mathbb{P}(F(Z) < t) = \lim_{t \rightarrow x, t > x} t = x$. Donc $F(Z) \sim U[0, 1]$.

- 6. Soit $q_1, q_2 \in [0, 1]$ avec $q_1 \leq q_2$. Alors $\{x \in \mathbb{R} : F(x) \geq q_2\} \subset \{x \in \mathbb{R} : F(x) \geq q_1\}$ donc $F^{(-1)}(q_1) \leq F^{(-1)}(q_2)$.

□

Remarque 2.9

Les item 1 et 4 peuvent "se déduire" à partir d'un dessin. On "voit" également que les paliers de F correspondent à un point de discontinuité de $F^{(-1)}$ et qu'un saut de F correspond à un palier de $F^{(-1)}$.

Remarque 2.10

Dans un certain nombre de cas (cf exemples ci-dessous), la p -valeur $p(X)$ d'un test suit une loi uniforme sous H_0 .

Exemple 2.11

Un échantillon $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ avec σ inconnu. Problème de test $H_0 : \mu = \mu_0$ contre $H_1 : \mu \leq \mu_0$. On utilise le test de Student $\phi = \mathbb{1}_{T \leq q_{\alpha}^{T(n-1)}}$. Alors d'après le théorème de Wasserman, la p -valeur observée s'écrit $p(x_1^n) = F_{T(n-1)}(T(x_1^n))$. Donc la p -valeur $p(X_1^n)$, en tant que variable aléatoire, vérifie $p(X_1^n) = F_{T(n-1)}(T(X_1^n))$. Or $T(X_1^n) \sim T(n-1)$ sous H_0 . Donc, d'après l'item 5 de la proposition précédente, $p(X_1^n)$ suit une loi uniforme sous H_0 .

Exemple 2.12

Même contexte mais avec $H_1 : \mu \geq \mu_0$. Alors le test s'écrit $\phi = \mathbb{1}_{T \geq q_{1-\alpha}^{T(n-1)}}$. Et la p -valeur observée satisfait $p(x_1^n) = \mathbb{P}_{\mu_0}(T(X_1^n) \geq T(x_1^n)) = \mathbb{P}(Z \geq T(x_1^n))$ avec $Z \sim T(n-1)$. Donc $p(x_1^n) = 1 - F_{T(n-1)}(T(x_1^n))$. Ainsi la p -valeur, en tant que variable aléatoire, satisfait $p(X_1^n) = 1 - F_{T(n-1)}(T(X_1^n))$. A nouveau, sous H_0 , $F_{T(n-1)}(T(X_1^n)) \sim U[0, 1]$ donc $p(X_1^n) \sim U[0, 1]$.

Exemple 2.13

Même contexte mais avec $H_1 : \mu \neq \mu_0$. Alors le test s'écrit $\phi_{\alpha} = \mathbb{1}_{|T| \geq q_{1-\frac{\alpha}{2}}^{T(n-1)}}$ et la p -valeur observée s'écrit

$$\begin{aligned} p(x_1^n) &= \inf \{ \alpha \in]0, 1[: |T(x_1^n)| \geq F_{T(n-1)}^{-1}(1 - \frac{\alpha}{2}) \} \\ &= \inf \{ \alpha \in]0, 1[: F_{T(n-1)}(|T(x_1^n)|) \geq 1 - \frac{\alpha}{2} \} \\ &= \inf \{ \alpha \in]0, 1[: \alpha \geq 2[1 - F_{T(n-1)}(|T(x_1^n)|)] \} \\ &= 2[1 - F_{T(n-1)}(|T(x_1^n)|)]. \end{aligned}$$

Ainsi

$$p(X_1^n) = 2[1 - F_{T(n-1)}(|T(X_1^n)|)]$$

Pour simplifier, on note $T(X_1^n) = T$ et $F_{T(n-1)} = F$.

On se place donc pour toute la suite sous H_0 .

On prouve d'abord que $2(1 - F(|T|))$ est bien à valeurs dans $[0, 1]$. Puis on prouvera que

$$P(2[1 - F(|T|)] \leq x) = x \text{ pour } x \in]0, 1[.$$

F est la CDF de $T(n-1)$, donc F correspond à une loi symétrique et continue. Donc $F(x) = 1 - F(-x)$. Donc $F(0) = 1/2$ et comme F est croissante, on a $u \geq 0 \implies F(u) \geq 1/2$. Ainsi $F(|T|) \geq 1/2$. De plus $F(|T|) \leq 1$, donc le premier point est prouvé.

On a ensuite si $x \in]0, 1[$,

$$\begin{aligned} \mathbb{P}(2[1 - F(|T|)] \leq x) &= \mathbb{P}(F(|T|) \geq 1 - \frac{x}{2}) \\ &= \mathbb{P}(F(T) \geq 1 - \frac{x}{2}, T \geq 0) + \mathbb{P}(F(-T) \geq 1 - \frac{x}{2}, -T \geq 0) \\ &= 2\mathbb{P}(F(T) \geq 1 - \frac{x}{2}, T \geq 0) = 2\mathbb{P}(F(T) \geq 1 - \frac{x}{2}) = x \end{aligned}$$

On a utilisé

- la symétrie de la loi de T .
- $1 - \frac{x}{2} > 1/2$ si $x \in]0, 1[$. Et comme $F(0) = 1/2$ et F est strictement croissante, on a $F(u) \geq \frac{1}{2} \implies u \geq 0$.

— dans la dernière égalité : $1 - F(T) \sim U[0, 1]$ et $\frac{x}{2} \in]0, 1[$.
Donc, à nouveau, $p(X_1^n) \sim U[0, 1]$ sous H_0 .

Exemple 2.14: Un exemple de calcul de p-valeur avec une stat de loi discrète

Reprenons l'exemple 1.30 : $X_1, \dots, X_n \stackrel{iid}{\sim} Be(p)$. On veut tester

$$H_0 : p = 1/2 \quad \text{contre} \quad p > 1/2.$$

On utilise la statistique $T = \sum_{i=1}^n X_i$ qui suit, sous H_0 , une loi binomiale $B(n, 1/2)$. Au vu de H_1 , on pose

$$\varphi = \mathbb{1}_{T > q_{1-\alpha}^{B(n, 1/2)}}.$$

Les quantiles d'une v.a. à valeurs dans un ensemble discret $\{x_1, \dots, x_r\}$ sont aussi à valeurs dans cet ensemble. Donc les quantiles de la loi $B(n, 1/2)$ sont des entiers. De plus, $T(x_1^n)$ est également un entier. Donc $\{T > q_{1-\alpha}^{B(n, 1/2)}\} = \{T \geq q_{1-\alpha}^{B(n, 1/2)} + 1\}$. Ainsi on peut utiliser le théorème de Wasserman. La p-valeur observée est donc donnée par

$$p(x_1^n) = P_{p=1/2}(T(X_1^n) \geq T(x_1^n))$$

La p-valeur, en tant que variable aléatoire est donc donnée par

$$1 - F_{B(n, 1/2)}(T(X_1^n) - 1)$$

(Elle ne suit pas tout à fait une loi uniforme).

On peut en fait retrouver directement le résultat du théorème de Wasserman :

$$\begin{aligned} p(x_1^n) &= \inf \{ \alpha \in]0, 1[: T(x_1^n) > F_{B(n, 1/2)}^{(-1)}(1 - \alpha) \} \\ &= \inf \{ \alpha \in]0, 1[: T(x_1^n) \geq F_{B(n, 1/2)}^{(-1)}(1 - \alpha) + 1 \} \\ &\stackrel{\text{item 2 prop 2.8}}{=} \inf \{ \alpha \in]0, 1[: F_{B(n, 1/2)}(T(x_1^n) - 1) \geq 1 - \alpha \} \\ &= \inf \{ \alpha \in]0, 1[: \alpha \geq 1 - F_{B(n, 1/2)}(T(x_1^n) - 1) \} \\ &= 1 - F_{B(n, 1/2)}(T(x_1^n) - 1) \\ &= P_{p=1/2}(T(X_1^n) \geq T(x_1^n)) \end{aligned}$$

2.2 Estimation de quantiles

Pour la construction de tests et de régions de confiance, on s'appuie sur la notion de quantiles. On rappelle la définition générale d'un quantile.

Définition 2.15

Pour $\beta \in]0, 1[$, on appelle quantile d'ordre β d'une loi de probabilité P à support dans $\mathbb{R}$ la quantité

$$q_\beta = \inf \{ x \in \mathbb{R} : \mathbb{P}(] - \infty, x]) \geq \beta \}$$

Autrement dit, en utilisant la fonction inverse généralisée, si P admet F pour fonction de répartition

$$q_\beta = F^{(-1)}(\beta)$$

Exemple 2.16

Soit la loi $\frac{\delta_0 + \delta_1 + \delta_2}{3}$ *a*. Le quantile d'ordre 25% est 0 et le quantile d'ordre 75% est 2.

a. C'est la loi uniforme sur $\{0, 1, 2\}$.

Proposition 2.17

1. Quand la fonction de répartition F est inversible, le quantile d'ordre β est égale à $F^{-1}(\beta)$ et alors on a $F(q_\beta) = \beta$. Et le quantile est l'unique solution de cette équation.
2. Plus généralement si F est continue, on a $F(q_\beta) = \beta$ (mais la solution n'est pas unique)
3. On a toujours $F(q_\beta) \geq \beta$ et, $F(q_\beta^-) \leq \beta$, i.e $P(X < q_\beta) \leq \beta$. Autrement dit

$$P(X \leq q_\beta) \geq \beta \quad \text{et} \quad P(X \geq q_\beta) \geq 1 - \beta.$$

Démonstration. 1. évident.

2. $F(q_\beta) = \beta$ est l'item 4 de la proposition 2.8.

3. $F(x^-) \equiv \lim_{t \rightarrow x, t < x} F(t) = \lim_{t \rightarrow x, t < x} P(X \leq t) = P(X < x)$. De plus si $t < q_\beta$ alors, par définition de q_β , on a $F(t) < \beta$. Donc $F(q_\beta^-) \leq \beta$. □

Exemple 2.18

En utilisant le point 3 de la proposition 2.17 il s'en suit que la médiane m vérifie :

$$\mathbb{P}(X \leq m) \geq 1/2 \quad \text{et} \quad \mathbb{P}(X \geq m) \geq 1/2.$$

De plus, lorsque F est continue ou si $\mathbb{P}(X = m) = 0$:

$$\mathbb{P}(X \leq m) = \mathbb{P}(X < m) = \mathbb{P}(X > m) = \mathbb{P}(X \geq m) = 1/2. \quad (2.2)$$

Remarque 2.19

D'autres conventions existent pour la définition d'un quantile. On peut aussi définir un quantile de manière non unique. Souvent, on appelle quantile d'ordre β de la loi F tout nombre q_β tel que

$$P(X \leq q_\beta) \geq \beta \quad \text{et} \quad P(X \geq q_\beta) \geq 1 - \beta. \quad (2.3)$$

Proposition 2.20

Soit X une variable aléatoire réelle de CDF F , et $\alpha \in]0, 1[$.

Le plus petit réel c tel que $\mathbb{P}(X > c) \leq \alpha$ est égal à $q_{1-\alpha}^F$.

Démonstration. $\mathbb{P}(X > c) \leq \alpha \Leftrightarrow \mathbb{P}(X \leq c) \geq 1 - \alpha$. Par définition, le plus petit réel c vérifiant cette inégalité est $F^{(-1)}(1 - \alpha)$. □

Exemple 2.21

Soit $X_1, \dots, X_n \stackrel{iid}{\sim} Be(p)$. On veut tester au niveau α

$$H_0 : p = 1/2 \quad \text{contre} \quad p > 1/2.$$

On utilise une procédure de test $\varphi_\alpha = \mathbb{1}_{\sum_{i=1}^n X_i > c}$ avec c choisi tel que le niveau du test soit

plus petit que α et tel que la région de rejet soit maximisée. On choisit donc $c = q_{1-\alpha}^{B(n,1/2)}$.

On admet le théorème suivant. Une preuve, pour les étudiants intéressés, se trouve dans le corrigé de l'examen 2018.

Théorème 2.22

Soit $(F_n)_{n \geq 0}$ une suite de fonctions de répartition sur $\mathbb{R}$ et F une fonction de répartition sur $\mathbb{R}$. Alors F_n converge vers F en tout point de continuité de F si et seulement si $F_n^{(-1)}$ converge vers $F^{(-1)}$ en tout point de continuité de $F^{(-1)}$.

Exemple 2.23

La loi de Student à n degrés de liberté tend vers la loi normale standard. Φ^{-1} est continue (Φ =CDF de $\mathcal{N}(0,1)$). Donc, pour tout $\alpha \in]0,1[$, $q_\alpha^{T(n)} \xrightarrow{n \rightarrow \infty} q_\alpha^{\mathcal{N}(0,1)}$.

On a besoin des quantiles pour les procédures de tests ainsi que pour les régions de confiance. Parfois on ne sait pas calculer les quantiles de la loi mais on sait simuler cette loi. Le quantile empirique peut alors être utilisé en remplacement du vrai quantile.

On rappelle la notation suivante pour les statistiques d'ordre :

$$X_{(1)} \leq \dots \leq X_{(n)}$$

Définition 2.24

Le quantile empirique d'un n échantillon i.i.d. $X = (X_1, \dots, X_n)$ est défini, pour $\beta \in]0,1[$, par

$$\hat{q}_{n,\beta} = \hat{F}_n^{(-1)}(\beta)$$

Il s'agit donc des quantiles de la loi empirique.

Proposition 2.25

$$\hat{F}_n^{(-1)}(\beta) = X_{(\lceil n\beta \rceil)}$$

où on a noté $\lceil t \rceil = \min\{m \in \mathbb{N} : m \geq t\}$.

On trouve donc facilement les quantiles empiriques en ordonnant les x_i .

Démonstration. (non exigée) On va utiliser la propriété immédiate suivante : pour tout x ,

$$x \leq \lceil x \rceil < x + 1.$$

1. Il y a au moins $\lceil n\beta \rceil$ indices $i \in [n]$ tels que $X_i \leq X_{(\lceil n\beta \rceil)}$ donc

$$\hat{F}_n(X_{(\lceil n\beta \rceil)}) \geq \frac{\lceil n\beta \rceil}{n} \geq \beta. \quad (2.4)$$

2. Soit $x < X_{(\lceil n\beta \rceil)}$. Il y a au plus $\lceil n\beta \rceil - 1$ indices $i \in [n]$ tels que $X_i \leq x$ donc

$$\hat{F}_n(x) \leq \frac{\lceil n\beta \rceil - 1}{n} < \beta. \quad (2.5)$$

(2.4) et (2.5) donnent le résultat. □

Exemple 2.26

Pour $n = 101$ le premier quartile empirique est donné par $\hat{F}_{101}^{(-1)}(1/4) = \hat{q}_{101,25\%} = X_{(26)}$.

Le théorème de Glivenko-Cantelli assure que $\|\hat{F}_n - F\|_\infty \rightarrow 0$ presque sûrement. On s'attend donc à ce que $\hat{q}_{n,\beta}$ soit proche de q_β quand n est grand.

Théorème 2.27

Soit $\beta \in]0, 1[$ tel que $F^{(-1)}$ est continue en β . Alors on a

$$\lim_{n \rightarrow \infty} \hat{q}_{n,\beta} = q_\beta \quad p.s.$$

Démonstration. D'après le théorème de Glivenko-Cantelli, il existe un ensemble mesurable A tel que $\mathbb{P}(A) = 1$ et si $\omega \in A$, $\|\hat{F}_n(\omega, \cdot) - F(\cdot)\|_\infty \xrightarrow{n \rightarrow \infty} 0$. Soit $\omega \in A$. On a en particulier $\hat{F}_n(\omega, t) \xrightarrow{n \rightarrow \infty} F(t)$ pour tout $t \in \mathbb{R}$. Donc $\hat{F}_n^{(-1)}(\omega, t) \xrightarrow{n \rightarrow \infty} F^{(-1)}(t)$ en tout point de continuité t de $F^{(-1)}$ d'après le théorème 2.22. $\square$

Remarque 2.28

Un point de continuité β pour $F^{(-1)}$ correspond à point de croissance stricte q_β pour F .

Remarque 2.29

On voit donc que si on ne sait pas calculer facilement le quantile d'une loi, mais si on sait simuler cette loi, on peut avoir une valeur approchée de ses quantiles en simulant un échantillon suffisamment grand et en calculant le quantile empirique. Une question associée est : quelle est la taille d'échantillon nécessaire pour avoir une précision donnée ? Le théorème suivant donne en partie une réponse à cette question. On admet ce théorème.

Théorème 2.30

Si F est dérivable en q_β avec $F'(q_\beta) > 0$ alors

$$\sqrt{n}(\hat{q}_{n,\beta} - q_\beta) \xrightarrow[n \rightarrow \infty]{Loi} \mathcal{N}\left(0, \frac{\beta(1-\beta)}{(F'(q_\beta))^2}\right)$$

Remarque 2.31

Les conditions du théorème sont en particulier vérifiées si la loi F est à densité f strictement positive sur $\mathbb{R}$. Pour construire un IC pour q_β , il faut alors connaître $f(q_\beta)$.

Si on connaît la densité, on peut s'en sortir comme dans la partie B du partiel 2014.

On peut cependant donner un IC sur $q_\beta = F^{-1}(\beta)$ même sans connaître la densité (cf. par ex. le polycopié d'Arnaud Guyader, Partie I, pages 53-54 : <https://perso.lpsm.paris/~aguyader/files/teaching/M1/PolycopiePartie1.pdf>).

2.3 Test d'ajustement à une loi ou à une famille de lois

2.3.1 Ajustement à une loi donnée

On fixe une loi de référence, de fonction de répartition F_0 et on observe un n -échantillon i.i.d. $X_1^n = (X_1, \dots, X_n)$ dont on note F la fonction de répartition commune. On veut tester

$$H_0 : F = F_0 \quad \text{contre} \quad H_1 : F \neq F_0$$

On va naturellement utiliser la statistique de test suivante

$$h_n(X_1^n, F_0) = \|\hat{F}_n - F_0\|_\infty$$

Dans la suite cette statistique est appelée statistique de Kolmogorov-Smirnov (KS).

Remarque 2.32

Il s'agit bien d'une statistique, c'est-à-dire que h_n est bien mesurable. En effet on peut montrer (grâce à la continuité à droite) que

$$h_n(X_1^n, F_0) = \sup_{x \in \mathbb{Q}} |\hat{F}_n(x) - F_0(x)|.$$

Proposition 2.33

On suppose F_0 et F continues. Alors (non exigé)

$$h_n(X_1^n, F_0) = \max_{1 \leq j \leq n} \left\{ \max \left\{ \frac{j}{n} - F_0(X_{(j)}), F_0(X_{(j)}) - \frac{j-1}{n} \right\} \right\}$$

Ce qu'il faut retenir 2.34

La forme particulière de la CDF empirique (constante par morceaux, valeurs j/n , voir illustration dans la figure 2.2) permet un calcul simple de la statistique associée au test de KS.

Démonstration. (non exigée) Comme F est continue, presque sûrement, tous les X_i sont distincts (cf. exercice 1 TD1). Donc $X_{(1)} < X_{(2)} < \dots < X_{(n)}$. Donc on peut décrire $\hat{F}_n$ de la manière suivante :

$$\hat{F}_n(x) = \begin{cases} 0 & \text{si } x < X_{(1)} \\ \frac{j}{n} & \text{si } x \in [X_{(j)}, X_{(j+1)}[, \quad 1 \leq j \leq n-1 \\ 1 & \text{si } x \geq X_{(n)} \end{cases}$$

On va donc utiliser l'égalité suivante

$$h_n(X_1^n, F_0) = \sup_{0 \leq j \leq n} M_j$$

où, pour $1 \leq j \leq n-1$,

$$M_j = \sup_{x \in [X_{(j)}, X_{(j+1)}[} |\hat{F}_n(x) - F_0(x)|,$$

et

$$M_0 = \sup_{x < X_{(1)}} |\hat{F}_n(x) - F_0(x)| \quad \text{et} \quad M_n = \sup_{x \geq X_{(n)}} |\hat{F}_n(x) - F_0(x)|$$

En utilisant la croissance de F_0 on obtient

$$M_n = \sup_{x \geq X_{(n)}} |1 - F_0(x)| = \sup_{x \geq X_{(n)}} \{1 - F_0(x)\} = 1 - F_0(X_{(n)})$$

et

$$M_0 = \sup_{x < X_{(1)}} |0 - F_0(x)| = \sup_{x < X_{(1)}} F_0(x) = F_0(X_{(1)}^-)$$

Et par la continuité de F_0 , $M_0 = F_0(X_{(1)})$. Considérons maintenant M_j pour $1 \leq j \leq n-1$. On a

$$M_j = \sup_{x \in [X_{(j)}, X_{(j+1)}[} \left| \frac{j}{n} - F_0(x) \right|.$$




FIGURE 2.2 – Différence entre fonction de répartition empirique et exacte pour la loi normale et différentes valeurs de n .

Soit f une fonction croissante et continue sur un segment $[a, b]$. On a

$$\begin{aligned} \sup_{a \leq x < b} |f(x)| &= \sup_{a \leq x < b} \left\{ \sup\{f(x), -f(x)\} \right\} = \sup \left\{ \sup_{a \leq x < b} f(x), \sup_{a \leq x < b} -f(x) \right\} \\ &= \sup \left\{ \sup_{a \leq x < b} f(x), -\inf_{a \leq x < b} f(x) \right\} = \max\{f(b), -f(a)\}. \end{aligned}$$

En appliquant cette propriété à la fonction croissante et continue $F_0 - \frac{j}{n}$, on obtient

$$M_j = \max\{F_0(X_{(j+1)}) - \frac{j}{n}, \frac{j}{n} - F_0(X_{(j)})\}.$$

En rassemblant tous les résultats on obtient finalement

$$h_n(X_1^n, F_0) = \max \left\{ \max_{1 \leq j \leq n-1} \{F_0(X_{(j+1)}) - \frac{j}{n}\}, \max_{1 \leq j \leq n-1} \{\frac{j}{n} - F_0(X_{(j)})\}, F_0(X_{(1)}), 1 - F_0(X_{(n)}) \right\}$$

On obtient le résultat final en remarquant que

$$\max \left\{ \max_{1 \leq j \leq n-1} \{\frac{j}{n} - F_0(X_{(j)})\}, 1 - F_0(X_{(n)}) \right\} = \max_{1 \leq j \leq n} \{\frac{j}{n} - F_0(X_{(j)})\}$$

et

$$\begin{aligned} \max \left\{ \max_{1 \leq j \leq n-1} \{F_0(X_{(j+1)}) - \frac{j}{n}\}, F_0(X_{(1)}) \right\} &= \max \left\{ \max_{2 \leq j \leq n} \{F_0(X_{(j)}) - \frac{j-1}{n}\}, F_0(X_{(1)}) \right\} \\ &= \max_{1 \leq j \leq n} \{F_0(X_{(j)}) - \frac{j-1}{n}\} \end{aligned}$$

□

Définition 2.35

On dit qu'une variable Z est **diffuse** si sa CDF est continue, c'est-à-dire si

$$\forall x \in \mathbb{R} : \mathbb{P}(Z = x) = 0. \quad (2.6)$$

Définition 2.36

Si la loi d'une statistique $\hat{g}(X_1, \dots, X_n)$ ne dépend pas de la CDF F_0 de l'échantillon X_1^n , on dit que cette statistique est « libre de F_0 ».

Nous faisons maintenant deux remarques utiles pour la preuve de la proposition suivante.

Remarque 2.37

Si $F : \mathbb{R} \rightarrow [0, 1]$ est une fonction de répartition alors

$$F \text{ continue} \Leftrightarrow]0, 1[\subset F(\mathbb{R})$$

En effet

- Si F est continue alors on peut appliquer le théorème des valeurs intermédiaires.
- Si F n'est pas continue, alors il y a au moins un saut en un certain $x \in \mathbb{R}$, alors les valeurs entres $F(x)$ et $F(x^-)$ ne sont pas prises par F .

Remarque 2.38

Si $Z = \max_{j=1, \dots, k} X_j$ avec des variables X_j diffuses, alors Z est diffuse. En effet, pour tout x ,

$$\mathbb{P}(Z = x) \leq \mathbb{P}(\cup_{j=1}^k \{X_j = x\}) \leq \sum_{j=1}^k \mathbb{P}(X_j = x) = 0$$

Proposition 2.39

Sous H_0 , si F_0 est continue alors la statistique $h_n(X_1^n, F_0)$ du test d'adéquation de K-S est une statistique libre de F_0 et de loi continue.

Démonstration. Soit $U_1^n = (U_1, \dots, U_n)$ est un n -échantillon i.i.d. de loi uniforme sur $]0, 1[$. Sous H_0 , comme $X_i \stackrel{i.i.d.}{\sim} F_0$, on a $(X_1, \dots, X_n) \sim (F_0^{(-1)}(U_1), \dots, F_0^{(-1)}(U_n))$ d'après la proposition 2.8. On a donc aussi, sous H_0 ,

$$h_n(X_1^n, F_0) \sim \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{F_0^{(-1)}(U_i) \leq x} - F_0(x) \right|$$

En utilisant l'item 2 de la proposition 2.8, on obtient

$$\begin{aligned} \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{F_0^{(-1)}(U_i) \leq x} - F_0(x) \right| &= \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq F_0(x)} - F_0(x) \right| \\ &= \sup_{s \in Im(F_0)} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right| \end{aligned}$$

En utilisant la remarque 2.37, ceci donne, presque sûrement,

$$\sup_{s \in Im(F_0)} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right| = \sup_{s \in]0, 1[} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right|.$$

En effet on a $]0, 1[\subset \text{Im}(F_0) \subset [0, 1]$ et la valeur de la fonction $s \mapsto \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s$ en $s = 0$ et en $s = 1$ est égale à 0 presque sûrement. On a donc obtenu que, sous H_0

$$h_n(X_1^n, F_0) \sim h_n(U_1^n, G)$$

où on a noté G la fonction de répartition de la loi uniforme sur $[0, 1]$, i.e. la fonction définie par $G(s) = s$ pour $s \in [0, 1]$. Cela montre que la loi, sous H_0 , de $h_n(X_1^n, F_0)$ est libre de F_0 .

On prouve maintenant que la loi de $h_n(U_1^n, G)$ est continue (preuve non exigée). D'après la proposition 2.33, comme G est continue,

$$h_n(U_1^n, G) = \max_{1 \leq j \leq n} \left\{ \max \left\{ \frac{j}{n} - U_{(j)}, U_{(j)} - \frac{j-1}{n} \right\} \right\}.$$

Comme la loi des U_j est absolument continue par rapport à la mesure de Lebesgue, celle de $U_{(j)}$ aussi (voir aussi l'exercice 1 du TD1, on a même ici $U_{(j)} \sim \text{Beta}(j, n-j+1)$). Donc, d'après la remarque 2.38, $h_n(U_1^n, G)$ est bien de loi continue. $\square$

Exemple 2.40

Soit $X_1, \dots, X_n \stackrel{iid}{\sim} N(0, 1)$ et $Y_1, \dots, Y_n \stackrel{iid}{\sim} \exp(1)$ alors

$$\sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq x} - \Phi(x) \right| \sim \sup_{x > 0} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{Y_i \leq x} - (1 - \exp(-x)) \right| \sim \sup_{s \in]0, 1[} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right|$$

(Φ est la CDF de $\mathcal{N}(0, 1)$)

Pour tout $\alpha \in]0, 1[$, si on note $q_{n,\alpha}$ le quantile d'ordre α de la loi de la statistique $h_n(U_1^n, G)$, on a donc, par continuité de cette loi,

$$\mathbb{P}_{X_1, \dots, X_n \stackrel{iid}{\sim} F_0} (h_n(X_1^n, F_0) \leq q_{n,\alpha}) = \alpha.$$

Pour les petites valeurs de n , on a tabulé les quantiles de cette statistique.

On en déduit une bande de confiance de niveau $1 - \alpha$ en posant

$$\begin{aligned} B(n, \alpha) &= \{ \text{fonctions de répartitions } G | \forall x \in \mathbb{R} \quad \hat{F}_n(x) - q_{n,1-\alpha} \leq G(x) \leq \hat{F}_n(x) + q_{n,1-\alpha} \} \\ &= \{ G : h_n(X_1^n, G) \leq q_{n,1-\alpha} \} \end{aligned}$$

Pour tester $H_0 : F = F_0$ contre $H_1 : F \neq F_0$, on pose

$$\varphi_\alpha(X_1^n) = \mathbb{1}_{h_n(X_1^n, F_0) \geq q_{n,1-\alpha}}.$$

On a donc obtenu le résultat suivant

Théorème 2.41: Test de Kolmogorov-Smirnov

Soit $(X_1, \dots, X_n)$ un n -échantillon iid de fonction de répartition F . Le test $\phi_\alpha(X_1^n)$ est de taille α pour tester $H_0 : F = F_0$ contre $H_1 : F \neq F_0$ quand F_0 est continue.

Remarque 2.42

Quand F_0 n'est pas continue, le test n'est plus de taille α mais il reste de niveau α . En effet on a, d'après la preuve de la Proposition 2.39,

$$h_n(X_1^n, F_0) \sim \sup_{s \in \text{Im}(F_0)} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right|$$

(En effet, la continuité de F_0 n'est pas nécessaire pour obtenir cette égalité en loi). Et comme

$$\sup_{s \in Im(F_0)} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right| \leq \sup_{s \in]0,1[} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - s \right|,$$

on a

$$\mathbb{P}_{X_1, \dots, X_n \stackrel{iid}{\sim} F_0} (h_n(X_1^n, F_0) \geq \xi_{n,1-\alpha}) \leq \mathbb{P}(h_n(U_1^n, G) \geq \xi_{n,1-\alpha}) = \alpha.$$

Remarque 2.43

Quand le nombre de données n est grand, on utilise un test asymptotique.

On a aussi l'inégalité de Dvoretzky-Kiefer-Wolfowitz ^a, et qui est valable sans condition sur F_0 .

Sous $H_0 : X_1, \dots, X_n \stackrel{iid}{\sim} F_0$, (non exigé)

$$\mathbb{P}(\|\hat{F}_n - F_0\|_\infty > \epsilon) \leq 2e^{-2n\epsilon^2} \text{ pour tout } n \in \mathbb{N} \text{ et tout } \epsilon > 0.$$

^a. Plus précisément, l'inégalité avec la constante 2 est due à Massart

Implémentation 2.44

1. R :

- Si on veut vérifier qu'un échantillon x suit bien une loi gaussienne de moyenne 3 et d'écart-type 2 :

```
ks.test(x, "pnorm", 3, 2)
```

- Si on veut vérifier qu'un échantillon x suit bien une loi gamma avec 3 comme paramètre de forme et 2 pour le taux :

```
ks.test(x, "pgamma", 3, 2)
```



Mise en garde 2.45

Attention, la fonction `ks.test` se comporte mal en cas d'ex æquo (dans le cas du test d'égalité des lois de deux échantillons, il ne faut pas avoir un ex æquo de type $x_i = y_j$). En théorie, on ne peut pas avoir deux valeurs identiques si la loi sous-jacente est continue. Mais dans la pratique, l'imprécision des mesures peut engendrer des ex æquo dans l'échantillon.

Illustration de ce comportement (ici la valeur 4.25 apparaît deux fois dans l'échantillon) :

```
x= c(4.25, 7.79, 5.18, 8.43, 4.25, 5.71, 4.1 , 4.2)
```

```
ks.test(x, "pnorm", mean=5, sd=1)
```

Résultat de l'exécution :

One-sample Kolmogorov-Smirnov test

```
data: x
```

```
D = 0.27337, p-value = 0.5883
```

```
alternative hypothesis: two-sided
```

Warning message:

```
In ks.test(x, "pnorm", mean = 5, sd = 1) :
```

```
ties should not be present for the Kolmogorov-Smirnov test
```

On peut éviter le message d'avertissement concernant les ex aequo en modifiant légèrement l'une des valeurs ex-aequo :

```
x= c(4.2500001, 7.79, 5.18, 8.43, 4.25, 5.71, 4.1 , 4.2)
```

```
ks.test(x,"pnorm",mean=5, sd=1)
```

Resultat de l'exécution :

One-sample Kolmogorov-Smirnov test

```
data: x
D = 0.27337, p-value = 0.5045
alternative hypothesis: two-sided
```

On observe effectivement une valeur du niveau de significativité assez différent du précédent.

- Dans le cas où on veut tester qu'un échantillon x suit bien une loi normale, sans préciser la moyenne ou la variance (cf section 2.3.2 et TD2), on peut utiliser la fonction `lillie.test` du package `nortest` :

```
library(nortest)
lillie.test(x)
```

2. Python :

Sous Python il y a deux possibilités ;

- la première, si on veut rester dans l'environnement R, est d'appeler les commandes R. Par exemple on peut faire :

```
from rpy2 import robjects
rks=robjects.r('ks.test')
```

Ensuite on utilise normalement la fonction qu'on a appelée `rks`, en prenant garde de transformer aussi les entrées. Par exemple si on a un échantillon dans le vecteur `x`, et si on veut vérifier qu'il s'agit d'un échantillon gaussien standard :

```
y=robjects.FloatVector(x)
z=rks(y,"pnorm")
```

- Une variante est d'utiliser directement les fonctions natives telles que `stats.kstest` ; cette fonction se comporte différemment de R en cas d'ex aequo. On teste ici si l'échantillon suit une loi $\mathcal{N}(5, 1)$:

```
from scipy import stats
x =[4.25, 7.79, 5.18, 8.43, 4.25, 5.71, 4.1, 4.2]
stats.kstest(x,'norm',args=(5.,1.))
Out[178]: KstestResult(statistic=0.2733726476231318, pvalue=0.504516077747122)
```

```
from scipy import stats
x =[4.2500001, 7.79, 5.18, 8.43, 4.25, 5.71, 4.1, 4.2]
stats.kstest(x,'norm',args=(5.,1.))
Out[180]: KstestResult(statistic=0.2733726175093874, pvalue=0.5045162143226165)
```

2.3.2 Ajustement à une famille paramétrique de lois : le cas des familles exponentielles

Soit $(X_1, \dots, X_n)$ un n - échantillon iid de variables positives de fonction de répartition F .

On veut tester si la loi des X_i est exponentielle, c'est-à-dire on veut tester s'il existe un $\lambda > 0$ tel que $F = F_\lambda$ avec $F_\lambda(x) = (1 - e^{-\lambda x})\mathbb{1}_{\mathbb{R}_+}(x)$ pour tout $x \in \mathbb{R}$. Cette hypothèse correspond à H_0 ¹.

Sous H_0 on va estimer le paramètre λ . L'estimateur du maximum de vraisemblance (noté EMV) est $\hat{\lambda} = 1/\bar{X}$. On considère alors la statistique

$$h'_n(X_1^n) = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_{\hat{\lambda}}(x)| \text{ où } \hat{\lambda} = 1/\bar{X}$$

Proposition 2.46

Sous H_0 , la loi de $h'_n(X_1^n)$ est libre du paramètre λ . De plus cette loi est continue.

Démonstration. On se place sous H_0 . On pose $Y_i = \lambda X_i$, pour $1 \leq i \leq n$. Alors $Y_1, \dots, Y_n \stackrel{iid}{\sim} \exp(1)$.

$$\begin{aligned} h'_n(X_1^n) &= \sup_{x>0} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq x} - (1 - e^{-\frac{x}{\bar{X}}}) \right| = \sup_{x>0} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\frac{Y_i}{\lambda} \leq x} - (1 - e^{-\frac{\lambda x}{\bar{Y}}}) \right| \\ &= \sup_{t>0} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{Y_i \leq t} - (1 - e^{-\frac{t}{\bar{Y}}}) \right| \end{aligned} \quad (2.7)$$

La statistique $\sup_{t>0} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{Y_i \leq t} - (1 - e^{-\frac{t}{\bar{Y}}}) \right|$ a une loi indépendante de λ . On admet la continuité de cette loi. $\square$

On en déduit un test de taille α en posant $\phi_\alpha(X_1^n) = \mathbb{1}_{h'_n(X_1^n) \geq q_{n,1-\alpha}}$, où $q_{n,1-\alpha}$ est le quantile d'ordre $1 - \alpha$ de la loi de $\sup_{t>0} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{Y_i \leq t} - (1 - e^{-\frac{t}{\bar{Y}}}) \right|$ avec $Y_1, \dots, Y_n \stackrel{iid}{\sim} \exp(1)$.

Remarque 2.47

On peut aussi faire le même type de test avec un certain nombre de familles de lois (cf. TD 2 pour un exemple avec les lois normales).



Mise en garde 2.48

Attention il s'agit d'un problème de test différent du problème de test de Kolmogorov-Smirnov de la section précédente. Dans ce dernier, on veut savoir si l'échantillon suit une loi exponentielle de paramètre λ_0 , avec λ_0 donné. La statistique de test est alors $h_n = \|\hat{F}_n - F_{\lambda_0}\|_\infty$. Les lois de ces deux statistiques de test h_n et h'_n sous H_0 sont différentes.

2.4 Test d'homogénéité de Kolmogorov Smirnov

On observe deux échantillons i.i.d. $X_1^n = (X_1, \dots, X_n)$ et $Y_1^m = (Y_1, \dots, Y_m)$, indépendants entre eux. m peut être différent de n . On veut tester si les deux échantillons ont la même loi.

Autrement dit, si on note F la CDF des X_i et G la CDF des Y_i , on veut tester

$$H_0 : F = G \quad \text{contre} \quad H_1 : F \neq G.$$

On note comme précédemment $\hat{F}_n$ et $\hat{G}_m$ les fonctions de répartitions empiriques respectives des échantillons $X_1^n = (X_1, \dots, X_n)$ et $Y_1^m = (Y_1, \dots, Y_m)$ et on pose

1. C'est donc une hypothèse composite.

$$h_{n,m}(X_1^n, Y_1^m) = \sup_{t \in \mathbb{R}} |\hat{F}_n(t) - \hat{G}_m(t)|$$

Proposition 2.49

Sous $H_0 : F = G$ et si F est continue alors la loi de $h_{n,m}(X_1^n, Y_1^m)$ ne dépend pas de F .

Démonstration. Sous H_0 , $X_1, \dots, X_n, Y_1, \dots, Y_m \stackrel{iid}{\sim} F$ donc, si $U_1, \dots, U_n, V_1, \dots, V_m \stackrel{iid}{\sim} U[0, 1]$, on a

$$(F^{(-1)}(U_1), \dots, F^{(-1)}(U_n), F^{(-1)}(V_1), \dots, F^{(-1)}(V_m)) \sim (X_1, \dots, X_n, Y_1, \dots, Y_m)$$

Ainsi on obtient, sous H_0 ,

$$\begin{aligned} h_{n,m}(X_1^n, Y_1^m) &= \sup_{t \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq t} - \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{Y_i \leq t} \right| \\ &\sim \sup_{t \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{F^{(-1)}(U_i) \leq t} - \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{F^{(-1)}(V_i) \leq t} \right| \\ &= \sup_{t \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq F(t)} - \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{V_i \leq F(t)} \right| \\ &= \sup_{s \in Im(F)} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{V_i \leq s} \right| \\ &\stackrel{p.s.}{=} \sup_{s \in]0, 1[} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{V_i \leq s} \right| \end{aligned}$$

On a utilisé la proposition 2.8 ainsi que la continuité de F . En effet, si F est continue, $]0, 1[\subset Im(F) \subset [0, 1]$ et on vérifie immédiatement que, presque sûrement, la fonction $s \mapsto \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{U_i \leq s} - \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{V_i \leq s}$ vaut 0 en $s = 0$ et $s = 1$. $\square$

Cette loi est tabulée. On pose

$$\varphi_\alpha(X_1^n, Y_1^m) = \mathbb{1}_{h_{n,m}(X_1^n, Y_1^m) > x_{n,m,1-\alpha}}$$

où $x_{n,m,1-\alpha}$ est le quantile d'ordre $1 - \alpha$ de la loi de la statistique $h_{n,m}(X_1^n, Y_1^m)$ sous H_0 .

Implémentation 2.50

Pour tester si deux échantillons x et y ont la même loi (continue), on peut utiliser

- R : `ks.test` du package `stat`. La formule est `ks.test(x,y)`.
- Python : (x et y sont des arrays de dim 1 ou des listes)

```
from scipy import stats
stats.ks_2samp(x,y)
```

2.5 Tests d'adéquation du khi-deux

On rappelle deux définitions liées aux tests asymptotiques.

Définition 2.51

Soit $\alpha \in]0, 1[$. On dit qu'une suite de tests est asymptotiquement de taille α si l'erreur de première espèce tend vers α quand n tend vers l'infini.

On dit qu'une suite de tests est consistante si la fonction puissance tend simplement vers 1 quand n tend vers l'infini.

2.5.1 Test d'adéquation à une loi donnée

Soit un n -échantillon $X_1, \dots, X_n$ de même loi qu'une variable X à valeur dans un ensemble fini $\{x_1, \dots, x_d\}$, pour $d \in \mathbb{N}^*$.

Notations : pour $1 \leq j \leq d$,

$$p_j = \mathbb{P}(X = x_j), \quad \hat{p}_j = \frac{1}{n} \sum_{i=1}^d \mathbb{1}_{X_i=x_j}.$$

On se donne une loi de référence $p^0 = (p_1^0, \dots, p_d^0)^a$ telle que $p_j^0 > 0$ pour tout $j \in \{1, \dots, d\}$.

On veut tester

$$H_0 : p = p^0 \quad \text{contre} \quad H_1 : p \neq p^0$$

On utilise un test basé sur la différence entre les fréquences empiriques $\hat{p}_j$ et les fréquences théoriques p_j^0 .

a. On a donc $\sum_{j=1}^d p_j^0 = 1$

Plus précisément, le test est basé sur la statistique de Pearson (non exigé)

$$D^2 = n \sum_{j=1}^d \frac{(\hat{p}_j - p_j^0)^2}{p_j^0}$$

On rappelle que, sous H_0 , on a

$$D^2 \xrightarrow[n \rightarrow \infty]{\text{Loi}} \chi^2(d-1)$$

et que, sous H_1 , $D^2 \xrightarrow[n \rightarrow \infty]{\text{p.s.}} +\infty$. On a donc

Théorème 2.52: test du khi-deux d'adéquation à une loi donnée

Soit $\alpha \in]0, 1[$, le test défini par $\phi(X_1^n) = \mathbb{1}_{D^2 > q_{1-\alpha}^{\chi^2(d-1)}}$ est asymptotiquement de taille α et consistant.

Conditions d'application de ce test :

On rappelle que, en pratique, l'approximation liée au TCL, d'une loi binomiale $B(n, p)$ par une loi normale $\mathcal{N}(np, \sqrt{np(1-p)})$ n'est valable que sous les conditions suivantes :

- Il faut que n soit assez grand.
- n doit être d'autant plus grand que p est proche de 0 ou de 1.

On utilise par exemple souvent la condition : $np \geq 5$ et $n(1-p) \geq 5$.

Dans la preuve de la convergence en loi de D^2 vers la loi $\chi^2(d-1)$ sous H_0 , on utilise le TCL pour approcher un vecteur multinomial par une loi normale. On a donc le même type de conditions.

Pour fixer les idées, on considérera que le test du khi-deux d'adéquation à une loi donnée est valide si :

$$n \geq 30 \quad \text{et} \quad np_j^0 \geq 5 \quad \forall j \in \{1, \dots, d\}.$$

2. bien sûr, comme toujours avec ce type de critère, les seuils sont plus ou moins arbitraires

Exemple 2.53

On nous donne les observations $x_1, \dots, x_n$ d'un échantillon i.i.d. de loi inconnue. On soupçonne qu'il d'agit de la loi de Poisson de paramètre $\lambda_0 = 1.5$. On peut alors utiliser le test du chi-deux d'adéquation à une loi donnée. Supposons que $n = 300$ et que l'on obtienne les résultats

suivants :

0	1	2	3	4	5	6
67	96	68	38	23	7	1

 de sorte que $\hat{p} = (\frac{67}{300}, \frac{96}{300}, \frac{68}{300}, \frac{38}{300}, \frac{23}{300}, \frac{7}{300}, \frac{1}{300})$

On utilise alors le test du khi-deux d'adéquation à une loi donnée pour le problème de test suivant

$$H_0 : p = p_0 \quad \text{contre} \quad H_1 : p \neq p_0$$

avec $p^0 = (p_0^0, \dots, p_6^0)$ où, si $Y \sim \mathcal{P}(1.5)$,

$$p_i^0 = \begin{cases} \mathbb{P}(Y = i) & \text{si } i \in \{0, \dots, 5\} \\ \mathbb{P}(Y \geq 6) & \text{si } i = 6 \end{cases}$$

Il faut en effet se ramener à une loi à support fini si la loi de référence est à valeurs dans un ensemble non fini.

On peut vérifier, à l'aide d'un ordinateur, que les conditions de l'encadré précédent ne sont pas vérifiées (np_6^0 est trop petit). Donc on prend plutôt $p^0 = (p_0^0, \dots, p_5^0)$ avec

$$p_i^0 = \begin{cases} \mathbb{P}(X = i) & \text{si } i \in \{0, \dots, 4\} \\ \mathbb{P}(X \geq 5) & \text{si } i = 5 \end{cases} \quad \text{et } \hat{p} = (\frac{67}{300}, \frac{96}{300}, \frac{68}{300}, \frac{38}{300}, \frac{23}{300}, \frac{7+1}{300})$$

Implémentation 2.54: implémentation de cet exemple avec R

```
x=c(67,96,68,38,23,8)
p=rep(0,6)
p[1:5]=dpois(c(0,1,2,3,4),1.5)
p[6]=1-ppois(4,1.5)
chisq.test(x=x,p=p)
```

Avec la sortie :

```
##
## Chi-squared test for given probabilities
##
## data:  x
## X-squared = 7.5475, df = 5, p-value = 0.183
```

Implémentation 2.55: implémentation de cet exemple avec Python

```
from scipy.stats import poisson, chisquare
fobs=[67,96,68,38,23,8]
fexp=[300*poisson.pmf(k,1.5) for k in range(5)]
fexp.append(300*(1-poisson.cdf(4,1.5)))
chisquare(f_exp=fexp,f_obs=fobs)
```

Remarque 2.56: quand le paramètre est inconnu

Il existe aussi un test du khi-deux d'adéquation à une famille paramétrée de lois à support fini, dans le cas où le paramètre n'est pas précisé (comme dans la section 2.3.2). On remplace alors le paramètre inconnu dans la formule du test d'adéquation du khi-deux par l'estimateur

du maximum de vraisemblance. La loi limite est à nouveau une loi du khi-deux mais avec un nombre de degrés de liberté modifié (par rapport au même problème de test mais où on connaîtrait le paramètre).

2.5.2 Test du chi-deux d'indépendance

On dispose de n couples de v.a. $(X_1, Y_1), \dots, (X_n, Y_n)$ prenant un nombre fini de valeurs, indépendantes et identiquement distribuées selon une loi notée ν . On veut tester

$$H_0 : \text{les } X_i \text{ sont indépendantes des } Y_i$$

Soient $\{x_1, \dots, x_r\}$, respectivement $\{y_1, \dots, y_s\}$ l'ensemble des valeurs prises par les X_i , respectivement par les Y_i .

La statistique de test est la suivante (non exigé)

$$D_{indep}^2 = n \sum_{j=1}^r \sum_{\ell=1}^s \frac{(\hat{\nu}_{(j,\ell)} - \hat{p}_j \hat{q}_\ell)^2}{\hat{p}_j \hat{q}_\ell}$$

où

$$\hat{\nu}_{(j,\ell)} = \frac{\sum_{i=1}^n \mathbb{1}_{\{(X_i, Y_i) = (x_j, y_\ell)\}}}{n} \quad \hat{p}_j = \frac{\sum_{i=1}^n \mathbb{1}_{X_i = x_j}}{n} \quad \hat{q}_\ell = \frac{\sum_{i=1}^n \mathbb{1}_{Y_i = y_\ell}}{n}$$

On rappelle que, sous H_0 , on a

$$D_{indep}^2 \xrightarrow[n \rightarrow \infty]{Loi} \chi^2((r-1)(s-1))$$

et que, sous H_1 , $D_{indep}^2 \xrightarrow[n \rightarrow \infty]{p.s.} +\infty$. On a donc

Théorème 2.57: test du khi-deux d'indépendance

Soit $\alpha \in]0, 1[$, le test défini par $\phi(X_1^n, Y_1^n) = \mathbb{1}_{D_{indep}^2 > q_{1-\alpha}^{\chi^2((r-1)(s-1))}}$ est asymptotiquement de taille α et consistant.

Conditions d'application de ce test :

La convergence donnée dans le théorème précédent repose (entre autres) sur le TCL appliqué à un vecteur multinomial. Donc on a aussi une condition de validité du type :

$$np_{j\ell} \text{ et } \nu_{j,\ell} \text{ doivent être suffisamment grand, pour tout } (j, \ell).$$

Comme on ne connaît pas les p_j ni les q_ℓ ni les $\nu_{j,\ell}$, on les remplace par leurs estimateurs $\hat{p}_j$, $\hat{q}_\ell$ et $\hat{\nu}_{j,\ell}$ pour vérifier ces conditions.

Pour fixer les idées, on considérera que le test du khi-deux d'indépendance est valide si :

$$n\hat{p}_j \hat{q}_\ell \geq 5 \text{ et } n\hat{\nu}_{j,\ell} \geq 5 \quad \forall (j, \ell) \in \{1, \dots, r\} \times \{1, \dots, s\}.$$

Exemple 2.58

Pour une certaine maladie, on désire savoir si le fait d'être malade dépend du sexe de la personne.

On prélève un échantillon et on obtient le tableau suivant

	M	F
malade	80	100
non malade	110	90

On a ici $r = s = 2$. Si on note p_1 la probabilité d'être malade et q_1 la probabilité d'être de sexe

masculin, on a alors, avec $p_2 = 1 - p_1$ et $q_2 = 1 - q_1$,

$$\hat{p}_1 = \frac{180}{380} \quad \hat{p}_2 = 1 - \hat{p}_1 = \frac{200}{380} \quad \hat{q}_1 = \frac{190}{380} \quad \hat{q}_2 = 1 - \hat{q}_1 = \frac{190}{380}$$

$$\hat{\nu}_{(1,1)} = \frac{80}{380} \quad \hat{\nu}_{(1,2)} = \frac{100}{380} \quad \hat{\nu}_{(2,1)} = \frac{110}{380} \quad \hat{\nu}_{(2,2)} = \frac{90}{380}$$

Vérification des conditions d'application : on vérifie immédiatement que $n\hat{p}_1\hat{q}_1$, $n\hat{p}_1\hat{q}_2$, $n\hat{p}_2\hat{q}_1$, $n\hat{p}_2\hat{q}_2$, $n\hat{\nu}_{1,1}$, $n\hat{\nu}_{1,2}$, $n\hat{\nu}_{2,1}$ et $n\hat{\nu}_{2,2}$ sont tous plus grands que 5.

Implémentation 2.59: implémentation de cet exemple avec R et Python

Implémentation avec R

```
M <- as.table(rbind(c(80, 100), c(110, 90)))
chisq.test(M)
## Pearson's Chi-squared test with Yates' continuity correction##
## data:  M
## X-squared = 3.8106, df = 1, p-value = 0.05093
```

Implémentation avec Python

```
from scipy.stats import chi2_contingency
import numpy as np
table=np.array([[80,100],[110,90]])
chi2_contingency(table)
```

Remarque 2.60

Résumons les différences essentielles entre le test de Kolmogorov-Smirnov et le test d'adéquation du χ^2 :

- Le test du χ^2 est plus adapté aux lois discrètes. Si on veut l'utiliser pour des lois continues, c'est possible, mais il faut discrétiser en choisissant des classes (quelles classes ? combien de classes ?). Le test de K-S est conçu pour les lois continues.
- Le test de Kolmogorov-Smirnov a la particularité d'être exact pour de petits échantillons : la loi est libre à n fini. Le test du χ^2 est uniquement asymptotique (il faut vérifier la condition $np_j^0 \gtrsim 5$).