

Chapitre 3

Tests robustes

L'objectif de ce chapitre est de présenter des tests qui ne nécessitent aucune hypothèse sur les distributions sous-jacentes, ou seulement des hypothèses très faibles. En ce sens, ces tests sont non paramétriques. Ils sont également plus adaptés à la présence d'observations aberrantes dans l'échantillon : on parle alors de tests robustes.

Les programmes en R/Python sont donnés à titre d'illustration.

3.1 Un exemple

Un exemple de question à laquelle on souhaite répondre dans ce chapitre est le suivant : les hommes gagnent-ils plus que les femmes ? Pour répondre à cette question, imaginons que nous disposions d'un échantillon

$$X_1^{n_1} = (X_1, \dots, X_{n_1})$$

de salaires de femmes et d'un échantillon

$$Y_1^{n_2} = (Y_1, \dots, Y_{n_2})$$

de salaires d'hommes.

Nous ferons des tests différents selon que

1. **les échantillons sont iid et indépendants entre eux**, c'est-à-dire

$$X_1, \dots, X_{n_1} \text{ sont iid de loi } F_X, \quad Y_1, \dots, Y_{n_2} \text{ sont iid de loi } F_Y, \quad X_1^{n_1} \perp\!\!\!\perp Y_1^{n_2};$$

2. **les données sont appariées**. Nous donnerons une définition plus précise de l'appariement plus loin. Disons ici que si les deux échantillons sont de même taille, $n_1 = n_2 = n$, et si l'on a regroupé les données par paires comparables (par exemple selon l'âge : les individus de même indice ont le même âge), alors les données sont appariées.

Imaginons désormais que nous soyons dans le cas des données appariées (par exemple regroupées par âge). On peut alors considérer les différences

$$D_i = Y_i - X_i, \quad 1 \leq i \leq n,$$

et supposer pour simplifier que $(D_i)_{1 \leq i \leq n}$ est un n -échantillon iid.

Le test que nous souhaitons faire est donc

H_0 : les femmes gagnent autant que les hommes contre H_1 : les hommes gagnent plus que les femmes.

Il y a bien sûr plusieurs façons de modéliser le problème. Ici, on travaille avec la variable différence $D_1 = Y_1 - X_1$ et on souhaite tester un *paramètre de position*. Deux choix usuels sont la moyenne et la médiane. On peut traduire “les femmes gagnent autant que les hommes” par :

— *version moyenne* : “la moyenne de D_1 est nulle” ;

— *version médiane* : “la médiane de D_1 est nulle”.

Autrement dit, si l’on choisit la moyenne comme paramètre de position, on teste

$$H_0 : \mathbb{E}[D_1] = 0 \quad \text{contre} \quad H_1 : \mathbb{E}[D_1] > 0.$$

Si l’on choisit la médiane comme paramètre de position, on teste plutôt

$$H_0 : \text{Med}(D_1) = 0 \quad \text{contre} \quad H_1 : \text{Med}(D_1) > 0.$$

Si nous modélisons le problème à l’aide de la moyenne et si nous supposons les données gaussiennes, alors nous ferons naturellement un test de Student, qui est un test paramétrique.

3.2 Un test paramétrique : le test de Student

3.2.1 Un seul échantillon

Soit $(X_1, \dots, X_n)$ un n -échantillon iid de loi $\mathcal{N}(\mu, \sigma^2)$, avec μ et σ^2 inconnus. On veut tester

$$H_0 : \mu = \mu_0 \quad \text{contre} \quad H_1 : \mu \neq \mu_0.$$

(ou bien $H_1 : \mu > \mu_0$, ou bien $H_1 : \mu < \mu_0$.)

Le test de Student est basé sur la statistique

$$\hat{T} = \sqrt{n} \frac{\bar{X} - \mu_0}{S}, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

et, sous H_0 , on a $\hat{T} \sim T_{n-1}$.

Au niveau α , le test de Student est :

$$\varphi_\alpha(X_1^n) = \mathbf{1} \left\{ |\hat{T}| > q_{1-\alpha/2} \right\} \quad \text{pour } H_1 : \mu \neq \mu_0,$$

$$\varphi_\alpha(X_1^n) = \mathbf{1} \left\{ \hat{T} > q_{1-\alpha} \right\} \quad \text{pour } H_1 : \mu > \mu_0,$$

$$\varphi_\alpha(X_1^n) = \mathbf{1} \left\{ \hat{T} < q_\alpha \right\} \quad \text{pour } H_1 : \mu < \mu_0,$$

où q_u désigne le quantile d’ordre u de la loi de Student à $(n-1)$ degrés de liberté.

Problèmes éventuels pour réaliser ce test dans la pratique :

- l’échantillon n’est pas de loi normale ;
- les variables sont gaussiennes mais ne sont pas identiquement distribuées (par exemple $X_i \sim \mathcal{N}(\mu, \sigma_i^2)$ avec des σ_i^2 différents) ;
- l’échantillon est contaminé par des valeurs aberrantes (observations atypiques, "outliers")^a.

En simplifiant, le problème de non-normalité n’est pas forcément grave si la taille de l’échantillon est grande (voir TD1 exo 5).

^a. La notion de valeur aberrante est subtile, notamment pour des distributions à queues épaisses. Une observation “peu probable” n’est pas nécessairement une valeur aberrante.

Remarque 3.1

Toutefois, si l'on veut tester la normalité d'un échantillon, on recommande d'abord des représentations graphiques, en particulier un *Q-Q plot* (ou *QQ-plot*). On peut ensuite effectuer l'un des nombreux tests de normalité, par exemple le test de Shapiro-Wilk (souvent considéré comme l'un des plus puissants).

Implémentation 3.2

Le test de Student sur un échantillon peut se faire en R avec `t.test` et en Python avec `scipy.stats.ttest_1samp`. Le test de Shapiro-Wilk peut se faire en R avec `shapiro.test` et en Python avec `scipy.stats.shapiro`.

3.2.2 Deux échantillons indépendants

On dispose de deux échantillons indépendants $U_1, \dots, U_n$ et $V_1, \dots, V_p$, pas forcément de même taille, et l'on veut tester l'égalité des moyennes. On suppose que

$$U_1, \dots, U_n \text{ sont iid de loi } \mathcal{N}(\mu_1, \sigma^2), \quad V_1, \dots, V_p \text{ sont iid de loi } \mathcal{N}(\mu_2, \sigma^2), \quad U_1^n \perp\!\!\!\perp V_1^p, \\ \mu_1, \mu_2 \text{ et } \sigma^2 \text{ sont inconnus.}$$

et on veut tester :

$$H_0 : \mu_1 = \mu_2 \quad \text{contre} \quad H_1 : \mu_1 \neq \mu_2.$$

(ou bien $H_1 : \mu_1 < \mu_2$ ou bien $H_1 : \mu_1 > \mu_2$).

On utilise alors la statistique

$$T = \frac{\bar{V} - \bar{U}}{\hat{\sigma} \sqrt{\frac{1}{n} + \frac{1}{p}}},$$

où l'estimateur *poolé* de la variance est défini par

$$\hat{\sigma}^2 = \frac{1}{n+p-2} \left[\sum_{i=1}^n (U_i - \bar{U})^2 + \sum_{i=1}^p (V_i - \bar{V})^2 \right].$$

Sous H_0 , on a

$$T \sim T(n+p-2).$$

En effet :

- $\sum_{i=1}^n \frac{(U_i - \bar{U})^2}{\sigma^2} \sim \chi^2(n-1)$ et $\sum_{i=1}^p \frac{(V_i - \bar{V})^2}{\sigma^2} \sim \chi^2(p-1)$;
- ces deux variables sont indépendantes, donc

$$\sum_{i=1}^n \frac{(U_i - \bar{U})^2}{\sigma^2} + \sum_{i=1}^p \frac{(V_i - \bar{V})^2}{\sigma^2} \sim \chi^2(n+p-2);$$

- $\bar{U} \sim \mathcal{N}\left(\mu_1, \frac{\sigma^2}{n}\right)$ et $\bar{V} \sim \mathcal{N}\left(\mu_2, \frac{\sigma^2}{p}\right)$, et $\bar{U} \perp\!\!\!\perp \bar{V}$;
- donc, sous H_0 ,

$$\bar{V} - \bar{U} \sim \mathcal{N}\left(0, \sigma^2 \left(\frac{1}{n} + \frac{1}{p}\right)\right).$$

Ainsi, sous H_0 ,

$$\frac{\bar{V} - \bar{U}}{\sigma \sqrt{\frac{1}{n} + \frac{1}{p}}} \sim \mathcal{N}(0, 1) \quad \text{et} \quad \frac{\hat{\sigma}^2}{\sigma^2} \sim \frac{\chi^2(n+p-2)}{n+p-2}.$$

De plus,

$$(U_1 - \bar{U}, \dots, U_n - \bar{U}) \perp \bar{U}, \quad (V_1 - \bar{V}, \dots, V_p - \bar{V}) \perp \bar{V}, \quad U_1^n \perp V_1^p.$$

Le vecteur

$$(U_1 - \bar{U}, \dots, U_n - \bar{U}, \bar{U}, V_1 - \bar{V}, \dots, V_p - \bar{V}, \bar{V})$$

étant gaussien (comme transformée linéaire de $(U_1, \dots, U_n, V_1, \dots, V_p)$), l'indépendance deux à deux de ses composantes implique l'indépendance mutuelle. Ainsi,

$$(U_1 - \bar{U}, \dots, U_n - \bar{U}, V_1 - \bar{V}, \dots, V_p - \bar{V}) \perp (\bar{U}, \bar{V}),$$

donc $\hat{\sigma}^2 \perp (\bar{V} - \bar{U})$, et finalement

$$T = \frac{\frac{\bar{V} - \bar{U}}{\sigma \sqrt{\frac{1}{n} + \frac{1}{p}}}}{\frac{\hat{\sigma}}{\sigma}} \sim T(n+p-2).$$

NB : pour plus de détails, cf. correction exercice 2 TD3 de *statmaths* L3.

Au niveau α , le test bilatéral est

$$\varphi_\alpha = \mathbf{1} \left\{ |T| > q_{1-\alpha/2} \right\}.$$

Pour les tests unilatéraux :

$$\varphi_\alpha = \mathbf{1} \{T > q_{1-\alpha}\} \quad \text{pour } H_1 : \mu_1 < \mu_2, \quad \varphi_\alpha = \mathbf{1} \{T < q_\alpha\} \quad \text{pour } H_1 : \mu_1 > \mu_2,$$

où q_u désigne le quantile d'ordre u de la loi de Student à $(n+p-2)$ degrés de liberté.

Le même type de problème que pour le test de Student sur la moyenne d'un échantillon se pose :

1. les données ne sont peut-être pas gaussiennes ;
2. les données peuvent être gaussiennes mais de variances différentes ;
3. les données peuvent être contaminées par des valeurs aberrantes.

Remarque 3.3: Test de Welch : $\sigma_1^2 \neq \sigma_2^2$

Il existe un test adapté à des données gaussiennes, proche du test de Student, mais valable lorsque l'on ne suppose plus l'égalité des variances (en particulier lorsque $\sigma_1^2 \neq \sigma_2^2$ et/ou lorsque $n_1 \neq n_2$). Ce test s'appelle le *test de Welch*. La procédure est basée sur une statistique de type

$$\frac{\bar{X} - \bar{Y}}{\hat{\sigma}},$$

mais l'estimation de l'écart-type $\hat{\sigma}$ est différente puisqu'on ne suppose plus que les variances sont égales. La statistique ne suit alors plus exactement une loi de Student ; en revanche elle est bien approchée par une loi de Student avec un nombre de degrés de liberté non entier, calculé à partir de s_X^2 , s_Y^2 et des tailles d'échantillon.

Un certain nombre d'auteurs indiquent qu'il est inutile de tester l'égalité des variances avant de choisir entre Welch et Student, et qu'il vaut mieux utiliser directement et systématiquement le test de Welch. C'est l'opinion majoritaire : d'une part, le test de Welch est plus fiable lorsque les

tailles d'échantillon et/ou les variances diffèrent nettement ; d'autre part, il donne des résultats très similaires au test de Student lorsque les tailles et les variances sont proches. Le problème de variances différentes est moins important pour le test de Student lorsque les tailles d'échantillon sont approximativement égales.

Implémentation 3.4

- R : pour faire un test de Student (variances supposées égales) ou un test de Welch avec `t.test`, il faut préciser l'argument `var.equal = TRUE` pour obtenir le test de Student. Par défaut (`var.equal = FALSE`), `t.test` réalise le test de Welch.
- Python : utiliser `scipy.stats.ttest_ind` avec l'option `equal_var=True` (Student) ou `equal_var=False` (Welch). Dans SciPy, `equal_var=True` est la valeur par défaut.

3.2.3 Échantillons appariés (*paired data*)

“Définition” de l'appariement

On veut par exemple comparer les effets de deux traitements sur deux populations d'individus que l'on peut appairer.

Expliquons d'abord ce qu'est l'appariement. Concrètement, on dispose de deux échantillons **de même taille** :

$$U_1, \dots, U_n \quad \text{et} \quad V_1, \dots, V_n.$$

On parle de *données appariées* lorsque “l'individu” i du premier échantillon est lié à “l'individu” i du second échantillon.

Ainsi, pour chaque i , il n'y a pas indépendance entre U_i et V_i .

En revanche, on suppose l'indépendance entre les couples (U_i, V_i) pour des indices différents : par exemple (U_1, V_1) est indépendant de (U_2, V_2) , mais U_1 et V_1 ne sont pas indépendants.

Prenons l'exemple d'un traitement médicamenteux. On veut comparer l'efficacité de deux médicaments : U_i et V_i mesurent l'efficacité respective du médicament 1 et du médicament 2 sur deux individus comparables, par exemple deux individus de même âge. Il peut aussi s'agir du même individu, auquel on a administré deux traitements différents à deux moments différents.

De manière générale, quand on considère des échantillons appariés, cela signifie que

- soit U_i et V_i correspondent à deux mesures sur le même individu ;
- soit les individus sont différents mais ils sont regroupés en fonction de covariables (sexe, âge, etc.).

Remarque 3.5

En général, l'appariement est utilisé pour améliorer la puissance d'un test.

Un test pour données appariées consiste à tester un paramètre de position de la différence des deux mesures.

Le test de Student pour données appariées

On dispose de deux échantillons appariés $U_1, \dots, U_n$ et $V_1, \dots, V_n$. On pose

$$X_i = U_i - V_i, \quad i = 1, \dots, n.$$

On suppose que

$$X_1, \dots, X_n \text{ sont iid de loi } \mathcal{N}(\mu, \sigma^2).$$

On veut tester

$$H_0 : \mu = 0 \quad \text{contre} \quad H_1 : \mu \neq 0$$

(ou bien $H_1 : \mu > 0$ ou bien $H_1 : \mu < 0$).

On effectue alors un test de Student sur l'échantillon des X_i . Plus précisément, au niveau α (test bilatéral),

$$\varphi_\alpha(U_1^n, V_1^n) = \mathbf{1} \left\{ |\hat{T}| > q_{1-\alpha/2} \right\},$$

où

$$\hat{T} = \sqrt{n} \frac{\bar{X}}{S_X} = \sqrt{n} \frac{\bar{U} - \bar{V}}{S_X}, \quad S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Sous H_0 , on a $\hat{T} \sim T(n-1)$.

Remarque 3.6

Une des hypothèses est que la distribution des X_i est la même pour tout i . En particulier, la variance doit être la même pour tout i . Certains auteurs recommandent une vérification graphique de cette hypothèse avec un graphe de Bland–Altman. Fréquemment, la dispersion est proportionnelle au niveau ; une transformation logarithmique peut alors être utile.

Implémentation 3.7

- R : on peut utiliser `t.test` en précisant `paired = TRUE` : `t.test(x, y, paired = TRUE)`. De façon équivalente, on peut utiliser `t.test(x - y)`.
- Python : utiliser `scipy.stats.ttest_1samp(x - y, popmean = 0)`.

3.2.4 Importance des conditions d'application

Les tests non paramétriques s'appliquent dans des situations plus générales et sont donc plus robustes. On les utilise en général quand les conditions d'application des tests paramétriques ne sont pas vérifiées (ou pas vérifiables). Toutefois, un test paramétrique peut devenir performant pour de grandes tailles d'échantillon, même si les conditions théoriques ne sont pas exactement vérifiées. En particulier, pour le test de Student de comparaison de deux populations, lorsque les tailles d'échantillon sont importantes et sous des conditions assez faibles, le test de Student est valide même si les échantillons ne sont pas gaussiens. Ce résultat est à rapprocher de ce qui se produit en modèle linéaire lorsque les erreurs ne sont pas gaussiennes.

De manière générale, on peut cependant préférer utiliser systématiquement les tests non paramétriques de Wilcoxon (voir section suivante) lorsqu'on ne sait pas si les échantillons sont gaussiens. En effet, la performance des tests de Wilcoxon sur des données gaussiennes n'est pas tellement moins bonne que celle des tests de Student. De plus, les tests de Wilcoxon ont souvent une meilleure performance que le test de Student lorsque les données ne sont pas gaussiennes (même pour de grandes tailles d'échantillon).

3.2.5 Illustration numérique – (lecture facultative)

cf. fichier .rmd dans teams.

3.3 Test du signe

Nous venons de voir un test paramétrique, le test de Student, qui peut être utilisé pour comparer deux populations indépendantes ou comparer deux traitements sur des données appariées. Ce test repose sur le caractère gaussien des données.

Nous allons maintenant construire des tests reposant sur des hypothèses beaucoup plus faibles.

On commence par le test du signe et le test de Wilcoxon des rangs signés, que l'on peut voir comme des versions non paramétriques du test de Student pour données appariées.

Nous travaillerons assez souvent avec des variables aléatoires diffuses ; voir la définition 2.35 page 33.

Intuition 3.8

Tirons au hasard X selon une loi continue de médiane 0. Alors le signe de X est une variable symétrique : $\mathbb{P}(X > 0) = \mathbb{P}(X < 0) = 1/2$. Si au contraire, par tirage, on obtient systématiquement des valeurs positives (ou négatives), cela indiquerait que la médiane n'est probablement pas nulle. Ceci sera formalisé avec le test du signe.

3.3.1 Test du signe sur un seul échantillon

L'objectif est de faire un test sur un paramètre de position, qui n'est ici pas la moyenne, mais la médiane. L'intérêt de ce choix est que le test ne requiert même pas l'existence d'une moyenne.

Les hypothèses sur les données $X_1, \dots, X_n$ sont :

$$\text{les } X_i \text{ sont indépendantes,} \quad (3.1)$$

$$\text{les } X_i \text{ ont une médiane commune } m, \quad (3.2)$$

$$\mathbb{P}(X_i = m) = 0, \quad \forall i. \quad (3.3)$$

Remarquez que les X_i ne sont pas nécessairement identiquement distribués.

L'hypothèse nulle est :

$$H_0 : m = 0.$$

Remarquons que $m = 0$ implique ici que $\mathbb{P}(X_i > 0) = \mathbb{P}(X_i < 0) = 1/2$ (voir (2.2) dans l'exemple 2.18, page 28) ; c'est ici qu'intervient la condition 3.3.

On pose

$$Y_i = \mathbb{1}_{\{X_i > 0\}}, \quad S = \sum_{i=1}^n Y_i.$$

Test unilatéral.

$$H_0 : m = 0 \quad \text{contre} \quad H_1 : m > 0,$$

1. Faisons d'abord, pour simplifier l'exposition, **l'hypothèse que les X_i sont de même loi**. On a alors

$$Y_1, \dots, Y_n \stackrel{iid}{\sim} Be(p) \quad \text{avec} \quad p = \mathbb{P}(X_i > 0).$$

Donc on peut réécrire le problème comme suit :

$$H_0 : p = 1/2 \quad \text{contre} \quad H_1 : p > 1/2.$$

Donc on se ramène à un test d'égalité sur le paramètre p d'un échantillon iid de v.a. de Bernoulli Y_i . On peut donc utiliser

$$\varphi_\alpha(X_1, \dots, X_n) = \mathbb{1}_{\left\{S > q_{1-\alpha}^{B(n, 1/2)}\right\}} = \mathbb{1}_{\left\{\sum_{i=1}^n \mathbb{1}_{\{X_i > 0\}} > q_{1-\alpha}^{B(n, 1/2)}\right\}}.$$

2. Maintenant, que se passe-t-il si les X_i ne sont pas de même loi ? Alors le test proposé fonctionne encore. En effet, sous H_0 on a bien, du fait que 0 est la médiane commune, $Y_i \stackrel{iid}{\sim} Be(1/2)$ donc le test est bien de niveau α .

Est-ce un test adapté au problème ? Cela revient à savoir si la statistique $\sum_{i=1}^n \mathbb{1}_{X_i > 0}$ prend bien de grandes valeurs sous H_1 . C'est bien le cas ici car si $m > 0$, les X_i ont tendance à prendre des valeurs positives et donc le nombre de X_i positifs va être grand.

Test bilatéral.

$$H_0 : m = 0 \quad \text{contre} \quad H_1 : m \neq 0,$$

De même on peut utiliser

$$\varphi_\alpha(Y_1, \dots, Y_n) = \mathbb{1}_{\left\{|S - n/2| > q_{1-\frac{\alpha}{2}}^{B(n, 1/2)} - \frac{n}{2}\right\}}.$$

Avec l'échantillon initial, cela donne

$$\varphi_\alpha(X_1, \dots, X_n) = \mathbb{1}_{\left\{|\sum_{i=1}^n \mathbb{1}_{X_i > 0} - n/2| > q_{1-\frac{\alpha}{2}}^{B(n, 1/2)} - \frac{n}{2}\right\}}.$$

Ce test, qui utilise uniquement le signe des X_i , est appelé *test du signe*.

Implémentation 3.9

1. R : on peut utiliser `binom.test`. Si l'échantillon est dans un vecteur `x` et pour l'alternative bilatérale :

```
binom.test(sum(x > 0), n = length(x), p = 0.5).
```

(Par défaut l'alternative est "two.sided".)

2. Python : on peut utiliser `binomtest` de `scipy.stats` :

```
from scipy.stats import binomtest
binomtest((x > 0).sum(), n=len(x), p=0.5) # two-sided par défaut
```

a. s'il y a des ex æquo, on commence en pratique par enlever les zéros :

```
x <- x[x != 0].
```

3.3.2 Test du signe sur deux échantillons

On dispose de deux échantillons appariés $U_1, \dots, U_n$ et $V_1, \dots, V_n$. Comme ce sont des données appariées, on se ramène à un test sur l'échantillon des différences $X_i = V_i - U_i$.

Pour fixer les idées, imaginons le cas de deux traitements que l'on veut comparer. On prend deux populations de même taille n . On les classe par âge. On donne à un individu i un premier traitement dont on mesure l'efficacité par U_i et on donne l'autre traitement à un individu du même âge, dont on mesure l'efficacité par V_i . On veut par exemple savoir si le second traitement est plus efficace que le premier.

On peut modéliser le fait que les deux traitements ont la même efficacité par l'égalité $\mathbb{P}(U_i \leq V_i) = \mathbb{P}(V_i \leq U_i)$, ce qui donne, en termes des X_i , $\mathbb{P}(X_i \leq 0) = \mathbb{P}(X_i \geq 0)$. En supposant que, presque sûrement, les X_i ne prennent jamais la valeur 0, ceci se traduit encore par "la médiane commune des X_i est égale à 0" (cf. sous-section 3.3.1).

On va donc faire un test du signe sur l'échantillon différence X_1^n .

Si le second traitement est plus efficace que le premier, V_i sera typiquement plus grand que U_i , donc $U_i < V_i$ (ou encore $X_i > 0$).

Pour tester "le second médicament est plus performant que le premier" (alternative unilatérale), on peut utiliser

$$\varphi_\alpha(U_1, \dots, U_n, V_1, \dots, V_n) = \mathbb{1}_{\left\{ \sum_{i=1}^n \mathbb{1}_{\{U_i < V_i\}} > q_{1-\alpha}^{B(n, 1/2)} \right\}}.$$

Si au contraire on pense que le premier est plus performant, on échange les rôles :

$$\varphi_\alpha(U_1, \dots, U_n, V_1, \dots, V_n) = \mathbb{1}_{\left\{ \sum_{i=1}^n \mathbb{1}_{\{V_i < U_i\}} > q_{1-\alpha}^{B(n, 1/2)} \right\}}.$$

Pour l'alternative bilatérale, on utilise

$$\varphi_\alpha(X_1, \dots, X_n) = \mathbb{1}_{\left\{ \left| \sum_{i=1}^n \mathbb{1}_{U_i < V_i} - n/2 \right| > q_{1-\frac{\alpha}{2}}^{B(n, 1/2)} - \frac{n}{2} \right\}}$$

Remarque 3.10

Le test du signe n'utilise que très peu d'information sur les variables $U_i - V_i$ (uniquement leur signe, pas leurs valeurs). C'est donc un test peu puissant. Son intérêt est qu'il peut s'appliquer lorsque seules des comparaisons de type "plus grand / plus petit" sont disponibles.

Remarque 3.11

En pratique, s'il y a des ex æquo ($U_i = V_i$), on les retire et on remplace n par le nombre de paires non nulles.

Implémentation 3.12

Comme il s'agit du test du signe sur les variables $X_i = U_i - V_i$, on utilise la même procédure que pour un seul échantillon : calculer les différences (ou bien les indicateurs $\mathbb{1}_{\{U_i < V_i\}}$), retirer éventuellement les ex æquo, puis appliquer `binom.test` (ou `scipy.stats.binomtest`).

Remarque 3.13: Le test du signe est-il un test d'homogénéité ?

On pourrait être tenté d'utiliser ce test pour tester que deux échantillons ont la même loi (test d'homogénéité). Supposons que l'on nous donne deux échantillons indépendants $U_1^n = (U_1, \dots, U_n)$ et $V_1^n = (V_1, \dots, V_n)$, avec $U_i \stackrel{iid}{\sim} F$ (continue) et $V_i \stackrel{iid}{\sim} G$ (continue). On veut tester

$$H_0 : F = G \quad \text{contre} \quad H_1 : F \neq G.$$

Si $F = G$, alors U et V sont interchangeables : $(U, V) \sim (V, U)$. On en déduit $U - V \sim V - U$, donc $\mathbb{P}(U < V) = \mathbb{P}(V < U)$. Comme F et G sont continues et que U et V sont indépendantes, on a $\mathbb{P}(U = V) = 0$, et donc

$$\mathbb{P}(U < V) = \mathbb{P}(V < U) = 1/2.$$

Ainsi, sous H_0 , la “propriété nulle” du test du signe est bien vérifiée.

Mais attention : la réciproque est fausse. On peut avoir

$$\mathbb{P}(U < V) = \mathbb{P}(V < U) = 1/2$$

sans que U et V aient la même loi. Autrement dit, l'égalité des lois est une propriété beaucoup plus forte que “la médiane de $V - U$ est nulle” (qui est ce que teste réellement le test du signe).

Par exemple, si U et V sont indépendantes, diffuses et symétriques (autour de 0), alors la médiane de $V - U$ soit égale à 0, même si U et V n'ont pas la même loi. Ainsi, le test du signe ne détectera pas la différence entre un échantillon $\mathcal{N}(0, 1)$ et un échantillon de loi de Cauchy.

On peut en effet écrire, si U et V sont symétriques et indépendantes, $(U, V) \sim (-U, -V)$, donc

$$U - V \sim -U - (-V) = V - U,$$

d'où $\mathbb{P}(U > V) = \mathbb{P}(V > U)$, et avec $\mathbb{P}(U = V) = 0$, on obtient $\mathbb{P}(U > V) = \mathbb{P}(V > U) = 1/2$.

Le test du signe, vu comme un test d'homogénéité, est donc un exemple de test particulièrement peu puissant : il “ne voit” pas certaines alternatives.

3.4 Statistiques d'ordre et de rang

Nous allons utiliser les statistiques d'ordre (cf. définition 2.1 page 23).

Définition 3.14: Statistiques de rang

Il existe une permutation aléatoire $\sigma_X \in \mathfrak{S}_n$ telle que

$$(X_{(1)}, \dots, X_{(n)}) = (X_{\sigma_X(1)}, \dots, X_{\sigma_X(n)}).$$

On définit le vecteur des rangs R_X comme la permutation inverse de σ_X , c'est-à-dire

$$R_X = \sigma_X^{-1}.$$

Évidemment, comme on peut avoir $X_i = X_j$ pour $i \neq j$, il n'y a pas toujours unicité de σ_X ni du vecteur de rangs. En théorie, si les X_i sont i.i.d. et de loi continue, alors il n'y a pas d'ex-æquo p.s. (cf. TD1, exercice 1) et σ_X et R_X sont alors uniques (p.s.).¹

Comme son nom l'indique, le vecteur de rangs donne le rang de chaque observation dans l'échantillon.

Exemple. Soit $x_1^7 = (4, 2, 1, 5, 3, 0, 6)$. Alors une permutation σ_x et le vecteur des rangs R_x sont donnés par :

numéro	1	2	3	4	5	6	7
σ_x	6	3	2	5	1	4	7

numéro	1	2	3	4	5	6	7
$R_x = \pi_x^{-1}$	5	3	2	6	4	1	7

On peut aussi trouver R_x directement à partir des observations :

x_1^7	4	2	1	5	3	0	6
R_x	5	3	2	6	4	1	7

3.5 Test des rangs signés de Wilcoxon

Intuition 3.15

Pour une variable diffuse X de médiane nulle, le test du signe n'utilise qu'une information très faible : le signe de X . Cela lui donne une grande applicabilité mais une puissance réduite.

Souvent, on dispose d'une information additionnelle exploitable, par exemple la symétrie. Sous symétrie autour de 0, l'aléa de X se décompose en deux parties : la valeur absolue $|X|$ et le signe de X . Formellement, on peut montrer que $|X|$ et $\mathbb{1}_{\{X>0\}}$ sont indépendantes. La valeur absolue est utile pour établir un ordre (comparer des tailles). Le test des rangs signés de Wilcoxon exploite précisément cette idée.

3.5.1 Sur un échantillon

On va à nouveau faire un test sur la médiane d'un échantillon. On considère des variables $(X_1, \dots, X_n)$ diffuses et indépendantes, mais pas forcément de même loi.

Proposition 3.16

Si les variables aléatoires $X_1, \dots, X_n$ sont indépendantes et diffuses, alors

$$\mathbb{P}(\exists i \neq j : |X_i| = |X_j|) = 0.$$

Démonstration. Pour tout $i \neq j$,

$$\begin{aligned} \mathbb{P}(|X_i| = |X_j|) &\leq \mathbb{P}(X_i = X_j) + \mathbb{P}(X_i = -X_j) \\ &= \int \mathbb{P}(X_i = x) dP_{X_j}(x) + \int \mathbb{P}(X_i = -x) dP_{X_j}(x) = 0, \end{aligned}$$

1. En pratique, à cause de la précision limitée des mesures et des arrondis, il peut y avoir des ex-æquo même pour un échantillon issu d'une loi continue. Il faut être attentif à ce problème : certaines procédures supposées valables pour des données continues ne gèrent pas toujours correctement les ex-æquo (et, même lorsqu'elles les gèrent, les résultats peuvent être moins fiables ; cf. plus loin).

car X_i est diffuse et indépendante de X_j . Ainsi,

$$\mathbb{P}(\exists i \neq j : |X_i| = |X_j|) \leq \sum_{\substack{1 \leq i, j \leq n \\ i \neq j}} \mathbb{P}(|X_i| = |X_j|) = 0.$$

□

On suppose disposer d'observations $(X_1, \dots, X_n)$ qui vérifient :

les X_i sont indépendantes entre elles ; (3.4)

les X_i sont diffuses ; (3.5)

les X_i ont une médiane commune m ; (3.6)

les lois des X_i sont symétriques par rapport à m . (3.7)

Notez que nous avons besoin d'une hypothèse supplémentaire par rapport au test du signe : la symétrie en loi autour de la médiane commune m . Dans ce cours, nous supposons ces conditions vérifiées sans discuter leur vérification.

L'hypothèse nulle est

$$H_0 : m = 0.$$

On va utiliser à nouveau le signe des X_i , mais en exploitant aussi les valeurs des $|X_i|$. L'idée est de donner un poids d'autant plus grand qu'une observation est grande en valeur absolue.

Si l'on dispose des valeurs des $|X_i|$, le test de Wilcoxon des rangs signés est préférable au test du signe, car il utilise plus d'information tout en ayant des conditions d'application presque aussi larges (il requiert la symétrie).

On considère les rangs des valeurs absolues $\{|X_i|\}_{1 \leq i \leq n}$. Comme elles sont diffuses, on a p.s.

$$|X|_{(1)} < |X|_{(2)} < \dots < |X|_{(n)}.$$

On note $R_{|X|}$ le vecteur des rangs associé. On pose

$$W_n^+ = \sum_{i=1}^n R_{|X|}(i) \mathbb{1}_{\{X_i > 0\}}, \quad W_n^- = \sum_{i=1}^n R_{|X|}(i) \mathbb{1}_{\{X_i < 0\}}.$$

Exemple 3.17

x_i	-0,15	-0,42	0,22	0,60	-0,10
$ x_i $	0,15	0,42	0,22	0,60	0,10
$R_{ X }(i)$	2	4	3	5	1

Alors $w_n^+ = 3 + 5 = 8$ et $w_n^- = 2 + 4 + 1 = 7$.

Remarque 3.18

On a $0 \leq W_n^+ \leq \frac{n(n+1)}{2}$. Le cas $W_n^+ = 0$ correspond au cas où $X_i < 0$ pour tout i ; le cas $W_n^+ = \frac{n(n+1)}{2}$ correspond au cas où $X_i > 0$ pour tout i .

Si $\mathbb{P}(X_i = 0) = 0$ (ce qui est le cas si les variables sont diffuses), alors

$$W_n^+ + W_n^- = \frac{n(n+1)}{2}.$$




FIGURE 3.1 – Échantillon de loi symétrique centré en $m = 0$ (à gauche) et en $m = 1$ (à droite).

Supposons pour fixer les idées que $H_1 : m > 0$. Sous H_1 , il y a plus de X_i positifs que de X_i négatifs (même idée que pour le test du signe). Mais, du fait de la symétrie, les X_i positifs ont aussi tendance à être plus grands en valeur absolue : c'est l'information supplémentaire exploitée ici. Sous cette alternative, W_n^+ a donc tendance à être grand. Si l'alternative est $H_1 : m < 0$, alors au contraire W_n^+ a tendance à être petit.

Exemple 3.19

Prenons un exemple concret. On simule un échantillon de taille $n = 30$ de loi de Cauchy standard (i.e. de paramètre de position $m = 0$), de densité $f(x) = \frac{1}{\pi(1+x^2)}$ (en noir). On simule ensuite un échantillon de même taille de loi de Cauchy de paramètre de position $m = 1$, i.e. de densité $f(x) = \frac{1}{\pi(1+(x-1)^2)}$. Ces deux échantillons sont représentés dans la figure 3.1.

On remarque que :

- dans le premier échantillon, il y a autant de valeurs positives que négatives ; par symétrie autour de 0, les valeurs absolues des x_i positifs n'ont pas tendance à être plus grandes que celles des x_i négatifs ;
- dans le second échantillon, il y a plus de valeurs positives que de valeurs négatives ; de plus, les valeurs positives ont tendance à recevoir les rangs les plus élevés parmi les $|x_i|$.

Exemple 3.20: Nécessité de la condition de symétrie

On simule un échantillon de densité

$$f(x) = \frac{1}{2}e^{-x}\mathbb{1}_{\{x>0\}} + \frac{1}{2} \cdot 3e^{3x}\mathbb{1}_{\{x<0\}}.$$

Cette loi a pour médiane 0 mais n'est pas symétrique. L'échantillon est représenté sur la figure 3.2. On observe qu'il y a à peu près autant de valeurs positives que négatives, mais que les x_i positifs ont tendance à prendre des valeurs absolues plus grandes.




FIGURE 3.2 – Échantillon de loi non symétrique de médiane égale à 0.

Théorème 3.21

Les conditions 3.4–3.7 sont supposées vérifiées. Sous $H_0 : m = 0$:

1. $W_n^+ \sim W_n^-$;
2. $\mathbb{E}[W_n^+] = \frac{n(n+1)}{4}$;
3. W_n^+ et W_n^- sont libres en loi de X_1^n : on a

$$W_n^+ \sim \sum_{k=1}^n k Y_k, \quad Y_1, \dots, Y_n \stackrel{iid}{\sim} Be(1/2);$$

4. $\text{Var}(W_n^+) = \frac{n(n+1)(2n+1)}{24}$;

5. asymptotiquement,

$$\frac{W_n^+ - \mathbb{E}[W_n^+]}{\sqrt{\text{Var}(W_n^+)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Démonstration. On admet la preuve de l'item 5. On se place sous H_0 .

1. On peut écrire

$$W_n^+ = \sum_{i=1}^n R_{|X|}(i) \mathbb{1}_{\{X_i > 0\}} = \sum_{j=1}^n j \mathbb{1}_{\{X_{\sigma_{|X|}(j)} > 0\}},$$

où $\sigma_{|X|} = R_{|X|}^{-1}$. De même

$$W_n^- = \sum_{j=1}^n j \mathbb{1}_{\{X_{\sigma_{|X|}(j)} < 0\}}.$$

Les lois des X_i étant symétriques et les X_i étant indépendantes, on a $X_1^n \sim -X_1^n$. Donc pour toute fonction mesurable f , $f(X_1^n) \sim f(-X_1^n)$.

Or W_n^+ est une fonction du vecteur X_1^n . Donc on a

$$W_n^+ = \sum_{j=1}^n j \mathbb{1}_{\{X_{\sigma_{|X|}(j)} > 0\}} \sim \sum_{j=1}^n j \mathbb{1}_{\{-X_{\sigma_{|X|}(j)} > 0\}}$$

Or $\sigma_{|X|} = \sigma_{|-X|}$ donc, $W_n^+ \sim \sum_{j=1}^n j \mathbb{1}_{\{-X_{\sigma_{|X|}(j)} > 0\}} = \sum_{j=1}^n j \mathbb{1}_{\{X_{\sigma_{|-X|}(j)} < 0\}} = W_n^-$, i.e. W_n^+ et W_n^- sont de même loi.

2. De la même manière que pour l'item 1, la symétrie de la loi de X_1^n implique que, pour tout $1 \leq j \leq n$, $X_{\sigma_{|X|}(j)} \sim -X_{\sigma_{|X|}(j)}$ et donc

$$\mathbb{P}(X_{\sigma_{|X|}(j)} > 0) = \mathbb{P}(X_{\sigma_{|X|}(j)} < 0).$$

Ainsi, si on montre que $\mathbb{P}(X_{\sigma_{|X|}(j)} = 0) = 0$, on aura

$$\mathbb{P}(X_{\sigma_{|X|}(j)} > 0) = 1/2$$

et donc

$$\mathbb{E}(W_n^+) = \sum_{i=1}^n i \mathbb{P}(X_{\sigma_{|X|}(i)} > 0) = n(n+1)/4$$

Montrons donc que $X_{\sigma_{|X|}(j)}$ est diffuse. On a pour tout $x \in \mathbb{R}$

$$\mathbb{P}(X_{\sigma_{|X|}(j)} = x) = \sum_{i=1}^n \mathbb{P}(X_i = x, \sigma_{|X|}(j) = i) = 0$$

car les X_i sont diffuses.

3. On va utiliser la symétrie de la même manière que dans la sous-section 1.6.2).

On va montrer que

$$(\mathbb{1}_{X_{\sigma_{|X|}(1)} > 0}, \dots, \mathbb{1}_{X_{\sigma_{|X|}(n)} > 0}) \sim (Y_1, \dots, Y_n)$$

où

$$Y_1, \dots, Y_n \stackrel{iid}{\sim} Be(1/2).$$

En effet, soit $(\epsilon_1, \dots, \epsilon_n) \in \{0, 1\}^n$, on a

$$\begin{aligned} \mathbb{P}((\mathbb{1}_{X_{\sigma_{|X|}(1)} > 0}, \dots, \mathbb{1}_{X_{\sigma_{|X|}(n)} > 0}) = (\epsilon_1, \dots, \epsilon_n)) \\ = \sum_{s \in \mathfrak{S}_n} \mathbb{P}((\mathbb{1}_{X_{s(1)} > 0}, \dots, \mathbb{1}_{X_{s(n)} > 0}) = (\epsilon_1, \dots, \epsilon_n), \sigma_{|X|} = s) \end{aligned}$$

On va montrer que, pour $s \in \mathfrak{S}_n$, on a

$$\mathbb{P}((\mathbb{1}_{X_{s(1)} > 0}, \dots, \mathbb{1}_{X_{s(n)} > 0}) = (\epsilon_1, \dots, \epsilon_n), \sigma_{|X|} = s) = \frac{1}{2^n} \mathbb{P}(\sigma_{|X|} = s) \quad (3.8)$$

Comme $X_{s(i)} \sim -X_{s(i)}$ et comme les $X_{s(i)}$ sont indépendantes on a

$$(X_{s(1)}, \dots, X_{s(n)}) \sim (\pm X_{s(1)}, \dots, \pm X_{s(n)}).$$

De plus le vecteur $\sigma_{|X|}$ ne change pas si on change les signes des $X_{s(i)}$ et les variables étant diffuses on a, p.s., $X_{s(i)} > 0$ ou $X_{s(i)} < 0$ pour tout i .

Ainsi on a, pour tout $(\tilde{\epsilon}_1, \dots, \tilde{\epsilon}_n) \in \{0, 1\}^n$,

$$\mathbb{P}((\mathbb{1}_{X_{s(1)} > 0}, \dots, \mathbb{1}_{X_{s(n)} > 0}) = (\epsilon_1, \dots, \epsilon_n), \sigma_{|X|} = s) = \mathbb{P}((\mathbb{1}_{X_{s(1)} > 0}, \dots, \mathbb{1}_{X_{s(n)} > 0}) = (\tilde{\epsilon}_1, \dots, \tilde{\epsilon}_n), \sigma_{|X|} = s)$$

Comme

$$\mathbb{P}(\sigma_{|X|} = s) = \sum_{(\tilde{\epsilon}_1, \dots, \tilde{\epsilon}_n) \in \{0, 1\}^n} \mathbb{P}(\sigma_{|X|} = s, \mathbb{1}_{X_{s(1)} > 0}, \dots, \mathbb{1}_{X_{s(n)} > 0}) = (\tilde{\epsilon}_1, \dots, \tilde{\epsilon}_n))$$

on obtient bien 3.8. Ainsi

$$\begin{aligned} \mathbb{P}((\mathbb{1}_{X_{\sigma_{|X|}(1)} > 0}, \dots, \mathbb{1}_{X_{\sigma_{|X|}(n)} > 0}) = (\epsilon_1, \dots, \epsilon_n)) \\ = \frac{1}{2^n} \sum_{s \in \mathfrak{S}_n} \mathbb{P}(\sigma_{|X|} = s) \\ = \frac{1}{2^n} \\ = \mathbb{P}((Y_1, \dots, Y_n) = (\epsilon_1, \dots, \epsilon_n)) \end{aligned}$$

Ceci prouve l'item 3 : $W_n^+ \sim \sum_{j=1}^n jY_j$. Ceci permet aussi de trouver la valeur de la variance : en effet

$$\begin{aligned}\text{Var}\left(\sum_{j=1}^n j\mathbb{1}_{\{X_{\sigma_{|X|}(j)} > 0\}}\right) &= \sum_{j=1}^n j^2 \text{Var}(Y_j) \\ &= \sum_{j=1}^n \frac{j^2}{4} = \frac{n(n+1)(2n+1)}{24}\end{aligned}$$

□

Remarque 3.22

Sous H_0 , la statistique W_n^+ a une distribution symétrique par rapport à sa moyenne $\frac{n(n+1)}{4}$. En effet, sous H_0 , $W_n^+ \sim W_n^-$ et $W_n^+ + W_n^- = \frac{n(n+1)}{2}$, donc

$$W_n^+ \sim \frac{n(n+1)}{2} - W_n^+,$$

c'est-à-dire $W_n^+ - \frac{n(n+1)}{4} \sim -\left(W_n^+ - \frac{n(n+1)}{4}\right)$.

En conséquence, pour l'alternative bilatérale $H_1 : m \neq 0$, on rejette lorsque $|W_n^+ - \frac{n(n+1)}{4}|$ est grand. Un test au niveau α peut s'écrire

$$\varphi_\alpha(X_1, \dots, X_n) = \mathbb{1}_{\left\{|W_n^+ - \frac{n(n+1)}{4}| > q_{1-\alpha/2} - \frac{n(n+1)}{4}\right\}},$$

où $q_{1-\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi de W_n^+ sous H_0 , c'est-à-dire de la loi de $\sum_{j=1}^n jY_j$ avec $Y_1, \dots, Y_n \stackrel{iid}{\sim} Be(1/2)$.

Remarque 3.23: Test exact ou asymptotique ?

On utilise la loi exacte de W_n^+ sous H_0 quand $n \leq 20$. Pour $n > 20$, on utilise un test asymptotique fondé sur la convergence en loi.

Implémentation 3.24

Pour tester $H_0 : m = 0$ contre $H_1 : m \neq 0$, si l'échantillon est dans un vecteur $\mathbf{x}$, on peut utiliser :

```
wilcox.test(x, alternative="two.sided").
```

En Python, on peut utiliser :

```
scipy.stats.wilcoxon(x, alternative="two-sided").
```

(On retire en pratique les zéros : la fonction le fait souvent automatiquement, mais il vaut mieux contrôler explicitement.)

3.5.2 Échantillons appariés

On dispose de deux échantillons appariés de taille n , $(U_1, \dots, U_n)$ et $(V_1, \dots, V_n)$. Comme pour le test du signe, on pose $X_i = V_i - U_i$ et on applique le test des rangs signés de Wilcoxon à l'échantillon $(X_1, \dots, X_n)$. On suppose donc que les X_i vérifient les conditions 3.4–3.7.

L'hypothèse nulle est $H_0 : m = 0$. Si l'on pense que l'alternative possible est $m > 0$ (i.e. V tend à être plus grand que U), on prend $H_1 : m > 0$.

Remarque 3.25

Le test des rangs signés est plus puissant que le test du signe ; il est donc conseillé de l'utiliser lorsqu'on a accès aux valeurs des différences (et lorsque l'hypothèse de symétrie est plausible).

Implémentation 3.26

R. On peut utiliser `wilcox.test` avec `paired=TRUE`. Si les échantillons sont dans `x` et `y` et si $H_1 : m \neq 0$, on écrit :

```
wilcox.test(x, y, paired=TRUE, alternative="two.sided").
```

Équivalent : `wilcox.test(x-y, alternative="two.sided").`

Attention aux ex-æquo (ties). Avec des ex-æquo dans $|x_i|$, la p-value exacte n'est plus calculable et `wilcox.test` bascule sur une approximation normale ; on obtient alors typiquement : `Warning message: cannot compute exact p-value with ties.`

L'approximation normale est fiable surtout pour des tailles d'échantillon suffisamment grandes ; pour des petits n avec beaucoup d'ex-æquo, il faut interpréter les résultats avec prudence.

Python. On peut utiliser `scipy.stats.wilcoxon(x, y)` ou `scipy.stats.wilcoxon(x-y)`. Par défaut, les ex aequo sont supprimés ; ce comportement est paramétrable.

Remarque 3.27

Pour tester l'hypothèse de symétrie des X_i (dans le cas i.i.d.), on peut commencer par représenter les données (histogramme, densité), ou utiliser un test de symétrie (par exemple `symmetry.test` du package `lawstat`, qui peut être un peu lent). En cas d'asymétrie forte sur l'échantillon des différences, il semble préférable d'utiliser le test du signe.

3.6 Test de Wilcoxon de la somme des rangs (Mann–Whitney)

Intuition 3.28

Nous avons vu dans l'intuition 3.15 (page 53) que le test de Wilcoxon des rangs signés utilise l'indépendance entre valeur absolue et signe.

Pour un échantillon iid $(X_1, \dots, X_n)$, une autre indépendance peut être exploitée : celle entre la statistique d'ordre $X^* = (X_{(1)}, \dots, X_{(n)})$ et le vecteur des rangs R_X . Intuitivement, une façon de générer l'échantillon $(X_1, \dots, X_n)$ est de tirer d'abord les valeurs triées X^* , puis de tirer une permutation aléatoire (le vecteur des rangs) qui ré-attribue ces valeurs aux indices. Cette indépendance est utilisée dans le test de Wilcoxon de la somme des rangs (dit aussi test de Mann–Whitney, ou Wilcoxon–Mann–Whitney).

3.6.1 Résultats préliminaires sur le vecteur des rangs

On commence par quelques résultats liés au vecteur des rangs dans le cas i.i.d.

Théorème 3.29

Soient $X_1, \dots, X_n$ des v.a. i.i.d. de loi continue, de statistique d'ordre X^* et de vecteur des rangs R_X . Alors X^* et R_X sont indépendants et, de plus, R_X est de loi uniforme sur $\mathfrak{S}_n$.

Démonstration. La loi est continue donc, p.s., il n'y a pas d'ex-æquo. Le rang R_X est à valeurs dans $\mathfrak{S}_n$. Comme R_X est la permutation inverse de σ_X , il suffit en fait de montrer que σ_X suit une

loi uniforme sur $\mathfrak{S}_n$ et que σ_X et X^* sont indépendants.

Puisque les X_i sont i.i.d., ils sont interchangeables. Donc, pour tout $s \in \mathfrak{S}_n$,

$$\mathbb{P}(\sigma_X = s) = \frac{1}{\text{Card}(\mathfrak{S}_n)} = \frac{1}{n!}.$$

Par exemple, pour $n = 3$, on a

$$\begin{aligned} \mathbb{P}(X_1 < X_2 < X_3) &= \mathbb{P}(X_1 < X_3 < X_2) = \mathbb{P}(X_2 < X_1 < X_3) = \mathbb{P}(X_2 < X_3 < X_1) \\ &= \mathbb{P}(X_3 < X_2 < X_1) = \mathbb{P}(X_3 < X_1 < X_2) = 1/6. \end{aligned}$$

Or, le premier terme n'est rien d'autre que $\mathbb{P}(\sigma_X = (1, 2, 3))$, le deuxième est $\mathbb{P}(\sigma_X = (1, 3, 2))$, le troisième $\mathbb{P}(\sigma_X = (2, 1, 3))$, etc.

Montrons l'indépendance entre σ_X et X^* .

On veut montrer que, pour tout borélien B de $\mathbb{R}^n$ et toute permutation s de $\mathfrak{S}_n$, on a

$$\mathbb{P}(X^* \in B \cap \sigma_X = s) = \mathbb{P}(X^* \in B) \mathbb{P}(\sigma_X = s).$$

Et comme $\mathbb{P}(\sigma_X = s) = \frac{1}{n!}$, cela revient à montrer que, pour toute permutation $s \in \mathfrak{S}_n$

$$\mathbb{P}(X^* \in B) = n! \mathbb{P}(X^* \in B \cap \sigma_X = s)$$

Comme les X_i sont indépendantes et de même loi, elles sont interchangeables et donc, pour tout s et tout B ,

$$\begin{aligned} \mathbb{P}(X^* \in B \cap \sigma_X = s) &= \mathbb{P}(X_{s(1)} < \dots < X_{s(n)}, (X_{s(1)}, \dots, X_{s(n)}) \in B) \\ &= \mathbb{P}(X_1 < \dots < X_n, (X_1, \dots, X_n) \in B) \end{aligned}$$

D'autre part

$$\begin{aligned} \mathbb{P}(X^* \in B) &= \sum_{s \in \mathfrak{S}_n} \mathbb{P}(X^* \in B \cap \sigma_X = s) \\ &= \sum_{s \in \mathfrak{S}_n} \mathbb{P}(X_1 < \dots < X_n, (X_1, \dots, X_n) \in B) \\ &= n! \mathbb{P}(X_1 < \dots < X_n, (X_1, \dots, X_n) \in B) \\ &= n! \mathbb{P}(X^* \in B \cap \sigma_X = s) \end{aligned}$$

où s est une permutation quelconque. □

La principale conséquence est que la loi de R_X ne dépend pas de la loi des X_i (tant qu'elle est continue). On en déduit que toute statistique ne dépendant que des rangs d'observations i.i.d. continues a une loi indépendante de la loi sous-jacente.

Remarque 3.30

Pour tout s (non aléatoire) dans $\mathfrak{S}_n$, on a

$$(X_{s(1)}, \dots, X_{s(n)}) \sim (X_1, \dots, X_n).$$

Mais ce n'est pas vrai si la permutation est aléatoire, sauf si elle est indépendante des X_i . Par exemple,

$$X^* = (X_{(1)}, \dots, X_{(n)}) \approx (X_1, \dots, X_n).$$

Proposition 3.31

Soient $X_1, \dots, X_n$ des v.a. i.i.d. de loi continue et de vecteur des rangs $R_X = (R_1, \dots, R_n)$. Pour tout entier s tel que $1 \leq s \leq n$, et pour toute suite d'entiers distincts $(r_1, \dots, r_s)$ dans $\{1, \dots, n\}$, on a

$$\mathbb{P}((R_1, \dots, R_s) = (r_1, \dots, r_s)) = \frac{1}{n(n-1) \cdots (n-s+1)}.$$

En particulier, pour tout $i \in \{1, \dots, n\}$, R_i suit une loi uniforme sur $\{1, \dots, n\}$.

Démonstration. Pour simplifier, considérons d'abord trois cas simples.

- $s = n$: $\mathbb{P}((R_1, \dots, R_n) = (r_1, \dots, r_n)) = \mathbb{P}(R = r)$ où $r = (r_1, \dots, r_n) \in \mathfrak{S}_n$. Donc, d'après le théorème précédent, on a $\mathbb{P}((R_1, \dots, R_n) = (r_1, \dots, r_n)) = \frac{1}{n!}$.
- $s = 1$: $\mathbb{P}(R_1 = r) = \mathbb{P}(\text{« } X_1 \text{ est le } r\text{-ème plus petit élément de l'échantillon »}) = \frac{1}{n}$, toujours du fait que les X_i sont interchangeables.
- $s = 2$: alors

$$\mathbb{P}((R_1, R_2) = (r_1, r_2)) = \mathbb{P}(R_1 = r_1) \mathbb{P}(R_2 = r_2 \mid R_1 = r_1) = \frac{1}{n} \frac{1}{n-1}$$

et le cas général s'obtient par la même idée (construction séquentielle). □

3.6.2 Définition et propriétés du test de Mann–Whitney

On se donne deux échantillons U_1^n et V_1^p tels que :

1. $U_1, \dots, U_n \stackrel{iid}{\sim} U$ et $V_1, \dots, V_p \stackrel{iid}{\sim} V$;
2. U_1^n et V_1^p sont indépendants ;
3. U et V sont diffuses.

Les échantillons ne sont pas forcément de même taille.

On note F la fonction de répartition de U et G celle de V . L'hypothèse nulle est

$$H_0 : F = G.$$

Cependant, contrairement au test d'homogénéité de K-S, l'alternative **n'est pas** $F \neq G$.

On suppose en fait que :

- soit U et V ont la même loi (H_0)
- soit l'une des deux variables a tendance à prendre des valeurs plus grandes que l'autre (H_1).

Remarque 3.32

Le test est souvent utilisé contre des alternatives de type “décalage de position” C'est pour cela que, dans R, on lit `alternative hypothesis: true location shift is not equal to 0`.

Exemple 3.33

On veut tester un nouveau médicament par rapport à un ancien médicament. On donne le premier à un groupe de n personnes, et le deuxième à un groupe de p personnes, ces deux groupes étant indépendants. On veut voir si le nouveau médicament est plus efficace que l'ancien.

Remarque 3.34

Le test de Student peut être vu comme un test d'égalité en loi quand on suppose que les données sont gaussiennes et ne peuvent différer que par leur moyenne. Dans ce sens, le test de Mann–Whitney peut être vu comme une version non paramétrique (et plus robuste) de la comparaison de deux populations indépendantes.

On regroupe les deux échantillons pour former un seul échantillon de taille $N = n + p$:

$$(U_1, \dots, U_n, V_1, \dots, V_p).$$

On classe ensuite toutes les observations par leur rang global dans cet échantillon. On obtient un vecteur de rangs, noté $R_{U,V}$. On note $R_1, \dots, R_n$ les rangs associés aux U_i et $S_1, \dots, S_p$ les rangs associés aux V_j .

Exemple 3.35

Soient $u_1 = 3.5$, $u_2 = 4.7$, $u_3 = 1.2$, $v_1 = 0.7$, $v_2 = 3.9$. Alors $v_1 < u_3 < u_1 < v_2 < u_2$. Donc $r_1 = 3$, $r_2 = 5$, $r_3 = 2$, $s_1 = 1$, $s_2 = 4$.

On pose

$$\Sigma_1 = R_1 + \dots + R_n, \quad \Sigma_2 = S_1 + \dots + S_p.$$

Intuition 3.36

Pour fixer les idées, supposons d'abord $n = p$. Sous H_0 , on s'attend à ce que Σ_1 et Σ_2 soient proches. Si l'alternative correspond au fait que les U_i ont tendance à être plus grands que les V_j , alors les rangs R_i des U_i seront en moyenne plus grands que les rangs S_j des V_j . Donc Σ_1 aura tendance à être “anormalement grand” sous H_1 .

Même si $n \neq p$, le même phénomène subsiste : sous H_1 , Σ_1 tend à être trop grand (ou trop petit) relativement à ce qui se passe sous H_0 .

Plus généralement, si l'on n'a pas d'a priori sur le sens de l'effet, on s'attend à ce que Σ_1 soit anormalement grand ou anormalement petit (par rapport à H_0).

La question devient : quelles valeurs de Σ_1 sont “normales” sous H_0 ? Les résultats suivants répondent à cette question.

Proposition 3.37

On a

$$\frac{n(n+1)}{2} \leq \Sigma_1 \leq np + \frac{n(n+1)}{2}, \quad \frac{p(p+1)}{2} \leq \Sigma_2 \leq np + \frac{p(p+1)}{2}.$$

Sous $H_0 : F = G$, et sous les conditions 1–3, on a, pour tout i et tout j ,

$$\mathbb{E}(R_i) = \mathbb{E}(S_j) = \frac{n+p+1}{2}, \quad \mathbf{Var}(R_i) = \mathbf{Var}(S_j) = \frac{(n+p)^2 - 1}{12}.$$

De plus,

$$\mathbb{E}(\Sigma_1) = \frac{n(n+p+1)}{2}, \quad \mathbb{E}(\Sigma_2) = \frac{p(n+p+1)}{2},$$

et

$$\mathbf{Var}(\Sigma_1) = \mathbf{Var}(\Sigma_2) = \frac{np(n+p+1)}{12}.$$

Au vu de la proposition, on considère naturellement :

$$M_U = \Sigma_1 - \frac{n(n+1)}{2}, \quad M_V = \Sigma_2 - \frac{p(p+1)}{2},$$

qui sont toutes deux à valeurs dans $\{0, 1, \dots, np\}$.

Proposition 3.38

On suppose les conditions 1–3 vérifiées. Alors :

1. $M_U + M_V = np$ p.s. ;
2. sous $H_0 : F = G$, la loi de M_V est symétrique par rapport à $\frac{np}{2}$;
3. sous $H_0 : F = G$, $M_U \sim M_V$;
4. M_V est égal au nombre de paires (U_i, V_j) telles que $U_i < V_j$.

Démonstration. 1. La somme des rangs de toutes les $N = n + p$ observations vaut $\sum_{k=1}^N k = \frac{N(N+1)}{2}$. Donc

$$M_U + M_V = \Sigma_1 - \frac{n(n+1)}{2} + \Sigma_2 - \frac{p(p+1)}{2} = \frac{(n+p)(n+p+1)}{2} - \frac{n(n+1)}{2} - \frac{p(p+1)}{2} = np.$$

2. Sous H_0 , considérons les rangs $(S'_1, \dots, S'_p)$ des V_j lorsque l'on ordonne l'échantillon global dans l'ordre décroissant. On a $(S'_1, \dots, S'_p) \sim (S_1, \dots, S_p)$ (même argument que dans la proposition 3.31), donc $\Sigma'_2 \sim \Sigma_2$ où $\Sigma'_2 = \sum_{j=1}^p S'_j$. Or, pour tout j , $S'_j = N + 1 - S_j$, donc

$$\Sigma'_2 = (N + 1)p - \Sigma_2.$$

Ainsi,

$$\Sigma_2 \sim (N + 1)p - \Sigma_2,$$

ce qui implique

$$M_V = \Sigma_2 - \frac{p(p+1)}{2} \sim (N + 1)p - \Sigma_2 - \frac{p(p+1)}{2} = np - M_U.$$

Donc M_V est symétrique par rapport à $np/2$.

3. On combine les deux premiers items.
4. On se place sous H_0 . Pour interpréter M_V , supposons sans perte de généralité que $v_1 < \dots < v_p$. Pour chaque j , il y a $S_j - j$ éléments du premier échantillon strictement plus petits que v_j . Donc le nombre total de paires (u_i, v_j) telles que $u_i < v_j$ vaut

$$\sum_{j=1}^p (S_j - j) = \Sigma_2 - \frac{p(p+1)}{2} = M_V.$$

□

Théorème 3.39

Sous les conditions 1–3 :

- sous H_0 , la loi de M_U (et donc celle de M_V) est libre : elle ne dépend que de n et p ;
- asymptotiquement, lorsque $n, p \rightarrow +\infty$,

$$\frac{M_U - \mathbb{E}(M_U)}{\sqrt{\text{Var}(M_U)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1),$$

et

$$\mathbb{E}(M_U) = \frac{np}{2}, \quad \text{Var}(M_U) = \frac{np(n+p+1)}{12}.$$

Démonstration. On admet la convergence en loi.

La variable $M_U = \Sigma_1 - \frac{n(n+1)}{2}$ est une fonction des rangs $(R_1, \dots, R_n)$. Sous H_0 , la loi de ces rangs est donnée par la proposition 3.31 : pour toute suite d'entiers $(r_1, \dots, r_n)$ à valeur dans $[N]$, on a

$$\mathbb{P}_{F=G}((R_1, \dots, R_n) = (r_1, \dots, r_n)) = \frac{1}{N(N-1) \dots (N-n+1)}.$$

Elle ne dépend donc pas de F mais seulement de n et p .

Les formules d'espérance et de variance se déduisent de celles de Σ_1 (proposition 3.37). $\square$

Remarque 3.40: Test exact ou asymptotique

Pour de petits n et p , on peut utiliser la loi exacte (tabulée/algorithme exacts). Pour des tailles plus grandes, on utilise l'approximation gaussienne.

Remarque 3.41: Correction de continuité

Supposons que la statistique de test T_n prenne des valeurs discrètes (par exemple entières) mais que, pour n grand, sa loi soit approchée par une loi gaussienne, donc continue. Alors, pour $p \in \mathbb{N}$ et $u \in [0, 1)$, on a $\mathbb{P}(T_n \geq p) = \mathbb{P}(T_n \geq p - u)$. La correction de continuité consiste à remplacer p par $p \pm 0,5$ dans l'approximation gaussienne. Plus précisément, si

$$a_n(T_n - t_n) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1),$$

on approche comme suit :

$$\mathbb{P}(T_n \geq p) = \mathbb{P}(a_n(T_n - t_n) \geq a_n(p - t_n)) \approx 1 - \Phi(a_n(p - 0.5 - t_n))$$

$$\mathbb{P}(T_n \leq p) = \mathbb{P}(a_n(T_n - t_n) \leq a_n(p - t_n)) \approx \Phi(a_n(p + 0.5 - t_n))$$

Implémentation 3.42

— R : on utilise `wilcox.test` avec `paired = FALSE` (par défaut). Par exemple :

```
wilcox.test(salaires$hommes, salaires$femmes, alternative = "greater")
```

l'argument `exact` indique si on veut le test exact ou l'approximation gaussienne. Cet argument est par défaut à `true` si l'un des échantillons a une taille supérieure à 50 et à `false` dans le cas contraire. L'argument `correct` indique si on veut la correction de continuité quand on utilise l'approximation gaussienne. Il est par défaut à `TRUE`.

— Python : `scipy.stats.mannwhitneyu(x, y, alternative='two-sided')`.

Remarque 3.43

De la même manière que le test de Student pour comparer deux moyennes se généralise à plus de deux échantillons par l'ANOVA à un facteur, l'analogue non paramétrique du test de Mann-Whitney pour plus de deux échantillons (de tailles éventuellement différentes) est le test de Kruskal-Wallis.

Implémentation 3.44: Kruskal–Wallis

- R : `kruskal.test`
- Python : `scipy.stats.kruskal`

Remarque 3.45

En plus d'être adaptés à un plus grand nombre de lois, les tests basés sur les rangs sont plus robustes à la présence d'observations aberrantes (*outliers*) dans l'échantillon.

Remarque 3.46: Paramétrique ou non paramétrique ?

Souvent, si le modèle paramétrique est correct, les tests paramétriques sont plus puissants que les tests non paramétriques. Cependant, ils sont aussi plus contraignants, car il faut vérifier davantage de conditions d'application. On choisira généralement un test non paramétrique lorsque :

- les conditions d'application du test paramétrique ne sont pas vérifiées ;
- ou il est impossible de vérifier ces conditions.

Remarque 3.47: Comparaison test KS et test de Mann–Whitney (MW)

Le test KS est sensible à tout changement entre deux distributions (forme, étendue, position, etc.). En revanche, le test MW est surtout sensible à un changement de position (et plus généralement à un ordre stochastique), d'où des comportements différents (cf. illustration).


Illustration : On regarde ci-dessous les performances respectives des tests de Kolmogorov-Smirnov et de Mann-Whitney sur un cas particulier. Plus précisément, on utilise deux échantillons qui ne sont pas de même loi : l'un est de loi normale, l'autre est un mélange de deux lois gamma dont on représente la densité ci-dessous. Imaginons qu'on utilise KS et MW pour tester l'égalité des lois sur ces deux échantillons. On regarde la p-valeur de chaque test ainsi que la puissance pour des test de niveau 95%.

```
set.seed(1)

n <- 100
B <- 1000
alpha <- 0.05

# densité de la Gamma(2,1) symétrisée
f <- function(x) 0.5 * dgamma(abs(x), shape = 2, rate = 1)

x <- seq(-10, 10, by = 0.01)
plot(x, f(x), type = "l")
```



Une fonction qui simule deux échantillons de chaque loi, effectue les deux tests sur ces échantillons et conserve la p-valeur :

```
one_run <- function() {
  z <- rnorm(n)
  t <- rgamma(n, shape = 2, rate = 1)
  rad <- sample(c(-1, 1), n, replace = TRUE) # Rademacher
  y <- rad * t

  c(
    KS = ks.test(y, z)$p.value,
    MW = wilcox.test(y, z, exact = FALSE)$p.value
  )
}
```

On effectue B=1000 fois cette expérience, on calcule la puissance moyenne et on affiche les histogrammes de

p-valeurs :

```
pvals <- replicate(B, one_run())
KS <- pvals["KS", ]
MW <- pvals["MW", ]
```

```
power_KS <- mean(KS <= alpha)
power_MW <- mean(MW <= alpha)
```

```
cat("Puissance (empirique) en alpha =", alpha,
    ": KS =", power_KS,
    ", MW =", power_MW, "\n")
```

```
## Puissance (empirique) en alpha = 0.05 : KS = 0.997 , MW = 0.066
```

```
par(mfrow=c(1,2))
hist(KS, breaks=30, main="KS p-values", xlab="p-value")
hist(MW, breaks=30, main="MW p-values", xlab="p-value")
abline(v=0.05, lty=2)
```

