

Chapitre 4

Estimation de densités par estimateurs à noyau

4.1 Rappels d'analyse

Définition de la différentiabilité : soit $\ell : \mathbb{R}^m \rightarrow \mathbb{R}^p$. L'application ℓ est différentiable en u s'il existe une application linéaire $D\ell(u) : \mathbb{R}^m \rightarrow \mathbb{R}^p$ (qu'on peut donc représenter par une matrice élément de $M_{pm}(\mathbb{R})$) telle que :

$$\forall \epsilon > 0, \exists \delta > 0 : \|x - u\| \leq \delta \longrightarrow \|\ell(x) - \ell(u) - D\ell(u)(x - u)\| \leq \epsilon \|x - u\|$$

Formule de Taylor-Lagrange : soit $f : [a, b] \rightarrow \mathbb{R}$ où $[a, b]$ est un intervalle de $\mathbb{R}$. On suppose que f est de classe $\mathcal{C}^{n-1}$ sur $[a, b]$ et n fois dérivable sur $]a, b[$. Alors il existe $\eta \in]0, 1[$ tel que

$$f(b) = \sum_{k=0}^{n-1} f^{(k)}(a) \frac{(b-a)^k}{k!} + f^{(n)}(a + \eta(b-a)) \frac{(b-a)^n}{n!}$$

Formule de Taylor avec reste intégral : on suppose que $f \in \mathcal{C}^n$ sur $[a, b]$ alors

$$f(b) = \sum_{k=0}^{n-1} f^{(k)}(a) \frac{(b-a)^k}{k!} + \int_a^b \frac{(b-t)^{n-1}}{(n-1)!} f^{(n)}(t) dt$$

4.2 Introduction

L'objectif du chapitre est d'estimer une densité f à l'aide d'un n -échantillon i.i.d. $X_1^n = (X_1, \dots, X_n)$ où X_i de densité f par rapport à la mesure de Lebesgue.

Mesure de la qualité d'un estimateur :

1. Définition d'une distance sur l'espace des fonctions :

- Distance L_p : $d(f, g) = \|f - g\|_p = \left(\int |f(x) - g(x)|^p dx \right)^{\frac{1}{p}}$
Cas usuel $p = 2$ ou $p = 1$.
- distance L_∞ : $d(f, g) = \|f - g\|_\infty = \sup_{x \in \mathbb{R}} |f(x) - g(x)|$.
- Distance ponctuelle en x_0 : $d(f, g) = |f(x_0) - g(x_0)|$

2. Définition d'une fonction de perte $\omega : \mathbb{R} \rightarrow \mathbb{R}^+$ telle que ω est convexe et $\omega(0) = 0$.

Exemple : $\omega(x) = x^2$.

3. Définition du risque d'un estimateur $\hat{f}_n$:

$$R(\hat{f}_n, f) = \mathbb{E}[\omega(d(\hat{f}_n, f))]$$

où $\mathbb{E}$ désigne l'espérance sous la loi des X_i .

Exemples usuels :

— $d(f, g) = |f(x_0) - g(x_0)|$, $\omega(x) = x^2$:

$$R(\hat{f}_n, f) = \mathbb{E}[|\hat{f}_n(x_0) - f(x_0)|^2]$$

— $d(f, g) = \|f - g\|_2$, $\omega(x) = x^2$

$$R(\hat{f}_n, f) = \mathbb{E}[\|\hat{f}_n - f\|_2^2]$$

On cherche à déterminer $\hat{f}_n$ tel que $R(\hat{f}_n, f)$ soit minimal. On ne suppose pas que la fonction de densité f appartient à une famille paramétrique. On fait des hypothèses moins restrictives : f appartient à une classe fonctionnelle qu'on note $\mathcal{F}$. On peut alors définir un risque, qu'on appelle risque minimax de $\hat{f}_n$ sur la classe $\mathcal{F}$, par

$$R(\hat{f}_n, \mathcal{F}) = \sup_{f \in \mathcal{F}} R(\hat{f}_n, f)$$

On va donc chercher un estimateur $\hat{f}_n$ tel que le risque $R(\hat{f}_n, \mathcal{F})$ tende vers zéro le plus vite possible quand n tend vers l'infini.

Définition 4.1

Soit $(r_n)_n$ une suite et une constante C telles que

$$\forall n \quad R(\hat{f}_n, \mathcal{F}) \leq C r_n$$

On dit que la suite d'estimateurs $(\hat{f}_n)_n$ atteint la vitesse (ou le taux) r_n sur la classe $\mathcal{F}$, pour la distance d et la perte ω .

Nous verrons que la vitesse sera d'autant plus grande que la classe $\mathcal{F}$ sera une classe de régularité élevée.

Exemple de classes de fonctions : $\mathcal{C}^k$, la classe de Holder (cf définition ci-dessous).

Si $\beta \in \mathbb{R}$ on note $\lfloor \beta \rfloor$ l'entier naturel qui soit le plus grand entier strictement inférieur à β .

ex : si $\beta = 3,5$ alors $\lfloor \beta \rfloor = 3$ et si $\beta = 4$ alors $\lfloor \beta \rfloor = 3$.

Définition 4.2: (non exigée)

Pour tout $\beta > 0$ et tout $L > 0$, on définit la classe de Holder de régularité β et de rayon L par

$\Sigma(\beta, L) = \{g : \mathbb{R} \rightarrow \mathbb{R} \text{ t.q. } g \text{ est } \lfloor \beta \rfloor \text{ fois dérivable et}$

$$\forall (x, y) \in \mathbb{R}^2 \quad |g^{(\lfloor \beta \rfloor)}(y) - g^{(\lfloor \beta \rfloor)}(x)| \leq L|x - y|^{\beta - \lfloor \beta \rfloor}\}$$

On note $\Sigma_d(\beta, L)$ l'intersection de $\Sigma(\beta, L)$ et de l'ensemble des densités.

Remarque 4.3

- Si $\beta = 1$ on obtient l'ensemble des fonctions lipschitziennes .
- Si $\beta > 1$ alors $g' \in \Sigma(\beta - 1, L)$.

Proposition 4.4: (admise et non exigée)

Soit $\beta > 0$ et $L > 0$, il existe une constante $M(\beta, L)$ telle que

$$\sup_{f \in \Sigma_d(\beta, L)} \|f\|_\infty = \sup_{x \in \mathbb{R}} \sup_{f \in \Sigma_d(\beta, L)} f(x) \leq M(\beta, L)$$

4.3 Estimation non paramétrique de la densité

L'approche classique pour estimer une densité consiste à postuler une famille paramétrique. Par exemple, en dimension 1, on peut commencer par visualiser les données à l'aide d'un histogramme : si celui-ci présente une forme en cloche et des queues légères, il est naturel d'envisager un modèle gaussien. Il suffit alors d'estimer ses paramètres (μ, σ^2) , c'est-à-dire un vecteur de dimension 2. Dans d'autres situations, des connaissances a priori (mécanismes physiques, contraintes de symétrie, positivité, etc.) peuvent également conduire à privilégier une famille paramétrique particulière.

Cette démarche présente toutefois plusieurs limites. En dimension supérieure, il devient difficile de représenter les données et « reconnaître » visuellement une loi standard. De plus, on ne dispose pas toujours d'informations a priori fiables permettant de guider le choix du modèle.

Surtout, un mauvais choix de modèle peut conduire à une estimation biaisée de la densité et, par conséquent, à une interprétation erronée des données.

À l'inverse, les méthodes non paramétriques reposent sur des hypothèses plus faibles et offrent une plus grande flexibilité : elles cherchent à s'adapter à la forme de la densité sans imposer a priori une structure trop restrictive.

Enfin, il faut garder à l'esprit que si le modèle paramétrique est correct — ou, plus généralement, s'il constitue une bonne approximation de la réalité — alors il est souvent plus efficace qu'un modèle non paramétrique.

4.3.1 Un estimateur simple de la densité : l'histogramme

Supposons, pour simplifier, que l'on se place en dimension 1 et que les observations $X_1, \dots, X_n$ prennent leurs valeurs dans $[0, 1]$. On cherche donc à estimer une densité

$$f : [0, 1] \rightarrow \mathbb{R}_+.$$

On se donne une partition de $[0, 1]$ en p classes

$$]a_1, a_2],]a_2, a_3], \dots,]a_p, a_{p+1}],$$

et, pour simplifier encore, on suppose que ces intervalles ont tous la même longueur :

$$a_{j+1} - a_j = h, \quad j = 1, \dots, p,$$

où $h > 0$ est la largeur des classes.

La méthode de l'histogramme consiste à approcher f par une fonction *constante sur chaque classe*, cette constante étant déterminée par la proportion d'observations X_i qui tombent dans la classe. Plus précisément, pour $t \in]a_j, a_{j+1}]$, on définit

$$\hat{f}_n(t) = \frac{1}{nh} \# \{ i \in \{1, \dots, n\} : X_i \in]a_j, a_{j+1}] \}.$$

Cette formule s'explique simplement. Si l'on suppose que f est constante sur $]a_j, a_{j+1}]$, égale à une valeur c_j , alors

$$F(a_{j+1}) - F(a_j) = \int_{a_j}^{a_{j+1}} f(u) du = c_j h.$$

Or $F(a_{j+1}) - F(a_j) = \mathbb{P}(X \in]a_j, a_{j+1}])$ peut être estimée par la fréquence empirique

$$\frac{1}{n} \#\{i : X_i \in]a_j, a_{j+1}]\}.$$

On obtient donc

$$c_j = \frac{F(a_{j+1}) - F(a_j)}{h} \approx \frac{1}{nh} \#\{i : X_i \in]a_j, a_{j+1}]\},$$

ce qui conduit exactement à la définition de $\hat{f}_n$.

Enfin, la performance de cet estimateur dépend fortement du choix de p (ou, de façon équivalente, de la largeur h) : trop peu de classes donne une estimation trop grossière, tandis que trop de classes augmente la variabilité.

Code R et illustration graphique du choix du nombre de classes

On illustre l'importance du choix du nombre de classes (ou, de manière équivalente, de la largeur h des classes) pour l'estimateur par histogramme, sur un exemple de densité bimodale.

On simule un mélange de deux lois gaussiennes $\mathcal{N}(2, 1)$ et $\mathcal{N}(6, 1)$ à poids $1/2-1/2$. La densité est donc

$$f(x) = \frac{1}{2} \varphi(x; 2, 1^2) + \frac{1}{2} \varphi(x; 6, 1^2), \quad \varphi(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$


Si l'approximation par histogramme est satisfaisante, on doit observer deux « cloches » (écart-type 1) centrées en 2 et 6, avec un léger chevauchement.

Simulation d'un échantillon ($n = 500$)

```
f <- function(x) {  
  0.5 * dnorm(x, mean = 2, sd = 1) + 0.5 * dnorm(x, mean = 6, sd = 1)  
}  
  
sim <- function(n) {  
  m <- sample(c(2, 6), size = n, replace = TRUE) # choix du centre  
  rnorm(n, mean = m, sd = 1)  
}  
  
n <- 500  
Z <- sim(n)  
df <- data.frame(x = Z)
```

On estime la densité par un histogramme et on superpose la densité vraie f (en rouge). On fixe explicitement `bins = 30` (c'est le choix par défaut de `ggplot2`).

```
xlim <- c(-4, 12)  
  
p_base <- ggplot(df, aes(x)) +  
  labs(x = "", y = "") +  
  coord_cartesian(xlim = xlim)  
  
p_base +  
  geom_histogram(aes(y = after_stat(density)),  
                 bins = 30, color = "black", fill = "white") +  
  stat_function(fun = f, colour = "red") +  
  labs(title = "nb de classes = 30")
```




Influence du nombre de classes

Le nombre de classes (ou la largeur h) est un paramètre crucial : il contrôle le compromis biais-variance. Comparons plusieurs choix.

```
plot_hist <- function(bins) {
  p_base +
    geom_histogram(aes(y = after_stat(density)),
                   bins = bins, color = "black", fill = "white") +
    stat_function(fun = f, colour = "red") +
    labs(title = paste0("nb de classes = ", bins))
}
```

```
p1 <- plot_hist(3)
p2 <- plot_hist(10)
p3 <- plot_hist(100)
```

```
grid.arrange(p1, p2, p3, nrow = 1)
```



On constate que :

- si h est trop petit (donc trop de classes), l'histogramme présente de nombreuses fluctuations inutiles (variance élevée) ;
- si h est trop grand (donc trop peu de classes), l'estimation est trop grossière (biais élevé) et peut masquer la structure de la densité (ici, la bimodalité).

On peut aussi spécifier directement la largeur h via l'argument `binwidth` plutôt que le nombre de classes (bins).

Dépendance en n

Le choix optimal de h dépend de la taille d'échantillon. Pour l'illustrer, on augmente la taille de l'échantillon : on passe de $n = 500$ à $n = 50\,000$.


```
n <- 50000
Z <- sim(n)
df <- data.frame(x = Z)

p_base <- ggplot(df, aes(x)) +
  labs(x = "", y = "") +
  coord_cartesian(xlim = xlim)

p30 <- p_base +
  geom_histogram(aes(y = after_stat(density)),
    bins = 30, color = "black", fill = "white") +
  stat_function(fun = f, colour = "red") +
  labs(title = "nb de classes = 30")

p100 <- p_base +
  geom_histogram(aes(y = after_stat(density)),
    bins = 100, color = "black", fill = "white") +
  stat_function(fun = f, colour = "red") +
  labs(title = "nb de classes = 100")

grid.arrange(p30, p100, nrow = 1)
```



Avec davantage de données, on peut se permettre un histogramme plus fin : le nombre optimal de classes croît généralement avec n (autrement dit, la largeur optimale h décroît avec n).

L'estimateur par histogramme est présenté ici à titre illustratif ; des éléments plus précis seront donnés pour l'estimateur qui nous intéresse vraiment : l'estimateur à noyau de fenêtre h .

Des illustrations en Python sont proposées dans un notebook sur teams.

4.3.2 Estimateurs à noyaux

Un inconvénient de l'estimateur par histogramme est que la densité estimée $\hat{f}_n$ est une fonction discontinue, alors que la densité f que l'on cherche à estimer est en général plus régulière (au moins continue). Les estimateurs à noyaux ont précisément pour but de *lisser* l'estimation.

Le point de départ est l'observation suivante : si f est continue en x , alors la fonction de répartition F est dérivable en x et

$$f(x) = F'(x) = \lim_{h \rightarrow 0} \frac{F(x+h) - F(x)}{h} = \lim_{h \rightarrow 0} \frac{F(x+h) - F(x-h)}{2h}.$$

L'idée est donc d'utiliser, pour $h > 0$ petit, l'approximation

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h}.$$

Pour estimer f , on remplace F par la fonction de répartition empirique

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq x},$$

et l'on choisit une fenêtre $h > 0$. On définit alors

$$\tilde{f}_{n,h}(x) = \frac{\hat{F}_n(x+h) - \hat{F}_n(x-h)}{2h} = \frac{1}{n} \sum_{i=1}^n \frac{1}{2h} \mathbb{1}_{h < X_i - x \leq h} \stackrel{p.s.}{=} \frac{1}{n} \sum_{i=1}^n \frac{1}{2h} \mathbb{1}_{|X_i - x| \leq h}.$$

Si l'on pose

$$K_0(u) = \frac{1}{2} \mathbb{1}_{[-1,1]}(u),$$

on peut réécrire (p.s.) cet estimateur sous la forme

$$\tilde{f}_{n,h}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K_0\left(\frac{x - X_i}{h}\right).$$

Cet estimateur correspond donc à un estimateur « à noyau » avec noyau uniforme K_0 . Cependant, K_0 n'étant pas continu, la fonction $x \mapsto \tilde{f}_{n,h}(x)$ reste irrégulière. On remplace donc K_0 par une fonction plus régulière.

Définition 4.5

Une fonction $K : \mathcal{R} \rightarrow \mathcal{R}$ est appelée *noyau* (kernel) si elle est intégrable et si

$$\int_{\mathcal{R}} K(u) du = 1.$$

Exemple 4.6: Exemples de noyaux

— Noyau triangulaire :

$$K(u) = (1 - |u|) \mathbb{1}_{[-1,1]}(u).$$

— Noyau d'Epanechnikov :

$$K(u) = \frac{3}{4} (1 - u^2) \mathbb{1}_{[-1,1]}(u).$$

— Noyau biweight :

$$K(u) = \frac{15}{16} (1 - u^2)^2 \mathbb{1}_{[-1,1]}(u).$$

— Noyau gaussien :

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right).$$

On définit alors l'estimateur à noyau (ou estimateur de Parzen–Rosenblatt) associé à un noyau K et une fenêtre $h > 0$.

Définition 4.7

Étant donné un noyau K et $h > 0$, on pose, pour tout $x \in \mathbb{R}$,

$$\hat{f}_{n,h}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right).$$

Le paramètre h est appelé *fenêtre* (bandwidth).

Remarque 4.8

1. Intuition : l'estimateur $\hat{f}_{n,h}(x)$ est une somme de « bosses » centrées en X_i (de forme K et d'échelle h). En particulier, si K est symétrique, positive et décroissante sur $\mathcal{R}_+$ (comme le noyau gaussien), alors pour un x fixé, plus X_i est proche de x , plus

$$K\left(\frac{x - X_i}{h}\right)$$

est grand. Ainsi, $\hat{f}_{n,h}(x)$ augmente lorsque beaucoup d'observations sont proches de x .

2. Si K est continue, alors $\hat{f}_{n,h}$ est continue (et plus généralement, la régularité de K se transmet à $\hat{f}_{n,h}$).
3. Le paramètre h contrôle le lissage : un h petit réduit le biais mais augmente la variance, tandis qu'un h grand lisse davantage (variance plus faible) au prix d'un biais plus important. Le choix de h est donc crucial (compromis biais/variance).
4. En pratique, le choix du noyau est en général moins critique que celui de la fenêtre h .
5. Si $K \geq 0$, alors $\hat{f}_{n,h} \geq 0$ et comme

$$\int_{\mathcal{R}} \hat{f}_{n,h}(x) dx = 1,$$

$\hat{f}_{n,h}$ est alors une densité.

Remarque 4.9

Lorsque le noyau K n'est pas positif, la fonction $\hat{f}_{n,h}$ n'est pas forcément positive, donc pas nécessairement une densité. Si l'on souhaite tout de même obtenir une densité à partir d'un tel estimateur, on peut prendre sa partie positive puis renormaliser :

$$g \mapsto \frac{\max\{g, 0\}}{\int_{\mathcal{R}} \max\{g(x), 0\} dx}.$$

Les noyaux signés peuvent cependant être utiles, par exemple pour construire des noyaux d'ordre 2 (ou plus) et réduire le biais (cf. plus loin).

Illustration graphique et commandes R : estimateur à noyau

On reprend le même exemple de distribution bimodale que précédemment. L'estimation par noyau peut se faire via la fonction `density()` (du package de base `stats`), qui estime une densité en dimension~1. Pour des densités multivariées, on peut utiliser, par exemple, le package `ks` (fonction `kde()`), qui couvre typiquement des dimensions faibles à modérées (de 1 à 6 variables).

Dans `density()`, le noyau par défaut est le noyau gaussien. On peut changer de noyau via l'argument `kernel`.

Dans ce document, on utilise surtout la version intégrée à `ggplot2`, `geom_density()`, qui s'appuie elle aussi sur `stats::density()`.

Le paramètre de lissage (la fenêtre h) s'appelle `bw` (*bandwidth*). Comme pour l'histogramme, le choix de `bw` est crucial.

Données simulées

On simule un mélange de deux lois gaussiennes $\mathcal{N}(2, 1)$ et $\mathcal{N}(6, 1)$, avec poids 1/2–1/2.

La densité vraie vaut donc

$$f(x) = \frac{1}{2}\varphi(x; 2, 1) + \frac{1}{2}\varphi(x; 6, 1), \quad \varphi(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right).$$

Influence du choix de la fenêtre (bandwidth)


On illustre l'influence du choix de `bw`. On retrouve le même phénomène que pour l'histogramme :

- `bw` trop petit $\Rightarrow$ estimation très irrégulière (variance élevée) ;
- `bw` trop grand $\Rightarrow$ sur-lissage (biais élevé), pouvant masquer la bimodalité.

```
p0 <- ggplot(df, aes(x)) + labs(x = "", y = "") + theme_minimal()

p1 <- p0 + geom_density(bw = 0.1) + stat_function(fun = f, col = "red", size = 0.8)+ggtitle("h = 0.1")
p2 <- p0 + geom_density(bw = 0.5) + stat_function(fun = f, col = "red", size = 0.8)+ggtitle("h = 0.5")
p3 <- p0 + geom_density(bw = 0.8) + stat_function(fun = f, col = "red", size = 0.8)+ggtitle("h = 0.8")
p4 <- p0 + geom_density(bw = 1.2) + stat_function(fun = f, col = "red", size = 0.8)+ggtitle("h = 1.2")

grid.arrange(p1, p2, p3, p4, nrow = 2, ncol = 2)
```




Fenêtres choisies automatiquement

On illustre maintenant deux fenêtres calculées à partir des données :

- **SJ** : méthode de Sheather–Jones ;
- **ucv** : validation croisée (unbiased cross-validation), discutée plus loin dans le cours.

Pour d'autres méthodes, consulter la documentation de `bw.*` et de `density()` (voir aussi la règle de Silverman dans l'exercice 2 de l'examen 2019).

```
p5 <- p0 + geom_density(bw = "ucv") + stat_function(fun = f, col = "red") + ggtitle("ucv")
bwSJ <- bw.SJ(Z)
p6 <- p0 + geom_density(bw = bwSJ) + stat_function(fun = f, col = "red") + ggtitle("SJ")
grid.arrange(p5, p6, ncol = 2)
```



Quelques noyaux usuels

On donne ci-dessous le graphe de quelques noyaux classiques (sur l'échelle standardisée u).


Les noyaux à support compact (rectangulaire, triangulaire, Epanechnikov, biweight) s'annulent hors de $[-1, 1]$, tandis que le noyau gaussien a un support non borné.

```
u <- seq(-3, 3, length.out = 2001)

K_rect <- 0.5 * (abs(u) <= 1)
K_tri  <- (1 - abs(u)) * (abs(u) <= 1)
K_epa  <- 0.75 * (1 - u^2) * (abs(u) <= 1)
K_biw  <- (15/16) * (1 - u^2)^2 * (abs(u) <= 1)
K_gau  <- dnorm(u)

kern_df <- data.frame(
  u = rep(u, 5),
  K = c(K_rect, K_tri, K_epa, K_biw, K_gau),
  kernel = factor(
    rep(c("Rectangular", "Triangular", "Epanechnikov", "Biweight", "Gaussian"), each = length(u)),
    levels = c("Rectangular", "Triangular", "Epanechnikov", "Biweight", "Gaussian")
  )
)

ggplot(kern_df, aes(x = u, y = K, colour = kernel)) +
  geom_line(size = 0.8) +
  labs(x = "u", y = "K(u)", title = "Quelques noyaux usuels") +
  theme_minimal() +
  coord_cartesian(xlim = c(-3, 3), ylim = c(0, max(kern_df$K) * 1.05))
```



Effet du noyau (à fenêtre fixée)

Le choix du noyau a en général un effet plus faible que celui de la fenêtre.





Pour l'illustrer, on fixe la même fenêtre `bw = 0.5` et on compare plusieurs noyaux disponibles dans `stats::density()`.

```
bw0 <- 0.5

q0 <- ggplot(df, aes(x)) + labs(x = "", y = "") + theme_minimal()

q1 <- q0 + geom_density(bw = bw0, kernel = "gaussian") + ggtitle("Gaussian")
q2 <- q0 + geom_density(bw = bw0, kernel = "epanechnikov") + ggtitle("Epanechnikov")
q3 <- q0 + geom_density(bw = bw0, kernel = "triangular") + ggtitle("Triangular")
q4 <- q0 + geom_density(bw = bw0, kernel = "biweight") + ggtitle("Biweight")

grid.arrange(q1, q2, q3, q4, nrow = 2, ncol = 2)
```



Remarque : version en dimension 2

`ggplot2` propose une version en dimension~2 via `geom_density_2d()` (et aussi `geom_density_2d_filled()`), qui permet de représenter des courbes de niveau de la densité estimée.

4.4 Risque quadratique ponctuel des estimateurs à noyau sur la classe des espaces de Holder

Dans cette section, on s'intéresse au risque quadratique ponctuel de $\hat{f}_n$, i.e. étant donné $x_0 \in \mathbb{R}$

$$R(\hat{f}_n, f) = \mathbb{E} \left[|\hat{f}_n(x_0) - f(x_0)|^2 \right]$$

Rappelons la décomposition "biais au carré+ variance" du risque quadratique :

$$\mathbb{E} \left[|\hat{f}_n(x_0) - f(x_0)|^2 \right] = \left(\mathbb{E}[\hat{f}_n(x_0)] - f(x_0) \right)^2 + \mathbf{Var}(\hat{f}_n(x_0))$$

Définition 4.10

Soit $\ell \in \mathbb{N}^*$. On dit que le noyau K est d'ordre ℓ si $\forall j \in \{1, \dots, \ell\}$, $u \rightarrow u^j K(u)$ est intégrable et $\int u^j K(u) du = 0$.

Proposition 4.11: Biais

Si $f \in \Sigma(\beta, L)$ avec $\beta > 0$ et $L > 0$ et si K est un noyau d'ordre $\ell = \lfloor \beta \rfloor$ tel que $\int |u|^\beta |K(u)| du < \infty$ alors pour tout $x_0 \in \mathbb{R}$, et pour tout $h > 0$ le biais peut être borné comme suit :

$$|\mathbb{E}[\hat{f}_n(x_0)] - f(x_0)| \leq C_1 h^\beta$$

où $C_1 = \frac{L}{\ell!} \int |u|^\beta |K(u)| du$.

Démonstration. On a

$$\begin{aligned} \mathbb{E}[\hat{f}_n(x_0)] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K \left(\frac{x_0 - X_i}{h} \right) \right] = \mathbb{E} \left[\frac{1}{h} K \left(\frac{x_0 - X_1}{h} \right) \right] \\ &= \frac{1}{h} \int K \left(\frac{x_0 - X_i}{h} \right) f(u) du = \int K(v) f(x_0 - hv) dv. \end{aligned}$$

Aparté : Détail technique : $\hat{f}_n(x_0)$ est bien intégrable car

$$\begin{aligned} \mathbb{E}[|\hat{f}_n(x_0)|] &\leq \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \frac{1}{h} |K| \left(\frac{X_i - x_0}{h} \right) \right] = \mathbb{E} \left[\frac{1}{h} |K| \left(\frac{X_1 - x_0}{h} \right) \right] \\ &= \frac{1}{h} \int |K| \left(\frac{u - x_0}{h} \right) f(u) du = \int |K|(v) f(x_0 + hv) dv \leq M(\beta, L) \int |K| < \infty. \end{aligned}$$

Fin aparté.

De plus

$$f(x_0) = f(x_0) \times 1 = f(x_0) \int K(v) dv.$$

Donc

$$|\mathbb{E}[\hat{f}_n(x_0)] - f(x_0)| = \left| \int K(v) [f(x_0 - hv) - f(x_0)] dv \right|$$

Comme $f \in \Sigma(\beta, L)$, f admet $\lfloor \beta \rfloor := \ell$ dérivées et par un développement de Taylor-Lagrange on a, pour tout $x \in \mathbb{R}$,

$$f(x) = \sum_{k=0}^{\ell-1} \frac{(x - x_0)^k}{k!} f^{(k)}(x_0) + \frac{(x - x_0)^\ell}{\ell!} f^{(\ell)}(x_0 + \xi(x - x_0))$$

avec $\xi \in]0, 1[$. Autrement dit on a, avec $x = x_0 - hv$,

$$f(x_0 - hv) - f(x_0) = \sum_{k=1}^{\ell-1} \frac{(-hv)^k}{k!} f^{(k)}(x_0) + f^{(\ell)}(x_0 - hv\xi) \frac{(hv)^\ell}{\ell!}$$

pour un certain $\xi \in]0, 1[$. Donc

$$\begin{aligned} \int K(v)[f(x_0 - hv) - f(x_0)]dv &= \int K(v) \left[\sum_{k=1}^{\ell-1} \frac{(-hv)^k}{k!} f^{(k)}(x_0) + f^{(\ell)}(x_0 - hv\xi) \frac{(-hv)^\ell}{\ell!} \right] dv \\ &= \frac{(-h)^\ell}{\ell!} \int K(v) v^\ell f^{(\ell)}(x_0 - hv\xi) dv \end{aligned}$$

Comme K est d'ordre ℓ , on a aussi $\int K(v) v^\ell f^{(\ell)}(x_0) dv = 0$. Donc on a

$$\int K(v)[f(x_0 - hv) - f(x_0)]dv = \frac{(-h)^\ell}{\ell!} \int K(v) v^\ell [f^{(\ell)}(x_0 - hv\xi) - f^{(\ell)}(x_0)] dv$$

Or, comme $f \in \Sigma(\beta, L)$, on a $|f^{(\ell)}(x_0 - hv\xi) - f^{(\ell)}(x_0)| \leq L|hv|^{\beta-\ell}$. Et finalement

$$\left| \int K(v)[f(x_0 - hv) - f(x_0)]dv \right| \leq \frac{|h|^\ell}{\ell!} \int |K(v)| |v|^\ell L |hv|^{\beta-\ell} dv$$

ce qui signifie que

$$\left| \mathbb{E}[\hat{f}_n(x_0)] - f(x_0) \right| \leq \frac{L|h|^\beta}{\ell!} \int |K(v)| |v|^\beta dv.$$

□

Ainsi, plus la fonction f est régulière, plus le biais est petit (à condition bien sûr que l'ordre du noyau soit suffisamment grand).

Proposition 4.12: Variance

Si f est bornée et si K est de carré intégrable alors

$$\mathbf{Var}(\hat{f}_n(x_0)) \leq \frac{\|f\|_\infty \|K\|_2^2}{nh}$$

En particulier, si $f \in \Sigma(\beta, L)$ alors

$$\mathbf{Var}(\hat{f}_n(x_0)) \leq \frac{C_2}{nh}$$

où $C_2 = M(\beta, L) \|K\|_2^2$.

Démonstration.

$$\begin{aligned}
\mathbf{Var}(\hat{f}_n(x_0)) &= \mathbf{Var}\left(\frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x_0}{h}\right)\right) \\
&\stackrel{\text{indep}}{=} \sum_{i=1}^n \mathbf{Var}\left(\frac{1}{nh} K\left(\frac{X_i - x_0}{h}\right)\right) \\
&= \sum_{i=1}^n \frac{1}{n^2 h^2} \mathbf{Var}\left(K\left(\frac{X_i - x_0}{h}\right)\right) \\
&\stackrel{i.d.}{=} \frac{1}{nh^2} \mathbf{Var}\left(K\left(\frac{X_1 - x_0}{h}\right)\right) \\
&\leq \frac{1}{nh^2} \mathbb{E}\left(K^2\left(\frac{X_1 - x_0}{h}\right)\right) \\
&= \frac{1}{nh^2} \int K^2\left(\frac{u - x_0}{h}\right) f(u) du \\
&= \frac{1}{nh} \int K^2(v) f(x_0 + vh) dv
\end{aligned}$$

Et enfin, on utilise la proposition 4.4 : il existe une constante positive $M(\beta, L)$ tel que $\|f\|_\infty \leq M(\beta, L)$. Ceci implique que

$$\mathbf{Var}(\hat{f}_n(x_0)) \leq \frac{1}{nh} M(\beta, L) \int K^2(v) dv.$$

□

Pour que la variance tende vers zéro, il faut que nh tende vers l'infini.

En particulier, à n fixé, la variance est une fonction décroissante de h au contraire du biais qui est une fonction croissante de h . Il y a donc une valeur optimale de h qui doit réaliser l'équilibre entre le biais au carré et la variance.

On peut à présent donner un contrôle du risque quadratique ponctuel.

Théorème 4.13

Soit $\beta > 0$ et $L > 0$ et K un noyau de carré intégrable et d'ordre $\lfloor \beta \rfloor$ tel que $\int |u|^\beta |K(u)| du < \infty$. Alors, en choisissant une fenêtre de la forme $h = cn^{-\frac{1}{2\beta+1}}$ avec une constante $c > 0$, on obtient

$$\forall x_0 \in \mathbb{R}, \quad R(\hat{f}_n(x_0), \Sigma_d(\beta, L)) := \sup_{f \in \Sigma_d(\beta, L)} \mathbb{E}[|\hat{f}_n(x_0) - f(x_0)|^2] \leq Cn^{-\frac{2\beta}{2\beta+1}}$$

où C est une constante dépendant de L , β , c et K .

Démonstration. On a

$$R(\hat{f}_n(x_0), f(x_0)) = \text{Biais au carré} + \text{Variance}$$

Le terme de biais a été traité dans la proposition 4.11 et le terme de variance a été traité dans la proposition 4.12. On trouve

$$R(\hat{f}_n(x_0), f(x_0)) \leq \left(\frac{h^\beta L}{\ell!} \int |u|^\beta |K(u)| du\right)^2 + \frac{M(\beta, L) \|K\|_2^2}{nh}.$$

On cherche la fenêtre h qui minimise ce majorant. Ceci peut se formuler comme un problème d'optimisation par rapport à h et admet une solution facile à trouver ; nous allons donner ci-dessous une interprétation plus intuitive.

Ici on ne va pas se soucier des constantes exactes, donc on utilise la notation $c_1 =$

$\left(\frac{L}{\ell} \int |u|^\beta |K(u)| du\right)^2$ et $c_2 = M(\beta, L) \|K\|_2^2$. On doit alors minimiser en h la quantité

$$c_1 h^{2\beta} + \frac{c_2}{nh}$$

On a une quantité croissante et une quantité décroissante en h . Comme on ne se soucie pas des constantes, on cherche seulement une fenêtre h correspondant à l'ordre minimal du risque. Quand h est trop grand, le biais est trop grand, et quand h est trop petit, c'est la variance qui est trop grande. On cherche donc la fenêtre h qui réalise un équilibre entre le biais au carré et la variance :

$$h^{2\beta} \approx \frac{1}{nh}$$

où le signe $\approx$ signifie ici "de l'ordre de". Cela donne

$$h \approx n^{-\frac{1}{2\beta+1}}$$

Autrement dit, pour une fenêtre h de l'ordre de $n^{-\frac{1}{2\beta+1}}$, le biais au carré et la variance sont de même ordre. Plus exactement, si on choisit la fenêtre $h_* = cn^{-\frac{1}{2\beta+1}}$, avec c une constante positive, on a

$$\text{Biais au carré} \approx h_*^{2\beta} \approx \text{variance} \approx \frac{1}{nh_*}$$

De plus on a alors $h_*^{2\beta} \approx n^{-\frac{2\beta}{2\beta+1}}$. Autrement dit, il existe une certaine constante C (dépendant de β, L, K et de c) telle que, pour cette fenêtre h_* , on a

$$R(\hat{f}_n(x_0), \Sigma_d(\beta, L)) \leq C n^{-\frac{2\beta}{2\beta+1}}.$$

Cette fenêtre est donc optimale à une constante près (si on change c , cela modifie C mais ça ne change pas le taux qui est $n^{-\frac{2\beta}{2\beta+1}}$). $\square$

Remarque 4.14

1. L'estimateur dépend de β à travers la fenêtre h . Or, **sans connaissance a priori sur la régularité de la fonction f , on ne peut donc pas utiliser cet estimateur**. On essaie alors de trouver un choix de fenêtre ne dépendant que des données et qui soit aussi performant que l'estimateur utilisant cette fenêtre optimale.
2. Le résultat du théorème est un résultat asymptotique, c'est-à-dire valable quand n est grand. Mais quand n est faible, le choix de K et h pose question.
3. Plus β est grand, plus la vitesse est grande. A la limite $\beta \rightarrow \infty$ on obtient une vitesse paramétrique.
4. **On peut généraliser le concept des estimateurs à noyaux pour une densité à plusieurs variables. Mais attention, en grande dimension, le problème du "fléau de dimension" ("curse of dimensionality") se pose souvent.** En fait, l'estimateur à noyau en dimension d donne une vitesse de $n^{-\frac{2\beta}{2\beta+d}}$. Donc cette vitesse se dégrade très vite avec la dimension. (Plus de détails sur le sujet dans le chapitre 5)

4.5 Choix de la fenêtre h par validation croisée

Le choix de la fenêtre dans la section précédente est critiquable : il dépend de la régularité qui est en général inconnue. On peut donc essayer de remplacer cette fenêtre inconnue par un estimateur $\hat{h}$. De façon à souligner la dépendance à la fenêtre h , on va noter $\hat{f}_{n,h}$ l'estimateur associé à un choix de fenêtre h . L'estimateur final sera $\hat{f}_{n,\hat{h}}$, une fois le choix de $\hat{h}$ fait.

On cherche à minimiser en h le risque quadratique pour la distance L^2 :

$$R(\hat{f}_{n,h}, f) = \mathbb{E}[\|\hat{f}_{n,h} - f\|_2^2]$$

Or la fonction f étant inconnue, ce risque n'est pas calculable à partir des données. On cherche donc à estimer ce risque en utilisant uniquement les données.

Minimiser en h la quantité $R(\hat{f}_{n,h}, f)$ est équivalent à minimiser en h la quantité $R(\hat{f}_{n,h}, f) - \|f\|_2^2$. On va en fait remplacer la minimisation de la quantité inconnue $R(\hat{f}_{n,h}, f) - \|f\|_2^2$ par la minimisation d'un estimateur $\hat{R}(h)$ de cette quantité. Plus précisément on va chercher un estimateur sans biais de $R(\hat{f}_{n,h}, f) - \|f\|_2^2$ ^a.

a. même idée que le Cp de Mallows, cf. cours MLG

Dans toute cette section, on suppose que la densité f et le noyau K sont de carré intégrable. Vérifions que cela implique que le risque quadratique intégré est bien fini : on a

$$\mathbb{E}[\hat{f}_n^2(x)] \leq \frac{1}{h} \int_{\mathcal{R}} K^2(v) f(x - hv) dv.$$

Ainsi¹

$$\int_{\mathcal{R}} \mathbb{E}[\hat{f}_n^2(x)] dx \leq \frac{1}{h} \int_{\mathcal{R}^2} K^2(v) f(x - hv) dv dx = \frac{1}{h} \int_{\mathcal{R}} K^2(v) \left(\int_{\mathcal{R}} f(x - hv) dx \right) dv = \frac{1}{h} \int_{\mathcal{R}} K^2(v) dv < +\infty$$

Théorème 4.15: Unbiased cross-validation (UCV)/ Least-squares cross validation (LSCV)

Si on pose

$$\hat{R}(h) = \|\hat{f}_{n,h}\|_2^2 - \frac{2}{n(n-1)} \sum_{i,j=1, j \neq i}^n \frac{1}{h} K\left(\frac{X_j - X_i}{h}\right)$$

alors $\hat{R}(h)$ est un estimateur sans biais de $R(\hat{f}_{n,h}, f) - \|f\|_2^2$.

Démonstration. Deux remarques techniques :

- $\int \mathbb{E}[\hat{f}_n(x)] f(x) dx < \infty$ car $\int \mathbb{E}[\hat{f}_n^2(x)] dx < \infty$ et $\int f^2(x) dx < \infty$.
- $\sum_{i,j=1, j \neq i}^n \frac{1}{h} K\left(\frac{X_j - X_i}{h}\right)$ est bien intégrable : en effet, si on note K_h la fonction définie par $K_h(x) = \frac{1}{h} K\left(\frac{x}{h}\right)$, on a

$$\begin{aligned} \mathbb{E}\left[\frac{1}{h} |K|\left(\frac{X_1 - X_2}{h}\right)\right] &= \int \int |K_h|(u - v) f(u) f(v) du dv \\ &\leq \sqrt{\int \left[\int |K_h|(u - v) f(u) du \right]^2 dv} \sqrt{\int f^2(v) dv} \end{aligned}$$

De plus $\left(\int K_h(u - v) f(u) du \right)^2 \leq \int K_h^2(u - v) f(u) du$ par Et donc

$$\int \left(\int K_h(u - v) f(u) du \right)^2 dv \leq \int \int K_h^2(u - v) f(u) du dv = \int K_h^2(x) dx < \infty$$

On veut montrer que

$$\mathbb{E}\hat{R}(h) = R(\hat{f}_{n,h}, f) - \|f\|_2^2$$

1. Bien sûr ceci peut aussi se justifier en utilisant un résultat très connu sur la convolution

Or

$$\begin{aligned} R(\hat{f}_{n,h}, f) - \|f\|_2^2 &= \mathbb{E}(\|\hat{f}_{n,h}\|_2^2 - 2 \int \hat{f}_{n,h}(x) f(x) dx) \\ &= \mathbb{E}\|\hat{f}_{n,h}\|_2^2 - 2 \int \mathbb{E}\hat{f}_{n,h}(x) f(x) dx \end{aligned}$$

Il suffit donc de montrer que

$$\int \mathbb{E}\hat{f}_{n,h}(x) f(x) dx = \frac{1}{n(n-1)} \mathbb{E} \left[\sum_{i,j=1, j \neq i}^n \frac{1}{h} K\left(\frac{X_j - X_i}{h}\right) \right]$$

Le côté gauche donne, d'après le calcul fait dans la proposition 4.11,

$$\begin{aligned} \int [\mathbb{E}\hat{f}_{n,h}(x)] f(x) dx &= \int \left[\int \frac{1}{h} K\left(\frac{u-x}{h}\right) f(u) du \right] f(x) dx \\ &\stackrel{\text{Fubini}}{=} \int \int \frac{1}{h} K\left(\frac{u-v}{h}\right) f(u) f(v) dudv \end{aligned}$$

Le côté droit donne

$$\begin{aligned} \frac{1}{n(n-1)} \mathbb{E} \left[\sum_{i,j=1, j \neq i}^n \frac{1}{h} K\left(\frac{X_j - X_i}{h}\right) \right] &= \mathbb{E} \left[\frac{1}{h} K\left(\frac{X_1 - X_2}{h}\right) \right] \\ &= \int \int \frac{1}{h} K\left(\frac{u-v}{h}\right) f(u) f(v) dudv \end{aligned}$$

□

On définit alors

$$\hat{h} = \arg \min_{h \in H} \hat{R}(h)$$

si ce minimum est atteint. H est un intervalle $H = [h_{\min}, h_{\max}]$, où $h_{\min}$ et $h_{\max}$ dépendent de n .

Remarque 4.16

Ce critère est sans biais mais peut avoir une forte variance, en particulier pour des valeurs de h petits et il peut avoir tendance à choisir une fenêtre trop petite (undersmoothing). Il existe beaucoup d'autres méthodes pour choisir la fenêtre à partir des données.

Remarque 4.17: Likelihood cross-validation LCV/MLCV

Dans le sous-module `model_selection` de `sklearn`, la fonction `GridSearchCV` fait de la validation croisée (cf. chap 5 ou cours de learning) en utilisant par défaut la log-vraisemblance comme fonction score.

- on choisit un nombre K de blocs (folds en anglais).
- On divise l'échantillon en K blocs de même longueur (ou à peu près de même longueur) : $B_1, B_2, \dots, B_K$.
- On note ℓ_k le cardinal de B_k (on a donc $\ell_k \approx n/K$).
- pour chaque $k \in \{1, \dots, K\}$, on calcule l'estimateur $\hat{f}_h^k$ basé uniquement sur les données X_i avec $i \in \{1, \dots, n\} \cap B_k^c$, i.e. on utilise toutes les données sauf celles qui correspondent au bloc B_k pour fabriquer $\hat{f}_h^k$.

Puis on calcule

$$CV(h) := \frac{1}{K} \sum_{k=1}^K \frac{1}{\ell_k} \sum_{i \in B_k} \log(\hat{f}_h^k(X_i))$$

C'est cette quantité qui est calculée par défaut par `GridSearchCV` quand cette fonction est utilisée avec l'estimateur `KernelDensity` du sous-module `neighbors` de `sklearn`. On cherche ensuite la fenêtre qui **maximise** cette quantité parmi une grille de valeurs.

Remarque 4.18: Choix du critère

On a tendance à choisir Likelihood-CV quand la densité sert vraiment de modèle probabiliste prédictif et en particulier quand on veut éviter les estimateurs qui donnent une densité quasi nulle là où des données peuvent tomber. La KL pénalise beaucoup plus durement que l'erreur quadratique dans les situations où $\hat{f}_h(x)$ devient très petit alors que $f(x)$ ne l'est pas, à cause du logarithme. Likelihood-CV est par exemple particulièrement naturel en détection d'anomalies par score de densité.

On a tendance à choisir un critère basé sur la perte quadratique (e.g. Least-Squares CV) si on veut une bonne reconstruction globale de la densité comme fonction, ou un estimateur visuellement stable et lisse, mais aussi par exemple en présence de queues lourdes ou d'outliers.

Remarque 4.19

On peut utiliser les estimations de densité non paramétriques pour la classification de manière directe en appliquant le théorème de Bayes ^a. Supposons un problème de classification binaire. Reprenons les mêmes notations que dans l'Exercice 5 TD1 du cours d'apprentissage statistique. Supposons que nous ajustons des estimations de densité non paramétriques $\hat{f}_0$ et $\hat{f}_1$, et que nous disposons également d'estimations des probabilités a priori des classes $\hat{p}_0$ et $\hat{p}_1$. Alors pour estimer $\eta(x) = P(Y = 1 | X = x)$ on peut utiliser

$$\hat{\eta}(x) = \frac{\hat{p}_1 \hat{f}_1(x)}{\hat{p}_0 \hat{f}_0(x) + \hat{p}_1 \hat{f}_1(x)}$$

De la même manière que pour Naive Bayes dans le cours de learning, nous pouvons ensuite proposer le classifieur suivant

$$\hat{g}(x) = \begin{cases} 1 & \text{if } \hat{p}_1 \hat{f}_1(x) > \hat{p}_0 \hat{f}_0(x) \\ 0 & \text{otherwise} \end{cases}$$

Cela peut être étendu à un problème à K classes, pour tout $K \geq 3$, de manière directe :

$$\hat{g}(x) = \arg \max_{j \in \{1, \dots, K\}} \hat{p}_j \hat{f}_j(x)$$

Un exemple est proposé dans le notebook sur teams.

a. surtout intéressant si l'estimation de η vous intéresse, et pas seulement la classification finale