

Chapitre 5

Régression non paramétrique

5.1 Introduction

Dans ce chapitre, on cherche à estimer une fonction de régression.
Les variables aléatoires $Y_1, \dots, Y_n$ sont réelles.

5.1.1 Design aléatoire

On cherche à expliquer les valeurs que peut prendre une variable réelle Y à partir des valeurs que peut prendre une variable (généralement multidimensionnelle) X .

Exemple 5.1 (médecine). *La variable à expliquer Y est le taux d'insuline dans le sang, qu'on explique (ou prédit) à l'aide de $X = (\text{IMC}, \text{pression du sang}, \text{concentration de molécules})$.*

Exemple 5.2 (sociologie). *La variable à expliquer Y est le niveau de diplôme obtenu, qu'on explique à l'aide de $X = (\text{âge}, \text{revenu des parents}, \text{métier des parents})$.*

On suppose que la variable Y est intégrable $\mathbb{E}|Y| < \infty$ et on note r la fonction de régression de Y sur X :

$$r(x) = \mathbb{E}(Y|X = x)$$

L'objectif est d'estimer la fonction r pour expliquer et prédire Y à partir de X . Pour cela on dispose des réalisations de n couples de variables i.i.d ; $(X_1, Y_1), \dots, (X_n, Y_n)$ de même loi que (X, Y) .

- Y est appelée la variable à expliquer ou variable réponse ou variable de sortie (target, output variable).
- le vecteur X représentent les variables explicatives, appelées aussi covariables, ou variables d'entrée (features, input variables, explanatory variables).

Si on pose $\epsilon = Y - \mathbb{E}(Y | X)$, on a

$$Y = r(X) + \epsilon \quad \text{avec} \quad \mathbb{E}(\epsilon|X) = 0. \quad (5.1)$$

Si on suppose que $\mathbb{E}(Y^2) < \infty$ alors r est l'estimateur de Bayes pour l'erreur quadratique.
On rappelle en effet que $r(X) = \mathbb{E}(Y | X)$ est t.q.

$$r(X) = \arg \min_{g \in \mathcal{G}} \mathbb{E}(Y - g(X))^2$$

(où $\mathcal{G}$ est l'ensemble des fonctions mesurables réelles t.q. $\mathbb{E}(g^2(X)) < \infty$). Cette fonction de régression est donc la meilleure fonction, au sens de la perte quadratique, pour prédire Y à partir de X .

On pose

$$\sigma^2 = \mathbb{E}(\epsilon^2) = \mathbb{E}(Y - E(Y | X))^2$$

σ^2 correspond donc à l'erreur de Bayes R^* rencontrée dans le cours de learning (correspondant donc ici au cas de la régression et de la perte quadratique ($\ell(x, y) = (y - g(x))^2$)).

Interprétation : σ^2 aura tendance à être grand quand les features du vecteur X ne prédisent pas suffisamment bien Y .

On aura donc pour l'échantillon

$$Y_i = r(X_i) + \epsilon_i, \quad i = 1, \dots, n, \quad \mathbb{E}(\epsilon_i | X_i) = 0.$$

En particulier on a donc $\mathbb{E}(\epsilon_i) = 0$.

Comme les (X_i, Y_i) sont i.i.d., les ϵ_i le sont aussi.

Assez souvent, pour simplifier les calculs, on fait aussi l'hypothèse que les ϵ_i sont indépendants des X_i .

5.1.2 Design déterministe

Le design pourra aussi être déterministe.

Exemple : un scientifique veut étudier le rendement d'une culture en fonction de la quantité d'un certain engrais. C'est le scientifique qui fixe alors l'expérience : il dispose d'un certain nombre n de champs¹ et il fait l'expérience consistant à verser des quantités différentes d'engrais notées $x_1, \dots, x_n$. C'est donc lui qui décide des quantités versées dans les différents champs. Il obtient alors des rendements observés $(y_1, \dots, y_n)$.

Il pourrait verser la même quantité d'engrais dans différents champs (ça n'est pas ce qu'il va faire bien sûr, c'est juste pour vous expliquer la modélisation) : en général, il aura un rendement relativement proche dans ces champs-là, mais ce ne sera pas exactement le même rendement. Il traduit la présence des ces fluctuations en disant que les rendements observés $y_1, \dots, y_n$ sont les observations de variables aléatoires $Y_1, \dots, Y_n$. Pour une quantité d'engrais x , $r(x)$ désigne alors la moyenne du rendement.

Si on modélise cela mathématiquement, cela signifie que nous disposons des observations de n variables aléatoires indépendantes $Y_1, \dots, Y_n$ associées aux valeurs $x_1, \dots, x_n$ (fixées par l'expérimentateur). Et nous avons

$$Y_i = r(x_i) + \epsilon_i, \quad i = 1, \dots, n$$

avec

$$\mathbb{E}(\epsilon_i) = 0.$$

(ce qui traduit le fait que $E(Y_i) = r(x_i)$)

Remarque (notation) : Dans le cas d'un design déterministe, on écrit souvent x_i à la place de X_i . Comme les Y_i sont indépendants², les ϵ_i le sont aussi.

Dans la suite, on va faire l'hypothèse suivante :

$$\text{Var}(\epsilon_i) = \sigma^2 < \infty \quad \text{variance finie et indépendante de } i$$

5.2 Estimateur des moindres carrés (OLS) non paramétrique

1. qui doivent être approximativement identiques sur des critères évidents comme l'exposition au soleil, au vent, la composition initiale du sol etc.

2. les Y_i ne sont plus de même loi, quand bien même les ϵ_i le seraient

5.2.1 Modèle linéaire : rappels

Le modèle linéaire consiste à supposer que r s'écrit, si $x = (x_1, \dots, x_p) \in \mathbb{R}^p$,

$$r(x) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

On note $\mathbf{X} = \begin{pmatrix} 1 & X_{11} & \dots & X_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \dots & X_{np} \end{pmatrix}$, $\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}$ et $\boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix}$

Dans ce cas, l'estimation de r revient à l'estimation du vecteur $\boldsymbol{\beta}$. C'est un problème paramétrique. On utilise en général les moindres carrés ordinaires :

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^p} \sum_{i=1}^n (Y_i - \beta_0 - \sum_{j=1}^p X_{ij}\beta_j)^2.$$

Si $\mathbf{X}$ est de plein de rang en colonnes alors $\mathbf{X}^T \mathbf{X}$ est inversible et $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ et $\hat{Y} = \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} = \mathbf{A} \mathbf{Y}$ où $\mathbf{A} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$. Et finalement, l'estimateur de la fonction de régression est

$$\hat{r}(x) = (1, x^T) \hat{\boldsymbol{\beta}}$$

pour $x \in \mathbb{R}^p$.

On rappelle que la matrice $\mathbf{A}$ (souvent appelée matrice chapeau, hat matrix) est la matrice de projection orthogonale sur le sous-espace engendré par les vecteurs colonnes de la matrice de design $\mathbf{X}$.

Dans le cas d'un design déterministe, on montre que, si le vecteur de bruit $(\epsilon_1, \dots, \epsilon_n)$ est formé v.a. indépendantes, centrées et de variance σ^2 alors on a ³

$$\mathbb{E}(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta} \quad \text{et} \quad \Sigma_{\hat{\boldsymbol{\beta}}} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$$

où $\Sigma_{\hat{\boldsymbol{\beta}}}$ est l'opérateur de covariance de $\hat{\boldsymbol{\beta}}$.

Remarque : les résultats théoriques obtenus pour un design déterministe ne sont pas sans intérêt quand on dispose d'un design aléatoire. Un certain nombre de résultats sont encore valides, sous certaines hypothèses, en conditionnant par rapport au design.

Par exemple : pour le cas d'un design aléatoire, avec des observations $(X_i, Y_i)_{1 \leq i \leq n}$ i.i.d., si la fonction de régression est bien affine et si la loi des X_i est telle que presque sûrement les colonnes de la matrice $\mathbf{X}$ sont linéairement indépendantes, alors on retrouve le fait que le biais de l'OLS $\hat{\boldsymbol{\beta}}$ est nul

$$\mathbb{E}(\hat{\boldsymbol{\beta}} \mid X_1, \dots, X_n) = \boldsymbol{\beta}$$

et donc

$$E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}.$$

Si en plus on suppose que $\mathbb{E}(\epsilon_i^2 \mid X_i)$ est constante égale à σ^2 (ce qui est vrai si on suppose en plus que les ϵ_i sont indépendants des X_i) alors on a ("matrice de covariance de $\hat{\boldsymbol{\beta}}$ sachant le design")

$$\mathbb{E}[(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mid X_1, \dots, X_n] = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$$

5.2.2 Équilibre biais-variance : rappels

Supposons que le design est déterministe. On a

$$Y_i = r(x_i) + \epsilon_i, \quad i = 1, \dots, n$$

On suppose que r est bien approchée par une fonction linéaire des variables.

Comme dans le paragraphe précédent, on suppose que $\mathbf{X}$ est de plein de rang en colonnes.

3. et on n'a pas besoin que le bruit soit gaussien pour ces résultats...

Soit m une partie de $\{1, \dots, p\}$. m représente un ensemble de covariables. Si $m = \{1, \dots, p\}$, il s'agit de l'OLS sur le modèle complet. Pour simplifier, on suppose qu'il n'y a pas d'intercept. La prédiction de l'OLS sur la i ème donnée d'entraînement est alors

$$\hat{r}(x_i) = x_i^T \hat{\beta}$$

Ainsi les prédictions de l'OLS sur les données d'entraînement $(x_1, \dots, x_n)$ sont fournies par

$$\hat{\mathbf{Y}} = \mathbf{X} \hat{\beta}$$

Si on utilise un OLS mais calculé seulement avec les features dont les indices appartiennent à m , on obtient un estimateur qu'on note $\hat{r}^m$. Les prédictions de cet estimateur sur les données d'entraînement

$$\hat{\mathbf{Y}}^m = \mathbf{X}^m \hat{\beta}^m$$

où $\mathbf{X}^m$ est la matrice $\mathbf{X}$ à laquelle on a ôté les colonnes dont les indices n'appartiennent pas à m et où $\hat{\beta}^m$ est l'OLS correspondant, i.e.

$$\hat{\beta}^m = (\mathbf{X}^{mT} \mathbf{X}^m)^{-1} \mathbf{X}^{mT} \mathbf{Y}$$

On s'intéresse au risque suivant :

$$R_m := \mathbb{E} \|\hat{\mathbf{Y}}^m - r^*\|_2^2$$

où $r^* = (r(x_1), \dots, r(x_n))^T$. On a

$$\mathbf{Y} = r^* + \xi$$

où $\xi = (\epsilon_1, \dots, \epsilon_n)^T$

$$R_m = \mathbb{E} \|P_m(r^* + \xi) - r^*\|_2^2$$

où P_m est la matrice de projection orthogonale sur le sous espace engendré par les colonnes de la matrice $\mathbf{X}^m$. D'où

$$\begin{aligned} R_m &= \|(I - P_m)r^*\|^2 + \mathbb{E} \|P_m \xi\|_2^2 \\ &= \|(I - P_m)r^*\|^2 + \sigma^2 |m| \end{aligned}$$

où $|m|$ est le cardinal de l'ensemble m .

Ce risque se décompose donc en deux termes :

- un terme de biais $\|(I - P_m)r^*\|^2$ qui reflète la qualité de l'approximation de r^* par les features dont les indices sont dans m
- un terme de variance $\sigma^2 |m|$ qui augmente avec le nombre de features.

Le meilleur modèle réalise un compromis entre ce terme de biais et ce terme de variance.

5.2.3 OLS non paramétrique (rappels)

Dans toute cette section, nous supposons pour simplifier que la fonction de régression r à estimer est une fonction à une variable réelle. Nous disposons donc des observations de $Y_1, \dots, Y_n$ et des n valeurs réelles $x_1, \dots, x_n$.

1. Cas où on sait que la fonction de régression est affine : il existe a et b réels tels que, pour tout x , $r(x) = ax + b$. Alors il suffit d'utiliser un modèle linéaire. Après avoir calculé l'OLS $(\hat{a}, \hat{b})$, on obtient directement l'estimateur de la fonction de régression :

$$\hat{r}(x) = \hat{a}x + \hat{b}.$$

2. Cas où on sait que r est un polynôme de degré M : il existe M réels $\theta_1, \dots, \theta_M$ tels que

$$r(x) = \sum_{j=1}^M \theta_j x^j, \quad \forall x$$

Alors on forme la matrice $\mathbf{X}$ de dimension $n \times (M+1)$ telle que sa j ème colonne est $X^j = (x_1^j, \dots, x_n^j)^T$ pour $j = 0, \dots, M$. Après avoir calculé l'OLS $(\hat{\theta}_0, \dots, \hat{\theta}_M)$, on obtient directement l'estimateur de la fonction de régression :

$$\hat{r}(x) = \sum_{j=0}^M \hat{\theta}_j x^j.$$

3. Cas où on sait seulement que la fonction de régression est continue : on peut penser à approcher r par un polynôme. On utilise alors l'OLS avec la matrice $\mathbf{X}$ décrite dans l'item précédent.

Problème : quel degré choisir ?

- Si M est trop petit, le polynôme risque de ne pas être assez proche de r : erreur d'approximation grande (underfitting).
- Si M est trop grand : c'est la variance qui est trop grande (overfitting).

Il y a plusieurs façons de choisir le degré M : on peut utiliser par exemple la validation croisée ou les critères de choix de modèles vus en MLG (ex : Cp de Mallows ou BIC). On revient sur la validation croisée en fin de chapitre.

Cf. Illustrations Jupyter notebook.

On peut utiliser le modèle linéaire avec n'importe quelle transformation de la variable d'origine (ou des variables d'origine s'il y a plusieurs variables explicatives).

De manière générale, on se donne un ensemble de fonctions $\varphi_1, \varphi_2, \dots$ et on suppose que r est bien approchée par une combinaison linéaire d'éléments de cet ensemble : $\exists M$ tel que

$$r \approx \theta_1 \varphi_1 + \dots + \theta_M \varphi_M$$

Si on choisit d'utiliser les M premières fonctions du dictionnaire alors on calcule l'EMC $\hat{\theta}$ en utilisant la matrice $\mathbf{X} = (X_{ij})_{\substack{1 \leq i \leq n \\ 1 \leq j \leq M}}$ telle que $X_{ij} = \varphi_j(X_i)$ (la matrice $\mathbf{X}$ doit être de plein rang en colonnes). On obtient alors directement l'estimateur $\hat{r}$:

$$\forall x, \quad \hat{r}(x) = \hat{\theta}_1 \varphi_1(x) + \dots + \hat{\theta}_M \varphi_M(x)$$

La question qui se pose alors est celle du nombre d'éléments du dictionnaire. Plus on choisit M grand, meilleure est l'approximation de départ $r \approx \theta_1 \varphi_1 + \dots + \theta_M \varphi_M$. Cependant, on sait que plus on choisit M grand, plus la variance augmente. Le biais et la variance se comportent de façon contraire vis-à-vis de M . Le paramètre M joue en fait le même rôle que la fenêtre h dans le chapitre précédent. Il s'agit donc de trouver un équilibre entre l'erreur d'approximation et la variance.

L'EMC non-paramétrique associé à cette base (non locale) de polynômes est lié à une approximation globale. L'estimateur par polynôme local qui fait l'objet des sections suivantes est au contraire une méthode locale.

On pourrait aussi penser à utiliser une pénalisation de type ridge ou lasso : si on pense que r est proche d'une combinaison parcimonieuse ("sparse", i.e. avec peu de coefficients non nuls) des éléments du dictionnaire, alors il est judicieux d'utiliser l'estimateur Lasso.

5.2.4 Rappels : Cp de Mallows et Lasso

On se place dans le contexte de la section 5.2.2, donc en design déterministe.

$$\mathbf{Y} = r^* + \xi, \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \xi = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}, \quad r^* = \begin{pmatrix} r(x_1) \\ \vdots \\ r(x_n) \end{pmatrix}.$$

On suppose

$$\mathbb{E}[\xi] = 0, \quad \text{Cov}(\xi) = \sigma^2 I_n.$$

où $\text{Cov}(\xi)$ est la matrice de covariance de ξ .

Soit $\mathcal{M}$ un ensemble de parties de $\{1, \dots, d\}$.

Par exemple :

- $\mathcal{M} = \mathcal{P}(\{1, \dots, d\})$ ("best subset selection", toutes les parties de $\{1, \dots, d\}$);
- si $k < d$, $\mathcal{M} =$ toutes les parties à moins de k éléments parmi $\{1, \dots, d\}$.

On cherche à résoudre

$$\tilde{m} \in \arg \min_{m \in \mathcal{M}} \|\widehat{\mathbf{Y}}^m - r^*\|_2^2,$$

c'est-à-dire on cherche le meilleur modèle au sens de cette perte.

On suppose σ^2 connu.

Problème : on ne connaît pas r^* , donc on ne connaît pas

$$\|\widehat{\mathbf{Y}}^m - r^*\|_2^2.$$

Idée : on remplace cette quantité inconnue par un estimateur, c'est-à-dire une quantité calculée à partir des données uniquement (et de quantités connues). On va utiliser un estimateur sans biais.

On a

$$R_m := \mathbb{E} \|\widehat{\mathbf{Y}}^m - r^*\|_2^2 = \|(I - P_m)r^*\|_2^2 + \sigma^2 |m|$$

(cf. section 5.2.2).

On cherche donc une quantité dépendant seulement des données (et de quantités connues comme n) dont l'espérance soit égale à R_m .

Recherche d'un estimateur sans biais :

On peut penser à utiliser

$$\|\widehat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2$$

(intuition : c'est r^* qui est inconnu dans $\|\widehat{\mathbf{Y}}^m - r^*\|_2^2$, et $\mathbf{Y} = r^* + \xi$, donc $\mathbf{Y}$ est une version bruitée de r^*).

Calculons son espérance :

$$\mathbb{E} \|\widehat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2 = \|(I - P_m)r^*\|_2^2 + \sigma^2(n - |m|).$$

(cf. TD5, exercice 1)

D'où

$$\mathbb{E} \left(\|\widehat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2 + \sigma^2(2|m| - n) \right) = R_m.$$

Donc

$$\|\widehat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2 + \sigma^2(2|m| - n)$$

est l'estimateur sans biais cherché (on rappelle qu'on a supposé σ^2 connu).

On va donc utiliser

$$\hat{m} \in \arg \min_{m \in \mathcal{M}} \left\{ \|\widehat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2 + \sigma^2(2|m| - n) \right\}$$

c'est-à-dire, de façon équivalente,

$$\hat{m} = \arg \min_{m \in \mathcal{M}} \left\{ \|\widehat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2 + 2|m|\sigma^2 \right\}.$$

NB : en pratique, on ne connaît pas σ^2 , donc il faut le remplacer par un estimateur $\hat{\sigma}^2$, ce qui conduit au critère de Mallows

$$C_p(m) := \frac{\|\widehat{\mathbf{Y}}_m - \mathbf{Y}\|_2^2}{\hat{\sigma}^2} + 2m.$$

Remarque 5.1: Lasso/Cp de Mallows

1. Cp de Mallows.

- (a) D'abord le cas de la "best subset selection", i.e. le cas où on considère toutes les parties possibles de $\{1, \dots, d\}$. On a alors possiblement deux types de problèmes :
 - Des problèmes de coûts de calculs : on a 2^d sous-ensembles candidats. Cela peut être très coûteux en temps.
 - La pénalisation du Cp de Mallows est trop petite quand d est un peu grand : On pourrait montrer (sous certaines hypothèses) qu'une bonne pénalisation pour la best subset selection doit aussi dépendre de d (par exemple on pourrait prendre une pénalisation de l'ordre de $\sigma^2|m|\log(d)$ au lieu d'une pénalisation de l'ordre de $\sigma^2|m|$ comme dans le critère Cp).
- (b) Cas d'une sélection de type forward ou backward (ou forward-backward) : les problèmes de temps de calculs sont alors atténués mais d'autres problèmes se posent, en particulier des problèmes de stabilité et un manque de garanties théoriques concernant les propriétés statistiques de l'estimateur final.

On peut reformuler les critères du Cp de Mallows ou du BIC sous la forme

$$\arg \min_{\beta \in \mathbf{R}^p} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_0 \right\},$$

où

$$\|\beta\|_0 = \#\{j : \beta_j \neq 0\}$$

avec $\lambda = 2\sigma^2$ pour le critère de Mallows et $\lambda = \sigma^2 \log(n)$ pour le critère BIC (avec σ^2 remplacé ensuite par un estimateur).

(Une preuve de cette reformulation est fournie après cette remarque.)

Cette pénalité (le critère ℓ^0) est discontinue et donne lieu à un problème d'optimisation non convexe : concrètement, cela conduit donc à une recherche combinatoire sur les sous-ensembles de variables. C'est donc cette pénalité qui crée les difficultés d'optimisation.

2. Estimateur Lasso :

Lasso permet de pallier les problèmes de complexité de calculs précédent (dans le cas de la "best subset selection") : en effet, même si on utilisait une pénalisation adaptée dans le cas où d est grand (comme suggéré plus haut) à la place de la pénalisation proposée dans le Cp de Mallows (ce qui revient à choisir plus soigneusement la valeur de λ) il resterait le problème de la complexité de calcul.

L'idée du Lasso est de remplacer $\|\beta\|_0$ par $\|\beta\|_1$, où

$$\|\beta\|_1 = \sum_{j=1}^p |\beta_j|.$$

L'estimateur Lasso est alors défini par

$$\hat{\beta}^{\text{Lasso}} \in \operatorname{argmin}_{\beta \in \mathbf{R}^p} \left\{ \frac{1}{2} \|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1 \right\}.$$

Autrement dit, on remplace la pénalité $\|\beta\|_0$ idéale mais discontinue par le proxy convexe $\|\beta\|_1$.

- $\|\beta\|_0$ compte directement le nombre de coefficients non nuls et correspond exactement à l'objectif de sélection de variables ;
- $\|\beta\|_1$ est convexe et tend malgré tout à produire des solutions parcimonieuses (cette propriété est liée au fait que la valeur absolue n'est pas dérivable en 0...).

Preuve de la reformulation des critères de type BIC et Cp avec $\|\cdot\|_0$.

Notons $\tilde{\beta}$ un estimateur associé au problème reformulé

$$\tilde{\beta} \in \arg \min_{\beta \in \mathbf{R}^p} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_0 \right\}. \quad (5.2)$$

Pour simplifier, pour tout $m \subset \{1, \dots, d\}$, on confondra le vecteur $\hat{\beta}^m$ de $\mathcal{R}^{|m|}$ (associé à l'OLSE sur les colonnes dont l'indice appartient à l'ensemble m) avec ce même vecteur mais vu dans $\mathcal{R}^d$ (donc c'est le vecteur de $\mathcal{R}^d$ dont les coordonnées associées à des indices dans m sont celles du vecteur $\hat{\beta}^m$ et avec des coordonnées nulles pour les indices appartenant au complémentaire de m). Ainsi tous les vecteurs considérés dans la suite sont dans $\mathcal{R}^d$.

Une solution du problème initial est un vecteur $\hat{\beta}^{\hat{m}}$ où $\hat{m}$ est tel que

$$\hat{m} \in \arg \min_{m \in \mathcal{M}} \left\{ \|\hat{\mathbf{Y}}^m - \mathbf{Y}\|_2^2 + \lambda |m| \right\}$$

i.e.

$$\hat{m} \in \arg \min_{m \in \mathcal{M}} \left\{ \|\mathbf{X}\hat{\beta}^m - \mathbf{Y}\|_2^2 + \lambda |m| \right\} \quad (5.3)$$

(NB : pas unicité pour ce problème)

On veut montrer que toute solution d'un des problèmes est également solution de l'autre.

- On vérifie que $\hat{\beta}^{\hat{m}}$ est bien un minimiseur du problème 5.2 :

Si $\beta \in \mathcal{R}^d$ est quelconque et si on note $m = \{i \in \{1, \dots, d\} \text{ t.q. } \beta_i \neq 0\}$ alors, par définition de $\hat{\beta}^m$, on a

$$\|\mathbf{Y} - \mathbf{X}\beta\|_2^2 \geq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^m\|_2^2$$

Donc

$$\|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda |m| \geq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^m\|_2^2 + \lambda |m| \geq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^{\hat{m}}\|_2^2 + \lambda |\hat{m}|$$

où la deuxième inégalité vient de la définition de $\hat{m}$. Ceci se réécrit

$$\|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_0 \geq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^{\hat{m}}\|_2^2 + \lambda \|\hat{\beta}^{\hat{m}}\|_0$$

c.q.f.d. (puisque β est quelconque).

- On vérifie maintenant que $\tilde{\beta}$ (qui est une solution du problème 5.2) est bien solution du problème associé au critère BIC ou Cp (avec le lambda associé).

Si on note $m(\tilde{\beta}) = \{i \in \{1, \dots, d\} \text{ t.q. } \tilde{\beta}_i \neq 0\}$ alors par définition de $\tilde{\beta}$ on a

$$\|\mathbf{Y} - \mathbf{X}\tilde{\beta}\|_2^2 + \lambda \|\tilde{\beta}\|_0 \leq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^{m(\tilde{\beta})}\|_2^2 + \lambda \|\hat{\beta}^{m(\tilde{\beta})}\|_0$$

i.e.

$$\|\mathbf{Y} - \mathbf{X}\tilde{\beta}\|_2^2 \leq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^{m(\tilde{\beta})}\|_2^2$$

(car $\|\hat{\beta}^{m(\tilde{\beta})}\|_0 = |m(\tilde{\beta})| = \|\tilde{\beta}\|_0$)

D'où, par définition de $\hat{\beta}^{m(\tilde{\beta})}$,

$$\tilde{\beta} = \hat{\beta}^{m(\tilde{\beta})} \quad (5.4)$$

Il reste donc à voir que $m(\tilde{\beta})$ est une solution du problème 5.3. Soit donc $m \in \{1, \dots, d\}$ quelconque. On a, par définition de $\tilde{\beta}$,

$$\|\mathbf{Y} - \mathbf{X}\tilde{\beta}\|_2^2 + \lambda\|\tilde{\beta}\|_0 \leq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^m\|_2^2 + \lambda\|\hat{\beta}^m\|_0$$

i.e., en utilisant la définition de $\|\cdot\|_0$ et en utilisant 5.4

$$\|\mathbf{Y} - \mathbf{X}\hat{\beta}^{m(\tilde{\beta})}\|_2^2 + \lambda|m(\tilde{\beta})| \leq \|\mathbf{Y} - \mathbf{X}\hat{\beta}^m\|_2^2 + \lambda|m|$$

donc $m(\tilde{\beta})$ est bien une solution du problème 5.3.

5.3 Estimateur de Nadaraya-Watson

On suppose que les (X_i, Y_i) admettent une densité $f : \mathbb{R}^2 \rightarrow \mathbb{R}$. On note f_X la densité de X . On suppose que pour tout $x \in \mathbb{R} : f_X(x) > 0$. Alors on a

$$\forall x \in \mathbb{R}, r(x) = \mathbb{E}[Y|X = x] = \int \frac{yf(x, y)}{f_X(x)} dy$$

Donc pour estimer r , on peut passer par l'estimation de f et f_X et poser

$$\hat{r}_n(x) = \begin{cases} \int \frac{y\hat{f}_n(x, y)}{\hat{f}_{n,X}(x)} dy & \text{si } \hat{f}_{n,X}(x) \neq 0 \\ 0 & \text{si } \hat{f}_{n,X}(x) = 0 \end{cases}$$

On peut utiliser les estimateurs à noyau du chapitre précédent :

$$\begin{aligned} \hat{f}_{n,X}(x) &= \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \\ \hat{f}_n(x, y) &= \frac{1}{nh^2} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) K\left(\frac{Y_i - y}{h}\right) \end{aligned}$$

Proposition 5.2

Si K est un noyau d'ordre 1 alors $\forall x \in \mathbb{R}$

$$\hat{r}_n(x) = \begin{cases} \frac{\sum_{i=1}^n Y_i K(\frac{X_i - x}{h})}{\sum_{i=1}^n K(\frac{X_i - x}{h})} & \text{si } \sum_{i=1}^n K(\frac{X_i - x}{h}) \neq 0 \\ 0 & \text{sinon} \end{cases}$$

Démonstration. $\hat{f}_{n,X}(x) = 0$ est équivalent à $\sum_{i=1}^n K(\frac{X_i - x}{h}) = 0$.

Supposons donc que $\sum_{i=1}^n K(\frac{X_i-x}{h}) \neq 0$. Alors

$$\begin{aligned}
 \hat{r}_n(x) &= \int \frac{y \hat{f}_n(x, y)}{\hat{f}_{n,X}(x)} dy \\
 &= \frac{1}{\hat{f}_{n,X}(x)} \int y \frac{1}{nh^2} \sum_{i=1}^n K(\frac{X_i-x}{h}) K(\frac{Y_i-y}{h}) dy \\
 &= \frac{nh}{\sum_{i=1}^n K(\frac{X_i-x}{h})} \frac{1}{nh^2} \sum_{i=1}^n K(\frac{X_i-x}{h}) \int y K(\frac{Y_i-y}{h}) dy \\
 &= \frac{1}{\sum_{i=1}^n K(\frac{X_i-x}{h})} \sum_{i=1}^n K(\frac{X_i-x}{h}) \frac{1}{h} \int y K(\frac{Y_i-y}{h}) dy \\
 &= \frac{1}{\sum_{i=1}^n K(\frac{X_i-x}{h})} \sum_{i=1}^n K(\frac{X_i-x}{h}) Y_i
 \end{aligned}$$

Pour la dernière ligne, on a utilisé le fait que

$$\frac{1}{h} \int y K(\frac{Y_i-y}{h}) dy = \frac{1}{h} \int (Y_i - uh) K(u) h du = Y_i \int K(u) du - h \int u K(u) du = Y_i$$

□

Remarque 5.3

Prenons le noyau (Rosenblatt) $K(u) = \frac{1}{2} \mathbb{1}_{|u| \leq 1}$.

Alors $\hat{r}_n(x)$ est la moyenne des Y_i tels que $X_i \in [x-h, x+h]$. Pour n fixé, les deux cas extrêmes pour la fenêtre sont :

- $h \rightarrow \infty$. **Quand h est suffisamment grand**, tous les X_i se trouvent dans l'intervalle $[x-h, x+h]$. Alors $\hat{r}_n$ est la moyenne des Y_i , c'est donc une fonction constante de x . **L'erreur d'approximation (liée au biais) est alors trop grande.**
- $h \rightarrow 0$. Soit x distinct de tous les X_i , **si h est assez petit**, très exactement $h < \min_{1 \leq i \leq n} \{|X_i - x|\}$, on a $\hat{r}_n(x) = 0$. Et si $x = X_j$ pour un certain $j = 1, \dots, n$, on a $r_n(X_j) = Y_j$ dès que $h < \min_{1 \leq i \leq n} \{|X_i - X_j|\}$. L'estimateur $\hat{r}_n$ est donc très oscillant : il reproduit les données Y_i aux points X_i et il s'annule partout ailleurs. **L'erreur stochastique (liée à la variance) est trop grande.**
(cf.illustrations graphiques.)

La fenêtre optimale équilibrant biais au carré et variance se trouve entre ces deux extrêmes.

Remarque 5.4

Si K est continu et strictement positif sur $\mathbb{R}$ alors $\hat{r}_n$ est continu.

Remarque 5.5

On peut écrire

$$\hat{r}_n(x) = \sum_{i=1}^n \omega_{n,i}(x) Y_i$$

$$\text{où } \omega_{n,i}(x) = \begin{cases} \frac{K(\frac{X_i-x}{h})}{\sum_{i=1}^n K(\frac{X_i-x}{h})} & \text{si } \sum_{i=1}^n K(\frac{X_i-x}{h}) \neq 0 \\ 0 & \text{sinon} \end{cases}$$

Si $\sum_{i=1}^n K(\frac{X_i-x}{h}) = 0$, i.e. si x se trouve dans une zone où il n'y a pas de X_i , alors $\hat{r}(x) = 0$.

Et sinon, comme $\sum_{i=1}^n \omega_{n,i}(x) = 1$, alors Y_i est une moyenne pondérée des Y_i qui correspondent aux points X_i proches de x .

Dans la pratique, comme K est en général symétrique et décroissant sur $\mathbb{R}^+$, le poids associé à Y_i dans cette moyenne pondérée est d'autant plus grand que X_i est proche de x . Les Y_i associés à des points X_i qui sont loin de x n'ont pas ou peu d'impact sur l'estimation de $r(x)$. C'est en cela que la méthode est locale, au contraire de l'EMC non paramétrique.

Remarque 5.6

Il se peut que la densité f_X soit connue. Dans ce cas, il est préférable d'utiliser

$$\tilde{r}_n(x) = \begin{cases} \int \frac{y \hat{f}_n(x,y)}{\hat{f}_X(x)} dy & \text{si } f_X(x) \neq 0 \\ 0 & \text{si } f_X(x) = 0 \end{cases}$$

i.e. , si K est un noyau d'ordre 1,

$$\tilde{r}_n(x) = \begin{cases} \frac{1}{nh f_X(x)} \sum_{i=1}^n Y_i K\left(\frac{X_i - x}{h}\right) & \text{si } f_X(x) \neq 0 \\ 0 & \text{si } f_X(x) = 0 \end{cases}$$

L'estimateur de Nadaraya-Watson est un cas particulier des estimateurs par polynômes locaux.

5.4 Estimateur par polynômes locaux

Proposition 5.7

Si $\hat{r}_n$ est l'estimateur de Nadaraya-Watson associé à un noyau K positif et si $\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \neq 0$ alors

$$\hat{r}_n(x) = \arg \min_{\theta \in \mathbb{R}} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) (Y_i - \theta)^2$$

$\hat{r}_n(x)$ est donc un estimateur des moindres carrés pondérés.

Démonstration.

$$\hat{r}_n(x) = \arg \min_{\theta \in \mathbb{R}} \tau(\theta)$$

où

$$\tau(\theta) = \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) (Y_i - \theta)^2$$

τ est un polynôme du second degré en θ . Recherche d'un point critique :

$$\tau'(\theta) = 0 \Leftrightarrow \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Y_i = \theta \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)$$

$$\Leftrightarrow \theta = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)} = \hat{r}_n(x) \text{ (par définition).}$$

C'est un minimum car $\tau'' \equiv 2 \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) > 0$. □

L'estimateur par polynômes locaux est une généralisation de l'estimateur de Nadaraya-Watson associée à sa caractérisation par la proposition précédente.

L'idée est de reprendre le problème de minimisation de la proposition précédente mais au lieu d'approcher la fonction localement par une constante θ , on utilise un polynôme.

Plus précisément, si r est suffisamment régulière alors, **autour de** x , r est proche du polynôme (de degré noté ℓ ici) associé à son développement de Taylor-Lagrange en x : pour u proche de x on a

$$r(u) \approx P_{\ell,x}(u)$$

avec

$$P_{\ell,x}(u) = \sum_{k=0}^{\ell} \frac{r^{(k)}(x)}{k!} (u-x)^k$$

Evidemment $P_{\ell,x}$ est tout aussi inconnu que $r(x)$ (ses coefficients dépendent de la quantité que l'on cherche à estimer $r(x)$ mais aussi des dérivées $r'(x), \dots, r^{(\ell)}(x)$).

On va en fait essayer d'estimer ce polynôme $P_{\ell,x}$: si on écrit

$$P_{\ell,x}(u) = \mu_0 + \mu_1(u-x) + \dots + \mu_{\ell}(u-x)^{\ell},$$

on cherche donc à estimer les coefficients $\mu_0, \dots, \mu_{\ell}$ de ce polynôme.

Une fois cette estimation réalisée, comme $\mu_0 = r(x)$, l'estimateur $\hat{\mu}_0$ sera l'estimateur $\hat{r}(x)$ recherché.

Comment estimer ces coefficients ? On a

$$r(X_i) \approx P_{\ell,x}(X_i) \text{ si } X_i \text{ est proche de } x$$

donc on est tenté de chercher un polynôme $\hat{P}$ qui soit tel que

$$\hat{P}(X_i) \text{ est proche de } r(X_i) \text{ pour les } X_i \text{ proches de } x.$$

Comme on n'a pas accès à $r(X_i)$ mais à sa donnée bruitée Y_i , on cherche en fait $\hat{P}$ tel que

$$\hat{P}(X_i) \text{ est proche de } Y_i \text{ pour les } X_i \text{ proches de } x.$$

Autrement dit

$$(\hat{P}(X_i) - Y_i)^2 \text{ petit pour les } X_i \text{ proches de } x.$$

Des poids $K(\frac{X_i-x}{h})$ sont ajoutés pour prendre en compte cette notion de proximité. On pose alors

Définition 5.8

Si K est un noyau positif, $h > 0$ une fenêtre et $\ell \geq 0$ un entier, on définit $\forall x \in \mathbb{R}$,

$$\hat{\theta}(x) = \arg \min_{\theta=(\theta_0, \dots, \theta_{\ell}) \in \mathbb{R}^{\ell+1}} \sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) \left[Y_i - \sum_{k=0}^{\ell} \frac{\theta_k}{k!} \left(\frac{X_i-x}{h}\right)^k \right]^2$$

On pose $\hat{\theta} = (\hat{\theta}_0, \hat{\theta}_1, \dots, \hat{\theta}_{\ell})$. L'estimateur par polynôme local d'ordre ℓ est alors défini par

$$\hat{r}_n^{\ell}(x) = \hat{\theta}_0$$

Remarque 5.9

Si $\ell = 0$ alors $\hat{r}_n^{\ell}(x)$ est égal à l'estimateur de Nadaraya-Watson.

Remarque 5.10

Attention ici l'idée est très différente de celle exposée dans les rappels sur l'EMC non paramétrique :

- Dans le cas de l'estimateur par polynômes locaux, on approche la fonction de régression **localement** par un polynôme. Le polynôme en question est donc différent pour chaque valeur de x .
- En revanche, r était approchée globalement pour l'EMC non paramétrique : c'était donc le même polynôme pour tout x .

Définition 5.11

Un estimateur $\hat{r}$ de la fonction de régression r est linéaire s'il s'écrit

$$\hat{r}(x) = \sum_{i=1}^n \omega_i(x) Y_i, \quad \forall x \in \mathbb{R}$$

où les $\omega_i(x)$ ne dépendent pas des Y_i .

Ex : l'estimateur de Nadaraya-Watson.

On peut aussi écrire $\hat{r}(x) = \omega(x)^T \mathbf{Y}$ où $\mathbf{Y}$ est le vecteur $(Y_1, \dots, Y_n)^T$ et $\omega(x) = (\omega_1(x), \dots, \omega_n(x))^T$.

Attention : ne pas confondre le fait que l'estimateur soit linéaire, ce qui signifie "linéaire en Y ", et le fait que la fonction de régression soit linéaire, ce qui signifie que $r(x)$ est linéaire en x .

L'estimateur associé aux MCO $\hat{r}(x) = \hat{\beta}^T x$ est linéaire en x et c'est également un estimateur linéaire : $\hat{r}(x) = x^T \hat{\beta} = x^T (X^T X)^{-1} X^T Y = \omega(x)^T Y$ où $\omega(x) = [x^T (X^T X)^{-1} X^T]^T$ est un vecteur qui ne dépend pas de Y .

Introduisons, pour la proposition suivante, quelques notations : pour tout $i = 1, \dots, n$ et tout $u \in \mathbb{R}$,

$$Z_i = \frac{X_i - x}{h}, \quad V_\ell(u) = \begin{pmatrix} 1 \\ u \\ \vdots \\ \frac{u^\ell}{\ell!} \end{pmatrix}$$

Et on pose

$$B_{n,x} = \sum_{i=1}^n K(Z_i) V_\ell(Z_i) V_\ell(Z_i)^T.$$

Proposition 5.12

Si la matrice $B_{n,x}$ est définie positive alors l'estimateur par polynômes locaux $\hat{r}_n^\ell(x)$ est un estimateur linéaire.

Preuve : cf. Exercice 3 TD5.

Remarque 5.13

On a

$$\sum_{i=1}^n \omega_i(x) = 1$$

cf. exercice 4 TD5.

Remarque 5.14

Comme pour l'estimation de densités par noyaux, en pratique le choix du noyau est moins important que le choix de la fenêtre. Quant au degré de polynôme, on choisit souvent 1 ou 2. On peut choisir la fenêtre (mais également le degré) par un critère de type validation croisée.

Remarque 5.15

Nous verrons en TD que choisir un degré ℓ grand permet d'obtenir un biais asymptotiquement plus petit, si la fonction de régression est suffisamment régulière (cf. exercice 5 TD5). Dans la pratique, on utilise rarement un degré supérieur à 1 ou 2 car :

- Le gain associé à un degré plus élevé, dans le cas où la fonction est très régulière, n'est qu'un gain "asymptotique" : il n'est réel que si " n est vraiment très grand". Quand on considère l'asymptotique, on néglige les constantes dans l'estimation du biais et de la variance (c.f. l'exercice 5 TD5 ou c.f. les exercices du chap 4) mais ces constantes peuvent avoir de l'importance si n n'est pas très grand.
- Les degrés plus élevés engendrent plus d'instabilité numérique pour certains designs.
- Le gain espéré n'est réel que si on choisit correctement la fenêtre.

(Ce choix n'est pas lié au coût de calcul, le degré 3 n'est pas beaucoup cher que le degré 1 ou 2).

5.5 Grande dimension

Remarque 5.16: Curse of dimensionality

On peut évidemment généraliser les estimateurs de Nadaraya-Watson et par polynômes locaux au cas où X est à valeurs dans $\mathbb{R}^d$, i.e. quand on a plusieurs variables explicatives. Comme pour les estimateurs de la densité, le problème du fléau de la dimension se pose.

Considérons un noyau à support dans $[-\frac{1}{2}, \frac{1}{2}]^d$. Alors le support de la fonction noyau redimensionnée K_h est $[-\frac{h}{2}, \frac{h}{2}]^d$, et ce support a un volume de h^d . Lorsque X suit une loi uniforme sur $[0, 1]^d$, le nombre d'observations dans le support de K_h est typiquement de l'ordre de nh^d . Par exemple, pour $n = 1000$, $h = 0,1$ et $d = 3$, il y a typiquement une seule observation dans le support de K_h . De manière générale, les voisinages locaux sont presque vides dans les espaces de grande dimension, ce qui rend les estimateurs à noyau peu efficaces dans ces espaces. Remarquez que cela dépend évidemment de n : par exemple, si $d = 10$ et $h = 0,1$, il faut n au moins de l'ordre de 10^{10} pour qu'il y ait au moins une observation dans le support de K_h . Voir aussi "distances between points" dans http://www.cs.cornell.edu/courses/cs4780/2018fa/lectures/lecturenote02_kNN.html dans le contexte des knn.

Cette remarque reste vraie pour d'autres contextes : par exemple, si on utilise l'EMC non paramétrique avec une base de polynômes de degré total inférieur ou égal à M en dimension d alors la matrice de régression a $\binom{M+d}{M}$ colonnes et la base produit tensoriel de la base de monômes de degrés inférieurs ou égaux à M fournit une matrice de régression à M^d colonnes. Donc avec un degré $M = 2$ et $d = 10$ variables on a déjà 2^{10} colonnes !

En revanche, si on utilise un modèle sans interaction, i.e. si on utilise des polynômes de degré M mais sans interactions, on obtient une nouvelle matrice de design qui a $dM + 1$ colonnes.

- **Les modèles paramétriques** imposent des hypothèses restrictives sur le mécanisme générateur des données.
- **Les modèles non paramétriques complets** peuvent souffrir du « fléau de la dimension » lorsque le nombre de variables explicatives est (un peu) élevé (par rapport à n).

Cependant, il est possible de construire des modèles intermédiaires entre les modèles paramétriques et les modèles entièrement non paramétriques. Les modèles semi-paramétriques comportent une partie paramétrique et une partie non paramétrique, et les modèles structurels imposent des restrictions qualitatives sur le mécanisme de génération des données.

Exemple 5.17: Non paramétrique en "assez grande dimension"

On suppose que les X_i sont à valeurs dans $\mathbb{R}^d$. On a donc des couples de v.a. (X_i, Y_i) i.i.d. à valeurs dans $\mathbb{R}^d \times \mathbb{R}$.

- **Le modèle additif** (modèle "structurel") : on suppose que la fonction de régression satisfait

$$r(x) = c + \sum_{j=1}^d g_j(x_j)$$

avec $c \in \mathbb{R}$ inconnu et des fonctions univariées g_j inconnues aussi. Il y a donc d fonctions univariées à estimer ^a. (en plus de la constante c). NB : pas d'interactions dans ce modèle.

- Modèle partiellement linéaire ("modèle semi-paramétrique") : on suppose qu'il existe $\beta \in \mathbb{R}^{d_1}$ inconnu et une fonction $g : \mathbb{R}^{d_2} \rightarrow \mathbb{R}$ inconnue aussi telle que, si $x = (x_1, x_2) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$, $r(x) = x_1^T \beta + g(x_2)$ ^b.

a. Pour l'identifiabilité, on suppose que $\mathbb{E}g_j(X^j) = 0$ où X^j est la j ème composante de la variable X si le design est aléatoire. On a alors $c = E(Y)$, on estime donc c par $\hat{c} = \bar{Y}$. Si le design est déterministe, on suppose que $\sum_{i=1}^n g_j(x_{ij}) = 0$ et à nouveau $\hat{c} = \bar{Y}$.

b. On ne met pas d'intercept dans le vecteur β pour des problèmes d'identifiabilité

Remarque 5.18: An algorithm to fit the additive model : backfitting (non exigé)

The backfitting algorithm is an iterative algorithm which is based on the idea that if we have estimates $\hat{g}_2, \dots, \hat{g}_d$ for $g_2, \dots, g_d$ and an estimate $\hat{c}$ for c , then we can apply a univariate non-parametric estimator to estimate g_1 . Let

$$R_i^1 = Y_i - \hat{c} - \hat{g}_2(X_{i2}) - \dots - \hat{g}_d(X_{id}), \quad 1 \leq i \leq n$$

Then we can use the data $(X_{i1}, R_i^1)_{1 \leq i \leq n}$ to estimate g_1 . We describe below the backfitting algorithm for calculating the estimates $\hat{g}_j(X_{ij})$, for $i = 1, \dots, n$ and $j = 1, \dots, d$:

1. Initialize : $\hat{c} = \bar{Y}$, $\hat{g}_j = 0$, $j = 1, \dots, d$.
2. Cycle : $j=1, 2, \dots, d, \dots, 1, 2, \dots, d, \dots$,
 - (a) Compute R_i^j , for $i = 1, \dots, n$, where

$$R_i^j = Y_i - \hat{c} - \sum_{j \neq i} \hat{g}_j(X_{ij})$$

- (b) Fit a one-dimensional regressor on the data $(X_{ij}, R_i^j)_{1 \leq i \leq n}$ to get the new $(\hat{g}_j(X_{ij}))_{1 \leq i \leq n}$.
- until $(\hat{g}_j(X_{ij}))_{1 \leq i \leq n}$ changes less than a prespecified threshold.

The univariate regressor can be a local polynomial regressor or a smoothing spline for instance.

Implémentation 5.19: Modèles additifs

- R : The two main packages in R that can be used to fit generalized additive models are `gam` and `mgcv`. Ces deux packages permettent aussi un modèle partiellement linéaire ainsi que l'utilisation d'un modèle additif généralisé (avec les mêmes fonctions de lien qu'en MLG).
- Python : packages `pygam` https://pygam.readthedocs.io/en/latest/notebooks/quick_start.html#Fit-a-Model et le sous-package `gam` de `statsmodels` : https://www.statsmodels.org/dev/gam.html#module-statsmodels.gam.smooth_basis.
- Quelques exemples dans le livre "An introduction to statistical learning" (version R et version Python) : <https://www.statlearning.com/>.

Remarque 5.20: Avantages et inconvénients des GAM

Avantages :

- Modélise des effets non linéaires.
- **Interprétation possible** (fonctions de dimension un visualisables).

Inconvénients :

- **Pas de sélection de variables automatique (contrairement aux méthodes basées sur les arbres)** (forêts aléatoires et tree gradient boosting).
- Évidemment ne prédit pas bien s'il y a des interactions importantes.
- Au moins un paramètre (λ ou h) par variable.

5.6 Choix des paramètres

5.6.1 Risque empirique, surajustement

On se place dans le cas d'un design aléatoire. Nous disposons donc d'un ensemble de v.a. $(X_i, Y_i)_{1 \leq i \leq n}$ i.i.d. et on suppose que $E(\epsilon_i^2) = \sigma^2$. Soit (X, Y) un couple de v.a. de même loi que les (X_i, Y_i) et **in-dépendant de l'échantillon**. C'est donc une donnée test.

On note $\hat{r}_h$ l'estimateur utilisant la fenêtre h . On va chercher une fenêtre h , parmi une grille H de valeurs, telle que l'estimateur associé à cette fenêtre soit performant sur de nouvelles données, i.e. "généralise" bien.

Rappelons la définition du **risque empirique (training error)** ou "erreur empirique" :

$$\hat{R}_n(\hat{r}_h) = \frac{1}{n} \sum_{i=1}^n (\hat{r}_h(X_i) - Y_i)^2$$

et de l'**erreur de généralisation**, aussi appelée **erreur test** :

$$R(\hat{r}_h) = E([Y - \hat{r}_h(X)]^2)$$

Remarque 5.21

- Le risque empirique est calculable à partir des données et donc connu. Le risque test dépend de la loi inconnue du couple de v.a. (X, Y) .
- Si $Y_1, \dots, Y_n \stackrel{iid}{\sim} Y$ alors pour estimer $E(Y)$ on utilise souvent son équivalent empirique $\frac{1}{n} \sum_{i=1}^n Y_i$.
- Ainsi, si g est une fonction déterministe (i.e. ne dépendant pas des données), alors

$$Y_1 - g(X_1), \dots, Y_n - g(X_n) \stackrel{iid}{\sim} Y - g(X).$$

Et il est alors naturel d'utiliser $\frac{1}{n} \sum_{i=1}^n (Y_i - g(X_i))^2$ pour estimer $E(Y - g(X))^2$. On a en particulier

$$E\left[\frac{1}{n} \sum_{i=1}^n (Y_i - g(X_i))^2\right] = E(Y - g(X))^2$$

et

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n (Y_i - g(X_i))^2\right) = \frac{\text{Var}((Y - g(X))^2)}{n}$$

Si on se donne un ensemble de fonctions *déterministes* $(g_h)_{h \in H}$ dépendant d'un paramètre h (en particulier cela implique que g_h **ne dépend pas de l'échantillon**), alors minimiser

le risque empirique semble un bon substitut à la minimisation du risque test pour choisir le paramètre h .

Mais attention ici, l'ensemble de fonctions $\{\hat{r}_h\}_{h \in H}$ dépend de l'échantillon !

As the model becomes more and more complex, it is able to adapt to more complicated underlying structures (a decrease in bias), but the estimation error increases (an increase in variance). In between there is an optimal model complexity that gives minimum test error. Unfortunately training error is not a good estimate of the test error. Training error consistently decreases with model complexity, typically dropping to zero if we increase the model complexity enough ⁴.

C'est donc en général une mauvaise idée d'utiliser le risque empirique comme substitut du vrai risque pour la sélection du modèle ou des paramètres du modèle ! En effet les mêmes données sont alors utilisées à la fois pour estimer r et estimer le risque.

L'erreur d'apprentissage a tendance à être trop optimiste. On aura en général $\mathbb{E}[\hat{R}_n(h)] < R(h)$. Utiliser cette erreur pour sélectionner un hyperparamètre aura tendance à pousser au sur-ajustement (overfitting) : l'estimateur associé aura tendance à être trop adapté aux données particulières dont on dispose et ne fonctionnera souvent pas bien sur de nouvelles données.

Prenons l'exemple de l'EMC non paramétrique. Si on utilise le risque empirique pour choisir le nombre M d'éléments du dictionnaire alors on choisira systématiquement le plus grand nombre (il s'agit de projections). Or comme on l'a déjà noté, une grande valeur de M mènera souvent à une variance trop grande (et dans certains cas à des problèmes de stabilité numérique).

Remarque 5.22: Un risque empirique nul n'implique pas nécessairement un sur-ajustement

Un estimateur ayant un risque empirique nul peut être sujet au sur-ajustement (overfitting). Toutefois, ce n'est pas une implication systématique. Il existe en effet des estimateurs qui interpolent parfaitement les données, c'est-à-dire tels que $\hat{Y} = Y$, et qui présentent donc un risque empirique nul, tout en conservant de bonnes propriétés de généralisation. Un exemple est donné avec l'estimateur de Nadaraya–Watson dans l'examen 2023.

Un phénomène clé lié à cette observation est celui de la *régularisation implicite*. Par exemple, dans le cas du modèle linéaire ^a, lorsque le modèle est surparamétré, la solution obtenue par descente de gradient peut avoir un risque empirique nul tout en généralisant correctement (au moins dans certains cas).

Plus précisément, lorsque le nombre de colonnes de la matrice $\mathbf{X}$ est supérieur au nombre de lignes (régime surparamétré), la matrice $\mathbf{X}^T \mathbf{X}$ n'est pas inversible. Si $\mathbf{Y}$ appartient à l'espace engendré par les colonnes de $\mathbf{X}$, alors l'équation $\mathbf{Y} = \mathbf{X}\beta$ admet une infinité de solutions. Dans ce cas, l'utilisation de la descente de gradient (initialisée en zéro) sélectionne une solution particulière parmi cet ensemble. On peut montrer que cette solution est donnée par

$$\arg \min_{\beta: \mathbf{X}\beta = \mathbf{Y}} \|\beta\|_2,$$

c'est-à-dire la solution de norme euclidienne minimale (en lien avec l'estimateur ridge lorsque le paramètre de régularisation tend vers zéro).

Il apparaît ainsi une forme de régularisation, dite *implicite*, qui dépend non pas du critère d'optimisation lui-même, mais de l'algorithme utilisé pour sélectionner une solution parmi celles minimisant le risque empirique.

Pour plus de détails, voir : <https://www.imo.universite-paris-saclay.fr/~christophe.giraud/Orsay/slides/ImplicitAndBenign.pdf>.

4. extrait de "The elements of statistical learning" : <https://hastie.su.domains/Papers/ESLII.pdf>

5.6.2 Validation croisée - 'Cross-Validation' - CV

La technique de validation croisée est très générale. Ici on va la décrire pour le choix de la fenêtre h de l'estimateur par polynômes locaux.

On se donne une grille de valeurs H de fenêtres, parmi lesquelles on veut choisir une fenêtre optimale $\hat{h}$ en se basant sur les données uniquement.

Notations : $\hat{r}_h^{-I}$ désigne un estimateur par polynôme locaux avec fenêtre h calculé à partir de l'échantillon $(X_i, Y_i)_{i \in I^c}$ où $I \subset \{1, \dots, n\}$ et I^c désigne le complémentaire de I .

Le principe général est de diviser l'échantillon d'apprentissage initial en un nouvel ensemble d'apprentissage (training set) et un ensemble de validation (validation set). On fabrique des estimateurs à partir de l'ensemble d'apprentissage et ensuite l'ensemble de validation est utilisé pour estimer leur risque de prédiction. Les schémas les plus populaires sont les suivants :

- **Hold-out CV** : on divise l'échantillon en deux parties : cela correspond à deux ensembles disjoints d'indices I_1 et I_2 de l'ensemble d'indices initial $\{1, \dots, n\}$. On calcule les estimateurs $(\hat{r}_h^{-I_2})_{h \in H}$ à partir de $(X_i, Y_i)_{i \in I_1}$. Puis on calcule les estimateurs des risques associés

$$\hat{R}(h) = \frac{1}{n_2} \sum_{i \in I_2} (Y_i - \hat{r}_h^{-I_2}(X_i))^2$$

où on a noté $n_2 = \text{Card}(I_2)$.

- **K-fold CV** : les données sont divisées en K ensembles disjoints $I_1, \dots, I_K$. Chacun de ces K sous-ensembles I_j est utilisé à tour de rôle comme ensemble de validation, son complémentaire I_j^c étant donc utilisé comme ensemble d'apprentissage :
 - On fabrique, pour chaque $j \in \{1, \dots, K\}$, l'ensemble des estimateurs $(\hat{r}_h^{-I_j})_{h \in H}$ avec $(X_i, Y_i)_{i \notin I_j}$.
 - Comme dans la Hold-out CV, on calcule la moyenne des erreurs de cet estimateur sur l'ensemble de validation correspondant

$$\hat{R}_j = \frac{1}{n_j} \sum_{i \in I_j} (Y_i - \hat{r}_h^{-I_j}(X_i))^2 \quad (5.5)$$

- Ensuite le risque de prédiction pour une fenêtre h est estimé par la moyenne des ces K erreurs

$$\hat{R}(h) = \frac{1}{K} \sum_{j=1}^K \hat{R}_j \quad (5.6)$$

où on a noté $n_j = \text{Card}(I_j)$.

Dans la pratique on choisit souvent $K = 5$ ou $K = 10$.

- **Leave-one out (LOOCV)** : cas particulier du K -fold CV avec $K = n$.

Remarque 5.23

Les méthodes ci-dessus sont présentées par ordre d'intensité de calculs.

- La Hold-out CV est typiquement utilisée quand on a beaucoup de données et que le modèle est coûteux à entraîner.
- La K-fold CV essaie de palier deux défauts de la Hold-out CV : le fait de ne pas utiliser toutes les données pour la construction de la régression et le choix arbitraire et non symétrique des ensembles d'entraînement et de validation. On s'attend en effet à une

effet stabilisateur (meilleure variance) en moyennant (même si les erreurs 5.5 utilisées pour la moyenne 5.6 sont évidemment corrélées!).

- Le leave-one out (LOOCV) peut être très couteux en temps de calcul. Cependant, dans certains cas ce coût est minime (cf. proposition 5.27).

Dans tous les cas on choisit

$$\hat{h} \in \arg \min_{h \in H} \hat{R}(h)$$

Et l'estimateur final est

$$\hat{r} = \hat{r}_{n, \hat{h}}.$$

où $\hat{r}_{n, \hat{h}}$ est l'estimateur par polynômes locaux calculé avec la fenêtre $\hat{h}$ et en utilisant tout l'échantillon.

5.6.3 Compléments sur la validation croisée

On note $X_1^n = (X_1, \dots, X_n)$ et $Y_1^n = (Y_1, \dots, Y_n)$. On cherche h tel que l'erreur test $\mathbb{E}[(Y - \hat{r}_{n, h}(X))^2]$ soit minimale.

Pour simplifier, on fait disparaître la dépendance à h dans la notation et on fait apparaître la taille de l'échantillon utilisée pour le fabriquer. On note donc $\hat{r}_n$ notre estimateur calculé sur toutes les données d'entraînement (X_1^n, Y_1^n) .

1. Risque empirique : Contrairement au cas de la remarque 5.21, $\hat{r}_n$ n'est pas déterministe, mais dépend des données (X_1^n, Y_1^n) et on a

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{r}_n(X_i))^2\right] \neq \mathbb{E}[(Y - \hat{r}_n(X))^2]$$

En effet on a, si l'estimateur est symétrique en ses variables (ce qui est le cas des estimateurs par polynômes locaux, cf. aussi corrigé de l'exercice 3 du TD4)

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{r}_n(X_i))^2\right] = \mathbb{E}[(Y_1 - \hat{r}_n(X_1))^2]$$

On indique la dépendance de $\hat{r}_n$ à (X_1^n, Y_1^n) en écrivant $\hat{r}_n(x) = g_n(X_1, \dots, X_n, Y_1, \dots, Y_n, x)$ pour une fonction g_n . On rappelle qu'on a noté f la densité du couple (X, Y) . On a alors

$$\begin{aligned} \mathbb{E}[(Y_1 - \hat{r}_n(X_1))^2] &= \mathbb{E}[(Y_1 - g(X_1, \dots, X_n, Y_1, \dots, Y_n, X_1))^2] \\ &= \int (y_1 - g(x_1, \dots, x_n, y_1, \dots, y_n, x_1))^2 f(x_1, y_1) \dots f(x_n, y_n) dx_1 dy_1 \dots dx_n dy_n \end{aligned}$$

Tandis que

$$\begin{aligned} \mathbb{E}[(Y - \hat{r}_n(X))^2] &= \mathbb{E}[(Y - g(X_1, \dots, X_n, Y_1, \dots, Y_n, X))^2] \\ &= \int (y - g(x_1, \dots, x_n, y_1, \dots, y_n, x))^2 f(x_1, y_1) \dots f(x_n, y_n) f(x, y) dx_1 dy_1 \dots dx_n dy_n dx dy \end{aligned}$$

2. Hold out CV : En revanche, si (X_{n+1}, Y_{n+1}) est une nouvelle donnée indépendante de (X_1^n, Y_1^n) et de même loi que (X, Y) , on a

$$\begin{aligned} \mathbb{E}[(Y_{n+1} - \hat{r}(X_{n+1}))^2] &= \mathbb{E}[(Y_{n+1} - g_n(X_1, \dots, X_n, Y_1, \dots, Y_n, X_{n+1}))^2] = \\ &= \int (y_{n+1} - g_n(x_1, \dots, x_n, y_1, \dots, y_n, x_{n+1}))^2 f(x_1, y_1) \dots f(x_n, y_n) f(x_{n+1}, y_{n+1}) dx_1 dy_1 \dots dx_n dy_n dx_{n+1} dy_{n+1} \\ &= \int (y - g_n(x_1, \dots, x_n, y_1, \dots, y_n, x))^2 f(x_1, y_1) \dots f(x_n, y_n) f(x, y) dx_1 dy_1 \dots dx_n dy_n dx dy \\ &= \mathbb{E}[(Y - \hat{r}_n(X))^2] \end{aligned}$$

On a finalement juste utilisé le fait que

$$Y_{n+1} - \hat{r}_n(X_{n+1}) = Y_{n+1} - g_n(X_1, \dots, X_n, Y_1, \dots, Y_n, X_{n+1}) \sim Y - g_n(X_1, \dots, X_n, Y_1, \dots, Y_n, X) = Y - \hat{r}_n(X)$$

car

$$(X_1, Y_1, \dots, X_n, Y_n, X, Y) \sim (X_1, Y_1, \dots, X_n, Y_n, X_{n+1}, Y_{n+1})$$

D'où l'idée du hold-out : si on a n données dans l'échantillon d'entraînement, on sépare cet échantillon en prenant $(X_1, Y_1), \dots, (X_{n_1}, Y_{n_1})$ pour fabriquer un estimateur, que l'on va noter $\hat{r}_{n_1}$, puis on utilise $(X_{n_1+1}, Y_{n_1+1}), \dots, (X_n, Y_n)$ pour estimer le risque test de l'estimateur (en réalité le choix des indices doit être fait aléatoirement mais on ignore ici ce fait pour simplifier). Pour simplifier l'exposé, on notera $(X_1^{n_1}, Y_1^{n_1})$ le "nouvel" échantillon d'entraînement et $(\tilde{X}_1^{n_2}, \tilde{Y}_1^{n_2})$ l'échantillon de validation. On a donc $(\tilde{X}_1^{n_2}, \tilde{Y}_1^{n_2}) = (X_{n_1+1}, Y_{n_1+1}), \dots, (X_n, Y_n)$.

Nos notations signifient que l'on a n_1 données dans le nouvel échantillon d'entraînement et $n_2 = n - n_1$ données dans l'échantillon de validation.

On a alors un bien meilleur estimateur du risque $\mathbb{E}[(Y - \hat{r}_n(X))^2]$ en prenant

$$\hat{R} = \frac{1}{n_2} \sum_{i=1}^{n_2} (\tilde{Y}_i - \hat{r}_{n_1}(\tilde{X}_i))^2$$

En effet, on a :

$$\tilde{Y}_1 - \hat{r}_{n_1}(\tilde{X}_1) \sim \tilde{Y}_2 - \hat{r}_{n_1}(\tilde{X}_2) \sim \dots \sim \tilde{Y}_{n_2} - \hat{r}_{n_1}(\tilde{X}_{n_2}) \sim Y - \hat{r}_{n_1}(X),$$

car, pour tout $i = 1, \dots, n_2$,

$$(X_1, Y_1, \dots, X_{n_1}, Y_{n_1}, \tilde{X}_i, \tilde{Y}_i) \sim (X_1, Y_1, \dots, X_{n_1}, Y_{n_1}, X, Y).$$

D'où

$$\mathbb{E} \left(\frac{1}{n_2} \sum_{i=1}^{n_2} (\tilde{Y}_i - \hat{r}_{n_1}(\tilde{X}_i))^2 \right) = \mathbb{E} [(Y - \hat{r}_{n_1}(X))^2].$$

On obtient en particulier un estimateur sans biais du risque test associé à un estimateur calculé sur n_1 données (au lieu de n données) : il y a donc un petit biais puisqu'on veut estimer le risque test associé à un estimateur calculé sur n données.

Pour la variance c'est plus compliqué.

Pour simplifier, on peut se contenter de regarder ici une variance conditionnelle : sachant $(X_1^{n_1}, Y_1^{n_1}) = (x_1^{n_1}, y_1^{n_1})$, on a

$$\tilde{Y}_1 - \hat{r}_{n_1}(\tilde{X}_1), \dots, \tilde{Y}_{n_2} - \hat{r}_{n_1}(\tilde{X}_{n_2}) \stackrel{\text{i.i.d.}}{\sim} Y - \hat{r}_{n_1}(X).$$

En effet,

$$\mathbb{P}_{(X_1^{n_1}, Y_1^{n_1}) = (x_1^{n_1}, y_1^{n_1})} (\tilde{X}_1^{n_2}, \tilde{Y}_1^{n_2}) = \mathbb{P}_{(x_1^{n_1}, y_1^{n_1}, \tilde{X}_1^{n_2}, \tilde{Y}_1^{n_2})}$$

par l'indépendance de $(X_1^{n_1}, Y_1^{n_1})$ et $(\tilde{X}_1^{n_2}, \tilde{Y}_1^{n_2})$.

On a donc aussi

$$\text{Var} \left(\frac{1}{n_2} \sum_{i=1}^{n_2} (\tilde{Y}_i - \hat{r}_{n_1}(\tilde{X}_i))^2 \middle| (X_1^{n_1}, Y_1^{n_1}) = (x_1^{n_1}, y_1^{n_1}) \right) = \frac{\text{Var}((Y - \hat{r}_{n_1}(X))^2 \mid (X_1^{n_1}, Y_1^{n_1}) = (x_1^{n_1}, y_1^{n_1}))}{n_2}$$

i.e.

$$\text{Var} \left(\frac{1}{n_2} \sum_{i=1}^{n_2} (\tilde{Y}_i - \hat{r}_{n_1}(\tilde{X}_i))^2 \middle| X_1^{n_1}, Y_1^{n_1} \right) = \frac{\text{Var}((Y - \hat{r}_{n_1}(X))^2 \mid X_1^{n_1}, Y_1^{n_1})}{n_2}$$

Mais dans le calcul de la variance, il y a encore un autre terme... Rappelons en effet la formule vu dans le TD1, exercice 2 :

$$\mathbf{Var}(V) = \mathbb{E}[\mathbf{Var}(V|W)] + \mathbf{Var}(\mathbb{E}[V|W]).$$

3. K-fold CV : On peut faire K partitions aléatoires sur l'ensemble d'entraînement initial (ce qui donne des blocs de taille environ égale à n/K) et effectuer cette estimation pour chaque partition, puis prendre la moyenne de ces estimations. L'estimateur du risque obtenu a le même biais que l'estimateur du risque associé au hold-out avec $n_2 \approx n/K$. On aura tendance à améliorer un peu la variance par rapport au hold-out. Attention cependant, les erreurs $\hat{R}_j$ calculées pour chaque fold sont corrélées.

Remarque 5.24: Biais/Variance

La validation croisée permet d'obtenir un estimateur du risque test associé à un estimateur fabriqué avec n données (et à un certain choix de paramètre). Cet estimateur du risque possède donc lui-même un biais et une variance :

- Lorsque K augmente, les $n_j \approx n/K$ diminuent donc les $n - n_j$ augmentent : les ensembles d'entraînement deviennent donc plus grands, ce qui diminue le biais. Le cas extrême est celui du *leave-one-out* : le biais est alors souvent très faible, puisque chaque estimateur est appris sur $n - 1$ observations (au lieu de n).
- Pour la variance, c'est beaucoup plus compliqué : la variance de l'estimateur final dépend bien sûr des variances individuelles des $\hat{R}_j$ mais aussi des corrélations entre les $\hat{R}_j$.
- Ainsi même si le biais diminue quand K augmente, la variance, elle, peut éventuellement diminuer (pas de règle absolue).

5.6.4 Calcul du LOOCV pour l'estimateur par polynômes locaux

La proposition suivante relie les poids associés à l'estimateur $\hat{r}_h^{(-i)}$ à ceux associés à l'estimateur $\hat{r}_h$.

Proposition 5.25

Soit $i \in \{1, \dots, n\}$. Si $\hat{r}_h(x) = \sum_{j=1}^n \omega_{j,h}(x) Y_j$ et si on note $\tilde{\omega}_{j,h}(x)$ les coefficients associés à l'estimateur $\hat{r}_h^{(-i)}(x)$, i.e. si $\hat{r}_h^{(-i)}(x) = \sum_{j \neq i} \tilde{\omega}_{j,h}(x) Y_j$, alors, pour tout $j \neq i$

$$\tilde{\omega}_{j,h}(X_i) = \frac{\omega_{j,h}(X_i)}{1 - \omega_{i,h}(X_i)}$$

Le même résultat existe pour l'estimateur Ridge (et donc aussi pour l'OLS) ainsi que pour l'estimateur par splines de lissage. On fournit dans la suite la preuve (non exigée) de ce résultat pour l'estimateur ridge.

Considérons ainsi le calcul du LOOCV pour l'estimateur ridge. On dispose de n données (X_i, Y_i) , avec X_i de dimension d et on considère le problème de régression linéaire avec pénalisation ridge :

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^d} \|Y - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \quad (5.7)$$

L'estimateur de la fonction de régression correspondant est donné par

$$\hat{r}(x) = x^T \hat{\beta} = x^T (\mathbf{X}^T \mathbf{X} + \lambda I_d)^{-1} \mathbf{X}^T Y$$

C'est donc un estimateur linéaire :

$$\hat{r}(x) = \sum_{j=1}^n \omega_j(x) Y_j.$$

avec $\omega(x) = (\omega_i(x))_{1 \leq i \leq n} = \left[x^T (\mathbf{X}^T \mathbf{X} + \lambda I_d)^{-1} \mathbf{X}^T \right]^T \in \mathbb{R}^n$ dépendant de X_1^n seulement (et pas de Y_1^n).

En particulier on a, pour tout $k = 1, \dots, n$:

$$\hat{r}(X_k) = \sum_{j=1}^n \omega_j(X_k) Y_j \quad (5.8)$$

Notons $\hat{\beta}^{(-i)}$ la solution du problème d'optimisation ($n - 1$ données) associé au calcul du LOOCV, i.e. le problème où on enlève la i ème donnée :

$$\hat{\beta}^{(-i)} = \arg \min_{\beta \in \mathbb{R}^d} \sum_{k \neq i} (Y_k - X_k^T \beta)^2 + \lambda \|\beta\|_2^2 \quad (5.9)$$

où X_k^T est la k ème ligne de la matrice de design $\mathbf{X}$.

L'estimateur correspondant est noté, comme précédemment, $\hat{r}^{(-i)}$. Cet estimateur est évidemment aussi linéaire. Ainsi il existe, pour tout $k \in \{1, \dots, n\}$, des coefficients, que l'on va noter $(\tilde{\omega}_j(X_i))_{\substack{1 \leq j \leq n, \\ j \neq i}}$, tels que

$$\hat{r}^{(-i)}(X_i) = \sum_{\substack{j \in \{1, \dots, n\} \\ j \neq i}} \tilde{\omega}_j(X_i) Y_j$$

La proposition suivante, qui est l'équivalent de la proposition précédente pour Ridge, dit que la même formule de calcul du LOOCV existe pour l'estimateur Ridge.

Proposition 5.26

Pour l'estimateur Ridge, on a, pour tout $j \in \{1, \dots, n\} \setminus \{i\}$,

$$\tilde{\omega}_j(X_i) = \frac{\omega_j(X_i)}{1 - \omega_i(X_i)}$$

Démonstration. Considérons le même problème d'optimisation que 5.7, mais au lieu d'utiliser les n données $((X_j, Y_j))_{1 \leq j \leq n}$, on utilise les n données $((X_j, \tilde{Y}_j))_{1 \leq j \leq n}$, où, pour $j \neq i$, $\tilde{Y}_j = Y_j$ et pour $j = i$, $\tilde{Y}_i = \hat{r}^{(-i)}(X_i) = X_i^T \hat{\beta}^{(-i)}$:

$$\begin{aligned} \tilde{\beta} &= \arg \min_{\beta \in \mathbb{R}^d} \sum_{j=1}^n (\tilde{Y}_j - X_j^T \beta)^2 + \lambda \|\beta\|_2^2 \\ &= \arg \min_{\beta \in \mathbb{R}^d} \sum_{j \neq i} (Y_j - X_j^T \beta)^2 + (\hat{r}^{(-i)}(X_i) - X_i^T \beta)^2 + \lambda \|\beta\|_2^2 \end{aligned}$$

Appelons $\tilde{r}$ l'estimateur de la fonction de régression associé à ce problème : $\tilde{r}(x) = x^T \tilde{\beta}$. Nous avons d'après 5.8,

$$\tilde{r}(X_i) = \sum_{j=1}^n \omega_j(X_i) \tilde{Y}_j = \sum_{j \neq i} \omega_j(X_i) Y_j + \omega_i(X_i) \hat{r}^{(-i)}(X_i)$$

De plus, il est immédiat que

$$\hat{\beta}^{(-i)} = \tilde{\beta}$$

En effet posons

$$\begin{aligned} f(\beta) &= \sum_{j \neq i} (Y_j - X_j^T \beta)^2 + (\hat{r}^{(-i)}(X_i) - X_i^T \beta)^2 + \lambda \|\beta\|_2^2 \\ g(\beta) &= \sum_{j \neq i} (Y_j - X_j^T \beta)^2 + \lambda \|\beta\|_2^2 \end{aligned}$$

Alors, pour tout $\beta \in \mathbb{R}^d$,

$$f(\beta) \geq g(\beta) \geq g(\hat{\beta}^{(-i)}) = f(\hat{\beta}^{(-i)})$$

Ainsi

$$\hat{r}^{(-i)}(X_i) = X_i^T \hat{\beta}^{(-i)} = X_i^T \tilde{\beta} = \tilde{r}(X_i) = \sum_{j \neq i} \omega_j(X_i) Y_j + \omega_i(X_i) \hat{r}^{(-i)}(X_i)$$

i.e.

$$\hat{r}^{(-i)}(X_i) = \frac{\sum_{j \neq i} \omega_j(X_i) Y_j}{1 - \omega_i(X_i)}$$

□

Pour calculer $(\hat{r}_h^{(-i)})_{1 \leq i \leq n}$ dans le cas des polynômes locaux (et pour bien d'autres estimateurs linéaires), on n'a donc pas besoin de faire de gros calculs supplémentaires. Grâce à la proposition précédente on a facilement le résultat suivant.

Proposition 5.27: Cacul rapide du LOOCV pour les polynômes locaux

Si $\hat{r}_h(x) = \sum_{i=1}^n \omega_{i,h}(x) Y_i$ alors

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{r}_h(X_i)}{1 - \omega_{i,h}(X_i)} \right)^2$$

Démonstration. On a

$$CV(h) = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{r}_h^{(-i)}(X_i))^2$$

avec

$$\begin{aligned} Y_i - \hat{r}_h^{(-i)}(X_i) &= Y_i - \sum_{j \neq i} \tilde{\omega}_{j,h}(X_i) Y_j \\ &= Y_i - \sum_{j \neq i} \frac{\omega_{j,h}(X_i)}{1 - \omega_{i,h}(X_i)} Y_j \\ &= \frac{(1 - \omega_{i,h}(X_i))Y_i - \sum_{j \neq i} \omega_{j,h}(X_i) Y_j}{1 - \omega_{i,h}(X_i)} \\ &= \frac{Y_i - \sum_{j=1}^n \omega_{j,h}(X_i) Y_j}{1 - \omega_{i,h}(X_i)} \\ &= \frac{Y_i - \hat{r}_h(X_i)}{1 - \omega_{i,h}(X_i)} \end{aligned}$$

□

Remarque 5.28: (non exigée)

Il existe une alternative qui consiste à remplacer les $\omega_{i,h}(X_i)$ par leur moyenne. Cette alternative s'appelle la validation croisée généralisée : on pose $\Omega = \sum_{i=1}^n \omega_{i,h}(x_i)$ puis

$$GCV(h) = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{r}_h(x_i)}{1 - \Omega/n} \right)^2 = \frac{1}{(1 - \frac{\Omega}{n})^2} \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{r}_h(x_i))^2$$

On minimise ensuite GCV par rapport à h .

Cette technique a été introduite dans le cas de l'estimateur Ridge pour palier un problème de manque d'invariance.

Implémentation 5.29: polynômes locaux dans R

Cf. teams.