

Introduction à la statistique non-paramétrique

TD1 : Rappels

Exercice 1 : Soit X une variable aléatoire réelle, absolument continue de densité continue f , de fonction de répartition F . On observe un n -échantillon iid $(X_1, \dots, X_n)$ de même loi que X . On considère la statistique T qui ordonne l'échantillon dans le sens croissant :

$$T(X_1, \dots, X_n) = (X_{(1)}, \dots, X_{(n)}),$$

avec $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$. $(X_{(1)}, \dots, X_{(n)})$ s'appelle la statistique d'ordre.

1. On suppose pour cette question uniquement que les X_i sont seulement indépendants et de lois continues (c'est-à-dire que les X_i sont indépendants et ont tous une fonction de répartition F_i continue, mais pas forcément absolument continue) . Montrer que

$$\mathbb{P}(\exists i \neq j : X_i = X_j) = 0,$$

et que dans la définition de la statistique d'ordre, on peut donc se limiter à des inégalités strictes : $X_{(1)} < X_{(2)} < \dots < X_{(n)}$.

2. Déterminer la densité de la loi du n -uplet $(X_{(1)}, \dots, X_{(n)})$.
3. Déterminer la fonction de répartition F_k et la densité f_k de $X_{(k)}$.
4. Montrer que si $\mathbb{E}[|X|]$ est finie, alors il en est de même de $\mathbb{E}[|X_{(k)}|]$.
5. Rappeler les densités des lois de $X_{(1)}$ et $X_{(n)}$ et déterminer la densité du couple $(X_{(1)}, X_{(n)})$. Quelle est la loi de $W_n = X_{(n)} - X_{(1)}$?
6. On considère une suite $(U_i)_{i \in \mathbb{N}}$ de variables i.i.d. selon la loi uniforme sur $[0, 1]$, et on pose

$$Y_n = \min_{1 \leq i \leq n} U_i \quad Z_n = \max_{1 \leq i \leq n} U_i - \min_{1 \leq i \leq n} U_i$$

- (a) Montrer que nY_n converge en loi vers une loi exponentielle.
- (b) Étudier la convergence en loi de Z_n , puis sa convergence en probabilité et $\mathbb{L}^1$.
- (c) Soit $\epsilon > 0$. Calculer $\mathbb{P}[|Z_n - 1| > \epsilon]$. En déduire que Z_n converge presque sûrement.
- (d) Rappeler les implications logiques entre les modes de convergence étudiés : en loi, en probabilité, en norme $\mathbb{L}^1$, en norme $\mathbb{L}^2$, presque sûre.

Exercice 2 (lois conditionnelles) :

(Début de l'exercice 1 de l'examen 2018, simplifié).

Soient $N, T_1, \dots, T_N$ des v.a. réelles. Soit f une fonction positive intégrable de support $[0, D]$.

On suppose que :

Propriété 1 : N est une variable aléatoire de loi de Poisson de paramètre $m = \int_0^D f(x)dx$:

$$\mathbb{P}(N = n) = \exp(-m) \frac{m^n}{n!}, \quad \forall n \in \mathbb{N}.$$

Propriété 2 : Pour $n \in \mathbb{N}^*$, conditionnellement à l'événement $N = n$, $T_1, \dots, T_N$ a même loi que la statistique d'ordre $X^* = (X_{(1)}, \dots, X_{(n)})$ associée à un n -échantillon $X_1, \dots, X_n$ de densité $m^{-1} \times f$.

Soit K une fonction réelle intégrable. On définit la v.a. réelle Y par, lorsque N est non nul,

$$Y = \sum_{i=1}^N K(T_i).$$

On pose $Y = 0$ lorsque $N = 0$. On suppose que $\int f(x)K^2(x)dx < \infty$.

1. En utilisant la Propriété 2, montrer que

$$\mathbb{E}[Y|N = n] = \frac{n}{m} \times \int_0^D K(x)f(x)dx$$

2. En utilisant la Propriété 1, en déduire que

$$\mathbb{E}[Y] = \int_0^D K(x)f(x)dx$$

3. Soit V et W deux variables aléatoires quelconques. Redémontrer la formule classique :

$$\text{var}(V) = \mathbb{E}[\text{var}(V|W)] + \text{var}(\mathbb{E}[V|W]).$$

4. En appliquant cette formule avec $V = Y$ et $W = N$, montrer alors que

$$\text{var}(Y) = \int_0^D K^2(x)f(x)dx$$

Exercice 3 : On reprend un exemple du cours. La limite légale d'un polluant contenu dans les déchets d'une usine est de 6mg/kg. On effectue un dosage sur 20 prélèvements sur lesquels on observe une moyenne empirique de 7mg/kg avec un écart-type empirique de 2.4mg/kg. On admet que la loi de dosage est gaussienne.

On observe donc $X_1, \dots, X_{20} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ avec μ et σ^2 inconnus.

1. Faire un test de niveau α pour le problème de test suivant :

$$H_0 : \mu \leq 6 \quad \text{contre} \quad H_1 : \mu > 6.$$

2. Montrer que la fonction puissance tend vers 1 quand n tend vers l'infini.

On admettra que $q_{1-\alpha}^{T(n-1)}$, le quantile d'ordre $1 - \alpha$ de la loi de Student à $n - 1$ degrés de liberté, tend vers le quantile de même ordre de la loi normale standard (cf. chap 2).

3. On calcule à partir de ces données $\bar{x} = 7$ et $\hat{\sigma}^2 = \frac{1}{19} \sum_{i=1}^{20} (x_i - \bar{x})^2 = 2.4^2$. Calculer la p -valeur observée et donner le résultat du test si on choisit le niveau $\alpha = 5\%$.

Exercice 4 : On dispose d'un échantillon de loi Bernoulli de paramètre $p : X_1, \dots, X_n \stackrel{iid}{\sim} Be(p)$.

1. Proposer une procédure de test non asymptotique pour le problème suivant

$$H_0 : p = 1/2 \quad \text{contre} \quad H_1 : p > 1/2.$$

2. Proposer une procédure de test non asymptotique pour le problème suivant

$$H_0 : p = 1/2 \quad \text{contre} \quad H_1 : p \neq 1/2$$

3. Proposer un test asymptotique pour le problème de la question précédente.

4. La puissance du test de la question 3 tend-elle simplement vers 1 quand n tend vers l'infini ?
5. Application numérique. On calcule à l'aide des données, $n = 100$, $\bar{x} = 0.59$, $q_{0.95} = 58$, $q_{0.975} = 60$ où on note q_α le quantile d'ordre α de la loi binomiale $B(100, 1/2)$. Quelle est la conclusion des deux premiers tests ci-dessus, au niveau $\alpha = 0.05$, pour ces données ?

Exercice 5 : L'objectif de cet exercice est d'étudier la performance du test de Student à un seul échantillon quand il est effectué sur un échantillon **non gaussien**.

On suppose que l'on dispose d'un échantillon iid $(X_1, \dots, X_n)$ tel que $\mathbb{E}X_1^2 < \infty$. On note σ^2 la variance de X_1 et $\mu = \mathbb{E}X_1$. On veut tester $H_0 : \mu = 0$ contre $H_1 : \mu > 0$ au niveau α pour $\alpha \in (0, 1)$.

On appelle Φ le test de Student. On a donc $\Phi = \mathbf{1}_{T_n > q_{1-\alpha}^{T(n-1)}}$ où $q_{1-\alpha}^{T(n-1)}$ est le quantile d'ordre $1-\alpha$ de la loi de Student à $n-1$ degrés de liberté et $T_n = \frac{\sqrt{n}\bar{X}}{\hat{\sigma}}$ avec $\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$.

1. Montrer que, sous H_0 , T_n tend en loi vers la loi normale standard quand n tend vers l'infini.
2. Montrer que l'erreur de première espèce du test de Student appliqué à l'échantillon $(X_1, \dots, X_n)$ tend vers α quand n tend vers l'infini.
3. Montrer que la puissance du test tend simplement vers 1 quand n tend vers l'infini.