

Remarques optimisation + détails sur la question 1 Ex. 4 TD2

Ce fichier a été écrit par Gabriel Turinici.

— Remarques générales sur l'optimisation :

1. Soit I un intervalle ouvert de $\mathbb{R}$ et ϕ une fonction réelle dérivable sur I . Supposons que ϕ a un unique point critique h_* sur I et que de plus h_* est un minimum (resp. maximum) local de ϕ sur I . Alors h_* est l'unique minimum (resp. maximum) global de ϕ sur I .

En effet, dans le cas d'un minimum, comme h_* est un minimum local de ϕ sur I et I ouvert, il existe $\epsilon > 0$ tel que $]h_* - \epsilon, h_* + \epsilon[\subset I$ et pour tout $x \in]h_* - \epsilon, h_* + \epsilon[$, $\phi(x) \geq \phi(h_*)$. Si il existe $x \in]h_* - \epsilon, h_* + \epsilon[$ tel que $\phi(x) = \phi(h_*)$ alors d'après le théorème de Rolle, il existe $y \in]x, h_*[$ tel que $\phi'(y) = 0$ ce qui est absurde car h_* est l'unique point critique de ϕ sur I , donc pour tout $x \in]h_* - \epsilon, h_* + \epsilon[$, on a $\phi(x) > \phi(h_*)$. De même, pour tout $x \in]h_*, h_* + \epsilon[$, on a $\phi(x) > \phi(h_*)$.

Soit $x \in I$ tel que $x \leq h_* - \epsilon$. Si $\phi(x) < \phi(h_*)$ alors comme $\phi(h_* - \frac{\epsilon}{2}) > \phi(h_*)$, par le théorème des valeurs intermédiaires, il existe $y \in]x, h_* - \frac{\epsilon}{2}[$ tel que $\phi(y) = \phi(h_*)$ et donc par le théorème de Rolle, il existe $z \in]y, h_*[$ tel que $\phi'(z) = 0$ ce qui est absurde donc $\phi(x) \geq \phi(h_*)$.

On montre de même que si $x \in I$ tel que $x \geq h_* + \epsilon$, alors $\phi(x) \geq \phi(h_*)$.

En conclusion, on a donc bien pour tout $x \in I$, $\phi(x) \geq \phi(h_*)$ ie h_* est un minimum global de ϕ .

Montrons que c'est l'unique minimum global. Supposons par l'absurde qu'il existe $\tilde{h} \in I \setminus \{h_*\}$ minimum global de ϕ sur I . Alors, nous avons $\phi(h_*) = \phi(\tilde{h})$. Si $\tilde{h} < h_*$, d'après le théorème de Rolle il existe $y \in]\tilde{h}, h_*[$ tel que $\phi'(y) = 0$ ce qui est absurde; de même si $\tilde{h} > h_*$, il existe $y \in]h_*, \tilde{h}[$ tel que $\phi'(y) = 0$ ce qui est absurde. Donc h_* est l'unique minimum global de ϕ sur I .

2. Soit ϕ une fonction réelle strictement convexe (resp. strictement concave) sur C sous-ensemble convexe de $\mathbb{R}^n$. Alors ϕ a au plus un minimum (resp. maximum) global sur C . (Attention, cette propriété est fausse si l'on enlève le mot "strictement" : penser à une fonction constante !)

Dans le cas ϕ strictement convexe, supposons qu'il existe deux minima globaux h_* et $\tilde{h}$ de ϕ sur C , on a donc $\phi(h_*) = \phi(\tilde{h})$. De plus pour tout $\lambda \in]0, 1[$,

$$\phi(\lambda h_* + (1 - \lambda)\tilde{h}) < \lambda\phi(h_*) + (1 - \lambda)\phi(\tilde{h}) = \phi(h_*)$$

ce qui contredit le fait que h_* est un minimum global de ϕ sur C .

3. Soit ϕ une fonction réelle différentiable et convexe (resp. concave) sur C sous-ensemble ouvert convexe de $\mathbb{R}^n$. Si ϕ a un point critique $x_0 \in C$, alors x_0 est un minimum global de ϕ sur C . Si ϕ a un unique point critique $x_0 \in C$, alors x_0 est l'unique minimum global de ϕ sur C .

Comme ϕ est différentiable et convexe sur C , nous savons que pour tous $x, y \in C$,

$$\phi(y) \geq \phi(x) + \nabla\phi(x).(y - x)$$

donc en prenant $x = x_0$, nous avons (puisque $\nabla\phi(x_0) = 0$ car x_0 point critique de ϕ), pour tout $y \in C$, $\phi(y) \geq \phi(x_0)$, ie x_0 minimum global de ϕ sur C .

Enfin, si x_0 est l'unique point critique de ϕ sur C , supposons que $\tilde{x}_0 \in C \setminus \{x_0\}$ soit un autre minimum global de ϕ sur C . Alors $\tilde{x}_0$ est un point critique de ϕ , ce qui amène à une absurdité. Donc x_0 est l'unique minimum global de ϕ sur C .

Remarques supplémentaires (L.C.) :

- a) **contre exemple à l'item 1 si on est en dimension > 1** : soit f la fonction définie sur $\mathbb{R}^2$ par $f(x, y) = x^2 + y^2(1 - x^3)$. Son unique point critique est $(0, 0)$. On peut vérifier que sa hessienne en ce point est définie positive. Donc $(0, 0)$ est un minimum local. Mais ça n'est pas un minimum global car $f(0, 0) = 0$ et $f(2, 3) = -5$. Ainsi l'item 1 n'est valable qu'en dimension 1.

1. Remarquez que $\lim_{x \rightarrow +\infty} f(x, 1) = -\infty$

- b) Concernant l'item 1 en dimension quelconque : si f est définie et différentiable sur $\mathbb{R}^n$ avec $n \geq 2$ quelconque, si f a un unique point critique et si on a par ailleurs montré que f admet un minimum global sur $\mathbb{R}^n$, alors ce point critique est forcément un minimum global. En effet, un minimum global sur un ouvert est forcément point critique.
- c) Ainsi, **si on rajoute l'hypothèse que f est coercive**, l'item 1 devient vrai pour une fonction définie sur $\mathbb{R}^n$ (mais alors on n'a même pas besoin de vérifier que le point critique est un min local strict). En effet, une fonction continue et coercive sur $\mathbb{R}^n$ admet un minimum global sur $\mathbb{R}^n$.
- d) Bien sûr on peut remplacer $\mathbb{R}^n$ par un ouvert quelconque dans l'item b).

— Détails concernant la question 1 Ex.4 TD2 :

Rappelons l'énoncé de cette question : nous considérons un n -échantillon i.i.d $X_1^n = (X_1, \dots, X_n)$ de variables aléatoires de loi normale $\mathcal{N}(\mu, \sigma^2)$ et l'on nous demande de déterminer l'estimateur du maximum de vraisemblance $(\hat{\mu}, \hat{\sigma}^2)$ de (μ, σ^2) .

Notons $\ell_n(x_1^n; \mu, \sigma^2)$ la log-vraisemblance ie

$$\begin{aligned}\ell_n(x_1^n; \mu, \sigma^2) &= \log\left(\prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}\right)\right) \\ &= -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\end{aligned}$$

Nous ferons toujours l'hypothèse qu'il existe $1 \leq i \neq j \leq n$ tels que $x_i \neq x_j$.

Nous cherchons donc à maximiser la fonction $(\mu, \sigma^2) \mapsto \ell_n(x_1^n; \mu, \sigma^2)$ sur $\mathbb{R} \times \mathbb{R}_+^*$.

Or

$$\sup_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*} \ell_n(x_1^n; \mu, \sigma^2) = \sup_{\sigma^2 \in \mathbb{R}_+^*} (\sup_{\mu \in \mathbb{R}} \ell_n(x_1^n; \mu, \sigma^2)) \quad (1)$$

En effet, de manière générale, si l'on a une fonction à valeurs réelles ϕ définie sur $A \times B$, avec A, B deux ensembles quelconques,

$$\begin{aligned}\sup_{(a,b) \in A \times B} \phi(a,b) &= \sup_{b \in B} (\sup_{a \in A} \phi(a,b)) \\ \inf_{(a,b) \in A \times B} \phi(a,b) &= \inf_{b \in B} (\inf_{a \in A} \phi(a,b))\end{aligned}$$

car (pour sup) :

- pour tout $(a', b') \in A \times B$, $\phi(a', b') \leq \sup_{a \in A} \phi(a, b') \leq \sup_{b \in B} (\sup_{a \in A} \phi(a, b))$ donc

$$\sup_{(a', b') \in A \times B} \phi(a', b') \leq \sup_{(a', b') \in A \times B} \sup_{b \in B} (\sup_{a \in A} \phi(a, b)) = \sup_{b \in B} (\sup_{a \in A} \phi(a, b))$$

- pour tout $(a', b') \in A \times B$, $\phi(a', b') \leq \sup_{(a,b) \in A \times B} \phi(a, b)$ donc

$$\sup_{a' \in A} \phi(a', b') \leq \sup_{a' \in A} \sup_{(a,b) \in A \times B} \phi(a, b) = \sup_{(a,b) \in A \times B} \phi(a, b)$$

et

$$\sup_{b' \in B} (\sup_{a' \in A} \phi(a', b')) \leq \sup_{b' \in B} \sup_{(a,b) \in A \times B} \phi(a, b) = \sup_{(a,b) \in A \times B} \phi(a, b)$$

Commençons donc, pour $\sigma^2 > 0$ fixé, par déterminer $\sup_{\mu \in \mathbb{R}} \ell_n(x_1^n; \mu, \sigma^2)$: notons $\phi_{\sigma^2} : \mu \in \mathbb{R} \mapsto \ell_n(x_1^n; \mu, \sigma^2)$. Cette fonction est de classe $\mathcal{C}^2$ sur $\mathbb{R}$, et pour tout $\mu \in \mathbb{R}$,

$$\phi'_{\sigma^2}(\mu) = \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma^2}$$

$$\phi''_{\sigma^2}(\mu) = -\frac{n}{\sigma^2}$$

Déterminons les points critiques de ϕ_{σ^2} :

$$\phi'_{\sigma^2}(\mu) = 0 \iff \sum_{i=1}^n \frac{x_i}{\sigma^2} - \mu \frac{n}{\sigma^2} = 0 \iff \mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Donc la fonction ϕ_{σ^2} a un unique point critique $\hat{\mu} := \frac{1}{n} \sum_{i=1}^n x_i$.

On peut ensuite raisonner de plusieurs manières pour en conclure que $\hat{\mu}$ est l'unique maximum global de ϕ_{σ^2} sur $\mathbb{R}$:

- utiliser le fait que ϕ_{σ^2} est une fonction polynôme du second degré en μ ;
- dresser le tableau de variations ;
- dire que $\phi''_{\sigma^2}(\hat{\mu}) = -\frac{n}{\sigma^2} < 0$, d'où $\hat{\mu}$ est un maximum local de ϕ_{σ^2} , et donc $\hat{\mu}$ est l'unique maximum global de ϕ_{σ^2} d'après la remarque ci-dessus (car à la fois maximum local et unique point critique sur un intervalle ouvert) ;
- dire que, comme pour tout $\mu \in \mathbb{R}$, $\phi''_{\sigma^2}(\mu) = -\frac{n}{\sigma^2} < 0$ la fonction ϕ_{σ^2} est concave, et donc $\hat{\mu}$ est un maximum global de ϕ_{σ^2} sur $\mathbb{R}$, et ϕ_{σ^2} est même strictement concave, donc $\hat{\mu}$ est l'unique maximum global de ϕ_{σ^2} sur $\mathbb{R}$.

Nous avons donc $\sup_{\mu \in \mathbb{R}} \ell_n(x_1^n; \mu, \sigma^2) = \ell_n(x_1^n; \hat{\mu}, \sigma^2)$.

Notons maintenant $\psi : \sigma^2 \in \mathbb{R}_+^* \mapsto \ell_n(x_1^n; \hat{\mu}, \sigma^2)$. Cette fonction est de classe $\mathcal{C}^2$ sur $\mathbb{R}_+^*$, et pour tout $\sigma^2 > 0$,

$$\begin{aligned}\psi'(\sigma^2) &= -\frac{n}{2\sigma^2} + \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2(\sigma^2)^2} \\ \psi''(\sigma^2) &= \frac{n}{2(\sigma^2)^2} - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{(\sigma^2)^3}\end{aligned}$$

Déterminons les points critiques de ψ :

$$\psi'(\sigma^2) = 0 \iff \frac{1}{2(\sigma^2)^2}(-n\sigma^2 + \sum_{i=1}^n (x_i - \hat{\mu})^2) = 0 \iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2$$

Donc la fonction ψ a un unique point critique $\hat{\sigma}^2 := \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2$.

De plus

$$\psi''(\hat{\sigma}^2) = \frac{n}{2(\hat{\sigma}^2)^2} - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{(\hat{\sigma}^2)^3} = \frac{1}{(\hat{\sigma}^2)^3} \left(\frac{n}{2} \hat{\sigma}^2 - \sum_{i=1}^n (x_i - \hat{\mu})^2 \right) = \frac{1}{(\hat{\sigma}^2)^3} \left(-\frac{n}{2} \hat{\sigma}^2 \right) = -\frac{n}{2(\hat{\sigma}^2)^2}$$

D'où $\psi''(\hat{\sigma}^2) < 0$, et $\hat{\sigma}^2$ est un maximum local de ψ . D'après la remarque ci-dessus, comme $\hat{\sigma}^2$ est de plus l'unique point critique de ψ , c'est aussi son unique maximum global.

Nous avons donc $\sup_{\sigma^2 \in \mathbb{R}_+^*} (\sup_{\mu \in \mathbb{R}} \ell_n(x_1^n; \mu, \sigma^2)) = \ell_n(x_1^n; \hat{\mu}, \hat{\sigma}^2)$ et $(\hat{\mu}, \hat{\sigma}^2)$ est l'estimateur du maximum de vraisemblance.

Autre méthode pour déterminer le maximum de vraisemblance :

La fonction $\tau : (\mu, \sigma^2) \mapsto \ell_n(x_1^n; \mu, \sigma^2)$ est de classe $\mathcal{C}^2$ sur $\mathbb{R} \times \mathbb{R}_+^*$. Cherchons ses points critiques ie les points $(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*$ qui annulent le gradient de τ , $\nabla \tau(\mu, \sigma^2) := \begin{pmatrix} \frac{\partial \tau}{\partial \mu}(\mu, \sigma^2) \\ \frac{\partial \tau}{\partial \sigma^2}(\mu, \sigma^2) \end{pmatrix}$. Pour cela calculons les dérivées partielles de τ : pour tous $(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*$,

$$\frac{\partial \tau}{\partial \mu}(\mu, \sigma^2) = \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma^2} \quad \text{et} \quad \frac{\partial \tau}{\partial \sigma^2}(\mu, \sigma^2) = -\frac{n}{2\sigma^2} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2(\sigma^2)^2}$$

Nous avons donc

$$\frac{\partial \tau}{\partial \mu}(\mu, \sigma^2) = 0 \iff \sum_{i=1}^n \frac{x_i}{\sigma^2} - \mu \frac{n}{\sigma^2} = 0 \iff \mu = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\frac{\partial \tau}{\partial \sigma^2}(\mu, \sigma^2) = 0 \iff \frac{1}{2(\sigma^2)^2}(-n\sigma^2 + \sum_{i=1}^n (x_i - \mu)^2) = 0 \iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

d'où

$$\nabla \tau(\mu, \sigma^2) = 0 \iff (\mu = \frac{1}{n} \sum_{i=1}^n x_i \text{ et } \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \frac{1}{n} \sum_{i=1}^n x_i)^2)$$

La fonction τ a donc un unique point critique $(\hat{\mu}, \hat{\sigma}^2) := (\frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2)$
 Etudions la matrice hessienne de τ :

$$H(\mu, \sigma^2) = \begin{pmatrix} \frac{\partial^2 \tau}{\partial \mu^2}(\mu, \sigma^2) & \frac{\partial^2 \tau}{\partial \mu \partial \sigma^2}(\mu, \sigma^2) \\ \frac{\partial^2 \tau}{\partial \mu \partial \sigma^2}(\mu, \sigma^2) & \frac{\partial^2 \tau}{\partial (\sigma^2)^2}(\mu, \sigma^2) \end{pmatrix} = \begin{pmatrix} -\frac{n}{\sigma^2} & -\sum_{i=1}^n \frac{(x_i - \mu)}{(\sigma^2)^2} \\ -\sum_{i=1}^n \frac{(x_i - \mu)}{(\sigma^2)^2} & \frac{n}{2(\sigma^2)^2} - \sum_{i=1}^n \frac{(x_i - \mu)^2}{(\sigma^2)^3} \end{pmatrix}$$

Pour $(\mu, \sigma^2) = (\hat{\mu}, \hat{\sigma}^2)$, nous avons $H(\hat{\mu}, \hat{\sigma}^2) = \begin{pmatrix} -\frac{n}{\hat{\sigma}^2} & 0 \\ 0 & -\frac{n}{2(\hat{\sigma}^2)^2} \end{pmatrix}$ car

$$-\sum_{i=1}^n \frac{(x_i - \hat{\mu})}{(\hat{\sigma}^2)^2} = -\frac{1}{(\hat{\sigma}^2)^2} \sum_{i=1}^n (x_i - \hat{\mu}) = 0$$

et

$$\frac{n}{2(\hat{\sigma}^2)^2} - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{(\hat{\sigma}^2)^3} = \frac{1}{(\hat{\sigma}^2)^3} \left(\frac{n}{2} \hat{\sigma}^2 - \sum_{i=1}^n (x_i - \hat{\mu})^2 \right) = -\frac{1}{(\hat{\sigma}^2)^3} \frac{n}{2} \hat{\sigma}^2 = -\frac{n}{2(\hat{\sigma}^2)^2}$$

La matrice $H(\hat{\mu}, \hat{\sigma}^2)$ est donc définie négative car diagonale à termes diagonaux strictement négatifs, donc $(\hat{\mu}, \hat{\sigma}^2)$ est un maximum local de τ et en ce point τ atteint la valeur

$$\tau(\hat{\mu}, \hat{\sigma}^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}^2) - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2\hat{\sigma}^2}$$

Montrons que pour tout $(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*$, nous avons $\tau(\mu, \sigma^2) \leq \tau(\hat{\mu}, \hat{\sigma}^2)$

$$\begin{aligned} \tau(\hat{\mu}, \hat{\sigma}^2) - \tau(\mu, \sigma^2) &= \left(-\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}^2) - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2\hat{\sigma}^2} \right) \\ &\quad - \left(-\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \right) \\ &= \frac{n}{2} (\log(\sigma^2) - \log(\hat{\sigma}^2)) + \left(\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2\hat{\sigma}^2} \right) \\ &= \frac{n}{2} (\log(\sigma^2) - \log(\hat{\sigma}^2)) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} - \frac{n}{2} \\ &= \frac{n}{2} (\log(\sigma^2) - \log(\frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2) - 1) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= \frac{n}{2} (-\log(\frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2}) - 1) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

donc

$$\tau(\hat{\mu}, \hat{\sigma}^2) - \tau(\mu, \sigma^2) \geq 0 \iff \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \geq \frac{n}{2} (\log(\frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2}) + 1)$$

Or $\log(\frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2}) = \log(1 + \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2} - 1) \leq \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2} - 1$ car pour tout $y > -1$, $\log(1 + y) \leq y$.

Donc

$$\frac{n}{2} (\log(\frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2}) + 1) \leq \frac{n}{2} \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\sigma^2} = \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2\sigma^2}$$

Montrons que

$$\sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2\sigma^2} \leq \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

ie en simplifiant par $2\sigma^2$,

$$\sum_{i=1}^n (x_i - \hat{\mu})^2 \leq \sum_{i=1}^n (x_i - \mu)^2$$

Or $\sum_{i=1}^n (x_i - \hat{\mu})^2 = \sum_{i=1}^n x_i^2 + n\hat{\mu}^2 - 2\hat{\mu} \sum_{i=1}^n x_i = \sum_{i=1}^n x_i^2 + n\hat{\mu}^2 - 2n\hat{\mu} \bar{x}$ et $\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n x_i^2 + n\mu^2 - 2\mu \sum_{i=1}^n x_i = \sum_{i=1}^n x_i^2 + n\mu^2 - 2n\mu \bar{x}$

Donc

$$\begin{aligned} \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{2\sigma^2} \leq \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} &\iff n\hat{\mu}^2 - 2n\hat{\mu} \bar{x} \leq n\mu^2 - 2n\mu \bar{x} \\ &\iff 0 \leq n\mu^2 - 2n\mu \hat{\mu} + n\hat{\mu}^2 = n(\mu - \hat{\mu})^2 \end{aligned}$$

Donc nous avons bien pour tout $(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*$, $\tau(\mu, \sigma^2) \leq \tau(\hat{\mu}, \hat{\sigma}^2)$, donc $(\hat{\mu}, \hat{\sigma}^2)$ est un maximum global de τ sur $\mathbb{R} \times \mathbb{R}_+^*$. De plus s'il existait un autre maximum global $(\tilde{\mu}, \tilde{\sigma}^2)$ de τ sur $\mathbb{R} \times \mathbb{R}_+^*$, alors $(\tilde{\mu}, \tilde{\sigma}^2)$ serait un point critique de τ , or τ admet un unique point critique $(\hat{\mu}, \hat{\sigma}^2)$. Donc $(\hat{\mu}, \hat{\sigma}^2)$ est l'unique maximum global de τ sur $\mathbb{R} \times \mathbb{R}_+^*$.

Autres remarques (LC) :

- preuve de "coercive+continue en dim finie" implique l'existence du min global : si f est une fonction coercive de $F \subset \mathbb{R}^n$ dans $\mathbb{R}$, avec F fermé de $\mathbb{R}^n$ alors, si $x_0 \in F$, on a : il existe M tel que si $\|x\| \geq M$ (choisissez la norme qui vous arrange...) et $x \in F$ alors $f(x) > f(x_0)$. Donc

$$\arg \min_{x \in F} f(x) = \arg \min_{x \in F : \|x\| \leq M} f(x)$$

Ainsi la coercivité permet de se ramener à un compact (car un fermé borné est compact en dim finie). Or, f étant continue, elle atteint son minimum sur ce compact.

- Si f est différentiable sur un ouvert U de $\mathbb{R}^n$ et si $x_0 \in U$ est un minimum global ou local alors x_0 est un point critique. Ceci est faux si on enlève l'hypothèse " U est ouvert" (penser à une fonction décroissante sur un intervalle fermé $[a, b]$).
- On aurait pu aussi, pour le pb de l'exercice 4 du TD2, d'abord fixer μ puis résoudre le problème en σ^2 (mais il est plus simple, dans cet exercice, de fixer d'abord σ^2). Plus précisément : fixons μ et résolvons le pb suivant (dim 1)

$$\sigma_0^2 \in \arg \min_{t > 0} n \log(t) + \frac{\sum_{i=1}^n (X_i - \mu)^2}{t}.$$

On devrait même écrire plutôt

$$\sigma_0^2(\mu) \in \arg \min_{t > 0} n \log(t) + \frac{\sum_{i=1}^n (X_i - \mu)^2}{t}$$

pour insister sur le fait que cette solution peut dépendre de μ (et ce sera le cas ici!).

Posons, pour $t > 0$, $f(t) = n \log(t) + \frac{\sum_{i=1}^n (X_i - \mu)^2}{t}$. On trouve facilement (c'est le même pb qu'en TD : remplacer $\bar{X}$ par μ) que le minimum global de cette fonction f sur $]0, +\infty[$ est donné par

$$\sigma_0^2(\mu) = \frac{\sum_{i=1}^n (X_i - \mu)^2}{n}.$$

Puis on injecte cette solution dans la fonction à deux variables originale et on résout le problème (de dim 1) suivant

$$\mu_0 \in \arg \min_{\mu \in \mathbb{R}} -\ell(\mu, \sigma_0^2(\mu))$$

i.e.

$$\mu_0 \in \arg \min_{\mu \in \mathbb{R}} n \log(\sigma_0^2(\mu)) + \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma_0^2(\mu)}$$

i.e.

$$\mu_0 \in \arg \min_{\mu \in \mathbb{R}} n \log\left(\sum_{i=1}^n \frac{(X_i - \mu)^2}{n}\right) + n$$

i.e.

$$\mu_0 \in \arg \min_{\mu \in \mathbb{R}} \sum_{i=1}^n (X_i - \mu)^2$$

ce qui donne

$$\mu_0 = \bar{X}$$

Ensuite, on doit réinjecter cette valeur dans la solution trouvée pour σ_0^2 pour avoir la solution finale (et c'est là que cela diffère de la manière dont on a procédé en TD, car en fixant d'abord σ^2 on avait trouvé pour μ_0 une solution ne dépendant pas de σ^2 !). On obtient finalement

$$\hat{\sigma}^2 = \sigma_0^2(\mu_0) = \sigma_0^2(\bar{X}) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

et

$$\hat{\mu} = \mu_0 = \bar{X}.$$

Pourquoi cela nous donne bien une solution (i.e. un min global de $-\ell$)? C'est à nouveau une application de (1). Autre façon de le dire :

On a, par déf de σ_0^2 et de μ_0 ,

$$-\ell(\mu, \sigma_0^2(\mu)) \leq -\ell(\mu, \sigma^2) \quad \forall \mu \in \mathbb{R} \text{ and } \forall \sigma^2 > 0$$

De plus

$$-\ell(\mu_0, \sigma_0^2(\mu_0)) \leq -\ell(\mu, \sigma_0^2(\mu)) \quad \forall \mu \in \mathbb{R}$$

En combinant ces deux inégalités, on trouve

$$-\ell(\mu_0, \sigma_0^2(\mu_0)) \leq -\ell(\mu, \sigma^2) \quad \forall \mu \in \mathbb{R} \text{ and } \forall \sigma^2 > 0$$

i.e. $(\mu_0, \sigma_0^2(\mu_0))$ est un min global de $-\ell$ sur $\mathbb{R} \times \mathbb{R}_{>0}$.