

Introduction à la statistique non-paramétrique

TD2 : Estimation de la fonction de répartition

Exercice 1 :

Soit $X_1, \dots, X_n \stackrel{iid}{\sim} Be(p)$. On veut tester, avec un test non asymptotique,

$$H_0 : p = 1/2 \quad \text{contre} \quad p \neq 1/2.$$

1. Rappeler la procédure de test vue dans l'exercice 5 du TD1.
2. Donner l'expression de la p -valeur.

Exercice 2 : On considère un n -échantillon i.i.d. $X_1^n = (X_1, \dots, X_n)$. On note F la fonction de répartition et $\hat{F}_n$ la fonction de répartition empirique associées à cet échantillon. On se donne F_0 une fonction de répartition.

1. Montrer que si F_0 est continue la loi, sous H_0 , de la statistique

$$h_n^+(X, F_0) = \sup_{t \in \mathbb{R}} \left\{ \hat{F}_n(t) - F_0(t) \right\}_+$$

est libre de F_0 .

2. Proposer une procédure de test de

$$H_0 : F = F_0 \quad \text{contre} \quad H_1 : \exists t \in \mathbb{R} \ F(t) > F_0(t).$$

Exercice 3 : On s'intéresse dans cet exercice à la puissance du test de Kolmogorov-Smirnov. On considère donc un échantillon i.i.d. $(X_1, \dots, X_n)$ de loi de cdf F et de cdf empirique $\hat{F}_n$. On veut tester

$$H_0 : F = F_0 \quad \text{contre} \quad H_1 : F \neq F_0$$

où F_0 est une loi donnée. On veut savoir si le test est capable de nous dire, avec une grande probabilité, que l'échantillon ne suit pas la loi F_0 , quand c'est bien le cas, et du moment que la taille de l'échantillon est suffisamment grande. Autrement dit, on veut savoir si le test est puissant.

On suppose que F_0 est continue.

1. A l'aide de l'inégalité DKW vue en cours, montrer que le quantile $\xi_{n,1-\alpha}$ d'ordre $1 - \alpha$ de la statistique de Kolmogorov-Smirnov, vérifie $\xi_{n,1-\alpha} = O(\frac{1}{\sqrt{n}})$ quand $n \rightarrow \infty$.
2. On suppose que $F \neq F_0$, c'est-à-dire que l'échantillon ne suit pas la loi F_0 . Montrer que si on pose

$$\underline{\beta}(F) = \mathbb{P}_{X_1, \dots, X_n \stackrel{iid}{\sim} F} (\|\hat{F}_n - F_0\|_\infty \geq \xi_{n,1-\alpha})$$

alors

$$\underline{\beta}(F) \xrightarrow{n \rightarrow \infty} 1$$

Exercice 4 : On considère un n -échantillon i.i.d. $X_1^n = (X_1, \dots, X_n)$ de variables aléatoires. On note F la fonction de répartition et $\hat{F}_n$ la fonction de répartition empirique associées à cet échantillon. Si les variables X_i sont de lois normales de paramètres μ et σ^2 , on note également N_{μ, σ^2} leur fonction de répartition commune.

1. On suppose que $F = N_{\mu, \sigma^2}$. Déterminer l'estimateur du maximum de vraisemblance $(\hat{\mu}, \hat{\sigma}^2)$ de (μ, σ^2) .
2. On pose

$$\Delta_n = \sup_{t \in \mathbb{R}} |\hat{F}_n(t) - N_{\hat{\mu}, \hat{\sigma}^2}(t)|.$$

Montrer que si $F = N_{\mu, \sigma^2}$, alors la loi de Δ_n ne dépend pas de μ et σ^2 .

3. En déduire un test d'appartenance à la famille des lois normales, c'est-à-dire un test de

$$H_0 : F \in \mathcal{FN} \quad \text{contre} \quad H_1 : F \notin \mathcal{FN},$$

où

$$\mathcal{FN} = \{G : \exists (\mu, \sigma^2) \in (\mathbb{R} \times \mathbb{R}_+^*) \text{ tel que } G = N_{\mu, \sigma^2}\}.$$

4. *Application (quasi indépendante du reste de l'exercice) :* La loi de la statistique de test de la question 3 a été tabulée. On s'intéresse aussi au test, vu en cours (section 2.3.2 du poly), d'appartenance à la famille exponentielle. On fournit ci-dessous quelques quantiles intéressants pour $n = 4$:

	$q_{5\%}$	$q_{10\%}$	$q_{90\%}$	$q_{95\%}$
Stat du test d'appartenance à la loi normale	0.18	0.20	0.36	0.39
Stat du test d'appartenance à la loi expo	0.21	0.23	0.44	0.48

Considérons la réalisation d'un échantillon de taille $n = 4$:

0.66 3.51 1.92 1.05

Nous cherchons à tester si cet échantillon est distribué selon une loi normale et s'il est distribué selon une loi exponentielle. Pour cela nous proposons d'appliquer le test précédemment construit et le test du cours. Sur la figure 1 (à droite et à gauche) nous avons tracé la fonction de répartition empirique correspondant à l'échantillon donné. D'autre part, à gauche nous avons tracé la fonction $N_{\hat{\mu}, \hat{\sigma}^2}$ où $\hat{\mu}$ et $\hat{\sigma}^2$ sont les estimateurs du maximum de vraisemblance ($\hat{\mu} = 1.78$ $\hat{\sigma}^2 = 1.20$). A droite nous avons tracé la fonction de répartition de la loi exponentielle de paramètre $\hat{\lambda}$ ($\hat{\lambda} = 0.56$).

- (a) Par une lecture graphique sur la figure 1, donner la valeur de la statistique des 2 tests.
- (b) En utilisant les quantiles donnés ci-dessus, effectuer les 2 tests pour un niveau 5%.
- (c) Les deux conclusions vous semblent-elles cohérentes ?

Exercice 5 : Soit $X_1, \dots, X_n$ un échantillon i.i.d. de loi de fonction de répartition F continue. Soit $p \in]0, 1[$. On note x_p le quantile d'ordre p de F .

On va montrer dans cet exercice comment obtenir un intervalle de confiance asymptotique sur x_p sans connaître F (en supposant seulement que F est continue).

Soit $\alpha \in]0, 1[$ un niveau de confiance. On note $\hat{F}_n$ la fonction de répartition empirique et on note $\hat{F}_n^{(-1)}$ la fonction quantile (ou inverse généralisée) associée à $\hat{F}_n$.




FIGURE 1 – Exercice 4 : fonction de répartition empirique de l'échantillon (en escalier) et fonction de répartition à tester.

1. Donner la limite en loi de $\sqrt{n}(\hat{F}_n(x) - F(x))$ quand n tend vers l'infini.
2. Donner la limite en loi de $\sqrt{n}(\hat{F}_n(x_p) - p)$ quand n tend vers l'infini.
3. En déduire que

$$P\left(p - \Phi^{-1}(1 - \alpha/2)\sqrt{\frac{p(1-p)}{n}} \leq \hat{F}_n(x_p) < p + \Phi^{-1}(1 - \alpha/2)\sqrt{\frac{p(1-p)}{n}}\right) \xrightarrow{n \rightarrow +\infty} 1 - \alpha$$

où Φ est la fonction de répartition de la loi normale standard.

4. En utilisant la fonction inverse généralisée $\hat{F}_n^{(-1)}$, en déduire un intervalle de confiance asymptotique de niveau $1 - \alpha$ pour x_p .

Exercice 6 : L'objectif de cet exercice est de proposer une procédure de tests multiples lorsque le nombre d'hypothèses à tester est élevé. On considère dans tout l'exercice $(\Omega, \mathcal{A}, \mathbb{P}_\theta, \theta \in \Theta)$ un modèle statistique.

Partie A. On se place tout d'abord dans le cadre simple où on veut tester

$$H_0 : \theta = \theta_0 \quad \text{contre} \quad H_1 : \theta \in \Theta_1$$

où $\theta_0 \notin \Theta_1$. Pour cela, on dispose d'une observation réelle X de loi $\mathbb{P}_\theta$. Pour $\alpha \in]0, 1[$ donné, on considère un test de H_0 contre H_1 de la forme $\varphi_\alpha(X) = 1_{X \geq k_\alpha}$ où $k_\alpha \in \mathbb{R}$. On note F_θ la cdf de X sous $\mathbb{P}_\theta$. On suppose que F_θ est continue.

1. Donner l'expression de la p-valeur observée en fonction de F_{θ_0} .

2. Que vaut $P_{\theta_0}(p(X) \leq u)$ pour $u \in]0, 1[$?

Remarque : pour comprendre le cas plus général où l'hypothèse nulle est composite, se reporter à l'examen 2014.

Partie B. Dans cette partie, indépendante de la partie A, pour $m \in \mathbb{N}^*$, on considère $2m$ sous-ensembles de Θ notés $\Theta_{01}, \Theta_{11}, \Theta_{02}, \Theta_{12}, \dots, \Theta_{0m}, \Theta_{1m}$ avec pour tout $i \in \{1, \dots, m\}$

$$\Theta_{0i} \cap \Theta_{1i} = \emptyset$$

et on veut réaliser **simultanément** m tests

$$H_{0i} : \theta \in \Theta_{0i} \quad \text{contre} \quad H_{1i} : \theta \in \Theta_{1i}, \quad i = 1, \dots, m.$$

On suppose pour simplifier que les hypothèses nulles sont des singletons $\Theta_{0i} = \{\theta_{0i}\}$ et que les tests sont de taille α . On note I_0 l'ensemble des indices i pour lesquels H_{0i} est vraie :

$$I_0 = \{i \in \{1, \dots, m\} : H_{0i} \text{ est vraie}\}.$$

On cherche à construire une procédure de tests multiples qui retourne un ensemble $\hat{R} \subset \{1, \dots, m\}$ correspondant aux indices i pour lesquels H_{0i} est rejetée.

Remarque : l'erreur consistant à ne pas prendre en compte le fait de tester plusieurs hypothèses simultanément fait partie de ce que l'on appelle le "p-hacking", cf. par exemple : <https://statisticsbyjim.com/hypothesis-testing/p-hacking/>, section "Excessive Hypothesis Testing and Multiple Comparisons".

On note FP le cardinal de l'ensemble des indices correspondant aux hypothèses nulles rejetées à tort et TP le cardinal de l'ensemble des indices correspondant aux hypothèses nulles rejetées à raison :

$$\text{FP} = \text{card}(\hat{R} \cap I_0), \quad \text{TP} = \text{card}(\hat{R} \setminus I_0).$$

FP est le cardinal des *faux positifs* et TP celui des *vrais positifs*. Idéalement, on cherche une procédure de tests de sorte que FP soit petit et TP soit grand. On note $\hat{p}_i$ la p-valeur du test de H_{0i} contre H_{1i} . Donc $\hat{p}_i$ est une statistique satisfaisant, pour tout $u \in]0, 1[$,

$$\mathbb{P}_{\theta_{0i}}(\hat{p}_i \leq u) = u. \tag{1}$$

1. On propose tout d'abord la procédure de Bonferroni qui permet le contrôle de FP en posant pour $\alpha \in]0, 1[$:

$$\hat{R} = \left\{ i \in \{1, \dots, m\} : \hat{p}_i \leq \frac{\alpha}{m} \right\}.$$

(a) Montrer que

$$\mathbb{P}(\text{FP} > 0) \leq \sum_{i \in I_0} \mathbb{P}_{\theta_{0i}}(\hat{p}_i \leq \alpha/m).$$

(b) En utilisant (1), en déduire que

$$\mathbb{P}(\text{FP} > 0) \leq \alpha.$$

2. La procédure de Bonferroni contrôle le nombre de faux positifs mais peut produire un trop petit nombre de vrais positifs. On dit que c'est une procédure trop conservatrice. Aussi, on propose l'alternative suivante. On se donne une fonction $f : \{0, 1, \dots, m\} \rightarrow [0, m]$ supposée croissante et on ordonne les statistiques $\hat{p}_i$ par ordre croissant :

$$\hat{p}_{(1)} \leq \hat{p}_{(2)} \leq \dots \leq \hat{p}_{(m)}.$$

On cherche à contrôler le rapport FDR défini par

$$\text{FDR} = \mathbb{E} \left[\frac{\text{FP}}{\text{FP} + \text{TP}} 1_{\{\text{FP} + \text{TP} \geq 1\}} \right]$$

avec la convention $0/0 = 0$.

On pose pour $\alpha \in]0, 1[$,

$$\hat{R} = \left\{ i \in \{1, \dots, m\} : \hat{p}_i \leq \frac{\alpha f(\hat{k})}{m} \right\}$$

avec

$$\hat{k} = \max \left\{ k \in \{1, \dots, m\} : \hat{p}_{(k)} \leq \frac{\alpha f(k)}{m} \right\}.$$

En particulier, on pose $\hat{k} = 0$ et $\hat{R} = \emptyset$ si pour tout entier k , $\hat{p}_{(k)} > \frac{\alpha f(k)}{m}$.

- (a) Montrer que

$$\hat{k} = \text{card}(\hat{R})$$

et que pour $j \geq \hat{k}$,

$$f(\hat{k}) \leq f(\min(j, m)).$$

- (b) Etablir alors que

$$\text{FDR} = \sum_{i \in I_0} \mathbb{E} \left[1_{\{\hat{p}_i \leq \alpha f(\hat{k})/m\}} \times \frac{1_{\{\hat{k} \geq 1\}}}{\hat{k}} \right].$$

- (c) Montrer que si $\hat{k} \geq 1$,

$$\frac{1}{\hat{k}} = \sum_{j=1}^{+\infty} \frac{1_{\{j \geq \hat{k}\}}}{j(j+1)}.$$

- (d) En déduire finalement que

$$\text{FDR} \leq \frac{\alpha \text{card}(I_0)}{m} \sum_{j=1}^{+\infty} \frac{f(\min(j, m))}{j(j+1)}.$$

- (e) Conclure que si f satisfait

$$\sum_{j=1}^{+\infty} \frac{f(\min(j, m))}{j(j+1)} \leq 1 \tag{2}$$

alors

$$\text{FDR} \leq \alpha.$$

(f) Donner un exemple de fonction f satisfaisant (2).

Remarque : on peut aussi généraliser ces résultats au cas d'hypothèses nulles composites (cf examen 2014).

Remarque : si les m tests sont indépendants, on peut en fait prendre f égale à l'identité : alors on a plus de vrais positifs que dans le cas précédent tout en ayant quand même un FDR borné par α . La procédure est alors la suivante :

$$\hat{R} = \left\{ i \in \{1, \dots, m\} : \hat{p}_i \leq \frac{\alpha \hat{k}}{m} \right\}$$

avec

$$\hat{k} = \max \left\{ k \in \{1, \dots, m\} : \hat{p}_{(k)} \leq \frac{\alpha k}{m} \right\}.$$

Elle s'appelle la procédure de Benjamini-Hochberg (cf partiel 2018).

Code R : si on a calculé les p-valeurs des m tests indépendants dans le vecteur $\mathbf{p}$ alors on peut utiliser le code suivant pour calculer $\hat{R}$, l'ensemble des indices des hypothèses rejetées par la procédure de Benjamini-Hochberg quand on, veut un FDR plus petit que 5% :

```
k<-sum(sort(p)<=0.05*(1:m)/m) # k= k-chapeau  
R<-(1:m)[p<=0.05*k/m]
```

Il existe un certain nombre de méthodes basées sur les p-valeurs pour résoudre ce type de problème de tests multiples. Par exemple on peut citer la procédure de Berk-Jones modifiée.