

Chapitre 6

Corrigés des exercices

6.1 Corrigés des exercices du chapitre 3

6.1.1 Exercice 1

1. Nous disposons de données appariées $(U_i, V_i)_{1 \leq i \leq 9}$ où U_i, V_i sont liées au même i -ème individu, le i -ème film, et représentent respectivement l'âge de l'acteur principal et l'âge de l'actrice principale dans ce film.

Nous avons accès aux valeurs des différences $X_i = U_i - V_i$ et pas seulement à leur signe : nous préférons donc utiliser toutes les informations à notre disposition et utiliser le test des rangs signés de Wilcoxon plutôt que le test du signe.

Remarque : nous ne nous occupons pas de la vérification de l'hypothèse de médiane commune, ni de celle de symétrie par rapport à cette médiane, qui sont des hypothèses nécessaires au test des rangs signés de Wilcoxon et nous nous contentons de les supposer satisfaites.

2. Rappel des hypothèses du test des rangs signés de Wilcoxon :

- $X_1, \dots, X_n$ sont indépendantes ;
- $X_1, \dots, X_n$ sont de lois diffuses ;
- $X_1, \dots, X_n$ sont de médiane commune m ;
- Pour $1 \leq i \leq n$, la loi de X_i est symétrique par rapport à m .

L'hypothèse nulle est $H_0 : m = 0$, l'hypothèse alternative est $H_1 : m > 0$. Nous utilisons la statistique de test

$$W_9^+ = \sum_{i=1}^9 R_{|X|}(i) \mathbb{1}_{\{X_i > 0\}}$$

où $(|X|_{(1)}, \dots, |X|_{(9)}) = (|X|_{\hat{\sigma}_{|X|}(1)}, \dots, |X|_{\hat{\sigma}_{|X|}(9)})$ et $R_{|X|} = \hat{\sigma}_{|X|}^{-1}$.

D'après le cours, nous savons que W_9^+ est égal en loi sous H_0 à

$$\tilde{h}_9 := \sum_{j=1}^9 jY_j$$

où $Y_1, \dots, Y_9 \stackrel{iid}{\sim} Be(\frac{1}{2})$ et donc $\mathbb{E}_{H_0}[W_9^+] = \frac{9 \times (9+1)}{4} = 22,5$.

3. Les valeurs observées de $U_i, V_i, X_i, \mathbb{1}_{\{X_i > 0\}}, \hat{\sigma}_{|X|}(i), R_{|X|}(i)$ sont :

i	1	2	3	4	5	6	7	8	9
u_i	40	57	44	52	39.2	77	48	36	39
v_i	39.5	55	41.5	49	39.5	84	79	30	23
x_i	0.5	2	2.5	3	-0.3	-7	-31	6	16
$\mathbb{1}_{\{x_i > 0\}}$	1	1	1	1	0	0	0	1	1
$\hat{\sigma}_{ x }(i)$	5	1	2	3	4	8	6	9	7
$R_{ x }(i)$	2	3	4	5	1	7	9	6	8

La valeur observée de W_9^+ est donc

$$w_9^+ = R_{|x|}(1) + R_{|x|}(2) + R_{|x|}(3) + R_{|x|}(4) + R_{|x|}(8) + R_{|x|}(9) = 2 + 3 + 4 + 5 + 6 + 8 = 28$$

Nous utilisons le test $\varphi_\alpha(X_1^9) = \mathbb{1}_{\{W_9^+ > q_{1-\alpha}^{\mathcal{L}(\tilde{h}_9)}\}}$ où $q_{1-\alpha}^{\mathcal{L}(\tilde{h}_9)}$ est le quantile d'ordre $1 - \alpha$ de la loi de $\tilde{h}_9$. Comme W_9^+ est à valeurs dans $\mathbb{N}$, nous avons aussi $\varphi_\alpha(X_1^9) = \mathbb{1}_{\{W_9^+ \geq q_{1-\alpha}^{\mathcal{L}(\tilde{h}_9)} + 1\}}$.

Calcul de la p-valeur observée :

On pose $w = w_9^+$ pour simplifier et on note F la CDF de la loi de $\tilde{h}_9$. Comme W_9^+ est à valeurs entières on a, en utilisant les propriétés de la fonction quantile,

$$\begin{aligned} p(x_1^9) &= \inf \left\{ \alpha \in]0, 1[: w > F^{(-1)}(1 - \alpha) \right\} \\ &= \inf \left\{ \alpha \in]0, 1[: w \geq F^{(-1)}(1 - \alpha) + 1 \right\} \\ &= \inf \left\{ \alpha \in]0, 1[: F(w - 1) \geq 1 - \alpha \right\} \\ &= 1 - F(w - 1) \\ &= 1 - P(\tilde{h}_n \leq w - 1) = P(\tilde{h}_n \geq w) \end{aligned}$$

Cela donne ici :

$$p(x_1^9) = 1 - P(\tilde{h}_9 \leq 28 - 1) = 1 - 0.7148 = 0.2852.$$

4. Nous avons $p(x_1^9) = 0,2852 > \alpha = 0,05$, donc nous ne rejettons pas H_0 au niveau $\alpha = 5\%$.

6.1.2 Exercice 2

Notons $U_1, \dots, U_9$ le nombre des vers adultes retrouvés dans les intestins des 9 souris non traitées, et $V_1, \dots, V_7$ le nombre des vers adultes retrouvés dans les intestins des 7 souris traitées.

Rappelons les hypothèses du test de Mann-Whitney :

- $U_1, \dots, U_n$ sont i.i.d. de même loi que U ;
- $V_1, \dots, V_p$ sont i.i.d. de même loi que V ;
- U_1^n est indépendant de V_1^p ;
- U et V sont diffuses.

Remarques : la dernière hypothèse ne pose pas de difficulté ici puisqu'il n'y a pas d'ex-aequo dans les deux séries de valeurs données par l'énoncé.

Notons F (resp. G) la fonction de répartition de U (resp. V).

Nous testons

$$H_0 : F = G \text{ (ie les } U_i \text{ et les } V_j \text{ ont même loi)}$$

contre

$$H_1 : \text{le traitement est efficace : les } V_j \text{ ont tendance à être plus petits que les } U_i$$

Ici $n = 9, p = 7$. Posons $\Sigma_1 = \sum_{i=1}^9 R_i$, $\Sigma_2 = \sum_{j=1}^7 S_j$, où R_i (resp. S_j) est le rang de U_i (resp. V_j) dans le vecteur global $(U_1, \dots, U_9, V_1, \dots, V_7)$, Z le vecteur global ordonné, $M_U = \Sigma_1 - \frac{n \times (n+1)}{2} = \Sigma_1 - 45$ et $M_V = \Sigma_2 - \frac{p \times (p+1)}{2} = \Sigma_2 - 28$. Nous avons donc $M_V = np - M_U = 63 - M_U$.

Nous savons, d'après la Proposition ??, que sous H_0 , M_U et M_V sont égales en loi à $\tilde{h}_{9,7}$ de fonction de répartition $F_{9,7}$, et libres de F .

Nous pouvons utiliser un test de la forme $\varphi_\alpha(U_1^9, V_1^7) = \mathbb{1}_{\{M_V < k_\alpha\}}$ ou un test de la forme $\varphi'_\alpha(U_1^9, V_1^7) =$

$\mathbb{1}_{\{M_U > k'_\alpha\}}$: nous nous attendons à ce que, sous H_1 , M_V soit petit et M_U soit grand.

Nous avons $P_{H_0}(M_U > k'_\alpha) = 1 - P_{H_0}(M_U \leq k'_\alpha) = 1 - F_{9,7}(k_\alpha)$ donc $P_{H_0}(M_U > k'_\alpha) \leq \alpha \Leftrightarrow 1 - \alpha \leq F_{9,7}(k'_\alpha)$ et nous prenons donc $k'_\alpha = q_{1-\alpha}^{\mathcal{L}(\tilde{h}_{9,7})}$ ie le quantile d'ordre $1 - \alpha$ de la loi de $\tilde{h}_{9,7}$. Comme $M_V = 63 - M_U$, nous avons $\mathbb{P}_{H_0}(M_V < k_\alpha) = \mathbb{P}_{H_0}(63 - k_\alpha < M_U)$ et donc $\mathbb{P}_{H_0}(M_V < k_\alpha) \leq \alpha \Leftrightarrow 1 - \alpha \leq F_{9,7}(63 - k_\alpha)$ et nous prenons donc $k_\alpha = 63 - q_{1-\alpha}^{\mathcal{L}(\tilde{h}_{9,7})}$.

Comme M_U et M_V sont à valeurs dans $\mathbb{N}$, cela revient à utiliser l'un ou l'autre des deux tests équivalents :

$$\varphi_\alpha(U_1^9, V_1^7) = \mathbb{1}_{\{M_V \leq 62 - q_{1-\alpha}^{\mathcal{L}(\tilde{h}_{9,7})}\}}$$

$$\varphi'_\alpha(U_1^9, V_1^7) = \mathbb{1}_{\{M_U \geq q_{1-\alpha}^{\mathcal{L}(\tilde{h}_{9,7})} + 1\}}$$

Notons respectivement $\sigma_1, \sigma_2, r_i, s_j, u_i, v_j, z_k, m_u, m_v$ les valeurs observées des variables $\Sigma_1, \Sigma_2, R_i, S_j, Z_k, M_U, M_V$. Nous observons les valeurs :

k	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
z_k	47	49	51	53	55	57	60	61	62	63	65	67	68	71	75	79
Indice dans u	-	-	1	-	2	-	-	-	3	4	5	-	6	7	8	9
Indice dans v	1	2	-	3	-	4	5	6	-	-	-	7	-	-	-	-

Donc :

i	1	2	3	4	5	6	7	8	9
r_i	3	5	9	10	11	13	14	15	16

d'où $\sigma_1 = 3 + 5 + 9 + 10 + 11 + 13 + 14 + 15 + 16 = 96$, $m_u = \sigma_1 - 45 = 51$, et

j	1	2	3	4	5	6	7
s_j	1	2	4	6	7	8	12

d'où $\sigma_2 = 1 + 2 + 4 + 6 + 7 + 8 + 12 = 40$, $m_v = \sigma_2 - 28 = 12$.

Remarque : d'après la Proposition 3.38, nous savons que M_V correspond au nombre de paires (U_i, V_j) tel que $U_i < V_j$ parmi toutes les paires possibles.

Ici nous observons

$$\begin{aligned} \{(i, j); u_i < v_j\} = \\ \{(1, 3), (1, 4), (1, 5), (1, 6), (1, 7), (2, 4), (2, 5), (2, 6), (2, 7), (3, 7), (4, 7), (5, 7)\} \end{aligned}$$

et nous retrouvons bien $m_v = 12$.

Calcul de la p-valeur observée : on note $F_{9,7}$ la CDF de la loi de $\tilde{h}_{9,7}$.

$$\begin{aligned} p(u_1^9, v_1^7) &= \inf \left\{ \alpha \in]0, 1[: m_u > F_{9,7}^{(-1)}(1 - \alpha) \right\} \\ &= \inf \left\{ \alpha \in]0, 1[: m_u \geq F_{9,7}^{(-1)}(1 - \alpha) + 1 \right\} \\ &= \inf \left\{ \alpha \in]0, 1[: F_{9,7}(m_u - 1) \geq 1 - \alpha \right\} \\ &= 1 - F_{9,7}(m_u - 1) \\ &= 1 - P(\tilde{h}_{9,7} \leq m_u - 1) = P(\tilde{h}_{9,7} \geq m_u) \end{aligned}$$

Cela donne ici :

$$p(u_1^9, v_1^7) = 1 - F_{9,7}(50)$$

Or l'énoncé ne nous donne pas cette quantité. On s'en sort en utilisant la symétrie de la loi de $\tilde{h}_{9,7}$ par rapport à $\frac{np}{2} = 63/2$:

$$1 - F_{9,7}(50) = P(\tilde{h}_{9,7} \geq 51) = P(2 \times 63/2 - \tilde{h}_{9,7} \geq 51) = \mathbb{P}(63 - \tilde{h}_{9,7} \geq 51) = F_{9,7}(12) = 0,021.$$

Pour un niveau de risque $\alpha < p(u_1^9, v_1^7) = 0,021$, nous ne rejetons pas H_0 au niveau α (nous ne pouvons pas dire que le traitement est efficace) ;

Pour un niveau de risque $\alpha > p(u_1^9, v_1^7) = 0,021$, nous rejetons H_0 au niveau α (au niveau de risque α de nous tromper nous pensons que le traitement est efficace).

6.1.3 Exercice 3

Notons U_i (resp. V_i) l'efficacité du nouveau traitement (A) (resp. de l'ancien traitement (B)) sur l'individu i , pour $1 \leq i \leq n$, $n = 18$. Notons $X_i = U_i - V_i$. Nous n'avons accès qu'au signe des X_i , ie aux $Y_i := \mathbb{1}_{\{X_i > 0\}}$, puisqu'il est uniquement demandé au patient de dire si le traitement (A) a été plus efficace que le traitement (B) (auquel cas $X_i > 0$), ou si le traitement (A) a été plus efficace que le traitement (B) (auquel cas $X_i < 0$).

Il n'y a pas de réponse nulle possible, ce qui correspond à $\mathbb{P}(X_i = 0) = 0$. Nous allons donc utiliser le test du signe. Rappelons les hypothèses nécessaires pour ce test :

- $X_1, \dots, X_n$ sont indépendants ;
- $X_1, \dots, X_n$ sont de médiane commune m ;
- Pour $1 \leq i \leq n$, $\mathbb{P}(X_i = m) = 0$.

Nous testons

$$H_0 : m = 0 \text{ (qui modélise "les deux traitements ont la même efficacité")}$$

contre

$$H_1 : m > 0 \text{ (qui modélise "le nouveau traitement est meilleur que l'ancien")}$$

Sous H_0 , $Y_1, \dots, Y_{18} \stackrel{iid}{\sim} Be(\frac{1}{2})$ car comme sous H_0 la médiane est 0, nous avons $\mathbb{P}(X_i \geq 0) \geq \frac{1}{2}$ et $\mathbb{P}(X_i \leq 0) \geq \frac{1}{2}$, mais comme de plus $\mathbb{P}(X_i = 0) = 0$, $\mathbb{P}(Y_i = 1) = \mathbb{P}(X_i > 0) = \frac{1}{2}$. Nous utilisons le test

$$\varphi_\alpha(X_1^{18}) = \mathbb{1}_{\{\sum_{i=1}^{18} \mathbb{1}_{\{X_i > 0\}} > q_{1-\alpha}^{B(18, \frac{1}{2})}\}}$$

ou encore, comme $\sum_{i=1}^{18} \mathbb{1}_{\{X_i > 0\}}$ est à valeurs dans $\mathbb{N}$,

$$\varphi_\alpha(X_1^{18}) = \mathbb{1}_{\{\sum_{i=1}^{18} \mathbb{1}_{\{X_i > 0\}} \geq q_{1-\alpha}^{B(18, \frac{1}{2})} + 1\}}.$$

Notons x_i la valeur observée de X_i . La valeur observée de $\sum_{i=1}^{18} \mathbb{1}_{\{X_i > 0\}}$ est donc $\sum_{i=1}^{18} \mathbb{1}_{\{x_i > 0\}} = 12$.

Calcul de la p-valeur observée : on note F la CDF de la loi de $B(18, 1/2)$.

$$\begin{aligned} p(x_1^{18}) &= \inf \left\{ \alpha \in]0, 1[: 12 > F^{(-1)}(1 - \alpha) \right\} \\ &= \inf \left\{ \alpha \in]0, 1[: 12 \geq F^{(-1)}(1 - \alpha) + 1 \right\} \\ &= \inf \left\{ \alpha \in]0, 1[: F(12 - 1) \geq 1 - \alpha \right\} \\ &= 1 - F(11) \end{aligned}$$

Cela donne ici :

$$p(x_1^{18}) = 1 - F(11) \approx 0,23.$$

Pour un niveau de risque $\alpha < p(x_1^{18}) = 0,23$, nous ne rejetons pas H_0 au niveau α (nous ne pouvons pas dire que le nouveau traitement est plus efficace que l'ancien) ;

Pour un niveau de risque $\alpha > p(x_1^{18}) = 0,23$, nous rejetons H_0 au niveau α (au niveau de risque α de nous tromper nous pensons que le nouveau traitement est plus efficace que l'ancien).

6.1.4 Preuve de la proposition 3.37

1. Il est immédiat de voir que $\Sigma_1 \geq 1 + 2 + \dots + n = \frac{n(n+1)}{2}$ et $\Sigma_2 \geq 1 + 2 + \dots + p = \frac{p(p+1)}{2}$.
Comme $\Sigma_1 + \Sigma_2 = \sum_{i=1}^{n+p} i = \frac{(n+p)(n+p+1)}{2}$, on a

$$\Sigma_1 \leq \frac{(n+p)(n+p+1)}{2} - \frac{p(p+1)}{2} = np + \frac{n(n+1)}{2}.$$

De même $\Sigma_2 \leq np + \frac{p(p+1)}{2}$.

2. On se place désormais sous H_0 .

- (a) Alors toutes les variables $U_1, \dots, U_n, V_1, \dots, V_p$ sont i.i.d. Donc on a un échantillon global i.i.d. de taille $N = n + p$. D'après la proposition 3.31 (cas $s = 1$), pour tout i , la v.a. R_i , qui est donc une composante du vecteur de rang de l'échantillon global $R_{U,V}$, suit une loi uniforme sur $\{1, \dots, N\}$. De même pour chaque S_j . Donc l'espérance et la variance de chacune de ces variables est simplement l'espérance et la variance d'une variable de loi uniforme sur $\{1, \dots, N\}$. Donc on a, pour tout $i = 1, \dots, n$, et pour tout $j = 1, \dots, p$,

$$\mathbb{E}(R_i) = \mathbb{E}(S_j) = \frac{1}{N} \sum_{i=1}^N i = \frac{N+1}{2} = \frac{n+p+1}{2}$$

$$\begin{aligned} \mathbf{Var}(R_i) &= \mathbf{Var}(S_j) = \frac{1}{N} \sum_{i=1}^N i^2 - \left(\frac{N+1}{2}\right)^2 = \frac{(N+1)(2N+1)}{6} - \left(\frac{N+1}{2}\right)^2 \\ &= \frac{N^2 - 1}{12} \end{aligned}$$

- (b) Donc on a

$$\begin{aligned} \mathbb{E}\Sigma_1 &= \mathbb{E}(R_1 + \dots + R_n) = n\mathbb{E}R_1 = \frac{n(n+p+1)}{2} \\ \mathbb{E}\Sigma_2 &= \mathbb{E}(S_1 + \dots + S_p) = p\mathbb{E}S_1 = \frac{p(n+p+1)}{2} \end{aligned}$$

- (c) Il reste le calcul des variances de Σ_1 et Σ_2 . Attention les variables R_i et S_j sont de même loi mais pas indépendantes ! On a

$$\mathbf{Var}\Sigma_1 = \mathbf{Var}(R_1 + \dots + R_n) = \sum_{i=1}^n \mathbf{Var}(R_i) + \sum_{i=1}^n \sum_{j \neq i} \mathbf{Cov}(R_i, R_j)$$

On a déjà calculé les variances, il faut donc calculer maintenant les covariances. Soit donc $i \neq j$,

$$\begin{aligned} \mathbf{Cov}(R_i, R_j) &= \mathbb{E}\left[(R_i - \mathbb{E}R_i)(R_j - \mathbb{E}R_j)\right] \\ &= \sum_{1 \leq k, l \leq N, k \neq l} \left(k - \frac{N+1}{2}\right)\left(l - \frac{N+1}{2}\right) \mathbb{P}(R_i = k, R_j = l) \end{aligned}$$

Or, (R_i, R_j) a la même loi que (R_1, R_2) et on a, pour $k \neq l$,

$$\mathbb{P}(R_1 = k, R_2 = l) = \frac{1}{N(N-1)}$$

Donc

$$\mathbf{Cov}(R_i, R_j) = \mathbf{Cov}(R_1, R_2) = \frac{1}{N(N-1)} \sum_{k \neq l} \left(k - \frac{N+1}{2}\right)\left(l - \frac{N+1}{2}\right)$$

Or on a

$$\begin{aligned}\sum_{k \neq l} (k - \frac{N+1}{2})(l - \frac{N+1}{2}) &= \sum_{1 \leq k, l \leq N} (k - \frac{N+1}{2})(l - \frac{N+1}{2}) - \sum_{k=1}^N (k - \frac{N+1}{2})^2 \\ &= \left[\sum_{k=1}^N (k - \frac{N+1}{2}) \right]^2 - \sum_{k=1}^N (k - \frac{N+1}{2})^2\end{aligned}$$

De plus

$$\sum_{k=1}^N (k - \frac{N+1}{2}) = \sum_{k=1}^N k - \frac{N(N+1)}{2} = 0$$

Donc

$$\mathbf{Cov}(R_i, R_j) = -\frac{1}{N(N-1)} \sum_{k=1}^N (k - \frac{N+1}{2})^2 = -\frac{1}{N-1} \mathbf{Var} R_1$$

Et finalement

$$\begin{aligned}\mathbf{Var}(\Sigma_1) &= \sum_{i=1}^n \mathbf{Var}(R_i) + \sum_{i=1}^n \sum_{j \neq i} \mathbf{Cov}(R_i, R_j) \\ &= n \mathbf{Var}(R_1) + n(n-1) \mathbf{Cov}(R_1, R_2) \\ &= n \mathbf{Var}(R_1) - \frac{n(n-1)}{N-1} \mathbf{Var}(R_1) \\ &= \frac{n(N-n)}{N-1} \frac{N^2-1}{12} \\ &= \frac{n(N-n)(N+1)}{12} \\ &= \frac{np(n+p+1)}{12}\end{aligned}$$

Le calcul de $\mathbf{Var}(\Sigma_2)$ se déduit de celui de $\mathbf{Var}(\Sigma_1)$ en échangeant les rôles de n et p .