

Méthodes plug-in de sélection de fenêtre pour le KDE

1 Méthodes plug-in

Extrait de l'examen 2019

Exercice 2 : (15pts)

Pour deux fonctions u et v définies sur $\mathbb{R}$, à valeurs dans $\mathbb{R}$ et intégrables, on notera $u * v$ leur produit de convolution : pour tout $x \in \mathbb{R}$,

$$u \star v(x) = \int_{-\infty}^{+\infty} u(x-t)v(t)dt.$$

Pour une fonction g définie sur $\mathbb{R}$ et à valeurs dans $\mathbb{R}$, et $h > 0$, on pose

$$g_h(x) = \frac{1}{h}g\left(\frac{x}{h}\right).$$

On se donne $X_1, \dots, X_n$ un n -échantillon de variables aléatoires réelles. On considère une densité f bornée et continue sur $\mathbb{R}$. On considère un noyau K de carré intégrable. On estime f à l'aide de l'estimateur à noyau suivant : pour $h > 0$,

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right), \quad x \in \mathbb{R}.$$

Soit x_0 fixé dans $\mathbb{R}$. On note pour toute fonction g ,

$$\|g\|_2^2 = \int_{-\infty}^{+\infty} g^2(u)du.$$

1. (1.5pts) Montrer que

$$\lim_{h \rightarrow 0} \frac{1}{h} \int_{-\infty}^{+\infty} K\left(\frac{u - x_0}{h}\right) f(u)du = f(x_0).$$

2. (1.5pts) Montrer que, si on pose $\tilde{K} = \frac{K}{\|K\|_2}$,

$$\text{var}(\hat{f}_n(x_0)) = \frac{1}{nh} \|K\|_2^2 \tilde{K}_h^2 * f(x_0) - \frac{1}{n} (K_h \star f(x_0))^2.$$

3. (1pt) En déduire que

$$\lim_{h \rightarrow 0} nh \text{var}(\hat{f}_n(x_0)) = f(x_0) \|K\|_2^2.$$

4. On suppose que la fonction f est deux fois continument dérivable et f'' est bornée. On suppose que K vérifie de plus que

$$\int_{-\infty}^{+\infty} tK(t)dt = 0, \quad \int_{-\infty}^{+\infty} t^2|K(t)|dt < \infty.$$

On pose

$$k_2 := \int_{-\infty}^{+\infty} t^2 K(t)dt.$$

a) (1.5pts) Montrer qu'il existe $u_t \in (0, 1)$ tel que

$$\mathbb{E}[\hat{f}_n(x_0)] - f(x_0) = \frac{1}{h} \int_{\mathbb{R}} K\left(\frac{t-x_0}{h}\right) \frac{(t-x_0)^2}{2} [f''(x_0 + u_t(t-x_0)) - f''(x_0)] dt + \frac{1}{2} h^2 f''(x_0) k_2.$$

b) (1pt) Soit $\varepsilon > 0$ et, pour tout réel v , soit α_v un réel dépendant de v et tel que $\alpha_v \in (0, 1)$. Montrer qu'il existe $M > 0$ tel que

$$\left| \int_{|v|>M} K(v) v^2 [f''(x_0 + h\alpha_v v) - f''(x_0)] dv \right| \leq \varepsilon.$$

c) (2pts) Montrer que si on pose $\varepsilon_1(h) = \frac{1}{h} \int_{\mathbb{R}} K\left(\frac{t-x_0}{h}\right) \frac{(t-x_0)^2}{2} [f''(x_0 + u_t(t-x_0)) - f''(x_0)] dt$, alors

$$\lim_{h \rightarrow 0} h^{-2} \varepsilon_1(h) = 0.$$

On suppose jusqu'à la fin de l'exercice que

$$\|\mathbb{E}[\hat{f}_n] - f\|_2^2 = \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \varepsilon_2(h),$$

où ε_2 est une fonction ne dépendant pas de n et qui vérifie :

$$\lim_{h \rightarrow 0} h^{-4} \varepsilon_2(h) = 0.$$

d) (2pts) En déduire que

$$\mathbb{E}[\|\hat{f}_n - f\|_2^2] \leq \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \frac{\|K\|_2^2}{nh} + \varepsilon_2(h).$$

e) (1pt) Déterminer précisément la valeur h^* qui minimise

$$h \mapsto \frac{1}{4} h^4 k_2^2 \|f''\|_2^2 + \frac{\|K\|_2^2}{nh}.$$

(On a enlevé les dernières questions de l'exercice)

Dénominations usuelles : "MISE" = "mean integrated squared error"

$$\text{MISE}(h) = \mathbb{E} \left[\int (\hat{f}_h(x) - f(x))^2 dx \right].$$

La question d) de l'exercice 2 donne le développement asymptotique du MISE

$$\text{MISE}(h) \approx \frac{h^4}{4} k_2^2 \int (f''(x))^2 dx + \frac{1}{nh} R(K).$$

On appelle souvent cela l'AMISE (A pour asymptotique) :

$$\text{AMISE}(h) = \frac{h^4}{4} k_2^2 \int (f''(x))^2 dx + \frac{1}{nh} R(K).$$

En minimisant l'AMISE par rapport à h , on obtient

$$h_{\text{AMISE}} = \left(\frac{R(K)}{\mu_2(K)^2 R(f'') n} \right)^{1/5}.$$

Cette formule dépend de la quantité inconnue $R(f'')$.

En effet, f est inconnue, f'' l'est aussi. Pour utiliser cette formule en pratique, il faut donc remplacer

$$R(f'') = \int (f''(x))^2 dx$$

par un estimateur.

Ainsi, le principe des méthodes dites de plug-in est le suivant :

- on construit un estimateur de f''
- on forme ensuite un estimateur de $R(f'')$ (plusieurs méthodes)
- on remplace $R(f'')$ par $\widehat{R(f'')}$ dans la formule de h_{AMISE} .

2 Rule of thumbs

Dans l'examen 2019, pour estimer $R(f'')$ (et seulement pour cette partie-là), pour simplifier, on fait "comme si" la densité était gaussienne (même si ça n'est pas le postulat de départ, puisque c'est du non-paramétrique !). Cette méthode s'appelle "rule-of-thumbs".

3 Méthode SJ

Une autre méthode est "méthode de Sheather and Jones" (SJ) encore appelée "Solve-the-equation plug-in".

Pour estimer $R(f'')$, en partant d'un estimateur $\widehat{f''}(x)$ de $f''(x)$ de type noyau (ex : TD4 ex 1) on, peut penser à former

$$\int (\widehat{f''}(x))^2 dx;$$

Puis on l'améliore un peu (on peut améliorer le biais facilement). On obtient alors un estimateur $\widehat{R(f'')}$ de $R(f'')$.

Remarque : pour être plus précis, l'estimateur de base $\widehat{f''}(x)$ dépend d'une fenêtre g qui elle-même dépend de la fenêtre h du KDE . Ainsi notre estimateur $\widehat{R(f'')}$ dépend d'une fenêtre $g(h)$: on peut le préciser en utilisant la notation $\widehat{R(f'')}_{g(h)}$.

Ainsi la fenêtre choisie h est solution de l'équation

$$h = \left(\frac{R(K)}{\mu_2(K)^2 \widehat{R(f'')}_{g(h)} n} \right)^{1/5}.$$

d'où le nom "solve-the-equation".