

Partie 1)

On suppose pour simplifier que p et q sont > 0 partout (ou μ -presque partout),
(en particulier on est dans le cas où $\Omega \ll p$ et $p \ll \Omega$),

$$1. 0 \leq \int p \left(\log \frac{p}{q} \right)_- d\mu = \int_{q > p} p \log \frac{q}{p}$$

$$\left(\log \frac{p}{q} \right)_- = \begin{cases} -\log \frac{p}{q} = \log \frac{q}{p} & \text{si } \frac{p}{q} \leq 1 \\ 0 & \text{sinon} \end{cases}$$

$$\text{Donc } \int p \left(\log \frac{p}{q} \right)_- d\mu \leq \int_{q > p} p \left(\frac{q}{p} - 1 \right) d\mu$$

$$\log x \leq x - 1 \quad \forall x > 0$$

$$= \int_{q > p} (q - p) d\mu \leq \int_{q > p} q d\mu \leq 1.$$

2. On peut supposer que $D_K L(p \parallel \Omega)$ est finie.

$$D_{KL}(p \parallel \Omega) = \int p \log \frac{p}{q} d\mu = - \int p \log \frac{q}{p} d\mu \geq - \int p \left(\frac{q}{p} - 1 \right) d\mu$$

$$\log x \leq x - 1 \quad \forall x > 0$$

$$= \int (p - q) d\mu = 1 - 1 = 0.$$

3. • Il est évident que $DKL(P||P) = 0$
 • Si $DKL(P||Q) = 0$ alors dans la question précédente,
 l'inégalité (en vert) est une égalité.

$$\text{Donc } p \log\left(\frac{q}{p}\right) = p \log\left(\frac{q-1}{p}\right) \quad \mu\text{-p.p.}$$

$$\text{donc } \log\frac{q}{p} = \frac{q-1}{p} \quad \mu\text{-p.p.} \quad (p > 0)$$

$$\text{Or, pour } x > 0, \quad \log(x) = x - 1 \quad (\Rightarrow) \quad x = 1.$$

$$\text{Donc on a: } \mu\text{-p.p.} \quad \frac{q}{p} = 1$$

$$\text{i.e. } q = p \quad \mu\text{-p.p.}$$

$$\text{Donc } Q = P$$

Rem: on peut prouver Q_2 et Q_3 dans le cas
 général, cf. pages suivantes : le cas général est NON EXIGÉ.

Partie 1 : cas général (non exigé) : pour la Q_1 , on suppose

seulement que $P \ll Q$.

1. $p \ll q$ donc $\{p > 0\} \subset \{q > 0\}$ (p.p.). Donc

Donc

$$\begin{aligned} \int (p \log \frac{p}{q})_- d\mu &= \int_{p > 0} p (\log \frac{p}{q})_- d\mu \\ &= \int_{p > 0} p (\log \frac{p}{q})_- d\mu = \int_{q > p > 0} p \log \frac{q}{p} d\mu \\ &\leq \int_{q > p > 0} p (\frac{q}{p} - 1) d\mu = \int_{q > p > 0} (q - p) d\mu \leq 1. \end{aligned}$$

$\uparrow$
 $\log x \leq x - 1 \quad \forall x > 0$

Il suffit de considérer le cas où $D_{KL}(P \parallel Q) < +\infty$
On a :

2.

$$D_{KL}(P \parallel Q) = \int p \log \frac{p}{q} d\mu = - \int_{p > 0} p \log \frac{q}{p} d\mu \geq - \int_{p > 0} p (\frac{q}{p} - 1) d\mu$$

$-\log x \geq -(x - 1) \quad \forall x > 0$

$$= \int_{p > 0} p - q d\mu = \int p d\mu - \int_{p > 0} q d\mu \geq 1 - 1 = 0.$$

3) a) Il est évident que $D_{KL}(P \parallel P) = 0$.
b) Supposons que $D_{KL}(P \parallel Q) = 0$. Alors les 2 inégalités ci-dessus (en vert) sont vérifiées.
Ainsi

1) $\int_{p > 0} q d\mu = 1$ donc $\boxed{Q \ll P} (*)$ (détails plus loin)

2) $\log \frac{q}{p} = \frac{q}{p} - 1 \quad p.d\mu - p.p.$

Or $\log x = x - 1 \Leftrightarrow x = 1$
donc 2) dit que $\boxed{\frac{q}{p} = 1 \quad p.d\mu - p.p.}$

or $\{Q \ll P\}$ et $\left\{\frac{q}{p} = 1 \text{ } p d\mu - \text{presque partout}\right\}$

impliquent que $P = Q$. (xx)

Détails: • preuve de (xx): soit $A \in \mathcal{F}$ on a:

$$P(A) = \int_A p d\mu = \int_{A \cap \{p > 0\}} p d\mu$$

$$= \int_{A \cap \{p > 0\}} q d\mu \stackrel{q=p}{=} \int_A q d\mu = Q(A)$$

$q = p$ $p d\mu - p \cdot$ $\left[Q \ll P \text{ donc } p = 0, q = 0 \text{ si } p = 0 \right]$

• preuve de (x)

$$\text{Si } \int_{p > 0} q d\mu = 1 \text{ alors } \int_{p=0} q d\mu = 0$$

(car $\int q d\mu = 1$).

Donc $\mu \ll P$, comme $q \geq 0$, on a $\frac{q=0 \text{ si } p=0}{Q \ll P}$ i.e.

Partie 2

$$1. \hat{\theta} \in \underset{\theta \in \Theta}{\operatorname{argmax}} \underbrace{\sum_{i=1}^n \log q_{\theta}(X_i)}_{\text{log-likelihood}} = \text{ENV. (MLE)}$$

2. Rem: si $D_{KL}(f d\mu \parallel q_0 d\mu) < +\infty$ alors on a aussi $\int f(x) \left| \log \frac{q_0(x)}{f(x)} \right| d\mu(x) < +\infty$ (cf. Partie 1 Q1), i.e. $\log \frac{q_0(x)}{f(x)}$ est intégrable.

$$\begin{aligned} E(\hat{D}(\theta)) &= -E \log \frac{q_{\theta}(X_1)}{f(X_1)} \\ &= - \int \log \frac{q_{\theta}(x)}{f(x)} f(x) \mu(dx) \\ &= D_{KL}(f d\mu \parallel q_{\theta} d\mu) \end{aligned}$$

et par la LGN on a

$$\hat{D}(\theta) \xrightarrow[n \rightarrow +\infty]{\text{p.o.}} D_{KL}(f d\mu \parallel q_{\theta} d\mu).$$

3. a) Soit $a \in \mathbb{R}$, $a > 0$, p.p. $\frac{1}{n} \sum_{i=1}^n \min(Y_i, a) \xrightarrow{p.p.} E(\min(Y_1, a))$

liminf $\frac{1}{n} \sum_{i=1}^n Y_i \geq \liminf_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \min(Y_i, a)$

$Y_i \geq 0$ p.p.

$\hookrightarrow \langle L.G.N \rangle$
 $\min(Y_1, a) \dots \min(Y_n, a)$
 i.i.d. et intégrable car
 $0 \leq E(\min(Y_1, a)) \leq a$.

Ainsi: $\forall a \in \mathbb{R}$ on a:

$$\liminf \bar{Y}_n \geq E(\min(Y_1, a)) \text{ p.p.}$$

i.e. $\forall h \in \mathbb{N}$, $\exists \Omega_h \in \mathcal{F}$ t.q. $P(\Omega_h) = 1$ et

$$\forall \omega \in \Omega_h \quad \liminf_{n \rightarrow \infty} \bar{Y}_n(\omega) \geq E(\min(Y_1, h))$$

en posant $\bar{\Omega} = \bigcap_{h \in \mathbb{N}} \Omega_h$ on obtient:

$$P(\bar{\Omega}) = 1 \text{ et } \forall \omega \in \bar{\Omega}:$$

$$\liminf_{n \rightarrow \infty} \bar{Y}_n(\omega) \geq$$

$$\sup_{h \in \mathbb{N}} E(\min(Y_1, h)) = +\infty$$

convergence
monotone ($E(Y_1) = +\infty$)

Ainsi: $\bar{Y}_n \xrightarrow[n \rightarrow \infty]{p.p.} +\infty$.

3. b) Si $D_{KL}(f d\lambda \parallel q_0 d\lambda) = +\infty$ alors $\log \frac{q_0(X_1)}{f(X_1)}$ n'est pas

intégrable. On a:

A) $E\left(\log \frac{f(X_1)}{q_0(X_1)}\right)_- < +\infty$ (cf. partie 1 ex 1)

et

B) $E\left(\log \frac{f(X_1)}{q_0(X_1)}\right)_+ = +\infty$

A) implique, par la L.G.N, que:

$$\frac{1}{n} \sum_{i=1}^n \left(\log \frac{f(X_i)}{q_0(X_i)} \right)_- \xrightarrow[n \rightarrow \infty]{p.p.} \int f(x) \left(\log \frac{f(x)}{q_0(x)} \right)_- d\mu(x) < +\infty$$

B) implique, par la (2.3a), que:

$$\frac{1}{n} \sum_{i=1}^n \left(\log \frac{f(X_i)}{q_0(X_i)} \right)_+ \xrightarrow[n \rightarrow \infty]{p.p.} +\infty$$

Donc $\frac{1}{n} \sum_{i=1}^n \log \left(\frac{f(X_i)}{q_0(X_i)} \right) \xrightarrow[n \rightarrow \infty]{p.p.} +\infty - C^{ste} = +\infty = D_{KL}(f d\lambda \parallel q_0 d\lambda)$

Partie 3) Remarque: dans toute cette partie, on supposera que l'on peut systématiquement intégrer des quantités considérées et que l'on peut appliquer Fubini ("à l'ingénieur").

1. Dans le paragraphe précédent, $f_2, \dots, f_p$ n'ont pas été fabriquées à partir de l'échantillon. Ce sont des fonctions déterministes. Ainsi on a bien dans ce cas:

$$E\left(-\frac{1}{n} \sum_{i=1}^n \log \frac{f_i(x_i)}{f(x_i)}\right) \stackrel{\text{i.i.d.}}{=} E\left(-\log \frac{f_2(x_2)}{f(x_2)}\right) = \int f(x) \log \frac{f_2(x)}{f(x)} \mu(dx) = \text{DKL}(f \parallel f_2)$$

Au contraire ici: si $H = \{h_2, \dots, h_p\}$, $\hat{f}_{h_2, \dots, h_p}$ dépend de $(x_2, \dots, x_n)$.

En particulier, pour une fonction h quelconque

$$A := E\left(-\log \frac{\hat{f}_h(x_2)}{f(x_2)}\right) \neq \text{DKL}(f \parallel \hat{f}_h) = B \quad \text{et } A \neq E(B) \text{ également}$$

($A \in \mathbb{R}$ et B est aléatoire ici ...)

Plus précisément: $\hat{f}_h(x) = \ell_h(x_2, \dots, x_n, x)$ pour une certaine fonction ℓ_h

$$\left(\ell_h(x_2, \dots, x_n, x) = \frac{1}{n} \sum_{i=2}^n K\left(\frac{x_i - x}{h}\right) \right)$$

$$\text{donc } E\left(-\log \frac{\hat{f}_h(x_2)}{f(x_2)}\right) = E\left(-\log \frac{\ell_h(x_2, \dots, x_n, x_2)}{f(x_2)}\right)$$

$$= - \int \log \frac{\ell_h(x_2, \dots, x_n, x_2)}{f(x_2)} \prod_{i=2}^n f(x_i) dx_i$$

$\hookrightarrow x_2, \dots, x_n \stackrel{\text{i.i.d.}}{\sim} f$ ($x = \text{la moyenne}$)

$$= \int \log f(x_2) \prod_{i=2}^n f(x_i) dx_i - \int \log \ell_h(x_2, \dots, x_n, x_2) \prod_{i=2}^n f(x_i) dx_i$$

$$= \int f(x_2) \log f(x_2) dx_2 - \int \log \ell_h(x_2, \dots, x_n, x_2) \prod_{i=2}^n f(x_i) dx_i$$

$\hookrightarrow \int \prod_{i=2}^n f(x_i) dx_i = 1.$

Fubini

$$A = \int f(x_1) \log f(x_1) dx_1 - \int \log h(x_1, \dots, x_n, x_1) \prod_{i=1}^n f(x_i) dx_i$$

$$\text{et } E(B) = \int f \log f - E \left(\int f(x) \log h(x_1, \dots, x_n, x) \prod_{i=1}^n f(x_i) dx \right)$$

$$= \int f \log f - \int f(x) \log h(x_1, x_2, \dots, x_n, x) \prod_{i=1}^n f(x_i) dx$$

Donc $A \neq E(B)$.

Remarque: $\log \frac{f(x_1)}{f(x_1)}, \dots, \log \frac{f(x_n)}{f(x_n)}$ sont i.i.d., en particulier de m même loi donc

$$E \left(\frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i)}{f(x_i)} \right) = E \left(\log \frac{f(x_1)}{f(x_1)} \right)$$

• Les v.a. $\log \frac{f(x_1)}{f(x_1)}, \dots, \log \frac{f(x_n)}{f(x_n)}$ ne sont pas i.i.d.:

elles ont de même loi mais pas indépendantes.

Elles ont de même loi car: $\frac{f_h(x_1)}{f(x_1)} = \frac{f_h(x_1, \dots, x_n, x_1)}{f(x_1)}$ et

• h est symétrique en $(x_1, \dots, x_n)$

• les x_i sont i.i.d. (donc interchangeables)

$$\text{donc } \frac{\hat{f}_h(x_1)}{f(x_1)} \sim \frac{\hat{f}_h(x_2)}{f(x_2)}$$

$$\text{donc } E \left(\frac{1}{n} \sum_{i=1}^n \log \frac{\hat{f}_h(x_i)}{f(x_i)} \right) = E \left(\log \frac{\hat{f}_h(x_1)}{f(x_1)} \right)$$

2. Notons $|I| = \text{Card } I$. Soit $x \in \mathbb{R}$.

$\hat{f}_h(x)$ est une fonction de x et de l'échantillon d'apprentissage $(X_i)_{i \in I}$:

Pour simplifier, supposons que $I = \{1, \dots, p\}$ et $J = \{p+1, \dots, n\}$

Alors $\hat{f}_h(x) = h(x_1, \dots, x_p, x)$ pour une certaine fonction h .

Avec ces notations on a:

$$\begin{aligned}
& E \left(-\frac{1}{|I|} \sum_{i \in I} \log \frac{\hat{f}_h(X_i)}{f(X_i)} \mid \{X_i\}_{i \in I} \right) \\
&= E \left(-\frac{1}{n-p} \sum_{i=p+1}^n \log \frac{\ell_h(X_1, \dots, X_p, X_i)}{f(X_i)} \mid X_1, \dots, X_p \right) \\
&= g(X_1, \dots, X_p)
\end{aligned}$$

$$\text{ou } g(X_1, \dots, X_p) = -E \left(\frac{1}{n-p} \sum_{i=p+1}^n \log \frac{\ell_h(X_1, \dots, X_p, X_i)}{f(X_i)} \right)$$

par indépendance $(X_i)_{i \in I}$ et $(X_i)_{i \in T}$.

Les $(X_i)_{i \in T}$ sont aussi i.i.d. de ℓ_h donc

$$\begin{aligned}
& E \left(-\frac{1}{n-p} \sum_{i=p+1}^n \log \frac{\ell_h(X_1, \dots, X_p, X_i)}{f(X_i)} \right) \\
&= - \int_{\mathbb{R}} \log \left(\frac{\ell_h(X_1, \dots, X_p, x)}{f(x)} \right) f(x) dx
\end{aligned}$$

$$= \text{DKL} \left(f d\lambda \parallel \ell_h(X_1, \dots, X_p, \cdot) d\lambda \right)$$

$$\text{D'où } E \left(-\frac{1}{n-p} \sum_{i=p+1}^n \log \frac{\hat{f}_h(X_i)}{f(X_i)} \mid X_1, \dots, X_p \right)$$

$$= g(X_1, \dots, X_p)$$

$$= \text{DKL} \left(f d\lambda \parallel \ell_h(X_1, \dots, X_p, \cdot) d\lambda \right)$$

$$= \text{DKL} \left(f d\lambda \parallel \hat{f}_h d\lambda \right)$$

Donc, sachant $X_1, \dots, X_p$, $-\frac{1}{|J|} \sum_{i \in J} \log \left(\frac{\hat{p}_h(X_i)}{f(X_i)} \right)$ est un estimateur sans biais de $DKL(f dx \parallel \hat{f}_h dx)$.

On a aussi :

$$E \left(-\frac{1}{|J|} \sum_{i \in J} \log \frac{\hat{p}_h(X_i)}{f(X_i)} \right) = E(DKL(f dx \parallel \hat{f}_h dx))$$

On peut donc penser à utiliser la fenêtre suivante

$$\begin{aligned} \hat{h} &\in \operatorname{argmin}_{h \in H} -\frac{1}{|J|} \sum_{i \in J} \log \left(\frac{\hat{p}_h(X_i)}{f(X_i)} \right) \\ &= \operatorname{argmax}_{h \in H} \sum_{i \in J} \log \hat{p}_h(X_i) \end{aligned}$$

où H est une grille de valeurs de la fenêtre.

On peut plus généralement diviser l'échantillon d'apprentissage en K blocs (souvent $K=5$ ou 10) et utiliser chaque bloc comme ensemble de validation. On obtient K moyennes du type $-\frac{1}{n-p} \sum_{i=p+1}^n \log \hat{p}_h(X_i)$ et on fait la moyenne de ces moyennes (cf cours, remarque 4.17).