

Introduction à la statistique non-paramétrique
TD4 : Estimation de densités par estimateurs à noyaux

Exercice 1 : Soient f une densité appartenant à la classe de Holder $\Sigma(\beta, L)$ et $(X_1, \dots, X_n)$ un n -échantillon de variables aléatoires de densité f . Pour tout entier $s < \lfloor \beta \rfloor$, on définit l'estimateur de $f^{(s)}$, la dérivée d'ordre s de f , en posant pour $h > 0$

$$\hat{f}_{n,s}(x) = \frac{1}{nh^{s+1}} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right), \quad x \in \mathbb{R}$$

où K est une fonction telle que pour tout $j \in \{0, 1, \dots, \lfloor \beta \rfloor\}$ $u \mapsto u^j K(u)$ est intégrable et pour tout $j \in \{0, \dots, \lfloor \beta \rfloor\} \setminus \{s\}$,

$$\|K\|_2 < \infty, \quad \int u^j K(u) du = 0 \quad \text{et} \quad \int u^s K(u) du = s! \quad (1)$$

$$\int |u|^\beta K(u) du < \infty$$

1. Montrer que pour tout $x_0 \in \mathbb{R}$, il existe deux constantes C_B et C_V telles que pour tout $h > 0$, on a :

$$B(\hat{f}_{n,s}(x_0)) := |\mathbb{E}[\hat{f}_{n,s}(x_0)] - f^{(s)}(x_0)| \leq C_B h^{\beta-s},$$

$$\text{var}(\hat{f}_{n,s}(x_0)) := \mathbb{E} \left[\left(\hat{f}_{n,s}(x_0) - \mathbb{E}[\hat{f}_{n,s}(x_0)] \right)^2 \right] \leq \frac{C_V}{nh^{2s+1}}.$$

2. Montrer qu'il existe une constante $C > 0$ telle que, si h est choisie correctement,

$$\mathbb{E} \left[\left(\hat{f}_{n,s}(x_0) - f^{(s)}(x_0) \right)^2 \right] \leq C n^{-\frac{2(\beta-s)}{2\beta+1}}.$$

Exercice 2 : On observe un n -échantillon $(X_1, Y_1), \dots, (X_n, Y_n)$ de même loi qu'un couple de variables aléatoires réelles (X, Y) . On suppose que le vecteur (X, Y) admet pour densité la fonction f telle que pour tout $x \in \mathbb{R}$ et tout $y \in \mathbb{R}$, $f(x, y) > 0$. Pour toutes fonctions f_1 et f_2 de deux variables, on note dans la suite $\star$ le produit de convolution entre f_1 et f_2 quand celui-ci est défini : pour tout $(x, y) \in \mathbb{R}^2$,

$$(f_1 \star f_2)(x, y) = \iint f_1(x - u, y - v) f_2(u, v) du dv.$$

On considère $\hat{f}_h$ l'estimateur de f défini pour tout $(x, y) \in \mathbb{R}^2$ par :

$$\hat{f}_h(x, y) = \frac{1}{nh_1 h_2} \sum_{i=1}^n K\left(\frac{x - X_i}{h_1}, \frac{y - Y_i}{h_2}\right),$$

où $h = (h_1, h_2)$ avec $h_1 > 0$, $h_2 > 0$ et $K : \mathbb{R}^2 \mapsto \mathbb{R}$ un noyau (donc $\iint K(u, v) du dv = 1$) tel que $\iint |K(u, v)| |v| du dv < \infty$, $\iint |K(u, v)| |u|^{1/2} du dv < \infty$ et tel que $\|K\|_2^2 = \iint K^2(u, v) du dv < \infty$. On pose alors pour tout $(x, y) \in \mathbb{R}^2$:

$$K_h(x, y) = \frac{1}{h_1 h_2} K\left(\frac{x}{h_1}, \frac{y}{h_2}\right).$$

1. Montrer que le risque quadratique ponctuel en $(x, y) \in \mathbb{R}^2$ de $\hat{f}_h$ s'écrit :

$$\mathbb{E} \left[(\hat{f}_h(x, y) - f(x, y))^2 \right] = \left(\mathbb{E}[\hat{f}_h(x, y)] - f(x, y) \right)^2 + \text{var}(\hat{f}_h(x, y)).$$

2. Montrer que pour $x \in \mathbb{R}$ et $y \in \mathbb{R}$, $\mathbb{E}[\hat{f}_h(x, y)] = (K_h \star f)(x, y)$.
 3. Calculer pour $x \in \mathbb{R}$ et $y \in \mathbb{R}$, $\text{var}(\hat{f}_h(x, y))$ en fonction de n , $K_h \star f$ et $K_h^2 \star f$.
 4. Montrer que si f est bornée par M alors

$$\text{var}(\hat{f}_h(x, y)) \leq \frac{M \|K\|_2^2}{nh_1 h_2}.$$

5. Montrer que si f vérifie de plus la propriété suivante : pour tous $(u, v) \in \mathbb{R}^2$ et $(u', v') \in \mathbb{R}^2$

$$|f(u, v) - f(u', v')| \leq |u - u'|^{1/2} + |v - v'| \quad (2)$$

alors $B_h(x, y)$, le biais de $\hat{f}_h(x, y)$, vérifie pour $x \in \mathbb{R}$ et $y \in \mathbb{R}$:

$$B_h(x, y) \leq C_K \left(h_1^{1/2} + h_2 \right),$$

où C_K est une constante ne dépendant que de K .

6. On suppose toujours f bornée satisfaisant (2). Déterminer les valeurs optimales de h_1 et h_2 à constante près afin d'obtenir la vitesse de l'estimateur $\hat{f}_h$ pour le risque quadratique ponctuel. Donner la valeur de cette vitesse, à constante près.

Exercice 3 :

Notations

- si μ et ν sont des mesures, la notation $\mu \ll \nu$ signifie que μ est absolument continue par rapport à ν . On rappelle que cela se traduit par : $\forall A \in \mathcal{F}$, si $\nu(A) = 0$ alors $\mu(A) = 0$.
- pour un réel x , on note $x_- = \max(-x, 0)$ sa partie négative et $x_+ = \max(x, 0)$ sa partie positive. On a bien sûr $x = x_+ - x_-$ et $|x| = x_+ + x_-$.

Divergence de Kullback-Leibler

Soient P et Q deux mesures de probabilité définies sur un espace mesurable $(\Omega, \mathcal{F})$, et soit μ une mesure de référence commune telle que $P \ll \mu$ et $Q \ll \mu$. On note $p = \frac{dP}{d\mu}$ et $q = \frac{dQ}{d\mu}$ les densités de P et Q par rapport à μ .

La divergence de Kullback–Leibler (ou *KL divergence*) de P par rapport à Q est définie par :

$$D_{\text{KL}}(P \| Q) = \begin{cases} \int_{\Omega} \log \left(\frac{p(x)}{q(x)} \right) p(x) d\mu(x) & \text{si } P \ll Q \\ +\infty & \text{sinon} \end{cases}$$

C'est une mesure de l'« écart » entre les deux distributions.

Remarques

- On peut aussi écrire cette définition sous forme :

$$D_{\text{KL}}(P \| Q) = \int_{\Omega} \log \left(\frac{dP}{dQ} \right) dP,$$

lorsque $P \ll Q$, où $\frac{dP}{dQ}$ est la densité de Radon–Nikodym de P par rapport à Q .

- Quand $P \ll Q$, on a, μ -presque partout : $p(x) > 0 \Rightarrow q(x) > 0$ (ce qui garantit que le rapport p/q est bien défini quand $p > 0$).
- La KL divergence n'est pas une distance au sens métrique : elle n'est pas symétrique, et ne satisfait pas l'inégalité triangulaire.
- **On va montrer que cette définition a toujours un sens et qu'on a toujours $D_{\text{KL}}(P\|Q) \geq 0$, avec égalité si et seulement si $P = Q$**
- Cas particulier : $\Omega = \{1, 2, \dots, d\}$. Les probabilités peuvent alors être assimilées à des vecteurs de $\mathbb{R}^d$: $p = (p_1, \dots, p_d)$ et $q = (q_1, \dots, q_d)$. Si, pour tout i , $q_i = 0$ implique $p_i = 0$ ¹, on a

$$D_{\text{KL}}(p\|q) = \sum_{i=1}^d p_i \log\left(\frac{p_i}{q_i}\right) = H(p, q) - H(p)$$

où $H(p, q) = -\sum_{i=1}^d p_i \log(q_i)$ est l'entropie croisée² et $H(p) = -\sum_{i=1}^d p_i \log p_i$ est l'entropie de p .

Partie 1

Pour simplifier (et éviter certaines complications techniques), on suppose que q et p sont strictement positives μ presque sûrement. On a alors $P \ll Q$ et $Q \ll P$.

Le résultat de la question 1 reste vrai si on suppose seulement que $P \ll Q$ et les résultats des questions 2 et 3 sont vrais sans hypothèse.

1. Montrer que $\int (p \log(\frac{p}{q}))_- d\mu$ est finie.

Remarque : cela montre que la divergence de Kullback-Leibler est toujours définie. En effet si Y est une v.a. telle que $E(Y_-) < \infty$ alors :

- Soit $E(Y_+) < \infty$, auquel cas $E(|Y|) < \infty$, i.e. Y est intégrable.
- Soit $E(Y_+) = +\infty$, auquel cas $E(|Y|) = +\infty$ mais on peut quand même donner un sens à $E(Y)$ en posant $E(Y) = +\infty$.

2. Montrer que $D_{\text{KL}}(P\|Q) \geq 0$ pour toute P et toute Q . (à connaître)
3. Montrer que $D_{\text{KL}}(P\|Q) = 0$ est équivalent à $P = Q$. (à connaître)

Partie 2

Soit un échantillon $X_1, \dots, X_n$ i.i.d. de loi P . On suppose que P est absolument continue par rapport à μ de densité inconnue f :

$$P = f d\mu.$$

Nous modélisons cette densité par q_θ avec $\theta \in \Theta$ (pour un certain ensemble $\Theta \in \mathbb{R}^d$). Autrement dit, nous supposons que

il existe θ_0 tel que q_{θ_0} est « proche de » f

Nous devons préciser le sens de "proche".

Nous choisissons comme mesure de proximité la divergence de Kullback-Leibler. Nous cherchons donc θ_0 tel que

$$\theta_0 \in \arg \min_{\theta \in \Theta} D_{\text{KL}}(f d\mu \| q_\theta d\mu)$$

1. c'est juste l'hypothèse d'absolue continuité de p par rapport à q

2. "cross-entropy", cf. cours de statistical learning

Problème : nous ne connaissons pas f donc nous n'avons pas non plus accès à $D_{\text{KL}}(fd\mu\|q_\theta d\mu)$. Nous cherchons donc à remplacer cette quantité inconnue $D_{\text{KL}}(fd\mu\|q_\theta d\mu)$ par une quantité proche (dans un certain sens) mais calculable à partir des données uniquement. Pour cela, nous remarquons que la quantité suivante

$$\hat{D}(\theta) := -\frac{1}{n} \sum_{i=1}^n \log \frac{q_\theta(X_i)}{f(X_i)}$$

est proche (dans un certain sens) de $D_{\text{KL}}(fd\mu\|q_\theta d\mu)$ (c'est l'objet des questions 2 et 3). Cette quantité dépend encore de f . Mais on remarque immédiatement que

$$\arg \min_{\theta \in \Theta} -\frac{1}{n} \sum_{i=1}^n \log \frac{q_\theta(X_i)}{f(X_i)} = \arg \min_{\theta \in \Theta} -\frac{1}{n} \sum_{i=1}^n \log q_\theta(X_i)$$

On décide donc d'estimer θ_0 par

$$\hat{\theta} = \arg \min_{\theta \in \Theta} -\frac{1}{n} \sum_{i=1}^n \log q_\theta(X_i)$$

1. L'estimateur $\hat{\theta}$ est un estimateur très connu : lequel ?
2. On suppose que $D_{\text{KL}}(fd\mu\|q_\theta d\mu)$ est fini. Montrer que $\hat{D}(\theta)$ est un estimateur sans biais et consistant de $D_{\text{KL}}(fd\mu\|q_\theta d\mu)$, i.e. montrer que

$$E(\hat{D}(\theta)) = D_{\text{KL}}(fd\mu\|q_\theta d\mu)$$

et que

$$\hat{D}(\theta) \xrightarrow[n \rightarrow +\infty]{p.s.} D_{\text{KL}}(fd\mu\|q_\theta d\mu)$$

3. (question optionnelle) Supposons que $fd\mu \ll q_\theta d\mu$ mais que $D_{\text{KL}}(fd\mu\|q_\theta d\mu) = +\infty$.
 - (a) Soit $Y_1, \dots, Y_n$ des v.a. positives i.i.d. telles que $E(Y_1) = +\infty$. Montrer que $\bar{Y}_n \xrightarrow[n \rightarrow +\infty]{p.s.} +\infty$.
 - (b) Montrer qu'on a encore

$$\hat{D}(\theta) \xrightarrow[n \rightarrow +\infty]{p.s.} D_{\text{KL}}(fd\mu\|q_\theta d\mu)$$

Partie 3

Nous nous sommes placés jusque là dans un contexte paramétrique. Mais les idées et les preuves auraient été les mêmes dans un contexte plus général.

Par exemple, pour simplifier le plus possible, supposons que nous hésitions entre plusieurs densités possibles : $f_1, \dots, f_p$ pour estimer la densité f inconnue. Autrement dit, plaçons-nous dans un cas idéalisé où nous savons que la densité inconnue f est égale à l'une de ces p densités (ou est proche de l'une de ces p densités), ces p densités étant quelconques, i.e. pas forcément issues d'une famille particulière de lois.

Nous pouvons alors choisir l'estimateur $f_{\hat{j}}$ avec $\hat{j}$ satisfaisant

$$\hat{j} \in \arg \min_{j \in \{1, \dots, p\}} -\frac{1}{n} \sum_{i=1}^n \log \frac{f_j(X_i)}{f(X_i)} = \arg \max_{j \in \{1, \dots, p\}} \sum_{i=1}^n \log f_j(X_i)$$

Finalement : pas besoin d'avoir un modèle paramétrique pour penser à la maximisation de la log-vraisemblance dans le contexte de l'estimation d'une densité inconnue. Les densités de référence peuvent être quelconques.

On pourrait alors avoir l'idée d'utiliser la maximisation de la log-vraisemblance pour choisir la fenêtre h d'un KDE. Les questions suivantes portent sur ce point.

Supposons avoir à notre disposition un ensemble de KDE $(\hat{f}_h)_{h \in H}$ où H est une grille de valeurs possibles

Ces KDE ont été ajustés à l'aide d'un échantillon i.i.d. de loi P de densité $f d\lambda$ où λ est la mesure de Lebesgue sur $\mathbb{R}$ et f est la densité inconnue que l'on souhaite estimer. On suppose que K est positif.

Nous souhaitons trouver la « meilleure » fenêtre possible dans la grille. Pour cela, il faut se donner une mesure de proximité. Nous choisissons la divergence de Kullback-Leibler : idéalement, nous aimerions trouver une fenêtre h_0 telle que

$$h_0 \in \arg \min_{h > 0} D_{\text{KL}}(f d\lambda \| \hat{f}_h d\lambda)$$

Comme précédemment, cette fenêtre "idéale" h_0 minimise une quantité inconnue car dépendant de la densité inconnue f . Nous souhaitons calculer, à partir des données uniquement, une fenêtre $\hat{h}$.

Hypothèse technique : nous supposons que (p.s.) $f d\lambda \ll \hat{f}_h d\lambda$.

On pourrait utiliser les idées du paragraphe précédent (choix de l'indice j) et choisir la fenêtre $\hat{h}_{\text{bad-idea}}$ telle que

$$\hat{h}_{\text{bad-idea}} \in \arg \max_{h > 0} \sum_{i=1}^n \log \hat{f}_h(X_i)$$

1. Expliquer pourquoi ça n'est pas une bonne idée de procéder ainsi.
2. On décide de scinder en deux notre échantillon $X_1, \dots, X_n$ pour former un échantillon dit d'entraînement (training set) et un échantillon dit de validation (validation set). Notons I les indices correspondants à l'échantillon d'entraînement et J les indices correspondant à l'échantillon de validation.

Pour chaque valeur de la grille H , nous fabriquons un KDE à l'aide de l'échantillon d'apprentissage. Nous disposons donc d'un ensemble d'estimateurs $(\hat{f}_h)_{h \in H}$ et ces estimateurs ont donc été calculés à partir de $(X_i)_{i \in I}$. Nous décidons de choisir la fenêtre $\hat{h}$ telle que

$$\hat{h} \in \arg \max_{h > 0} \sum_{i \in J} \log \hat{f}_h(X_i)$$

(attention, la somme porte donc sur les indices correspondant à l'échantillon de validation !!)

Calculer

$$E\left(\frac{-1}{\text{Card}(J)} \sum_{i \in J} \log \frac{\hat{f}_h(X_i)}{f(X_i)} \mid \{X_i\}_{i \in I}\right)$$

(Vous devriez alors comprendre l'intérêt d'utiliser un échantillon de validation pour le choix du paramètre h ...)

Ensuite on utilise les mêmes idées que dans le cours de learning pour la validation croisée.